

AI 공정성 및 편향

AI 공정성 및 편향에 오신 것을 환영합니다.



01 공정성 및 편향 개요

02 편향 식별 – TFDV 도구

03 편향 식별 – What-if 도구

04 편향 식별 – TFMA 도구

05 편향 완화 – 데이터 개입

06 편향 완화 – 기준점 보정

07 편향 완화 – 모델 수정

08 실습: TensorFlow에서 MinDiff로 편향 완화하기

이 모듈은 8개의 강의로 구성되어 있습니다.

이 모듈에서 학습할 내용



01	AI의 불공정 편향 유형을 정의합니다.
02	AI 공정성이 머신러닝에 중요하면서도 달성하기 어려운 이유를 논의합니다.
03	AI 시스템에서 발생하는 편향의 원인을 식별합니다.
04	AI 공정성 권장사항을 이해합니다.
05	데이터 세트와 모델의 편향을 완화하는 도구와 기법을 살펴봅니다.

학습할 내용

- AI의 불공정 편향 유형을 정의합니다.
- AI 공정성이 머신러닝에 중요하면서도 달성하기 어려운 이유를 논의합니다.
- AI 시스템에서 발생하는 편향의 원인을 식별합니다.
- AI 공정성 권장사항을 이해합니다.
- 데이터 세트와 모델의 편향을 완화하는 도구와 기법을 살펴봅니다.



01 공정성 및 편향 개요

02 편향 식별 – TFDV 도구

03 편향 식별 – What-if 도구

04 편향 식별 – TFMA 도구

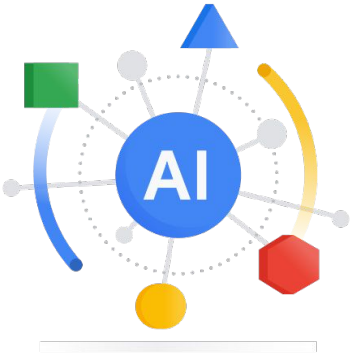
05 편향 완화 – 데이터 개입

06 편향 완화 – 기준점 보정

07 편향 완화 – 모델 수정

08 실습: TensorFlow에서 MinDiff로 편향 완화하기

공정성과 편향에 대한 개요부터 살펴보겠습니다.



1. 사회에 도움이 되어야 합니다.
2. 불공정한 편향을 만들거나 강화해서는 안 됩니다.
3. 안전을 염두에 두고 개발되고 테스트되어야 합니다.
4. 사람들에 대한 책임 의식을 가져야 합니다.
5. 개인 정보 보호 적용 설계 원칙이 반영되어야 합니다.
6. 과학적 우수성에 있어 엄격한 기준을 충족해야 합니다.
7. 이러한 원칙을 준수하는 사용자에게 제공되어야 합니다.

공정성은 Google의 AI 원칙 중 두 번째인 '불공정한 편향을 만들거나 강화해서는 안 된다'는 원칙과 관련이 있습니다. 하지만 원칙들이 교차하는 경우가 많습니다.

먼저 편향이 무엇인지 정의해 보겠습니다.

편향이란 무엇인가요?



특정한 사물, 사람 또는 그룹에 대한 정형화, 편견 또는 편애를 말합니다.

정의:
https://developers.google.com/machine-learning/glossary/fairness

편향이란 특정한 사물, 사람 또는 집단에 대한 정형화, 편견 또는 편애를 말합니다. 편향을 말하기는 쉽지만, 자신이 가지고 있는 편향은 본인의 관점 안에 숨어 있기 때문에 일반적으로 이를 깨닫기가 어렵습니다.

신발을 그려보세요

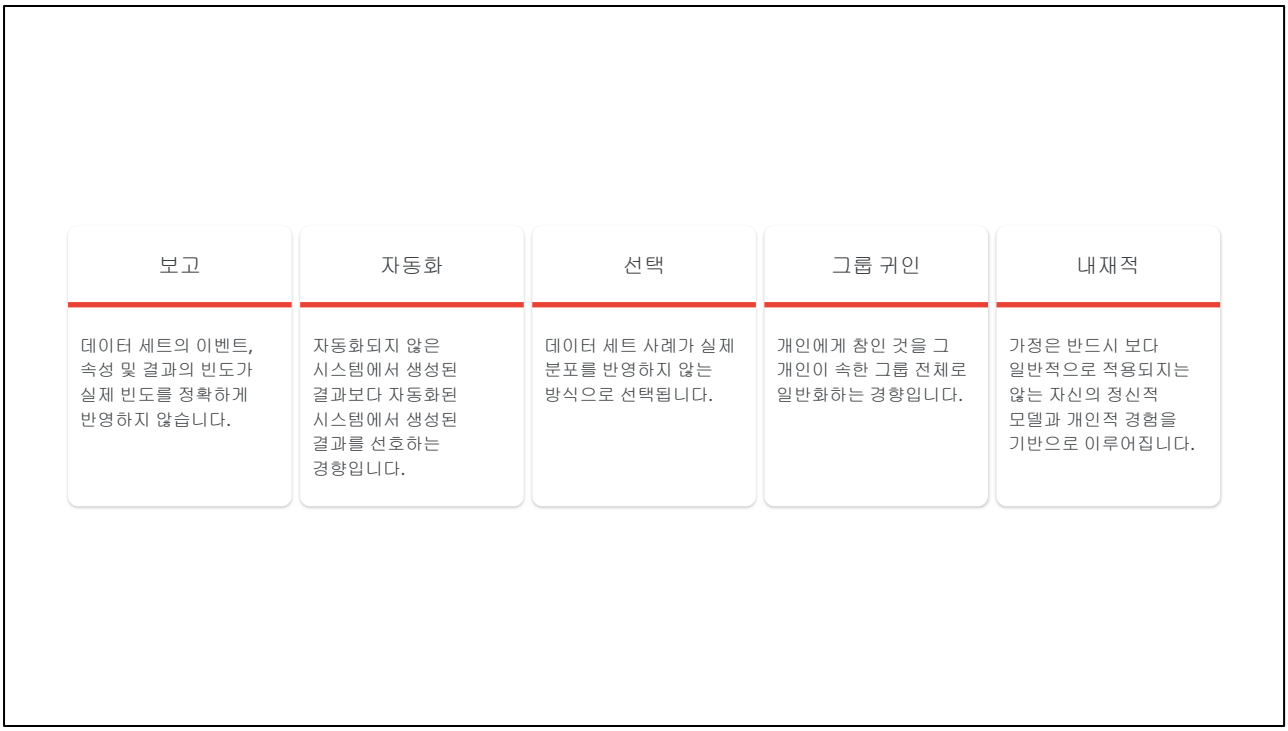
간단한 실험을 해보겠습니다. 신발을 그려보세요.
어떤 종류의 신발을 그리셨나요?



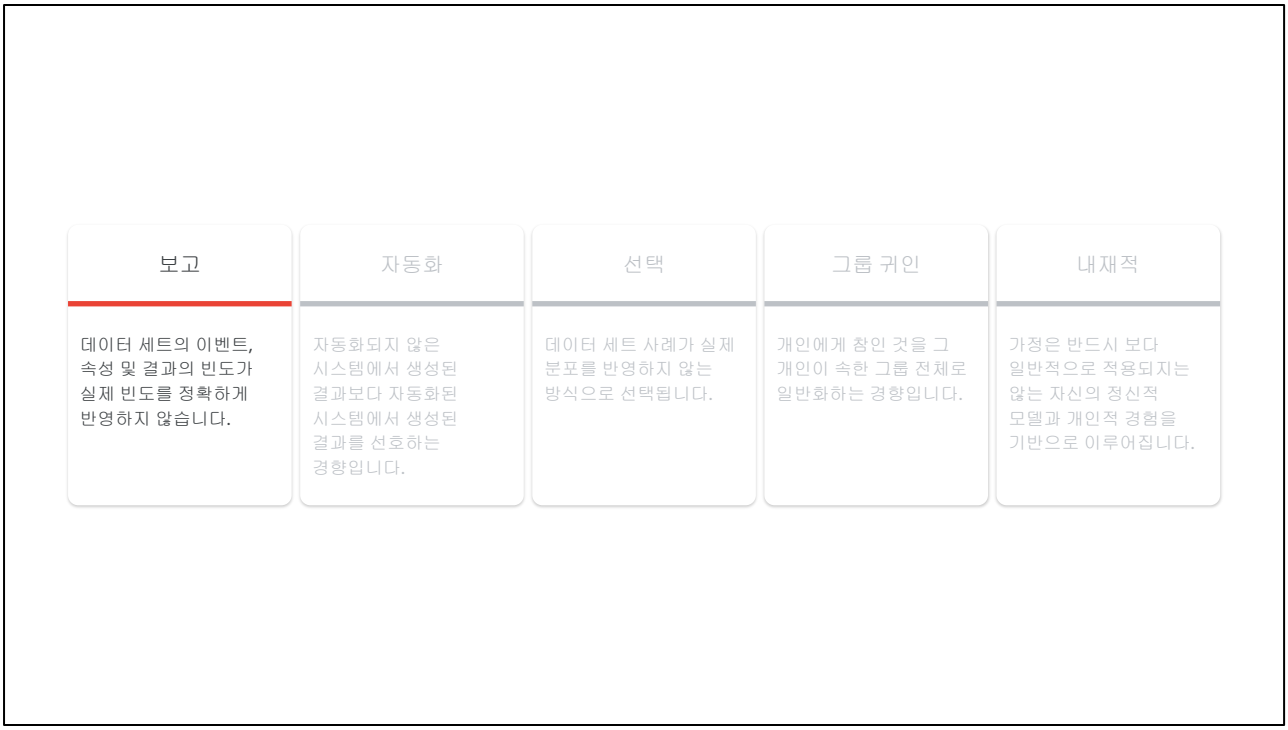
여기에 신발의 예가 몇 가지 있습니다. 여러분이 그린 것과 가장 비슷한 것은 무엇인가요? 왼쪽의 운동화 같은 종류입니까? 아니면 오른쪽의 하이힐입니까?

모든 편향이 유해한 것은 아니지만, 우리는 자신이 속한 집단이나 갖고 있는 정보에 따라 인식, 사고 과정, 상식 등에서 자연스럽게 어느 정도의 경향을 갖게 된다는 사실을 알아야 합니다.

'과학자'를 그려보라고 하면 어떨까요? 특정한 성별이나 인종이 떠올랐습니까?



Wikipedia의 인지 편향 카탈로그에는 100가지가 넘는 인간의 다양한 편향 유형이 나와 있습니다.
AI 시스템용 제품을 개발할 때 데이터와 모델에 나타날 수 있는 일반적인 인간의 편향을 알아두어야 합니다. 그러면 편향의 영향을 완화하기 위한 사전 조치를 취할 수 있습니다. 가장 일반적인 5가지 편향을 살펴보겠습니다.



보고 편향은 데이터 세트에 캡처된 이벤트, 속성 및 결과의 빈도가 실제 빈도를 정확하게 반영하지 않을 때 나타납니다. 평범한 것은 대체로 당연하다고 받아들여지므로, 이러한 편향은 사람들이 특이하거나 특별히 기억에 남는 상황을 기록하는 데 집중하는 경향이 있기 때문에 발생할 수 있습니다.



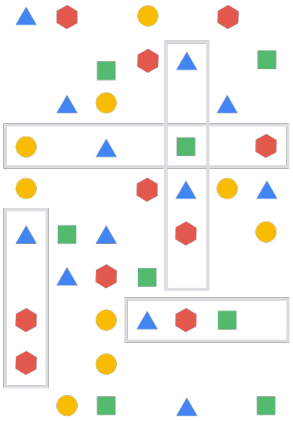
자동화 편향은 각 시스템의 오류율과 관계없이, 자동화되지 않은 시스템이 생성한 결과보다 자동화 시스템이 생성한 결과를 선호하는 경향을 말합니다.



표본 선택 편향은 데이터 세트의 사례가 실제 분포를 반영하지 않는 방식으로 선택되는 경우에 발생합니다.

표본 선택 편향의 형태

- 포함 편향
- 무응답 편향(또는 응답 참여 편향)
- 표본 추출 편향



표본 선택 편향은 다양한 형태로 나타날 수 있습니다.

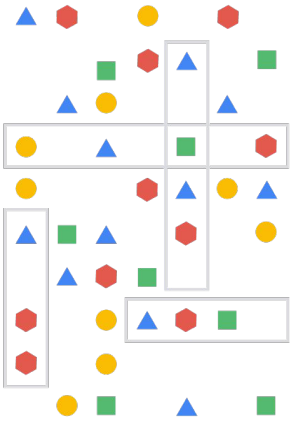
- 포함 편향은 데이터가 대표적인 방식으로 선택되지 않은 경우에 발생합니다.
- 무응답 편향 또는 응답 참여 편향은 데이터 수집 과정에서 참여 격차로 인해 데이터가 대표성이 없어질 때 발생합니다.
- 표본 추출 편향은 데이터 수집 중에 적절한 무작위 순서 지정이 사용되지 않을 때 발생합니다.



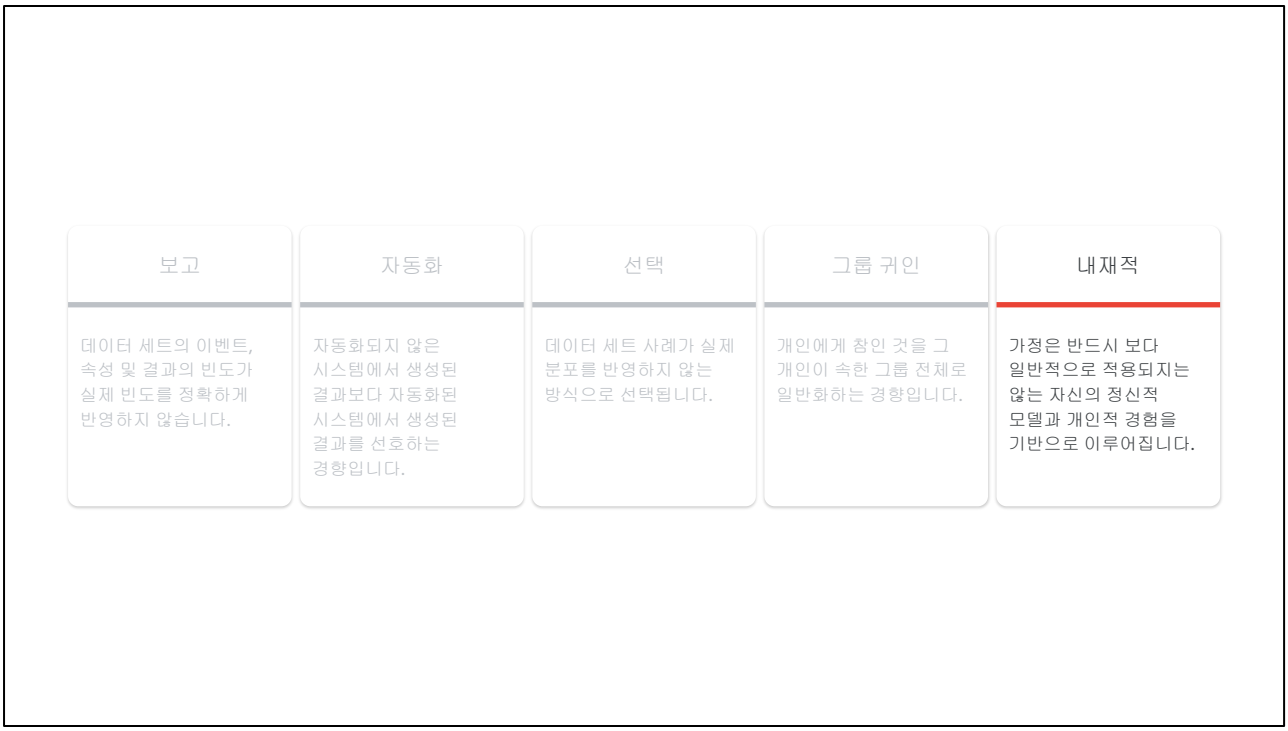
그룹 귀인 편향은 개인에게 참인 것을 그 개인이 속한 그룹 전체로 일반화하는 경향입니다. 이러한 편향의 두 가지 주요 모습은 내집단 편향과 외부 집단 동질화 편향입니다.

그룹 귀인 편향의 형태

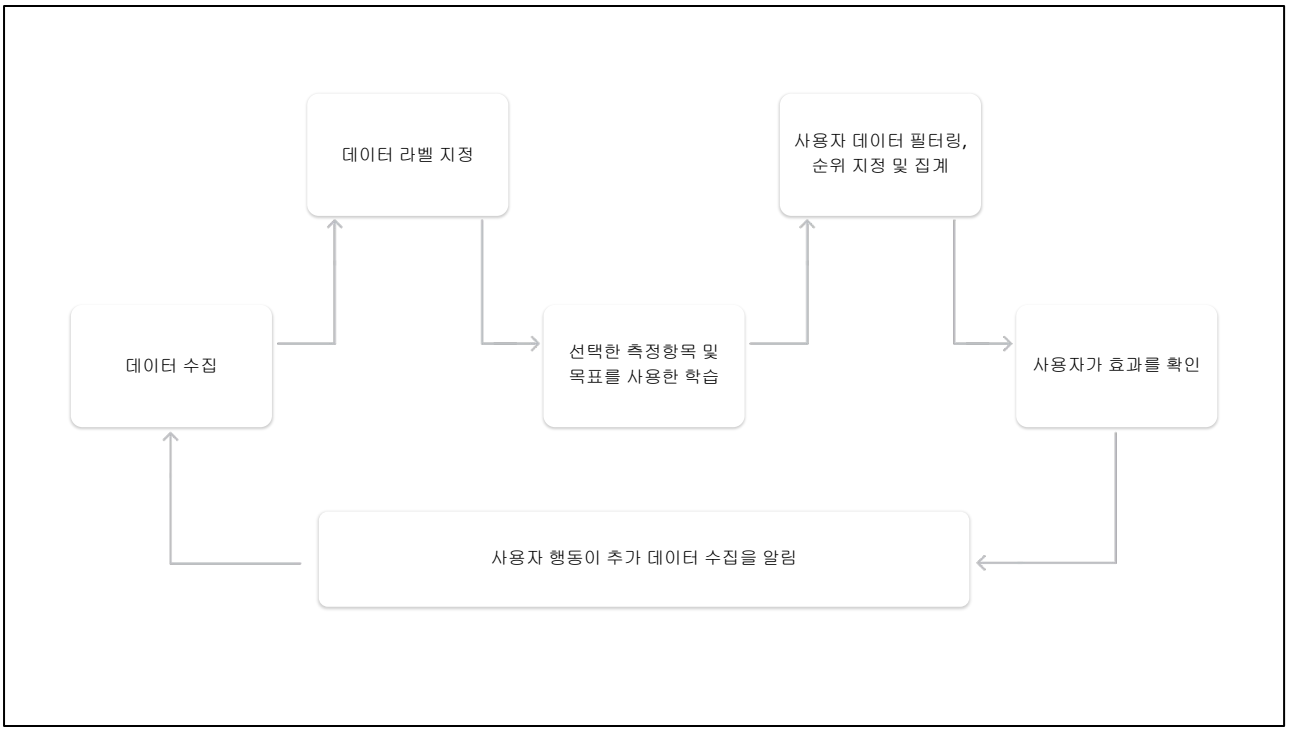
- 내집단 편향
- 외부 집단 동질화 편향



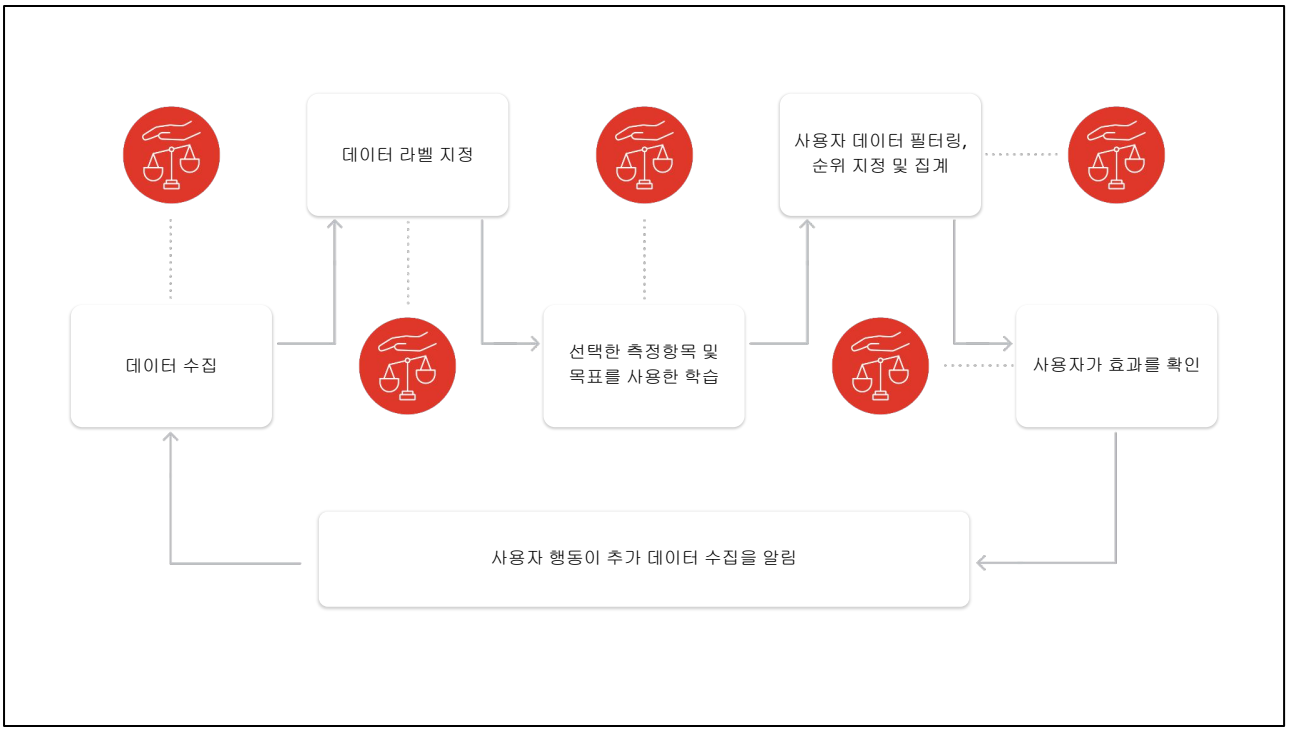
- 내집단 편향은 자신이 속한 집단의 구성원에 대한 선호 또는 자신도 공유하는 특성에 대한 선호가 있을 때 발생합니다.
- 외부 집단 동질화 편향은 자신이 속하지 않은 집단의 구성원 개개인에 대해 고정관념을 갖거나 그들의 특성을 더 획일적으로 보는 경향이 있을 때 발생합니다.



그리고 내재적 편향은 반드시 보다 일반적으로 적용되지는 않는 자신의 정신적 모델과 개인적 경험을 기반으로 가정을 할 때 발생합니다.
내재적 편향의 일반적인 형태는 확증 편향으로, 모델을 만드는 사람이 자기도 모르게 이미 가지고 있는 믿음이나 가설을 긍정하는 방향으로 데이터를 처리하는 것을 말합니다. 경우에 따라 모델 빌더는 모델이 처음의 가설과 일치하는 결과를 생성할 때까지 모델을 계속 학습시킬 수 있으며 이를 실험자 편향이라고 합니다.

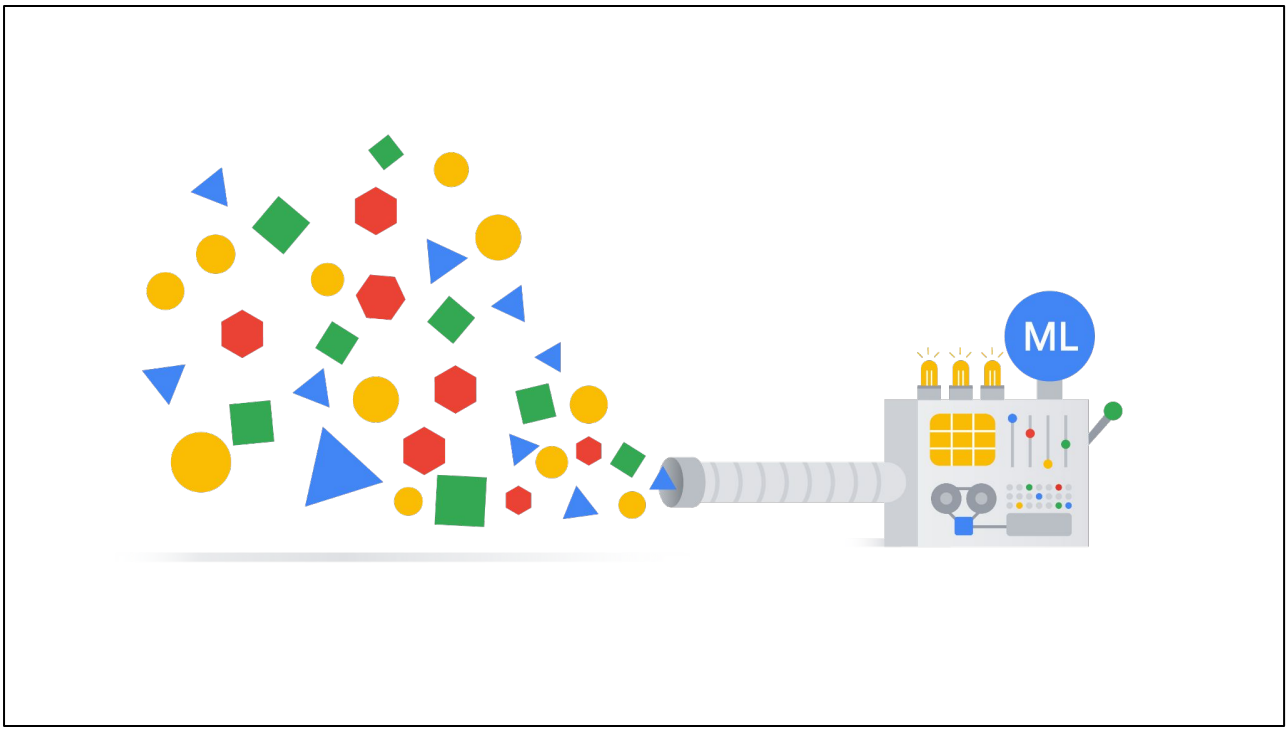


그렇다면 AI 시스템은 어떨까요? 아시다시피 일반적으로 데이터 수집과 라벨링, 학습, 평가, 배포를 포함한 여러 단계가 있습니다.
수명 주기 전반에서 샘플링 또는 보고 절차에 의해 발생하는 체계적인 오류로 시스템에 편향이 유입될 수 있습니다.

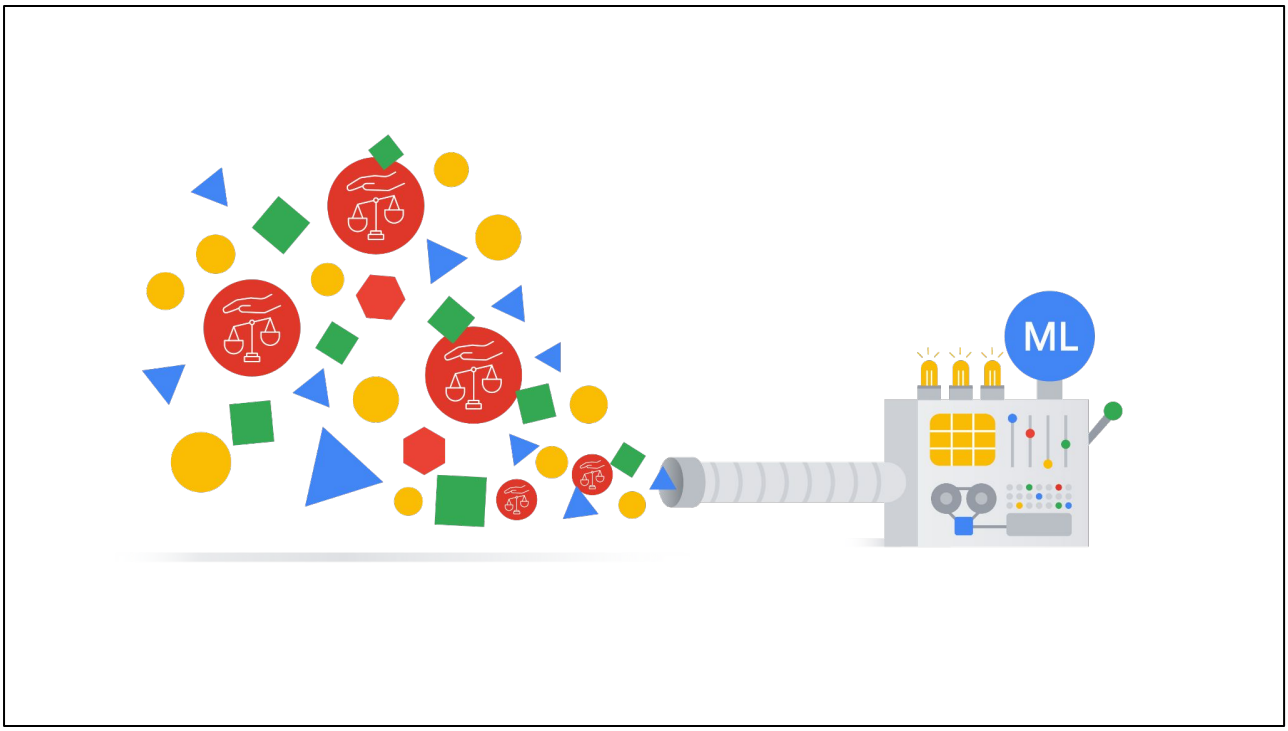


데이터 수집에 잘못된 가정이나 구현이 있으면 데이터 세트 자체에 표본 선택 편향과 같은 편향이 많이 존재합니다.
엔지니어는 편향된 데이터 세트를 제공하여 의도하지 않게 모델을 학습시킬 수 있고, 그러면 머신러닝 모델은 예측에서 편향 패턴을 쉽게 찾아서 반복하게 됩니다.

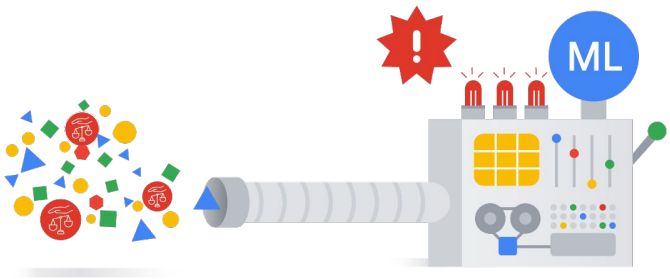
모델을 빌드할 때 편향은 모델 구성요소와 로직이 정의되는 방식에도 유입됩니다.
배포 후에도 피드백 루프와 모델 반복을 통해 편향이 나타날 수 있습니다.



이러한 편향 문제에서 단일 원인이나 솔루션을 파악할 수 있는 경우는 거의 없습니다.



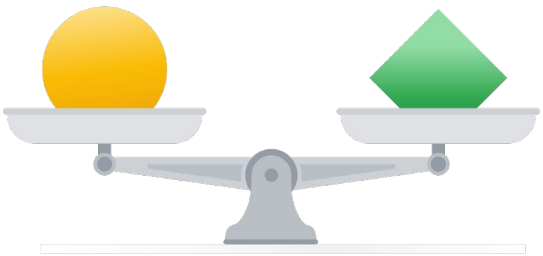
이보다 훨씬 더 자주 일어나는 일은 ML 시스템에서 상호 작용하여 문제가 있는 결과를 생성하는



다양한 원인이 존재하는 경우입니다. 이로 인해 다양한 솔루션이 필요하게 됩니다.

AI 공정성

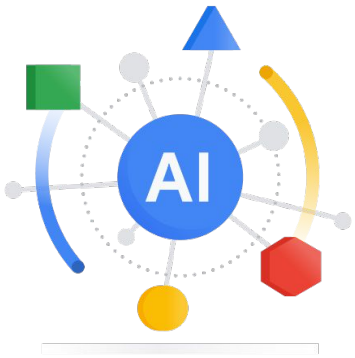
머신러닝 프로세스 후에 컴퓨터가 내린 결정이 민감한 것으로 간주되는 변수를 기반으로 한다면 불공정하다고 볼 수 있습니다.



Wikipedia의 정의

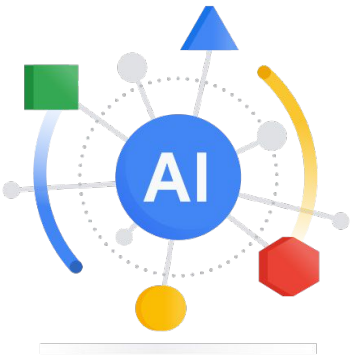
모든 유형의 편향이 반드시 불공정한 것은 아니라는 점에 유의해야 합니다.
공정성의 정의는 약간 더 제한적입니다. 머신러닝 프로세스 후에 컴퓨터가 내린 결정이 민감한 것으로 간주되는 변수를 기반으로 한다면 불공정하다고 볼 수 있습니다.
이러한 변수의 예로는 성별, 민족, 성적 지향 또는 장애가 있습니다.
이러한 변수를 고려할 때 공정성에는 형평성과 포용성도 포함됩니다.

AI의 영향이 사회 전반의 여러 부문에서 증가하는 추세



따라서 모두를 위한 공정하고 포용적인 AI 시스템을 갖추도록 노력해야 합니다. AI 시스템은 책이나 TV 프로그램을 추천하는 일뿐만 아니라 사람을 직업 및 파트너와 연결하거나, 사기 거래를 식별하거나, 빨간불에 길을 건너는 사람을 식별하는 등 보다 중요한 일에 사용될 수 있습니다.

AI의 영향이 사회 전반의 여러 부문에서 증가하는 추세



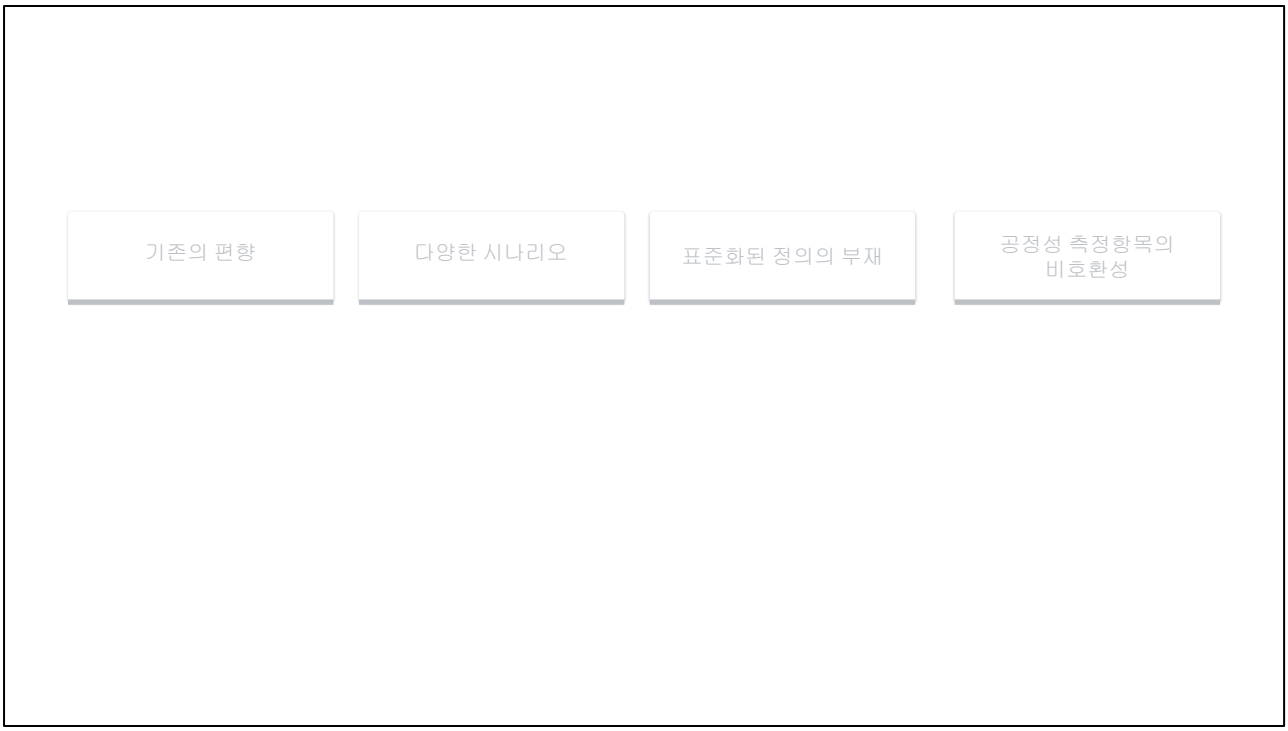
기회

보다 넓은 범위에서 더 공정하고 더 포용적일 수 있습니다.

위험

광범위하게 부정적인 영향을 미칠 가능성이 있습니다.

그렇다면 어떤 기회가 있을까요? AI 시스템은 임시 규칙이나 인간의 판단에 기반한 의사 결정 프로세스보다 넓은 범위에서 더 공정하고 더 포용적일 수 있는 잠재력을 가지고 있습니다.
그러면 어떤 위험이 있을까요? 이러한 시스템의 불공정성이 부정적이고 광범위한 영향을 미칠 수도 있습니다.



이러한 이유들 때문에 AI 공정성은 실제로 달성하기 어려운 과제입니다.



무엇보다 AI 모델은 기존 데이터를 바탕으로 학습하며, 정확한 모델이라도 문제가 있는 기존의 편향을 학습하거나 심지어 강화할 수 있습니다.



둘째, 가장 엄격하고 다양한 부문을 포괄하는 학습과 테스트를 거치더라도 모든 상황에서 공정한 시스템을 구축하기란 어려운 일입니다.



셋째, 인간이 내린 정의든 머신이 내린 정의든 공정성에 대한 표준화된 정의가 없습니다. 시스템에 대한 적절한 공정성 기준을 식별하려면 사용자 경험, 문화, 사회, 역사, 정치, 법률, 윤리 등 여러 분야를 고려해야 합니다. 그 중 몇몇에는 절충이 필요할 수 있습니다. 단순해 보이는 상황에서도 사람들은 무엇이 공정한지 서로 의견이 다를 수 있으며, 특히 글로벌 환경에서는 어떤 관점에서 정책을 결정해야 하는지 분명하지 않을 수 있습니다.



마지막으로, 공정성 측정항목은 호환되지 않고 동시에 충족하기가 불가능할 수 있습니다. 따라서 공정성에 대한 보편적인 측정항목을 정의하기란 불가능합니다. 하지만 낙담할 필요는 없습니다. 이는 공정성을 주어진 AI 문제에 맞는 맥락 속에서 정의해야 한다는 의미일 뿐입니다.



01 공정성 및 편향 개요

02 편향 식별 – TFDV 도구

03 편향 식별 – What-if 도구

04 편향 식별 – TFMA 도구

05 편향 완화 – 데이터 개입

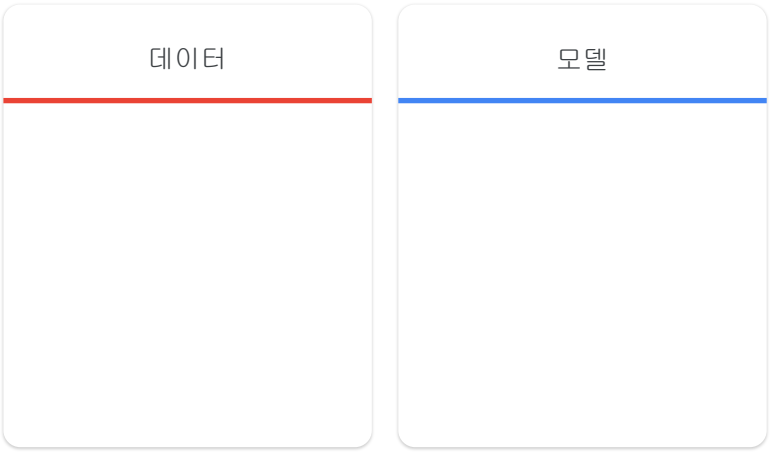
06 편향 완화 – 기준점 보정

07 편향 완화 – 모델 수정

08 실습: TensorFlow에서 MinDiff로 편향 완화하기

이제 AI 시스템의 편향 문제를 식별하는 방법을 살펴보겠습니다.

머신러닝의 편향은 어떻게 식별할까요?



AI 시스템의 편향에는 여러 원인이 있을 수 있습니다.
데이터와 모델이라는 두 가지 관점에서 살펴보겠습니다.

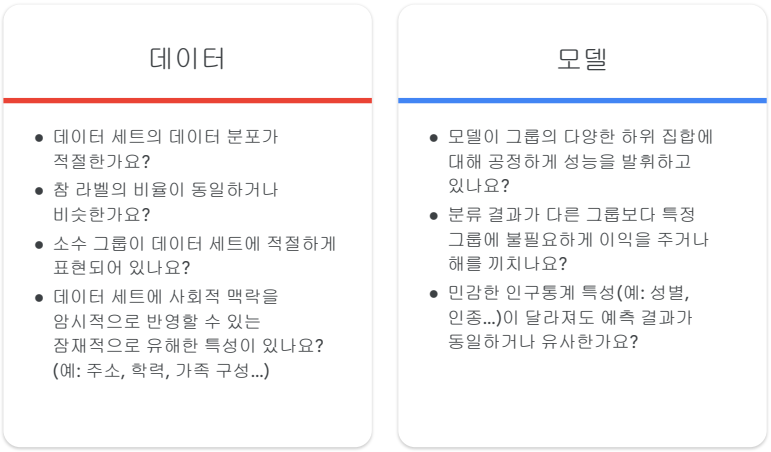
편향의 식별은 항상 좋은 질문을 묻는 것으로 시작합니다.

머신러닝의 편향은 어떻게 식별할까요?



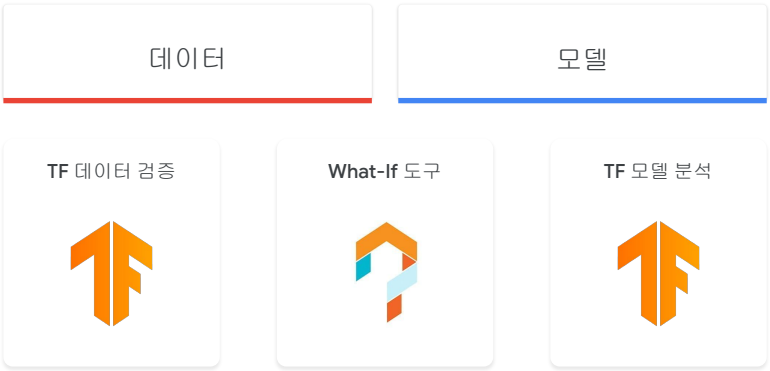
예를 들면 데이터 세트의 데이터 분포가 적절한지 유의해야 합니다. 모집단의 하위 그룹에 편향되어 있나요? 표본 선택 편향 문제가 있나요?
또한 비율에도 주의해야 합니다. 데이터 세트에 소수 모집단에 대한 충분한 수의 데이터 포인트가 포함되어 있더라도 라벨 비율은 다수 모집단의 라벨 비율과 다를 수 있습니다.

머신러닝의 편향은 어떻게 식별할까요?



모델의 학습을 마친 후에도 다양한 방법으로 편향 문제를 확인할 수 있습니다. 데이터 세트의 다양한 하위 집합에서 모델 성능을 확인하여 유해한 편향이 없는지 검증할 수 있습니다. 또한 특정 모집단에 불필요하게 혜택을 주거나 해를 끼치지 않는지 확인할 수도 있습니다.

공정성을 식별하는 데 좋은 도구는 무엇일까요?



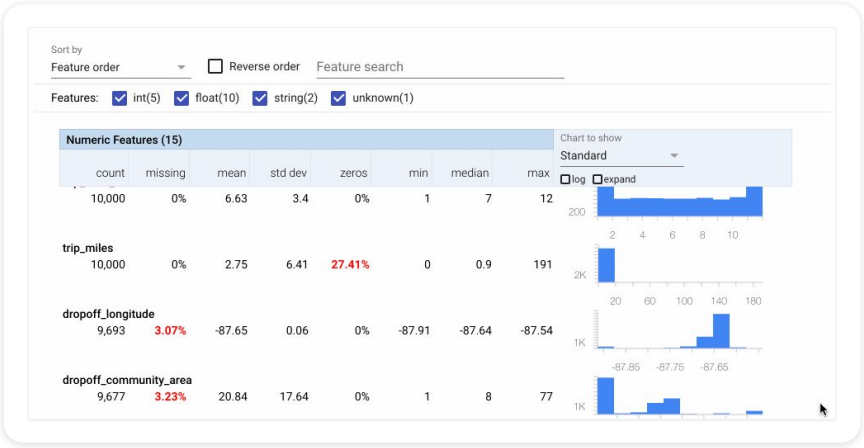
편향 문제를 식별하는 데 도움이 되는 오픈소스 도구를 활용할 수 있습니다.

- TensorFlow 데이터 검증은 ML 데이터를 대규모로 탐색하고 검증하는 데 유용한 도구입니다.
- Google의 What-If 도구는 데이터 및 예측 시각화를 통해 데이터와 모델의 편향을 조사하고 반사실적 분석을 적용하는 데 도움이 됩니다.
- 그리고 TensorFlow Model Analysis은 세분화된 모델 평가를 적용하여 모델 동작을 분석하도록 설계되었습니다.

여기에서는 TensorFlow 생태계 도구에 초점을 두지만, 앞에서 언급한 도구들은 TensorFlow 라이브러리에만 국한되지 않으며 다른 프레임워크와 호환됩니다. 더 중요한 점은 아이디어 자체가 보편적이라는 사실입니다. 따라서 다른 라이브러리를 선호한다면 다른 대안을 찾아볼 수 있습니다. 무엇을 해야 할지 제대로 파악했다는 생각이 들면 스스로 다른 대안을 구현할 수도 있습니다.

TensorFlow 데이터 검증:

데이터 분포 및 통계를 이해하는 데 유용



Tensorflow 데이터 검증 또는 TFDV부터 살펴보겠습니다. 이 도구는 데이터 분포 및 통계를 이해하는 데 도움을 줍니다.
공정성 목적만을 위해 개발된 것은 아니지만 항상 조사에 유용한 출발점이 됩니다.

TensorFlow 데이터 검증:

확장성이 뛰어난 오픈소스 데이터 검증 라이브러리

- 학습 및 테스트 데이터에 관한 요약 통계의 확장 가능한 계산
- 특성 쌍의 분포, 통계 및 다면적 비교를 위한 데이터 뷰어와 통합
- 자동화된 데이터 스키마 생성 및 스키마 뷰어
- 누락된 특성, 범위를 벗어난 값, 잘못된 특성 유형 등에 대한 이상 감지 및 뷰어

```
stats = tfdv.generate_statistics_from_tfrecord(
    data_location=path,
)
```

무엇보다 TFDV를 사용하면 데이터 세트에서 데이터 요약 통계를 쉽게 계산할 수 있습니다.
이 코드 예시는 TensorFlow 고유의 아주 효율적인 바이너리 스토리지 형식인 tf_record 형식을 보여 주지만 .csv 파일이나 dataframe을 직접 사용할 수도 있습니다. 데이터에 대한 경로만 있으면 됩니다.

TensorFlow 데이터 검증:

확장성이 뛰어난 오픈소스 데이터 검증 라이브러리

- 학습 및 테스트 데이터에 관한 요약 통계의 확장 가능한 계산
- 특성 쌍의 분포, 통계 및 다면적 비교를 위한 데이터 뷰어와 통합
- 자동화된 데이터 스키마 생성 및 스키마 뷰어
- 누락된 특성, 범위를 벗어난 값, 잘못된 특성 유형 등에 대한 이상 감지 및 뷰어

```
# Slice on country feature
# (i.e., every unique value of the feature)
slice_fn1 = slicing_util.get_feature_value_slicer(
    features={'country': None}
)

# Slice on the cross of country and state feature
# (i.e., every unique pair of values of the cross)
slice_fn2 = slicing_util.get_feature_value_slicer(
    features={'country': None, 'state': None}
)

# Slice on specific values of a feature
slice_fn3 = slicing_util.get_feature_value_slicer(
    features={'age': [10, 50, 70]}
)

stats_options = tfdv.StatsOptions(
    slice_functions=[slice_fn1, slice_fn2, slice_fn3]
)
```

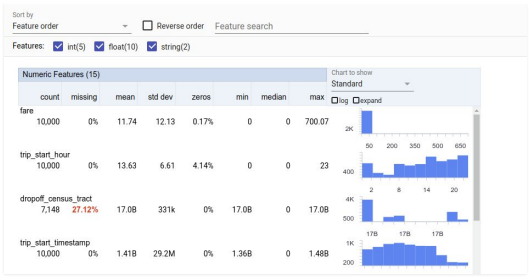
TFDV를 사용하면 데이터 슬라이스별로 통계를 계산할 수도 있습니다.
예를 들어 데이터를 국가별 또는 주별로 구분하면 다양한 위치의 데이터 비율 차이를 이해하는 데 도움이 될 수 있습니다.

TensorFlow 데이터 검증:

확장성이 뛰어난 오픈소스 데이터 검증 라이브러리

- 학습 및 테스트 데이터에 관한 요약 통계의 확장 가능한 계산
- 특성 쌍의 분포, 통계 및 다면적 비교를 위한 데이터 뷰어와 통합
- 자동화된 데이터 스키마 생성 및 스키마 뷰어
- 누락된 특성, 범위를 벗어난 값, 잘못된 특성 유형 등에 대한 이상 감지 및 뷰어

```
tfdv.visualize_statistics(stats)
```



통계를 계산한 후에 visualize_statistics 메서드를 사용하여 간편하게 시각화하세요.

대시보드에는 두 개의 테이블이 있습니다. 하나는 숫자 특성 테이블이고, 다른 하나는 범주형 특성 테이블입니다. 대시보드에는 제어판도 있습니다. 두 데이터 유형에 대해 서로 다른 정보가 표시되므로 테이블과 대시보드가 분리됩니다.

그리고 테이블의 행은 특성에 해당합니다. 여기에는 전체 데이터 세트에서 해당 특성의 값에 대해 계산된 통계와 함께 값의 분포를 보여주는 여러 차트가 포함되어 있습니다.

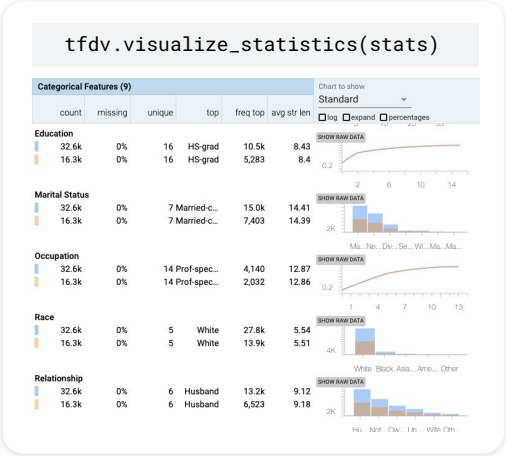
숫자 값의 경우 TFDV는 평균, 표준 편차, 0의 개수, 최솟값, 중앙값, 최댓값을 계산합니다.

이 도구는 문제가 될 수 있는 일부 통계를 굵게 표시하고 빨간색으로 표시하여 자동으로 태그를 지정합니다. 예를 들어 특성에 null 값이라고도 하는 0 값이 많은 경우 자동으로 태그가 지정될 수 있습니다.

TensorFlow 데이터 검증:

확장성이 뛰어난 오픈소스 데이터 검증 라이브러리

- 학습 및 테스트 데이터에 관한 요약 통계의 확장 가능한 계산
- 특성 쌍의 분포, 통계 및 다면적 비교를 위한 데이터 뷰어와 통합
- 자동화된 데이터 스키마 생성 및 스키마 뷰어
- 누락된 특성, 범위를 벗어난 값, 잘못된 특성 유형 등에 대한 이상 감지 및 뷰어



범주형 특성으로는 결측값의 개수, 고유값의 개수, 상위/최다 빈도 범주, 상위 범주 빈도, 평균 강도 길이가 있습니다.

이 새로운 스크린샷이 이전 스크린샷과 어떻게 다른지 확인하세요. 여기에서는 동일한 뷰 안에서 파란색 및 주황색 막대로 표시된 여러 데이터 슬라이스를 직접 비교할 수 있습니다.

TensorFlow 데이터 검증:

확장성이 뛰어난 오픈소스 데이터 검증 라이브러리

- 학습 및 테스트 데이터에 관한 요약 통계의 확장 가능한 계산
- 특성 쌍의 분포, 통계 및 다면적 비교를 위한 데이터 뷰어와 통합
- 자동화된 데이터 스키마 생성 및 스키마 뷰어
- 누락된 특성, 범위를 벗어난 값, 잘못된 특성 유형 등에 대한 이상 감지 및 뷰어

```
schema = tfdv.infer_schema(stats)
```

```
feature {
  name: "payment_type"
  value_count {
    min: 1
    max: 1
  }
  type: BYTES
  domain: "payment_type"
  presence {
    min_fraction: 1.0
    min_count: 1
  }
}
```

TFDV를 사용하면 통계가 제공된 스키마를 자동으로 추론할 수도 있습니다. 이는 특성이 많아서 스키마를 수동으로 정의하기가 지루한 작업이 될 수 있는 데이터 세트에 특히 유용합니다. 대신에 스키마 추론을 사용하여 스키마를 자동으로 생성하고 필요에 따라 미세 조정할 수 있습니다.

이 스키마는 자동화된 MLOps 파이프라인에서 데이터 검증 단계를 자동화하려는 경우에 특히 유용합니다. 데이터 세트의 이상적인 특성을 정의한 후 다음에 MLOps 파이프라인을 실행할 때 데이터 문제를 자동으로 확인할 수 있습니다.

TensorFlow 데이터 검증:

확장성이 뛰어난 오픈소스 데이터 검증 라이브러리

- 학습 및 테스트 데이터에 관한 요약 통계의 확장 가능한 계산
- 특성 쌍의 분포, 통계 및 다면적 비교를 위한 데이터 뷰어와 통합
- 자동화된 데이터 스키마 생성 및 스키마 뷰어
- 누락된 특성, 범위를 벗어난 값, 잘못된 특성 유형 등에 대한 이상 감지 및 뷰어

```
anomalies = tfdv.validate_statistics(
   statistics=other_stats, schema=schema,
)
```

```
payment_type  Unexpected string values
Examples contain values missing from the
schema: Prcard (<1%).
```

```
options = tfdv.StatsOptions(schema=schema)
anomalous_stats = tfdv.validate_examples_in_csv(
       data_location=input, stats_options=options
)
```

```
tfdv.get_feature(schema,payment_type).skew_comparat
or.infinity_norm.threshold = 0.01
skew_anomalies = tfdv.validate_statistics(
   statistics=stats_1, schema=schema,
   serving_statistics=stats_2,
)
```

마지막으로, TFDV를 사용하면 정의된 스키마를 사용하여 이상치를 쉽게 감지하고 조치를 취할 수 있습니다.

이상치는 도메인 외부의 예상치 못한 특성 전체 데이터 세트의 왜곡이나 여러 데이터 슬라이스 간의 비율 격차일 수 있습니다.

머신러닝 파이프라인, 특히 자동화된 시스템에서 이 기능을 사용하면 모델을 학습시키기 전에 데이터 문제를 감지할 수 있습니다.

TFDV는 유용한 기능을 제공하지만 원하는 경우 다른 라이브러리를 사용하여 유사한 데이터 검증 시스템을 개발할 수도 있습니다.



01 공정성 및 편향 개요

02 편향 식별 – TFDV 도구

03 편향 식별 – What-if 도구

04 편향 식별 – TFMA 도구

05 편향 완화 – 데이터 개입

06 편향 완화 – 기준점 보정

07 편향 완화 – 모델 수정

08 실습: TensorFlow에서 MinDiff로 편향 완화하기

다음 도구를 살펴보겠습니다. What-If 도구를 사용하면 데이터 세트와 ML 모델의 상호작용을 시각적으로 분석할 수 있습니다.

What-If 도구:

ML 데이터 세트 및 모델을 시각적으로 프로브하는 오픈소스 도구

- 추론 결과 시각화
- 데이터 포인트를 수정해 모델의 성능 확인
- 단일 특성의 영향 살펴보기
- 유사성을 기준으로 예제 배열
- 혼동 행렬과 기타 측정항목 보기
- 알고리즘 공정성 제약조건 테스트

What-If 도구를 사용하면 데이터 포인트 편집기와 성능 및 공정성 탭을 사용하여 여러 가지 탐색 분석을 수행할 수 있습니다.

각각 살펴보겠습니다.

What-If 도구:

ML 데이터 세트 및 모델을 시각적으로 프로브하는 오픈소스 도구

- 추론 결과 시각화
- 데이터 포인트를 수정해 모델의 성능 확인
- 단일 특성의 영향 살펴보기
- 유사성을 기준으로 예제 배열
- 혼동 행렬과 기타 측정항목 보기
- 알고리즘 공정성 제약조건 테스트



모델과 데이터 세트를 로드한 후 표시되는 첫 번째 뷰에서는 패싯 다이브를 사용해 추론 결과를 시각화할 수 있습니다.

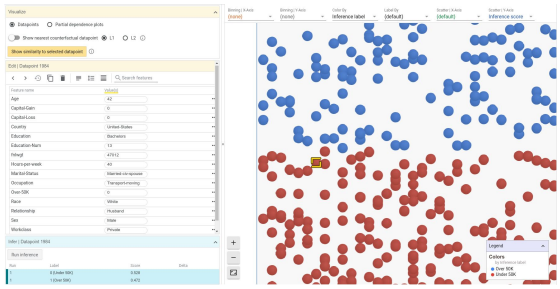
이 예에서 각 데이터 포인트는 모델이 예측한 범주대로 색상이 지정됩니다. 포인트는 추론 점수에 따라 위에서 아래로 배치됩니다. 다시 말하면 하단에 있는 포인트는 예측이 0에 가까우며 음성 라벨에 속할 가능성이 매우 높습니다. 맨 위에 있는 포인트는 예측이 1에 가까우며 양성 라벨에 속할 가능성이 매우 높습니다.

이 뷰를 보면 대부분의 포인트가 0이나 1에 가깝기 때문에 모델이 매우 확신하는 경우가 많으며, 모델은 더 많은 포인트가 빨간색 라벨에 속할 것으로 예측한다고 쉽게 말할 수 있습니다.

What-If 도구:

ML 데이터 세트 및 모델을 시각적으로 프로브하는 오픈소스 도구

- 추론 결과 시각화
- 데이터 포인트를 수정해 모델의 성능 확인
- 단일 특성의 영향 살펴보기
- 유사성을 기준으로 예제 배열
- 혼동 행렬과 기타 측정항목 보기
- 알고리즘 공정성 제약조건 테스트

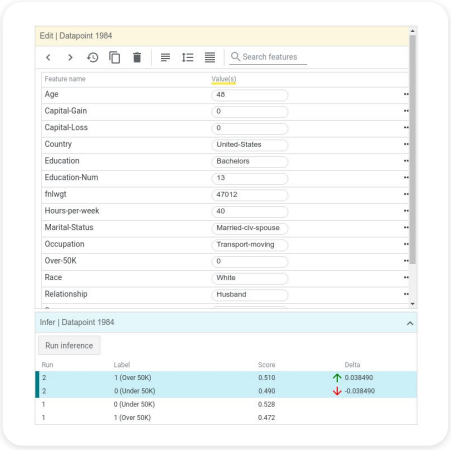


패싯 다이브 뷰에서는 모든 데이터 포인트를 조사할 수 있습니다. 이 경우에는 결정 경계 가까이에 있는 데이터 포인트와 같은 다루기 어려운 사용 사례를 선택합니다. 데이터 포인트 세부정보를 보려면 데이터 포인트를 클릭하세요. 그러면 시각화 왼쪽에 패널이 나타납니다.
여기에서 값을 수정하여 예측이 달라지는지 확인할 수 있습니다.

What-If 도구:

ML 데이터 세트 및 모델을 시각적으로 프로브하는 오픈소스 도구

- 추론 결과 시각화
- 데이터 포인트를 수정해 모델의 성능 확인
- 단일 특성의 영향 살펴보기
- 유사성을 기준으로 예제 배열
- 혼동 행렬과 기타 측정항목 보기
- 알고리즘 공정성 제약조건 테스트



예를 들어 이 데이터 포인트의 연령이나 성별 집단을 변경하면 어떻게 될까요?

반사실적 분석은 숨겨진 모델 편향을 이해하는 데 유용



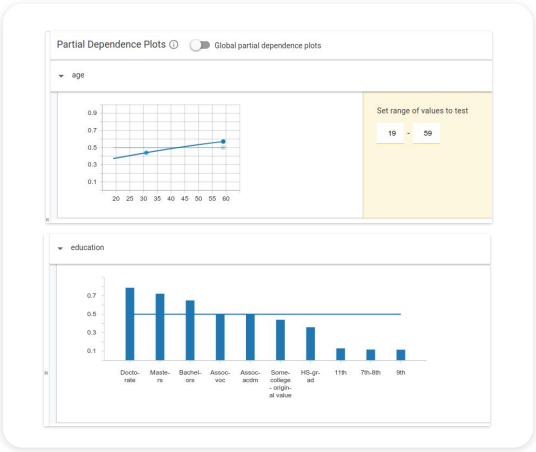
특정한 특성을 변경하여 예측이 그로 인해 영향을 받는지 확인할 수 있습니다. 예를 들어 **'sex'** 특성을 **Male**에서 **Female**로 변경하면 모델 예측이 양성에서 음성으로 반전됩니다.
이러한 종류의 **'what-if'** 분석을 반사실적 분석이라고 하며, 이는 모델 동작을 이해하고 편향 문제를 식별하는 데 도움이 됩니다.

또한 이 방법을 전체 데이터 세트에 적용하여 민감한 특성 값을 변경할 경우 반전되는 결과의 비율을 정량화할 수도 있습니다. 이러한 공정성 측정항목을 '반전 비율'이라고 하며 이를 통해 모델의 취약점을 이해할 수 있습니다.

What-If 도구:

ML 데이터 세트 및 모델을 시각적으로 프로브하는 오픈소스 도구

- 추론 결과 시각화
- 데이터 포인트를 수정해 모델의 성능 확인
- 단일 특성의 영향 살펴보기
- 유사성을 기준으로 예제 배열
- 혼동 행렬과 기타 측정항목 보기
- 알고리즘 공정성 제약조건 테스트



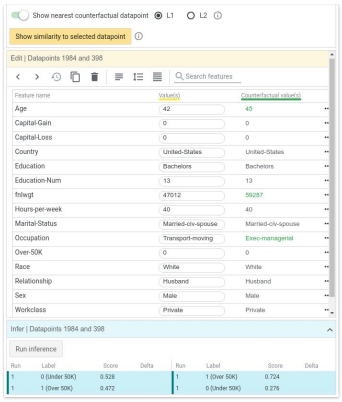
부분 의존도를 통해 예측 결과에 대한 단일 특성의 효과를 탐색할 수도 있습니다. 이 기법은 또한 편향 문제를 찾는 데 도움이 될 수 있으며 이 내용은 다음 해석 가능성 모듈에서 설명하겠습니다.

맨 위의 예는 숫자 값에 대한 부분 의존도 그림을 보여주고, 두 번째 예는 범주형 값에 대한 차트를 보여줍니다.
이를 통해 모델이 연령과 양성 예측 사이에서 긍정적인 상관관계를 학습했으며, 정도가 높을수록 양성 예측도가 높아짐을 쉽게 알 수 있습니다.

What-If 도구:

ML 데이터 세트 및 모델을 시각적으로 프로브하는 오픈소스 도구

- 추론 결과 시각화
- 데이터 포인트를 수정해 모델의 성능 확인
- 단일 특성의 영향 살펴보기
- 유사성을 기준으로 예제 배열
- 혼동 행렬과 기타 측정항목 보기
- 알고리즘 공정성 제약조건 테스트



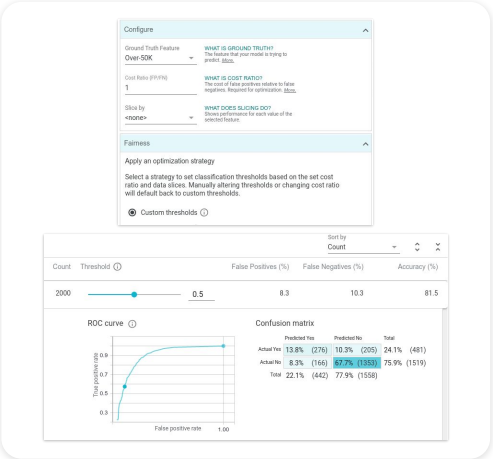
그리고 데이터 포인트 편집기 탭에서는 L1 또는 L2 거리를 사용하여 데이터 포인트와 가장 유사한 예를 찾을 수 있습니다.
이 도구는 두 포인트를 나란히 비교하는데 녹색 텍스트는 두 데이터 포인트가 다른 특성을 나타냅니다.

이제 '성능 및 공정성' 탭에서 마지막 두 포인트를 살펴보겠습니다.

What-If 도구:

ML 데이터 세트 및 모델을 시각적으로 프로브하는 오픈소스 도구

- 추론 결과 시각화
- 데이터 포인트를 수정해 모델의 성능 확인
- 단일 특성의 영향 살펴보기
- 유사성을 기준으로 예제 배열
- 혼동 행렬과 기타 측정항목 보기
- 알고리즘 공정성 제약조건 테스트

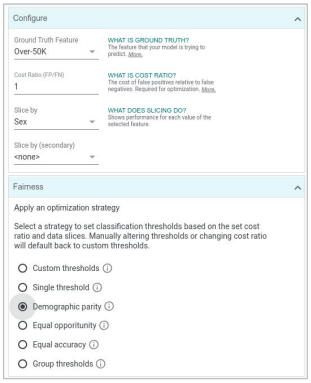


여기에서는 혼동 행렬과 기타 행렬을 전체적으로 또는 그룹별로 볼 수 있습니다. 분류 임곗값을 조정할 수도 있으며 그러면 이에 따라 측정항목이 업데이트됩니다. 또한 예를 들어 거짓양성 대 거짓음성의 상대적 비용과 같은 원하는 비용 비율이 주어지면 최적의 분류 임곗값을 자동으로 계산할 수도 있습니다. 도구의 기본 비용 비율은 1입니다. 이는 거짓음성과 거짓양성이 똑같이 바람직하지 않음을 의미합니다.

What-If 도구:

ML 데이터 세트 및 모델을 시각적으로 프로브하는 오픈소스 도구

- 추론 결과 시각화
- 데이터 포인트를 수정해 모델의 성능 확인
- 단일 특성의 영향 살펴보기
- 유사성을 기준으로 예제 배열
- 혼동 행렬과 기타 측정항목 보기
- 알고리즘 공정성 제약조건 테스트



마지막으로 '성능 및 공정성' 탭에서 슬라이스 기능을 사용해 알고리즘 공정성 제약조건을 테스트할 수 있습니다.
(민감한) 특성에 대한 모델 성능을 분석할 수 있습니다. 예를 들어 성별을 사용하면 모델이 남성보다 여성의 경우에 더 정확하다는 것을 알 수 있습니다. 이는 거짓양성과 거짓음성이 더 적다는 의미입니다.

또한 인구통계 동등성과 같은 공정성 목표가 주어지면 최적의 분류 임곗값을 자동으로 계산할 수 있으며 이 내용은 다음 섹션에서 설명합니다.



01 공정성 및 편향 개요

02 편향 식별 – TFDV 도구

03 편향 식별 – What-if 도구

04 편향 식별 – TFMA 도구

05 편향 완화 – 데이터 개입

06 편향 완화 – 기준점 보정

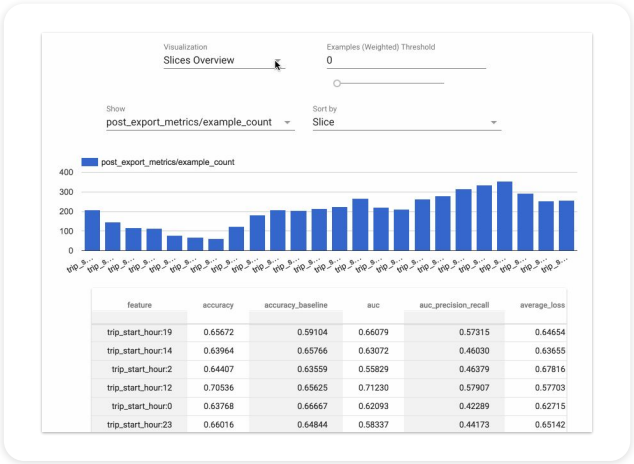
07 편향 완화 – 모델 수정

08 실습: TensorFlow에서 MinDiff로 편향 완화하기

TensorFlow Model Analysis, TFMA 라이브러리를 사용하면 학습된 모델의 성능을 공정성을 포함한 다양한 관점에서 분석할 수 있습니다.

TensorFlow Model Analysis:

확장성이 뛰어난 오픈소스 모델 분석 라이브러리



feature	accuracy	accuracy_baseline	auc	auc_precision_recall	average_loss
trip_start_hour:19	0.65672	0.59104	0.66079	0.57315	0.64654
trip_start_hour:14	0.63964	0.65766	0.63072	0.46030	0.63655
trip_start_hour:2	0.64407	0.63559	0.55829	0.46379	0.67816
trip_start_hour:12	0.70536	0.65625	0.71230	0.57907	0.57703
trip_start_hour:0	0.63768	0.66667	0.62093	0.42289	0.62715
trip_start_hour:23	0.66016	0.64844	0.58337	0.44173	0.65142

TFMA 라이브러리는 TensorFlow 기반 모델을 지원하도록 설계되었지만 Pandas DataFrame이나 scikit-learn 모델과 같은 다른 프레임워크로 쉽게 확장할 수 있습니다. TF Keras 모델의 경우 평가 시 학습 측정항목을 자동으로 적용할 수 있으며 추가 단계 없이 사전 계산된 예측으로 계산할 수 있습니다. 결과는 모델과 함께 자동으로 저장됩니다.

TensorFlow Model Analysis:

확장성이 뛰어난 오픈소스 모델 분석 라이브러리

지원되는 측정항목:



TFMA는 모든 표준 TensorFlow 측정항목을 포함하여 다양한 측정항목을 지원합니다. 여기에는 회귀 측정항목과 분류 측정항목 그리고 반전율과 같은 공정성 관련 측정항목이 포함됩니다.

측정항목 설정을 맞춤설정할 수 있으며 맞춤 측정항목을 세세하게 정의할 수도 있습니다.

TensorFlow Model Analysis:

확장성이 뛰어난 오픈소스 모델 분석 라이브러리

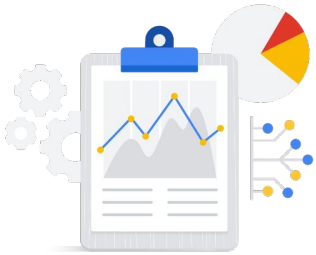
- 단일 서빙 모델에 대한 모델 분석 실행
- 정의된 측정항목에 대한 모델 성능 검증
- 두 모델 비교
- 공정성 지표를 사용하여 공정성 분석 수행

TFMA의 기능을 보다 자세히 살펴보겠습니다.

TensorFlow Model Analysis:

확장성이 뛰어난 오픈소스 모델 분석 라이브러리

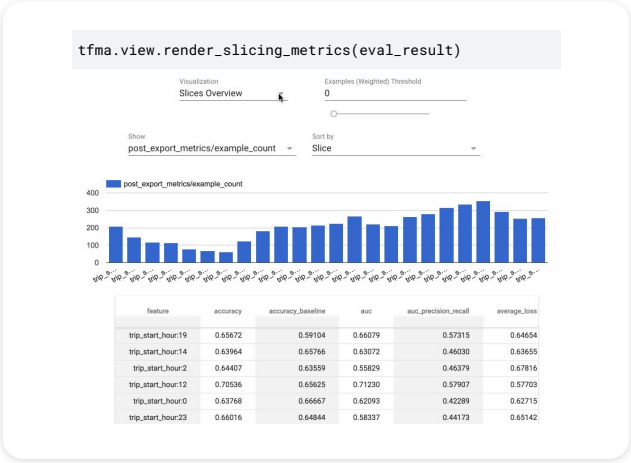
- 단일 서빙 모델에 대한 모델 분석 실행
- 정의된 측정항목에 대한 모델 성능 검증
- 두 모델 비교
- 공정성 지표를 사용하여 공정성 분석 수행



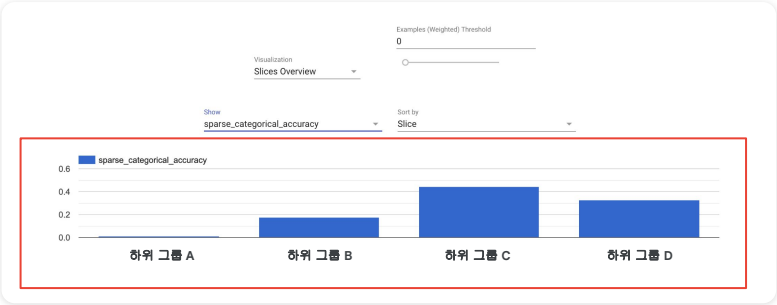


모델을 학습시킨 후에 먼저 모델에 대한 모델 분석을 실행할 수 있습니다. 이 단계에서는 나중에 사용하도록 저장할 수 있는 평가 결과를 생성합니다.

TMFA 결과 시각화



이 결과는 TFMA 위젯을 사용하여 시각화할 수 있으며 이를 통해 모델 성능 측정항목을 대화형으로 확인할 수 있습니다.

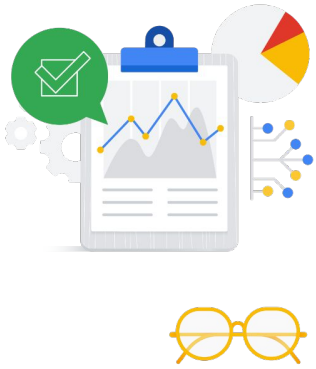


인종 그룹과 같은 민감한 특성을 사용하여 성능을 슬라이스할 수도 있습니다. 이 기능을 사용하면 여러 그룹 간에 현저한 성능 격차가 있는지 손쉽게 확인할 수 있습니다.

TensorFlow Model Analysis:

확장성이 뛰어난 오픈소스 모델 분석 라이브러리

- 단일 서빙 모델에 대한 모델 분석 실행
- 정의된 측정항목에 대한 모델 성능 검증
- 두 모델 비교
- 공정성 지표를 사용하여 공정성 분석 수행

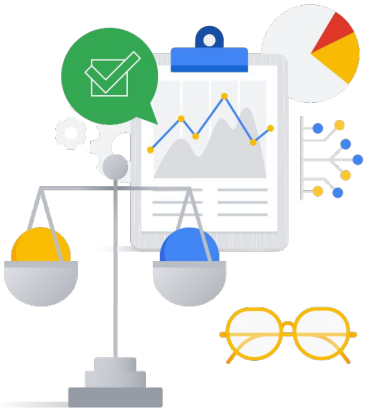


정의된 측정항목 임곗값을 사용하여 모델 성능 검증 프로세스를 자동화할 수 있습니다.
예를 들어 자동화된 머신러닝 파이프라인에서 TFMA가 현저한 성능 격차를 발견하면 모델을 배포하기 전에 모델 업데이트 프로세스를 중지할 수 있습니다.
이 기능은 자동화된 머신러닝 시스템을 빌드할 때 중요합니다.

TensorFlow Model Analysis:

확장성이 뛰어난 오픈소스 모델 분석 라이브러리

- 단일 서빙 모델에 대한 모델 분석 실행
- 정의된 측정항목에 대한 모델 성능 검증
- 두 모델 비교
- 공정성 지표를 사용하여 공정성 분석 수행

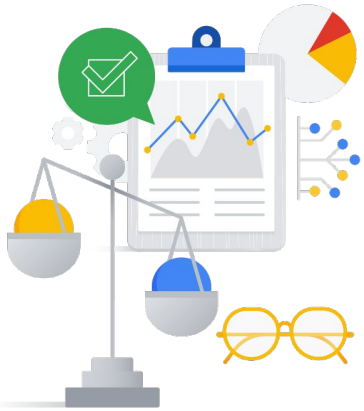


두 모델의 성능을 비교할 수도 있습니다. 이는 이전 모델에 비해 새로운 모델의 성능 향상을 확인하는 데 자주 사용됩니다.

TensorFlow Model Analysis:

확장성이 뛰어난 오픈소스 모델 분석 라이브러리

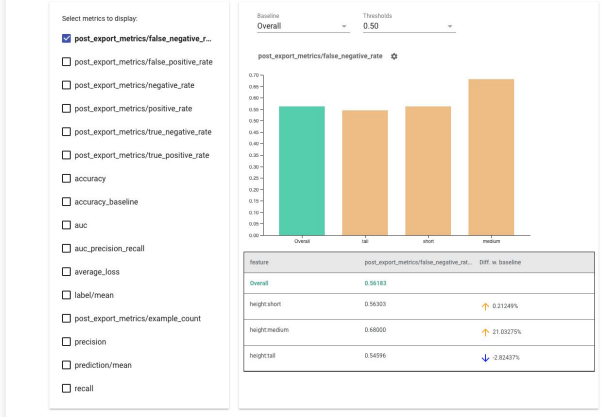
- 단일 서빙 모델에 대한 모델 분석 실행
- 정의된 측정항목에 대한 모델 성능 검증
- 두 모델 비교
- 공정성 지표를 사용하여 공정성 분석 수행



또한 TFMA 분석 결과를 추가 라이브러리, 공정성 지표에 연결할 수 있으며 여기에서 여러 공정성 측정항목을 사용하여 모델을 조사할 수 있습니다.

```
from tensorflow_model_analysis.addons.fairness.view
import widget_view

tfma.view.render_slicing_metrics(eval_result)
```



공정성 지표는 모델 성능을 조사할 수 있는 대화형 위젯도 제공합니다. 이 기능은 What-If 도구에 통합될 수도 있습니다.



01 공정성 및 편향 개요

02 편향 식별 – TFDV 도구

03 편향 식별 – What-if 도구

04 편향 식별 – TFMA 도구

05 편향 완화 – 데이터 개입

06 편향 완화 – 기준점 보정

07 편향 완화 – 모델 수정

08 실습: TensorFlow에서 MinDiff로 편향 완화하기

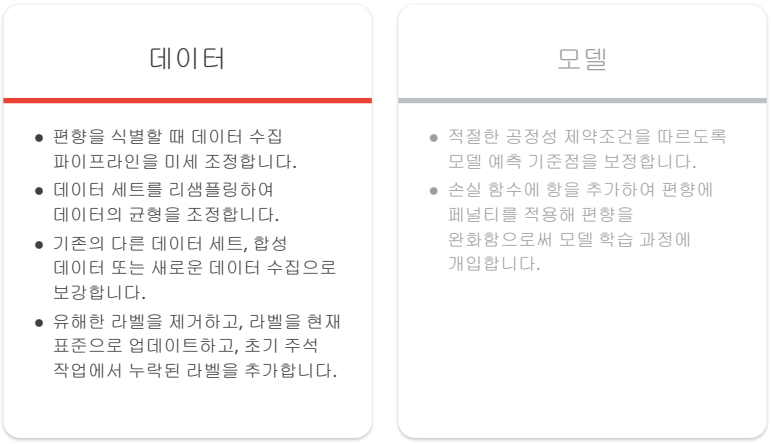
이제 실제로 편향을 완화하기 위한 또 다른 도구와 기법을 살펴보겠습니다.

머신러닝의 편향은 어떻게 식별할까요?



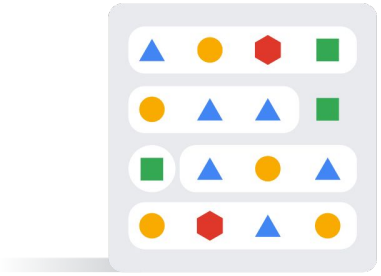
동일한 형식으로 데이터와 모델을 사용해 보겠습니다.
여러 기법을 적용하여 편향 문제를 완화하는 시도를 할 수 있습니다. 실제 접근 방식은 사용 사례에 따라 다르지만 일반적으로 여러 방법을 사용합니다.

머신러닝의 편향은 어떻게 식별할까요?



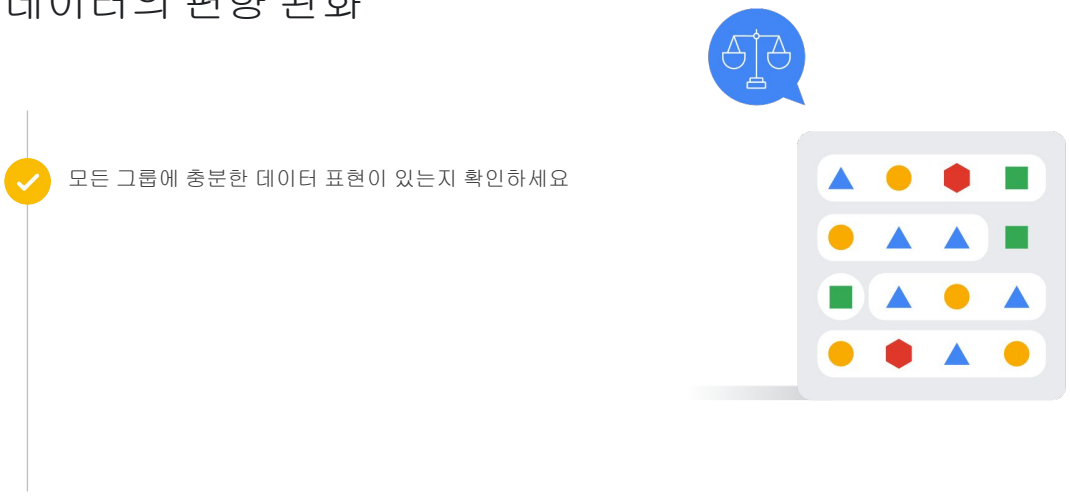
먼저 데이터를 개입시켜 편향을 완화하는 방법에 대해 설명하겠습니다.

데이터의 편향 완화



데이터 격차가 유해할 수 있으므로 팀은 학습 데이터 세트에 포함된 데이터 소스와 주석을 지속적으로 개선하고 다각화해야 합니다. 그 이유는 특정 하위 그룹의 과대표현 및 불충분한 학습 데이터로 인해 여러 하위 그룹 간에 급격한 성능 차이가 발생할 수 있기 때문입니다.

데이터의 편향 완화

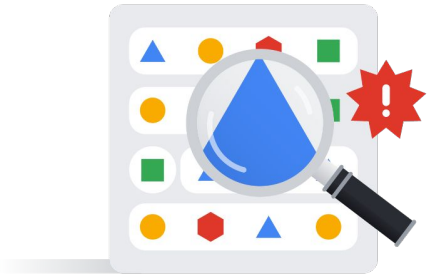


머신러닝 모델의 학습 데이터를 개선하려면 이러한 목표를 지향해야 합니다.

- 모든 그룹에 충분한 데이터 표현이 있는지 확인하세요

데이터의 편향 완화

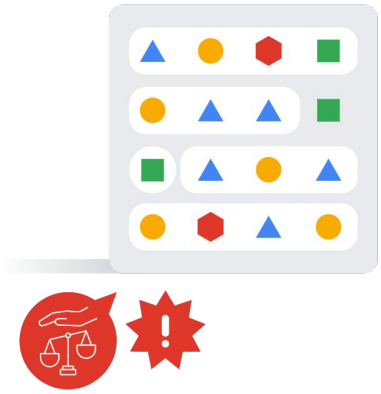
- 모든 그룹에 충분한 데이터 표현이 있는지 확인하세요
- 데이터에 의도한 사용 사례를 벗어나는 유해한 라벨이나 미디어가 포함되지 않게 하세요



- 데이터에 경멸적인 라벨이나 품질이 낮은 데이터와 같이 의도한 사용 사례를 벗어나는 유해한 라벨이나 미디어가 포함되지 않게 하세요.

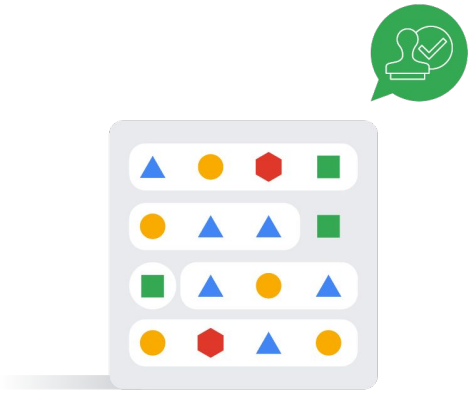
데이터의 편향 완화

- 모든 그룹에 충분한 데이터 표현이 있는지 확인하세요
- 데이터에 의도한 사용 사례를 벗어나는 유해한 라벨이나 미디어가 포함되지 않게 하세요
- 데이터가 유해한 편향으로 치우치지 않게 하세요



- 데이터가 고정관념이나 편향된 상관관계와 같은 유해한 편향으로 치우치지 않게 하세요. 모델에 의도하지 않은 상관관계가 발생할 수 있기 때문입니다.

데이터의 편향 완화



- 또한 데이터가 작성자(데이터를 수집한 사람), 데이터가 캡처된 방식(캡처된 방식), 데이터가 설명된 방식(주석/라벨을 지정한 사람) 또는 데이터의 내용 자체(캡처된 내용)에 의도하지 않은 편향이 없는지 확인하세요.

데이터의 편향 완화

데이터 수집 파이프라인 미세 조정	데이터 균형 조정	다른 데이터로 보강	데이터 라벨 재지정
데이터 수집 파이프라인의 필터와 그 영향을 이해합니다. 편향을 식별할 때 파이프라인을 미세 조정합니다.	소수/다수 그룹의 예를 기존 데이터로 업샘플링하거나 다운샘플링합니다.	기존 데이터 세트, 합성 데이터 또는 새로운 데이터 수집으로 보강합니다.	유해한 라벨을 제거하고, 라벨을 현재 표준으로 업데이트하고, 초기 주석 작업에서 누락된 라벨을 추가합니다.

이러한 목표를 달성하는 데 도움이 되는 몇 가지 기법이 있습니다.

데이터의 편향 완화

데이터 수집 파이프라인 미세 조정	데이터 균형 조정	다른 데이터로 보강	데이터 라벨 재지정
데이터 수집 파이프라인의 필터와 그 영향을 이해합니다. 편향을 식별할 때 파이프라인을 미세 조정합니다.	소수/다수 그룹의 예를 기존 데이터로 업샘플링하거나 다운샘플링합니다.	기존 데이터 세트, 합성 데이터 또는 새로운 데이터 수집으로 보강합니다.	유해한 라벨을 제거하고, 라벨을 현재 표준으로 업데이트하고, 초기 주석 작업에서 누락된 라벨을 추가합니다.

- 특히 파이프라인의 데이터 필터와 관련된 편향을 식별할 때 데이터 수집 파이프라인을 미세 조정합니다.

데이터의 편향 완화

데이터 수집 파이프라인 미세 조정	데이터 균형 조정	다른 데이터로 보강	데이터 라벨 재지정
데이터 수집 파이프라인의 필터와 그 영향을 이해합니다. 편향을 식별할 때 파이프라인을 미세 조정합니다.	소수/다수 그룹의 예를 기존 데이터로 업샘플링하거나 다운샘플링합니다.	기존 데이터 세트, 합성 데이터 또는 새로운 데이터 수집으로 보강합니다.	유해한 라벨을 제거하고, 라벨을 현재 표준으로 업데이트하고, 초기 주석 작업에서 누락된 라벨을 추가합니다.

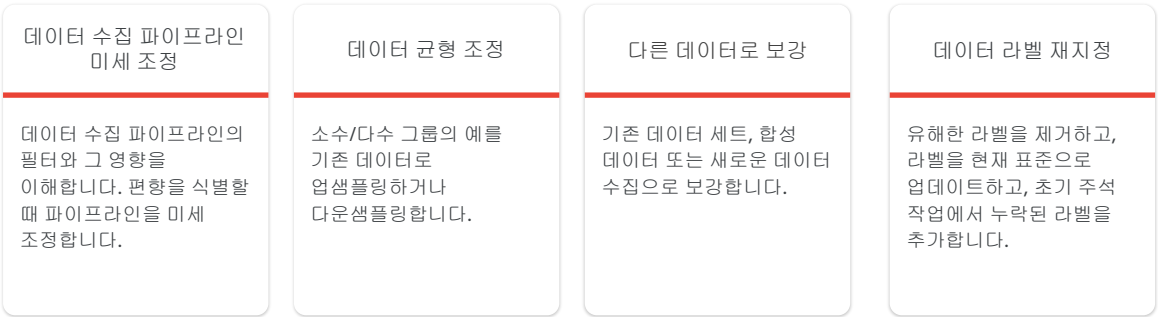
- 데이터 세트를 다시 샘플링하여 데이터 균형을 조정합니다.

데이터의 편향 완화

데이터 수집 파이프라인 미세 조정	데이터 균형 조정	다른 데이터로 보강	데이터 라벨 재지정
데이터 수집 파이프라인의 필터와 그 영향을 이해합니다. 편향을 식별할 때 파이프라인을 미세 조정합니다.	소수/다수 그룹의 예를 기존 데이터로 업샘플링하거나 다운샘플링합니다.	기존 데이터 세트, 합성 데이터 또는 새로운 데이터 수집으로 보강합니다.	유해한 라벨을 제거하고, 라벨을 현재 표준으로 업데이트하고, 초기 주석 작업에서 누락된 라벨을 추가합니다.

- 기존의 다른 데이터 세트, 합성 데이터 또는 새로운 데이터 수집과 같은 추가 데이터로 보강합니다.

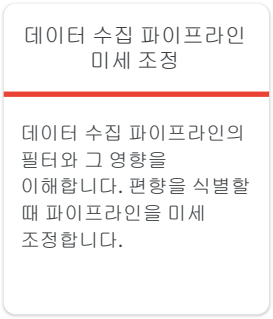
데이터의 편향 완화



- 유해한 라벨을 제거하고, 라벨을 현재 표준으로 업데이트하고, 초기 주석 작업에서 누락된 라벨을 추가하여 데이터 라벨을 재지정합니다.

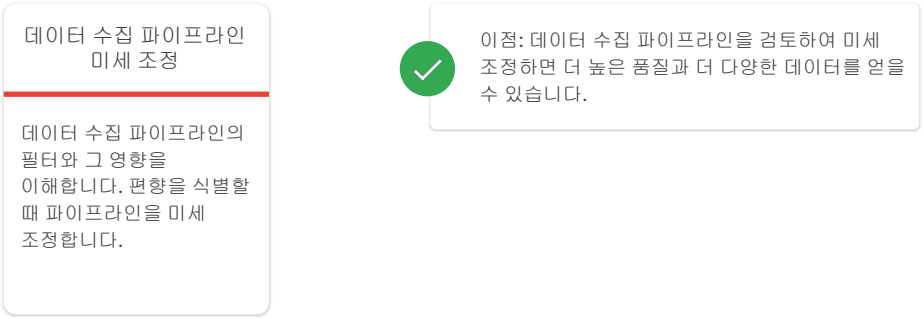
소개한 기법을 각각 자세히 살펴보겠습니다.

데이터 수집 파이프라인 미세 조정



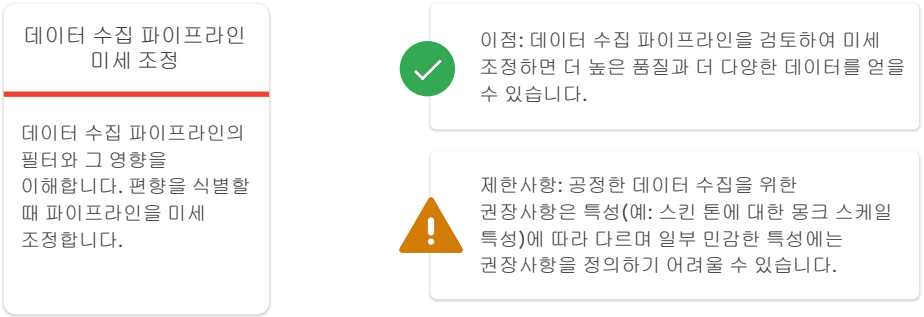
데이터의 편향을 식별할 때 먼저 파이프라인을 검토하여 미세 조정합니다.
데이터 수집 파이프라인에 데이터를 포함하거나 제외하는 필터가 있는 경우
의도하든 의도하지 않았든 필터링을 통해 포함되거나 제외되는 데이터의 영향을
충분히 고려해야 합니다.
데이터에 필터를 추가할 때마다 어떻게든 데이터의 편향성이 높아집니다.

데이터 수집 파이프라인 미세 조정



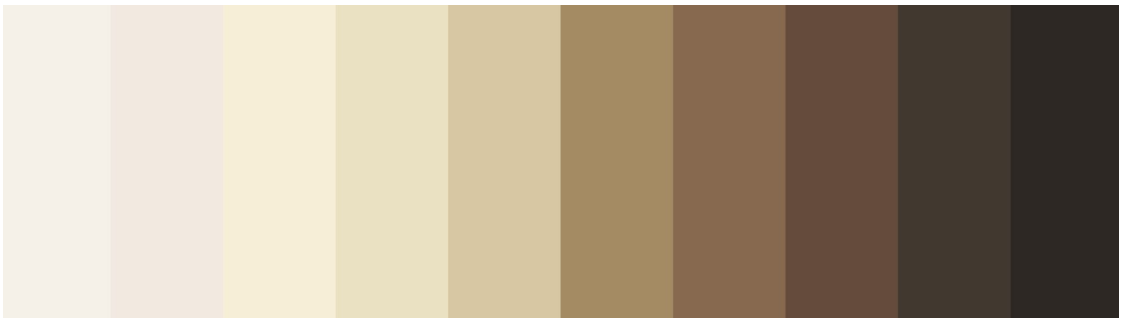
파이프라인을 미세 조정하면 더 높은 품질과 더 다양한 데이터를 얻을 수 있습니다.

데이터 수집 파이프라인 미세 조정



파이프라인 미세 조정에도 한계가 있습니다. 공정한 데이터 수집을 위한 권장사항은 특성에 따라 다릅니다.

몽크 스킨 톤(MST) 스케일

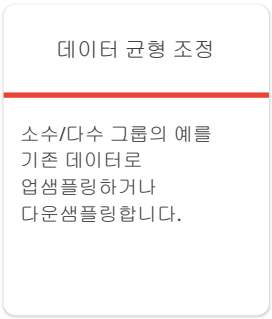


#f6ede4	#f3e7db	#f7ead0	#eadaba	#d7bd96	#a07e56	#825c43	#604134	#3a312a	#292420
Monk 01	Monk 02	Monk 03	Monk 04	Monk 05	Monk 06	Monk 07	Monk 08	Monk 09	Monk 10

예를 들어 공정한 사람 얼굴 이미지 데이터 세트를 수집하려면 몽크 스킨 톤(MST) 스케일을 사용할 수 있습니다. Ellis Monk 박사가 Google과 협력하여 개발한 MST 스케일은 더 나은 표현을 위해 데이터 세트와 ML 모델을 평가하는 데 사용할 수 있는 10가지 피부색 스케일을 제공합니다.

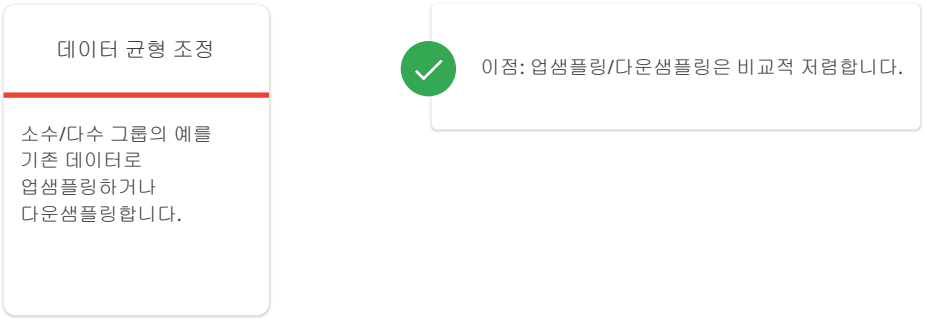
그러나 이러한 종류의 권장사항은 일부 민감한 기능에는 사용하지 못할 수 있으며 처음부터 정의하기 어려울 수 있습니다.

데이터 균형 조정



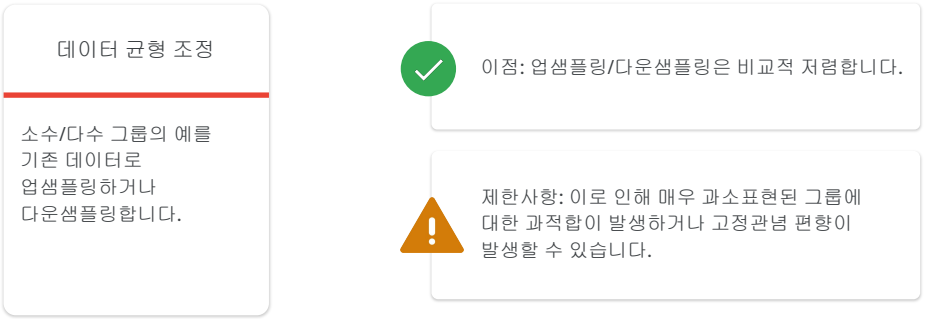
데이터 세트를 다시 샘플링하여 데이터 균형을 맞출 수 있습니다. 예를 들면 소수 또는 다수 그룹의 예를 기존 데이터로 업샘플링하거나 다운샘플링할 수 있습니다. 리샘플링은 ML 워크플로의 다양한 단계에서 일어날 수 있으며 종종 데이터 세트의 사용에 따라 달라집니다.

데이터 균형 조정

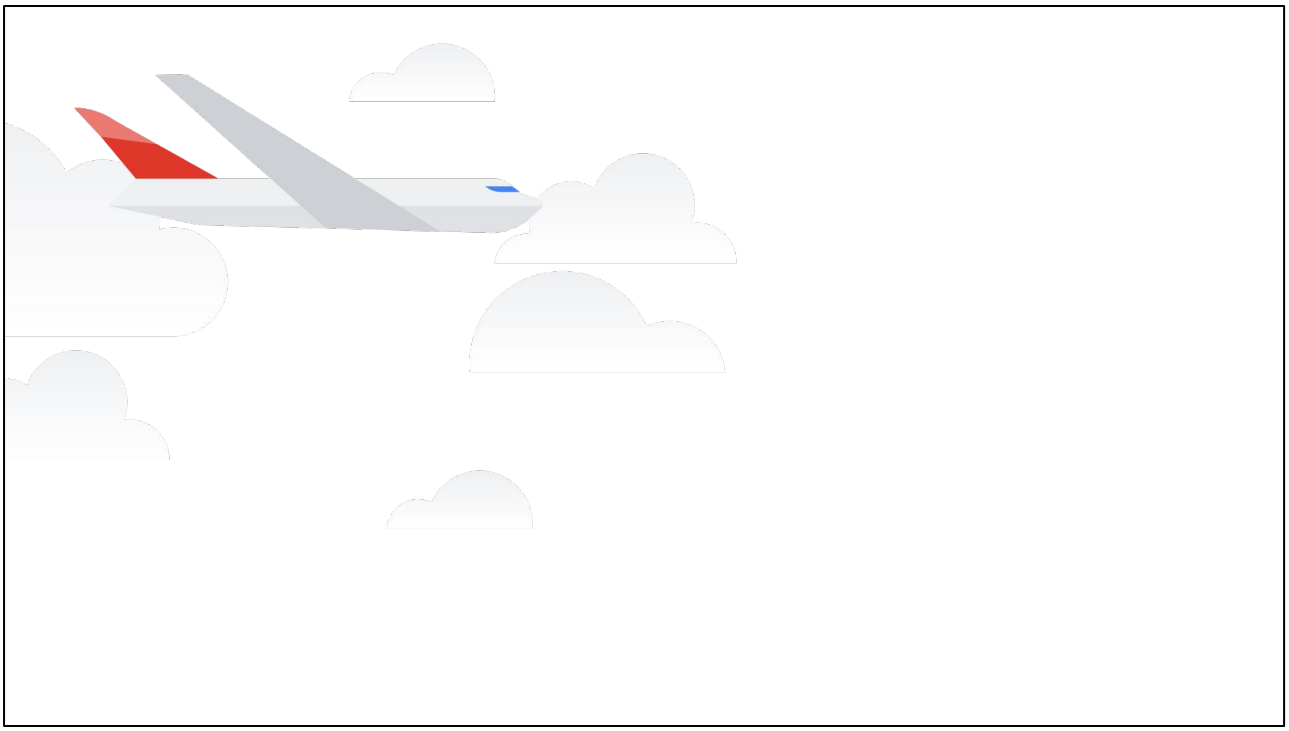


이 기법의 이점은 비교적 저렴하다는 것입니다. 과소표현된 그룹을 업샘플링하는 경우에는 새로운 데이터가 필요하지 않습니다.

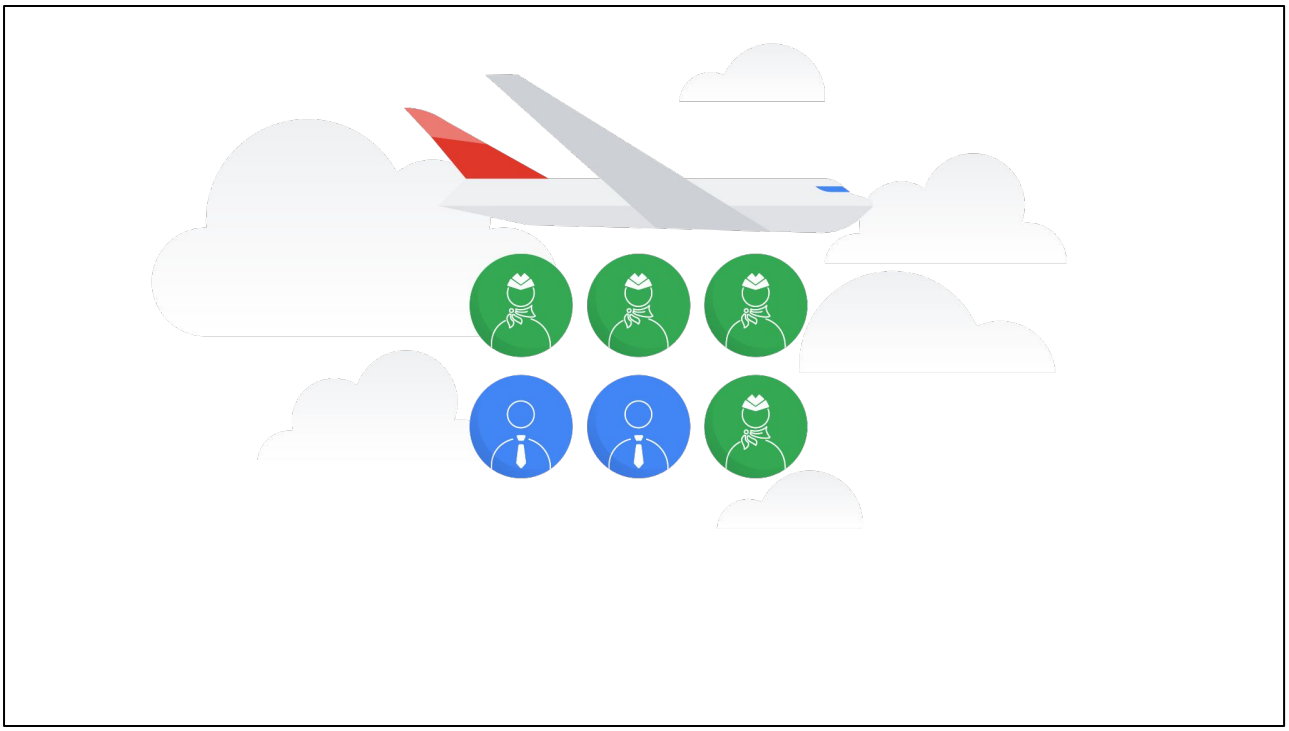
데이터 균형 조정



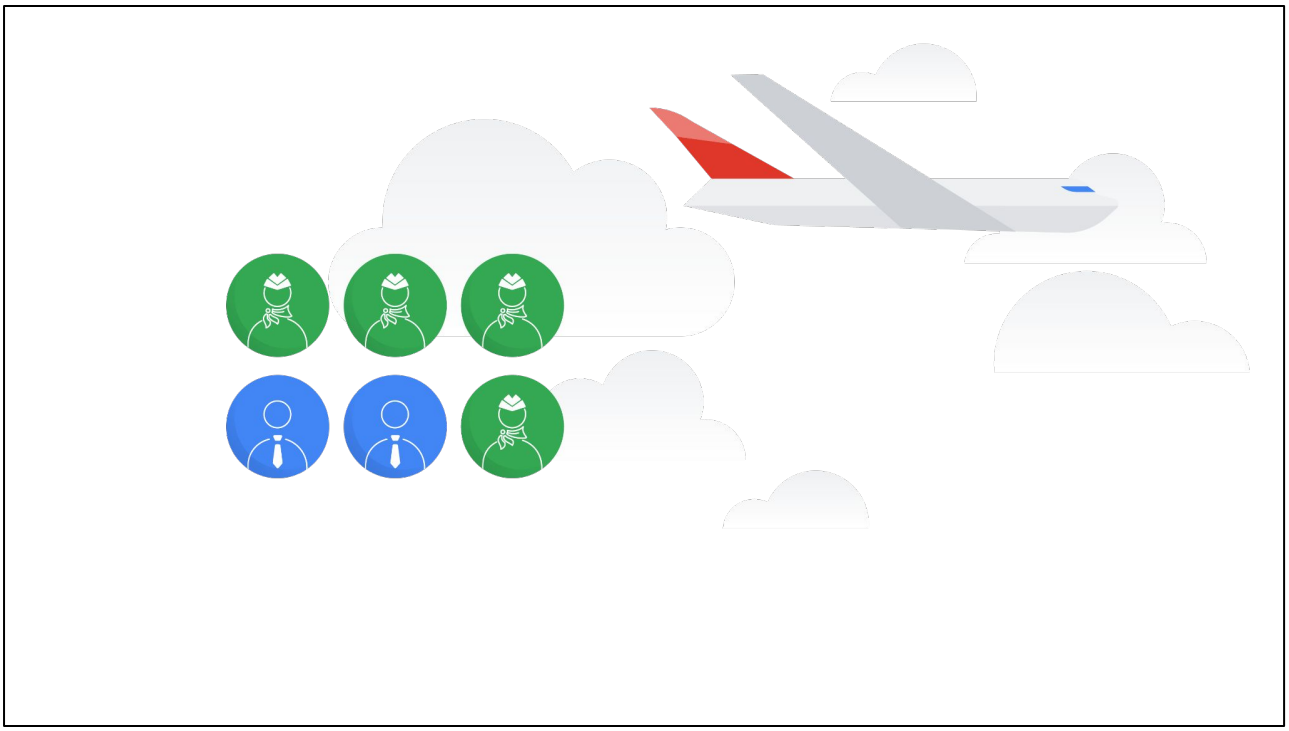
그러나 매우 과소표현된 그룹을 과적합시킬 수 있는 제한 가능성을 인식하고 고정관념 편향으로 이어지는 증폭에 주의해야 합니다.



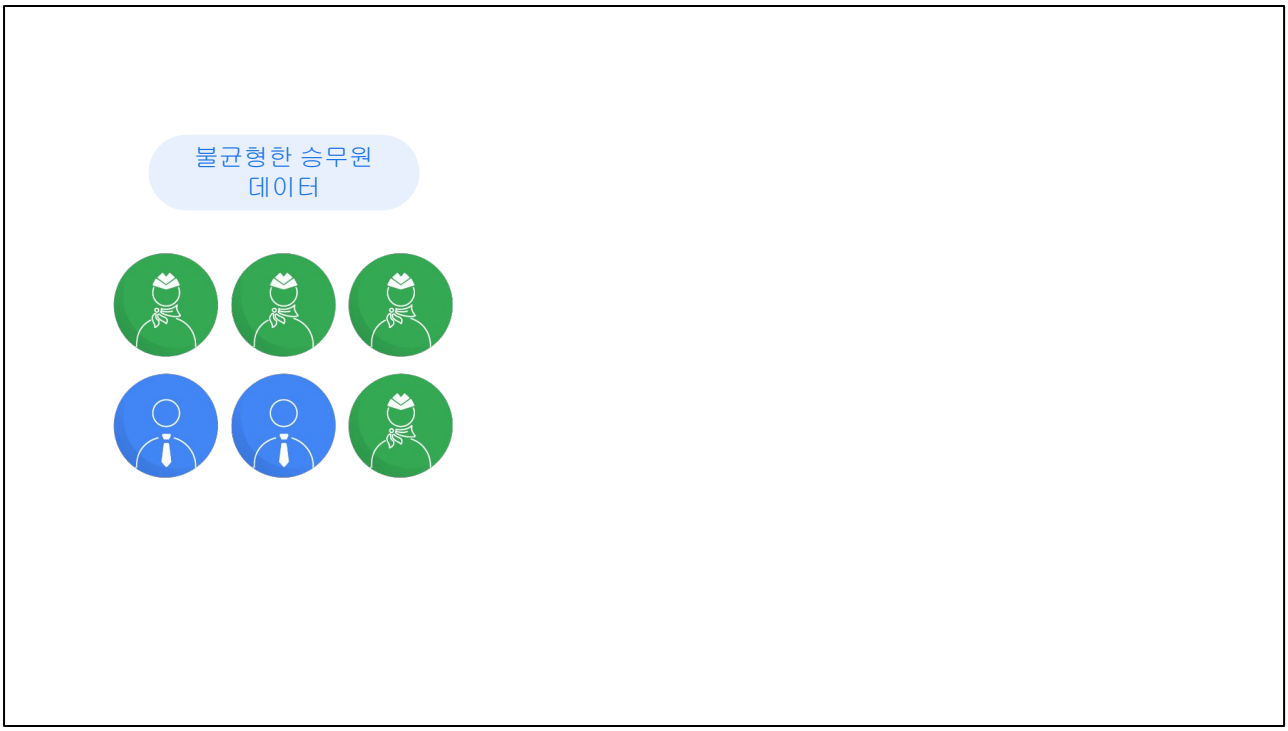
데이터 균형 조정의 예를 살펴보겠습니다.



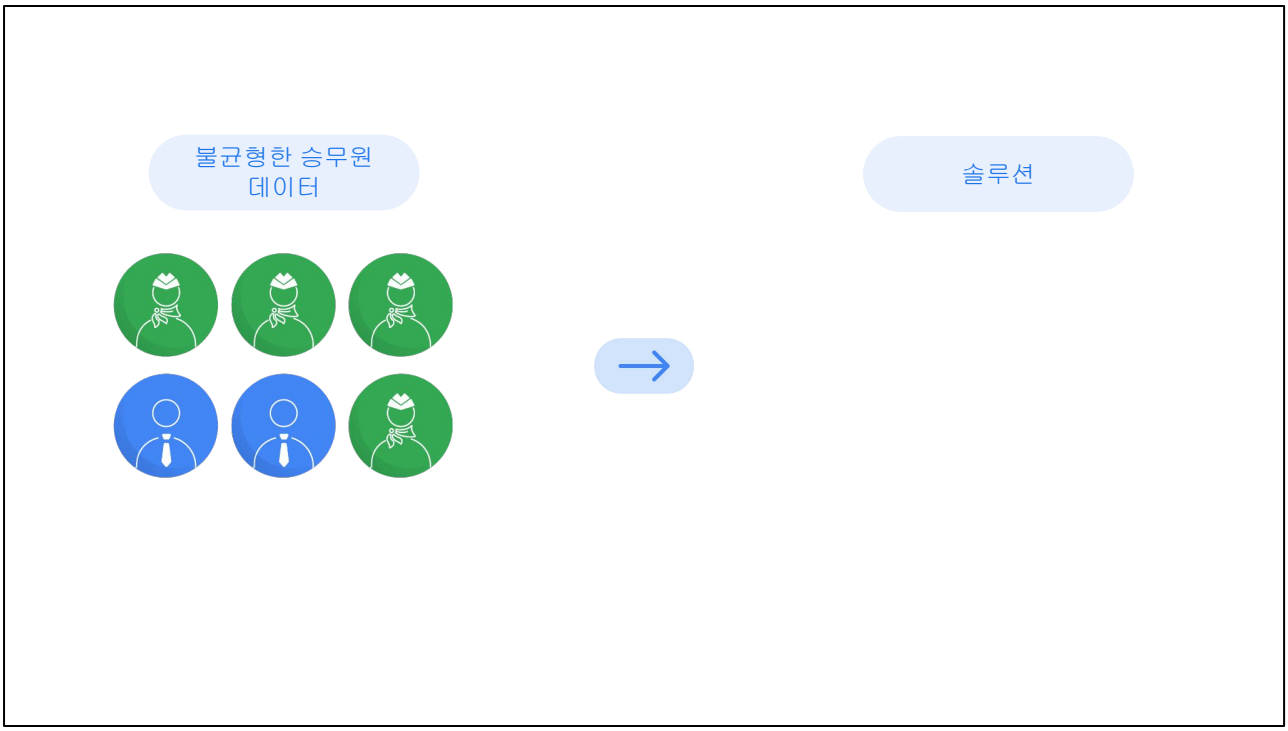
승무원 데이터가 포함된 데이터 세트를 사용하여 머신러닝 모델을 학습시킨다고 가정해 보겠습니다.



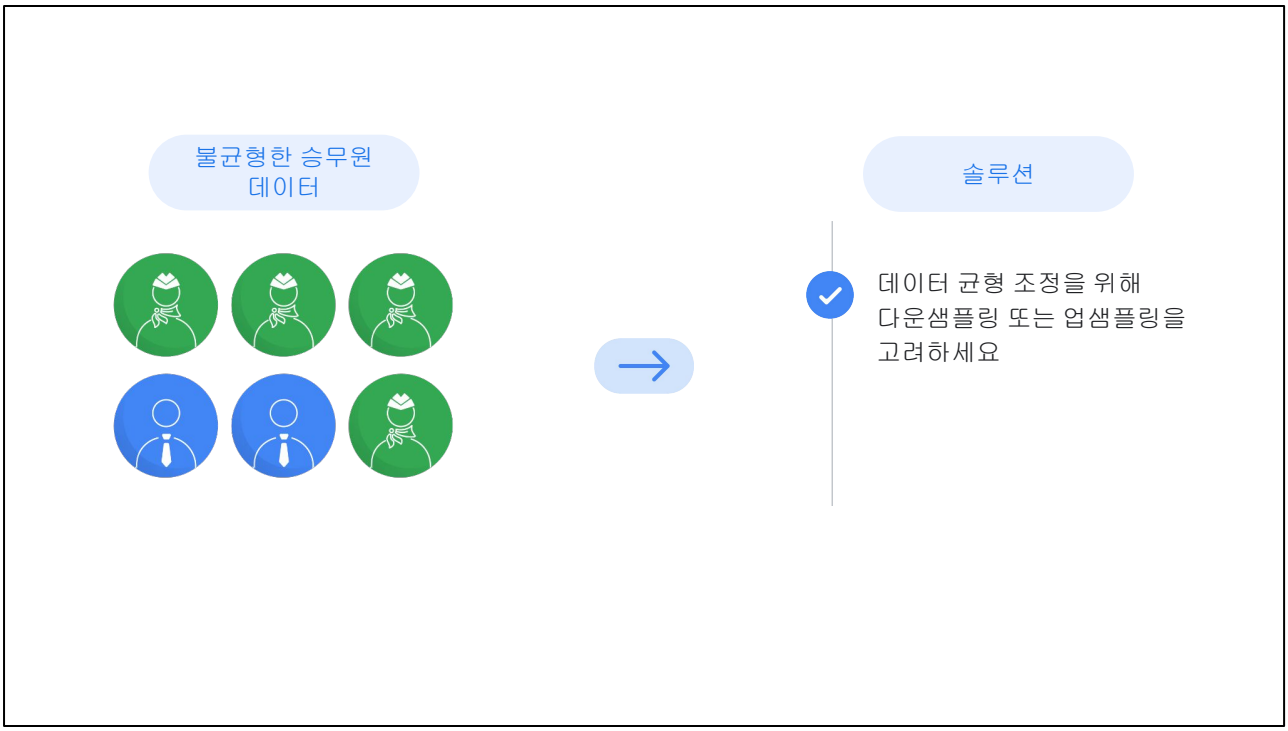
이 데이터 세트에는



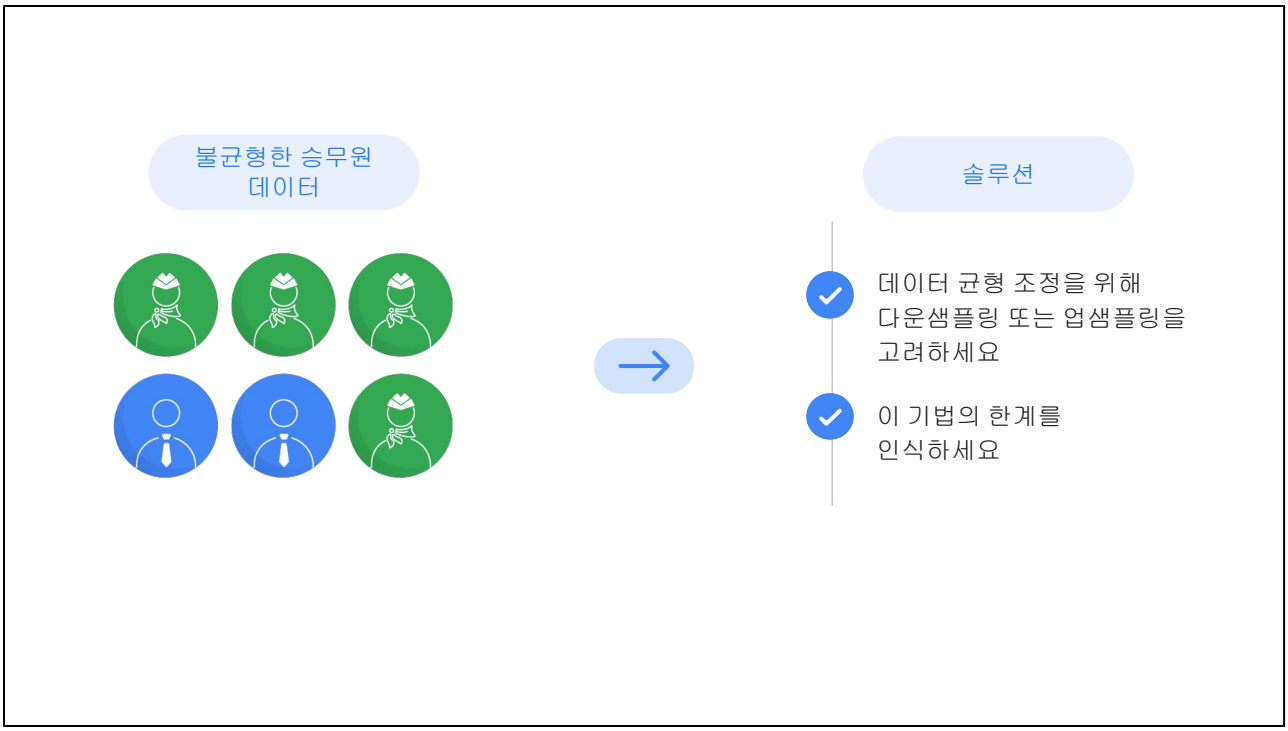
소수의 남성 승무원만 데이터에 존재합니다.



이러한 경우

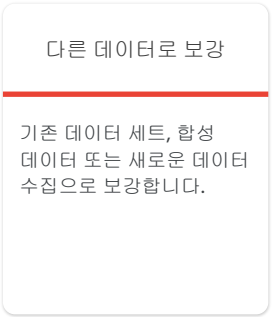


여성 승무원 그룹을 다운샘플링하거나 남성 승무원 그룹을 업샘플링하는 것을 고려하는 것이 좋습니다.



이 기법의 한계는 각각의 예가 과대표현될 수 있다는 점입니다. 이를 상쇄하려면 소수 그룹에 대해 더 많은 데이터를 탐색 및 수집하여 데이터를 보강하는 것이 좋습니다.

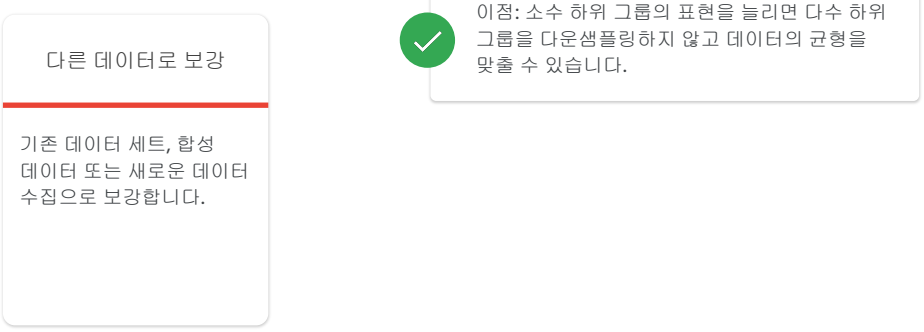
다른 데이터로 보강



기존의 다른 데이터 세트, 합성 데이터 또는 새로운 데이터 수집으로 보강하는 것은 데이터의 편향을 완화하는 중요한 기법입니다. 하지만 데이터를 보강하면 데이터 풀이 확대됩니다. 반면에 리샘플링을 통한 데이터 균형 조정은 기존 데이터를 기반으로 이루어집니다.

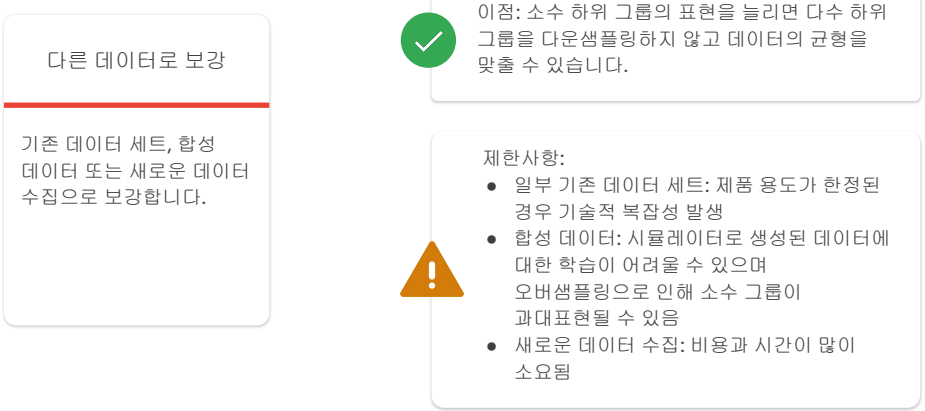
또한 여러 데이터 세트에서 데이터를 수집하면 소수 하위 그룹 또는 실패 사례의 표현이 증가할 수 있습니다. 과소표현된 소수 하위 그룹에 대한 새로운 예를 추가하려면 합성 데이터를 생성할 수 있습니다. 그리고 시간과 예산이 촉박하지 않다면 새로운 데이터를 수집하여 새로운 예를 추가할 수도 있습니다.

다른 데이터로 보강



더 많은 데이터로 보강하면 몇 가지 이점이 있습니다. 공정성 특성이 향상된 추가 데이터를 널리 사용할 수 있습니다. 소수 하위 그룹의 표현을 늘리면 다수 하위 그룹을 다운샘플링하지 않고 데이터의 균형을 맞출 수 있습니다. 그리고 합성 데이터로 보강하면 이러한 격차를 해소하기 위해 새로운 데이터 세트를 선별하는 것보다 비용이 저렴할 수 있습니다.

다른 데이터로 보강

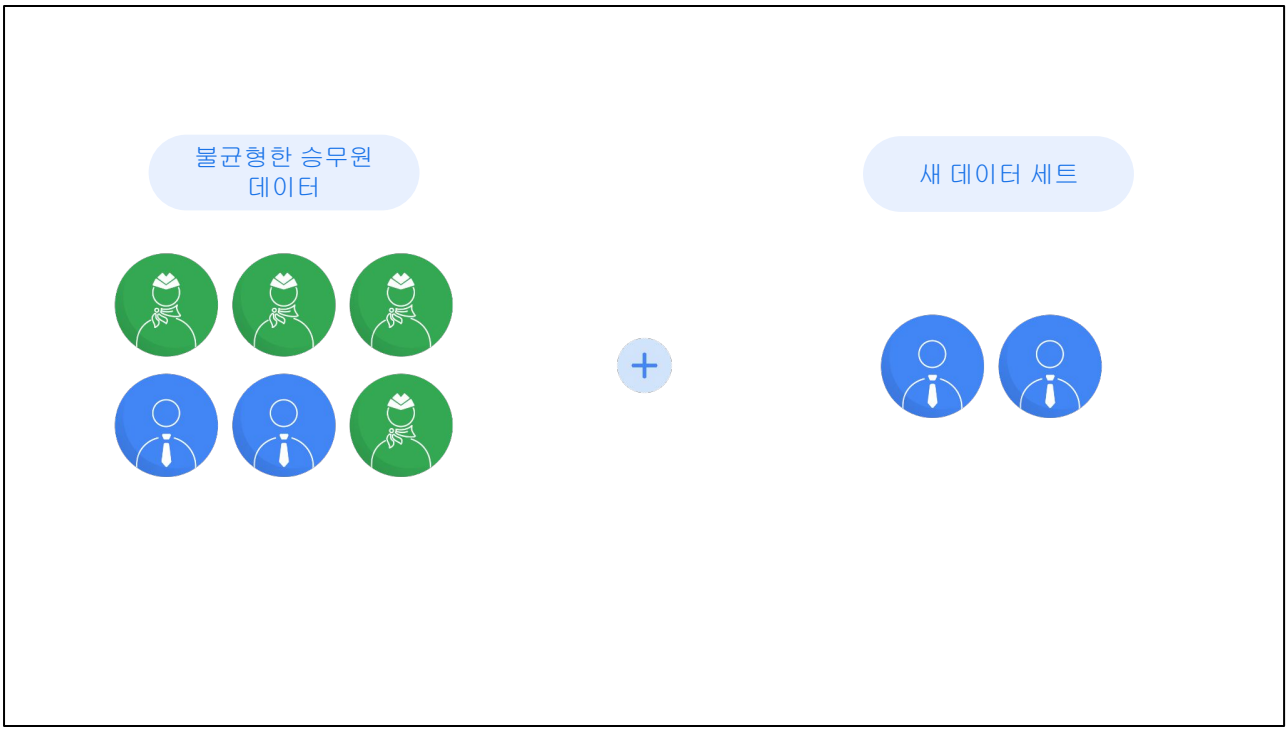


그러나 각 기법에는 고유한 제한사항이 있습니다.

희귀한 데이터 속성이 있어 제품 용도가 한정된 경우 그 범위를 벗어난 데이터를 추가로 사용하면 범위 격차를 극복하기 위한 관련 ML 작업에서 기술적 복잡성이 발생할 수 있습니다.
합성 데이터에 대한 학습은 특히 시뮬레이터에서 생성된 데이터의 경우에 문제가 될 수 있습니다. 예를 들어 학습을 수행한 모델이 합성 이미지의 점수만 변경해서 '속임수'를 저지르지 않게 하려면 모델이 합성 이미지를 '자연적' 이미지와 다르게 처리하는지 여부를 주의 깊게 살펴야 합니다. 그리고 업샘플링과 마찬가지로 오버샘플링도 소수 그룹의 과대표현을 초래할 수 있습니다.
나열된 모든 기법 중에서 새로운 데이터 수집이 가장 비용이 많이 들고 시간이 오래 걸립니다.

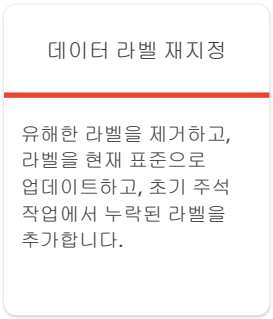


앞의 예로 돌아가서 더 많은 남성 승무원이 포함된 새로운 데이터 세트로 데이터를 보강하여 학습 모델의 표현을 개선하고 편향을 줄이기 위한 다른 접근 방식을 사용할 수도 있습니다.



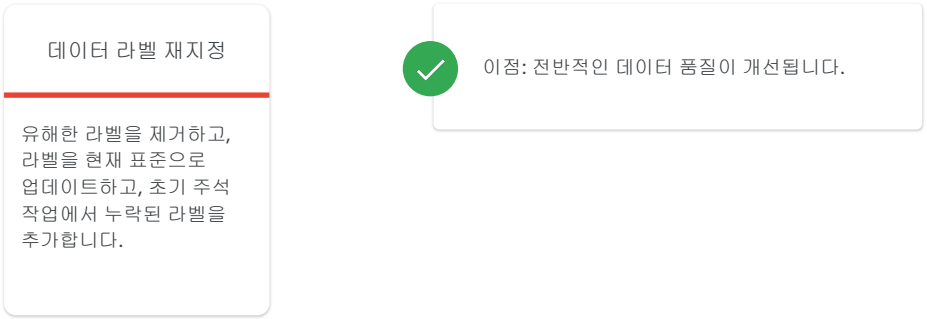
앞의 예로 돌아가서 더 많은 남성 승무원이 포함된 새로운 데이터 세트로 데이터를 보강하여 학습 모델의 표현을 개선하고 편향을 줄이기 위한 다른 접근 방식을 사용할 수도 있습니다.

데이터 라벨 재지정



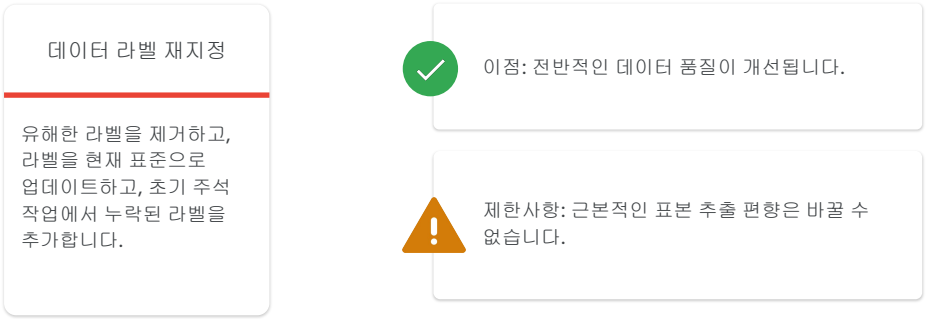
마지막으로 유해한 라벨을 제거하고, 라벨을 현재 표준으로 업데이트하고, 초기 주석 작업에서 누락된 라벨을 추가하여 데이터 라벨을 재지정합니다.

데이터 라벨 재지정



이 방법은 전반적인 데이터 품질을 개선할 수 있습니다.

데이터 라벨 재지정



하지만 근본적인 표본 추출 편향은 바꿀 수 없습니다.



머신러닝 모델의 편향을 줄이기 위해 데이터 라벨 재지정을 사용하는 방법의 실제 사례를 감정 분석을 통해 살펴보겠습니다.



"이 영화는 전형적인 밀레니얼 세대의 삶을
유쾌하게 보여줍니다. 이들은 게으르고
특권 의식이 있으며 스마트폰에
집착합니다. 하지만 이러한 결점에도
불구하고 사랑스럽고 공감을 일으킵니다.
이 영화는 포복절도할 만큼 웃음을 터뜨릴
장면들로 가득합니다. 마음껏 웃고 싶을 때
보기에 딱 좋은 영화입니다."

영화 리뷰가 긍정적인지 부정적인지 분류하도록 머신러닝 모델을 학습시킨다고
가정해 보겠습니다.



"이 영화는 전형적인 밀레니얼 세대의 삶을 유쾌하게 보여줍니다. 이들은 게으르고 특권 의식이 있으며 스마트폰에 집착합니다. 하지만 이러한 결점에도 불구하고 사랑스럽고 공감을 일으킵니다. 이 영화는 포복절도할 만큼 웃음을 터뜨릴 장면들로 가득합니다. 마음껏 웃고 싶을 때 보기에 딱 좋은 영화입니다."

감정 분석을 거친 결과 부정적인 리뷰로 판별됩니다.

학습 데이터에 고정관념이 담긴 문구를 사용하거나 특정 그룹의 사람들을 일반화하는 등 편향된 언어가 담긴 리뷰가 포함되어 있을 가능성이 있습니다.



"이 영화는 전형적인 밀레니얼 세대의 삶을 유쾌하게 보여줍니다. 이들은 게으르고 특권 의식이 있으며 스마트폰에 집착합니다. 하지만 이러한 결점에도 불구하고 사랑스럽고 공감을 일으킵니다. 이 영화는 포복절도할 만큼 웃음을 터뜨릴 장면들로 가득합니다. 마음껏 웃고 싶을 때 보기에 딱 좋은 영화입니다."

감정 분석을 거친 결과 부정적인 리뷰로 판별됩니다.

사람의 검토를 통해 이를 긍정적인 리뷰로 바꾸고 모델을 학습시킵니다.

편향을 줄이려면 전문가가 신중하게 리뷰를 검토하도록 하여 일부 리뷰의 라벨을 재지정해 보다 중립적인 라벨을 지정합니다. 이렇게 하면 모델이 편향된 언어 대신 감정을 리뷰의 실제 콘텐츠와 연관시키는 방법을 학습하는 데 도움이 됩니다.



01 공정성 및 편향 개요

02 편향 식별 – TFDV 도구

03 편향 식별 – What-if 도구

04 편향 식별 – TFMA 도구

05 편향 완화 – 데이터 개입

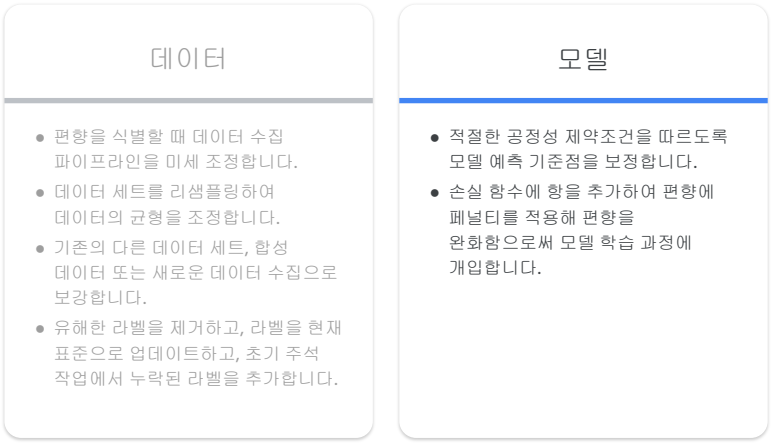
06 편향 완화 – 기준점 보정

07 편향 완화 – 모델 수정

08 실습: TensorFlow에서 MinDiff로 편향 완화하기

지금까지 데이터의 편향을 완화하는 방법을 알아보았습니다.

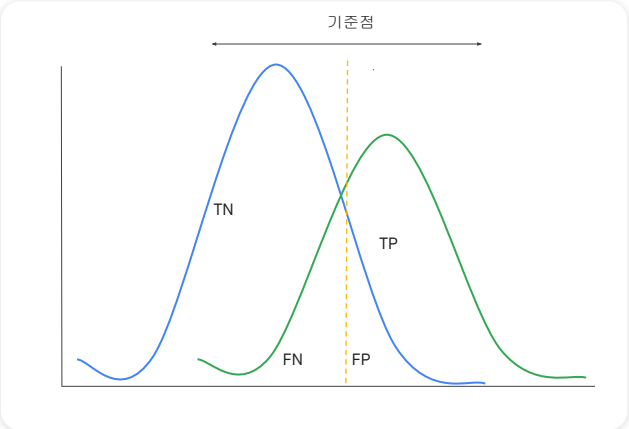
머신러닝의 편향은 어떻게 식별할까요?



이제 문제를 완화하기 위해 다양한 방식으로 머신러닝 모델에 개입하는 기법을 살펴보겠습니다.

기준점 보정:

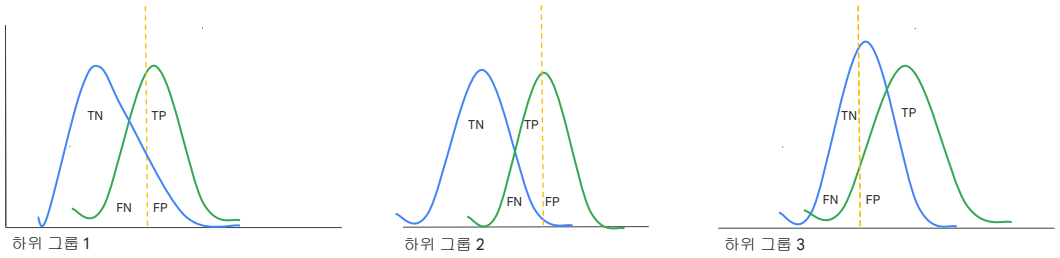
공정한 결과를 가져오는 기준점 찾기



첫째, 머신러닝 모델을 학습시키고 수정한 후에도 기준점을 보정하여 분류 동작을 제어할 여지가 여전히 있습니다.
기준점 보정은 예측 결과를 참양성, 거짓양성, 거짓음성, 참음성으로 분류하여 비율을 정의합니다.

전체 데이터 세트에 대해 이러한 측정항목을 결정한 후에는 데이터 내의 여러 하위 그룹에서 측정항목을 계산하여 한 단계 더 나아가세요.

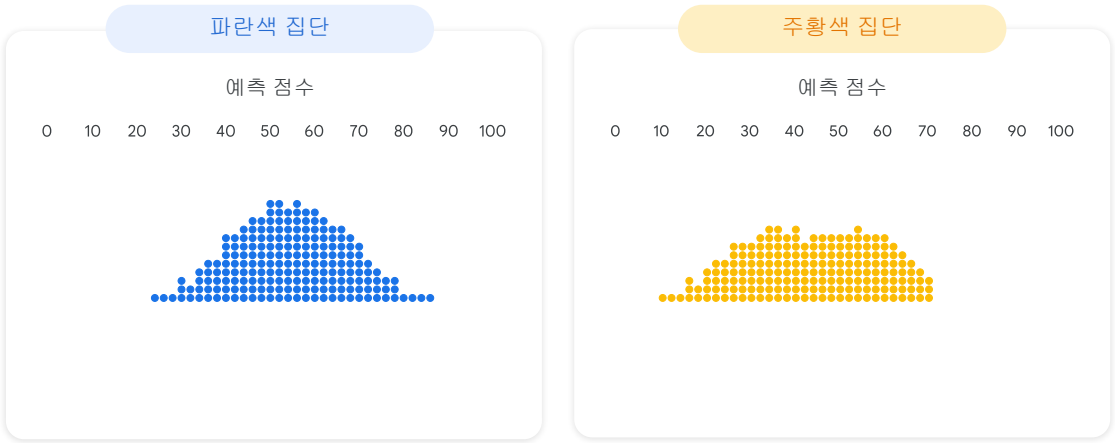
예를 들어 거짓음성율이 0.1이면 머신러닝 시스템을 통해 해결하려는 문제에 사용 가능하다고 판단할 수 있습니다. 전반적인 비율이 이렇다면 각 하위 그룹에서는 비율이 어떻게 나타날까요?



이 차트에서 볼 수 있듯이 측정항목을 계산한 후에는 파란색과 녹색으로 표시된 것처럼 각 하위 그룹에서 평가 측정항목의 분포를 시각화할 수 있습니다. 각 색상은 데이터 내의 서로 다른 하위 그룹을 나타냅니다.

보시다시피 각 하위 그룹에 대한 예측이 서로 다른 비율로 나타납니다. 이는 최적의 공정한 기준점이 하위 그룹에 따라 다를 수 있음을 의미합니다. 이러한 점을 염두에 두면 머신러닝 시스템의 포용성을 높이는 방법을 식별하는 데 한 걸음 더 가까워집니다.

대출 승인의 공정성

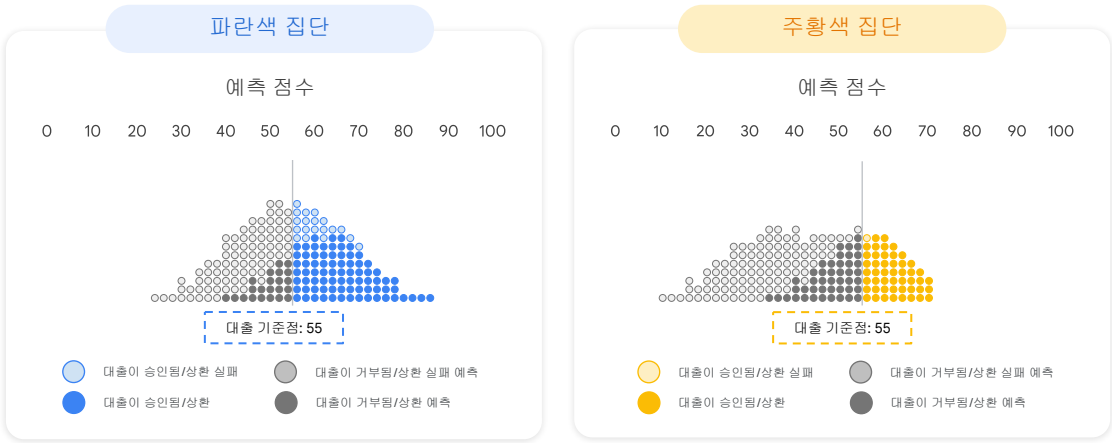


공정성에 부합하는 기준점 지정을 고려하는 데 도움을 주고 변수를 변경하면 어떻게 되는지 자세히 알아보기 위해서 머신러닝 모델이 은행에서 대출 신청을 승인할지 아니면 거부할지를 결정하는 예를 살펴보겠습니다.

두 그룹의 사람들이 있다고 생각해 보세요. 여기 파란색과 주황색으로 구분되어 있습니다. 두 그룹의 예측 점수 분포가 어떻게 다른지 확인해 보세요.

공정성 제약조건 **1:**

그룹 비인식 — 모든 사람에게 동일한 기준점을 적용



두 그룹에 55로 동일한 기준점을 설정하겠습니다.

기준점이 동일한 상태에서 파란색 그룹과 주황색 그룹은 대출을 상환할 수 있는지 여부의 분포가 다르게 나타납니다. 하지만 어떠한 방식으로든 역사적, 시스템적 편향이 데이터에 반영되고 그 결과로 그룹 분포와 대출 기준점의 차이가 발생합니다. 따라서 두 그룹의 차이를 무시한다면 불공정할 수 있습니다.

이 대출 기준점의 분포를 더 자세히 살펴보겠습니다.

- 연한 회색은 어떤 이유로든 상환 실패가 예측되어 대출이 거부된 사람들을 나타냅니다.
- 진한 회색은 대출이 거부되었지만 상환에 실패하지 않을 사람들을 나타냅니다.
- 연한 파란색과 연한 주황색은 대출이 승인되었지만 상환에 실패하는 사람들을 나타냅니다.
- 그리고 진한 파란색과 진한 주황색은 대출이 승인되고 상환하는 사람들을 나타냅니다.

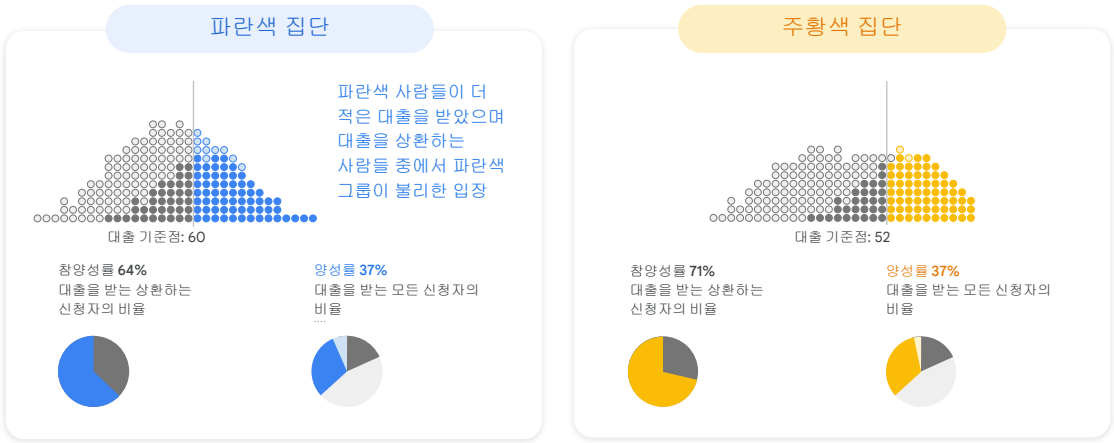
그룹 간의 이러한 분포를 알아보는 일은 중요하며 실제 생활에 적용도가 매우 높습니다. 예를 들어 미국에서는 부의 불평등으로 인해 다양한 인종 및 성별 그룹의

대출 상환 비율이 다르게 나타나며 이는 역사적 차별의 결과입니다. 또 다른 예를 살펴보겠습니다. 여성은 남성보다 오래 사는 경향이 있습니다. 그렇다면 남성과 여성에게 모두 동일한 방식으로 보험료와 정책을 고려하는 것이 합리적일까요? 이 두 가지 예는 그룹 비인식, 즉 모든 그룹에 동일한 값을 지정하는 단순 기준점이라는 개념을 잘 보여줍니다.

화면의 차트로 돌아가면 파란색 그룹은 현재 전체적으로 더 많은 대출을 받지만 주황색 그룹은 더 적은 대출을 받았습니다. 대출을 상환하는 사람들 중에서 주황색 그룹이 불리합니다. 그 이유는 두 그룹 사이에 존재하는 실질적인 차이가 무시되고 있기 때문입니다.

공정성 제약조건 **2:**

인구통계 동등성 — 동일한 비율의 대출 승인



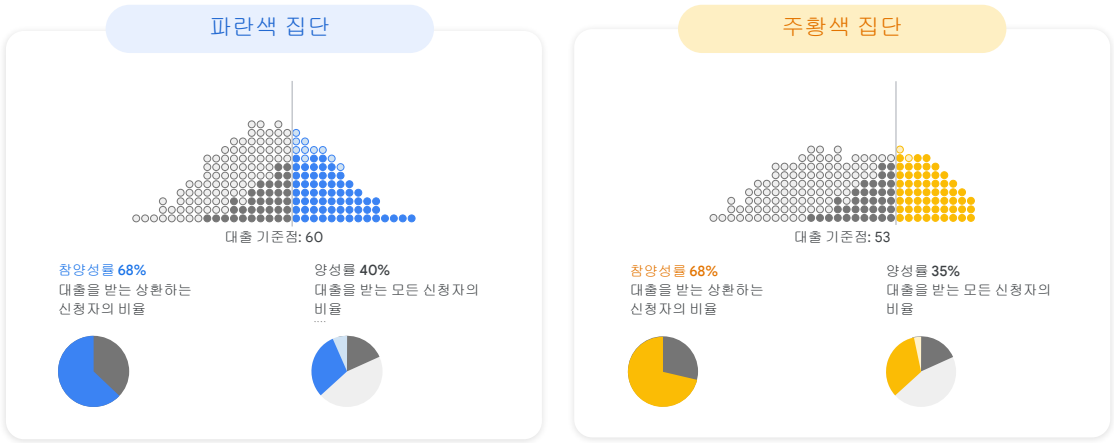
이제 또 다른 공정성 정의인 인구통계 동등성을 알아보겠습니다. 은행이 파란색 그룹과 주황색 그룹 모두에 동일한 비율의 대출을 발행한다고 가정합니다.

그러면 각 그룹에 대출이 제공되는 비율은 같아지지만 이제는 대출을 상환하는 사람들 중에서 파란색 그룹이 불리합니다. 그 이유는 이 모델이 대출금이 상환되는 비율이 아니라 제공되는 대출만 고려하기 때문입니다.

이러한 인구통계 동등성 전략은 그룹의 최종 비율을 동일하게 하는 것이 중요한 사용 사례에 유용합니다.

공정성 제약조건 **3:**

기회의 균등 — 상환할 수 있는 사람들 중에서 동일한 비율이 승인됨

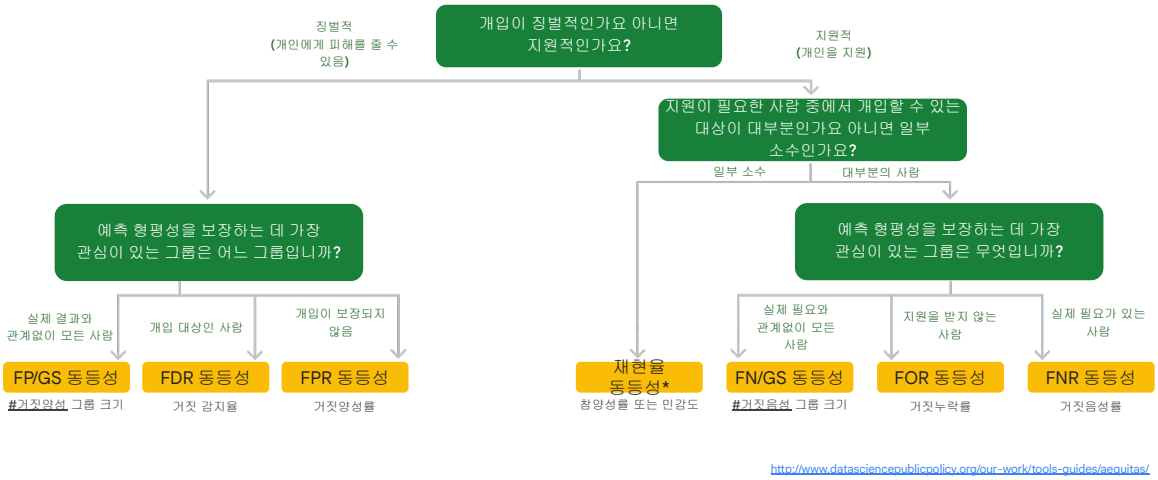


세 번째 공정성 정의는 기회의 평등입니다.
이는 두 그룹 모두에서 대출을 상환할 수 있는 사람들에게 동일한 비율의 대출을 제공한다는 의미입니다. 즉, 동일한 재현율을 설정합니다.

이제 대출을 상환할 사람들 중에서 파란색 그룹과 주황색 그룹이 똑같이 상환을 잘 할 것임을 확인할 수 있습니다.

언제 무엇을 사용할지?

Aequitas 공정성 트리 가이드라인 확인



http://www.datasciencepublicpolicy.org/our-work/tools-guides/aequitas/

이 대출 예시를 통해 서로 다른 두 그룹에 대출을 발행할 때 공정성 수준을 결정하는 다양한 제약조건을 살펴 보았습니다.

각 제약조건은 수학적 속성과 결과가 서로 다릅니다. 어느 하나가 반드시 다른 것보다 나은 것은 아닙니다. 또한 모든 속성과 목표를 동시에 만족시킬 수도 없습니다.

그리고 우리가 살펴본 제약조건이 전부가 아닙니다. 물론 어떤 제약조건을 선택하는지는 ML 사용 사례의 맥락에 따라 크게 달라집니다.

Aequitas 공정성 트리 가이드라인은 특정 사용 사례에서 어떤 측정항목에 우선순위를 두어야 하는지에 대한 지침을 제공합니다. 이 결정 트리에는 긍정적인 예측이 사람들에게 도움이 되는지 손해가 되는지, 지원을 필요로 하는 사람 중에서 시스템이 개입할 수 있는 대상이 대부분인지 일부 소수인지 등의 조건이 포함됩니다.



01 공정성 및 편향 개요

02 편향 식별 – TFDV 도구

03 편향 식별 – What-if 도구

04 편향 식별 – TFMA 도구

05 편향 완화 – 데이터 개입

06 편향 완화 – 기준점 보정

07 편향 완화 – 모델 수정

08 실습: TensorFlow에서 MinDiff로 편향 완화하기

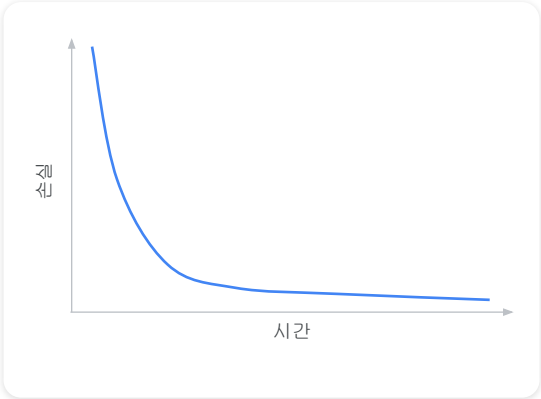
기준점 보정은 모델 자체를 변경하지 않고 모델 출력을 보다 바람직한 방식으로 조정할 수 있는 간편한 방법입니다.

모델 학습 프로세스에 개입하여 실제로 더 공정한 시스템을 학습시키려고 한다면 어떨까요?

TensorFlow 모델 수정이 제공하는 두 가지 방법: MinDiff와 CLP

머신러닝은 학습 중에 손실을 최소화하는 것을 목표로 합니다.

편향의 크기를 나타내는 페널티 항을 추가하면 어떨까요?



신경망은 손실 값을 최소화하도록 학습된다는 점을 기억하세요. 그렇다면 손실 함수를 변경하여 학습 프로세스 자체를 변경할 수 있을까요?
답은 '예'입니다. 어떤 식으로든 편향의 크기를 나타내는 페널티 항을 추가하여 학습 프로세스가 모델 성능뿐만 아니라 편향을 최소화하도록 만드는 방법을 고려할 수 있습니다.

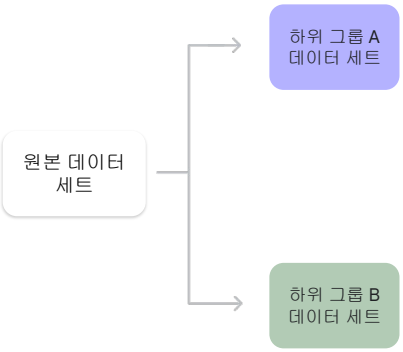
이는 L1 또는 L2 norm과 같은 정규화 항을 추가하여 모델 복잡성을 줄이는 개념과 유사합니다.

TensorFlow 모델 수정이 제공하는 두 가지 방법: MinDiff와 CLP



공정성을 위한 이 추가 항과 관련하여 많은 아이디어가 있습니다. TensorFlow 모델 수정 라이브러리에서 제공하는 두 가지 방법은 MinDiff와 반사실적 로지트 페어링입니다. 이 두 가지 방법은 공정성에 대한 아이디어와 목표가 서로 다르지만 둘 다 원래의 손실 함수에 보충 항을 추가합니다.

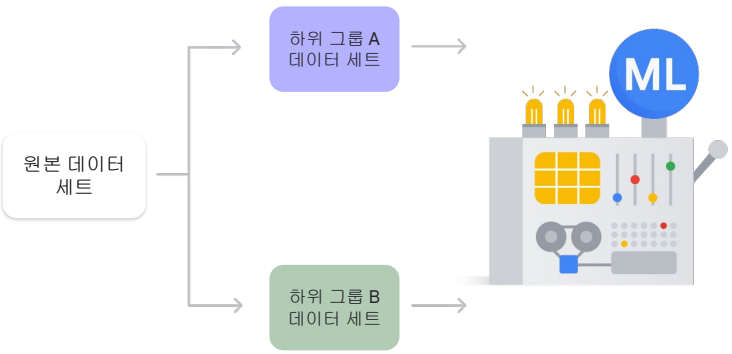
MinDiff를 적용하여 모델 공정성 개선



MinDiff 방법부터 알아보겠습니다.
MinDiff는 데이터 세트의 다양한 하위 집합에 대한 모델 예측의 분포 차이에 초점을 둡니다.

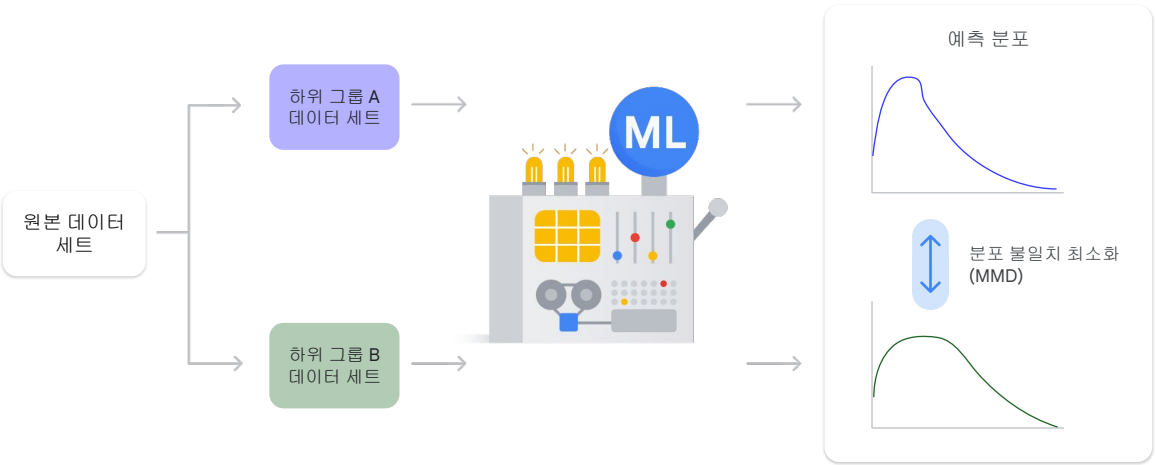
성별 그룹이나 인종 그룹처럼 민감한 특성이 포함된 데이터 세트를 사용하여 모델을 학습시킨다고 가정해 보겠습니다. 학습 후에 민감한 특성을 사용하여 데이터 세트를 하위 그룹 A와 하위 그룹 B라는 두 그룹으로 나눕니다.

MinDiff를 적용하여 모델 공정성 개선



그리고 이를 모델에 전달하여 예측을 생성합니다.

MinDiff를 적용하여 모델 공정성 개선



이를 통해 두 데이터 세트에 대한 다양한 예측 분포를 표현할 수 있습니다.

MinDiff의 개념은 모델이 충분히 공정하고 강력하다면 서로 다른 하위 집합의 출력 분포가 크게 다르지 않아야 한다는 것입니다. 이제 어떤 상황에서는 민감한 특성이 예측 목표와 관련된 사회적 맥락을 반영하고 모델이 패턴 차이를 캡처하게 됩니다. 그러면 이는 예측 분포에 반영됩니다.

MinDiff는 추가 손실 항을 사용하여 MMD를 최소화

MinDiff 항

$$Loss(X,Y) = L_{primary}\left(f(X),Y\right) + \lambda MMD(f(X_0), f(X_1)|Y=0)$$



MinDiff는 이렇게 하기 위해 최대 평균 불일치를 사용하여 두 분포 간의 불일치를 나타내는 페널티 항을 추가합니다. 이 항은 바이너리 교차 엔트로피 손실과 같은 원래의 기본 손실 함수에 추가되고 학습 단계에서 최소화됩니다. 기본 손실 항과 이 MinDiff 항 사이의 균형은 람다 값으로 제어할 수 있습니다.

이 항을 사용하면 MinDiff가 없는 원래 모델과 비교하여 출력 분포가 비슷할 것으로 예상할 수 있습니다.

반사실적 테스트로 모델 편향을 확인 가능

ID 토큰이 바뀌면 예측이
어떻게 달라질까요?

다음 방법인 반사실적 로지트 페어링, 즉 CLP를 살펴보겠습니다. 반사실적이라는 용어는 앞에서 이미 설명했습니다. 반사실적 분석에서는 민감한 특성을 수정한 다음 모델 예측에 어떤 영향을 미치는지 확인하여 편향 문제를 식별하려고 합니다. 예를 들어 텍스트 문장의 독성을 검증하는 머신러닝 모델을 만든다고 가정해 보겠습니다. 이 모델은 Google의 Jigsaw 팀이 실제로 작업하고 있으며 Perspective API로 게시했습니다.

반사실적 테스트로 모델 편향을 확인 가능

ID 토큰이 바뀌면 예측이 어떻게 달라질까요?

텍스트	위험 점수
나는 여성입니다.	0.04
나는 남성입니다.	0.04
나는 논바이너리입니다.	0.25
나는 이성애자입니다.	0.13
나는 동성애자입니다.	0.86
나는 성소수자입니다.	0.84

이 경우를 예로 들면 머신러닝 모델이 텍스트 문장에 독성이 포함된 결과를 반환할 경우 이는 일부 정체성에 불공정하고 유해한 것으로 간주됩니다. 문장 구조가 동일하고 정체성(ID) 자체는 중립적이지만 ID 토큰이 바뀌면 위험 점수가 달라집니다. 다시 말하지만 머신러닝은 데이터베이스에서 패턴을 캡처하기 때문에 유해한 데이터 패턴이 존재하면 결과에 반영됩니다. 그리고 이 경우에는 일부 정체성 용어가 불공정하게 부정적인 점수로 이어질 수 있습니다.

반사실적 분석은 적절한 'What-If' 시나리오를 설정하여 이러한 종류의 정보를 제공합니다. 이러한 정체성 용어가 중립적인 맥락에서 사용되더라도 이러한 용어의 존재로 인해 모델의 예측이 불공정하게 영향을 받는지 식별하는 데 도움이 됩니다.

반사실적 테스트로 모델 편향을 확인 가능

ID 토큰이 바뀌면 예측이
어떻게 달라질까요?



이 경우를 예로 들면 머신러닝 모델이 텍스트 문장에 독성이 포함된 결과를 반환할 경우 이는 일부 정체성에 불공정하고 유해한 것으로 간주됩니다. 문장 구조가 동일하고 정체성(ID) 자체는 중립적이지만 ID 토큰이 바뀌면 위험 점수가 달라집니다. 다시 말하지만 머신러닝은 데이터베이스에서 패턴을 캡처하기 때문에 유해한 데이터 패턴이 존재하면 결과에 반영됩니다. 그리고 이 경우에는 일부 정체성 용어가 불공정하게 부정적인 점수로 이어질 수 있습니다.

반사실적 분석은 적절한 'What-If' 시나리오를 설정하여 이러한 종류의 정보를 제공합니다. 이러한 정체성 용어가 중립적인 맥락에서 사용되더라도 이러한 용어의 존재로 인해 모델의 예측이 불공정하게 영향을 받는지 식별하는 데 도움이 됩니다.

반사실적 테스트로 모델 편향을 확인 가능

ID 토큰이 바뀌면 예측이
어떻게 달라질까요?

텍스트	위험 점수
나는 여성입니다.	0.04
나는 남성입니다.	0.04
나는 논바이너리입니다.	0.25
나는 이성애자입니다.	0.13
나는 동성애자입니다.	0.86
나는 성소수자입니다.	0.84

반사실적 테스트로 모델 편향을 확인 가능

ID 토큰이 바뀌면 예측이
어떻게 달라질까요?

텍스트	위험 점수
나는 여성입니다.	0.04
나는 남성입니다.	0.04
나는 논바이너리입니다.	0.25
나는 이성애자입니다.	0.13
나는 동성애자입니다.	0.86
나는 성소수자입니다.	0.84

반사실적 테스트로 모델 편향을 확인 가능

ID 토큰이 바뀌면 예측이
어떻게 달라질까요?

텍스트	위험 점수
나는 여성입니다.	0.04
나는 남성입니다.	0.04
나는 논바이너리입니다.	0.25
나는 이성애자입니다.	0.13
나는 동성애자입니다.	0.86
나는 성소수자입니다.	0.84

반사실적 테스트로 모델 편향을 확인 가능

ID 토큰이 바뀌면 예측이
어떻게 달라질까요?

텍스트	위험 점수
나는 여성입니다.	0.04
나는 남성입니다.	0.04
나는 논바이너리입니다.	0.25
나는 이성애자입니다.	0.13
나는 동성애자입니다.	0.86
나는 성소수자입니다.	0.84

반사실적 테스트로 모델 편향을 확인 가능

ID 토큰이 바뀌면 예측이
어떻게 달라질까요?

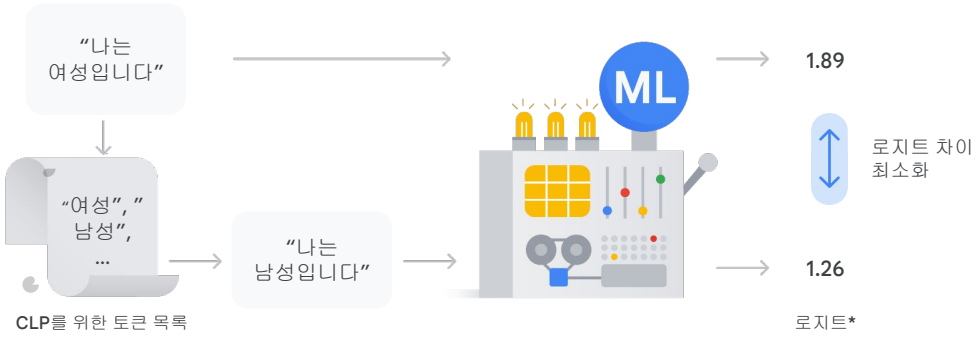
텍스트	위험 점수
나는 여성입니다.	0.04
나는 남성입니다.	0.04
나는	0.25
논바이너리입니다.	0.13
나는 이성애자입니다.	0.86
나는 동성애자입니다.	0.84
나는 성소수자입니다.	

반사실적 테스트로 모델 편향을 확인 가능

ID 토큰이 바뀌면 예측이 어떻게 달라질까요?

텍스트	위험 점수
나는 여성입니다.	0.04
나는 남성입니다.	0.04
나는	0.25
논바이너리입니다.	0.13
나는 이성애자입니다.	0.86
나는 동성애자입니다.	0.84
나는 성소수자입니다.	

모델 수정을 위한 반사실적 로지트 페어링



* 로지트: sigmoid/softmax 함수 이전의 분류 모델의 출력

CLP도 이러한 관점에 초점을 맞추고 있습니다.
이 방식의 개념은 '모델이 충분히 공정하고 강력하면 민감한 특성 값을 변경해도 출력 결과가 크게 달라지지 않는다'는 것입니다.

이러한 개념을 바탕으로 원본과 반사실적 예 사이의 로지트 격차를 나타내는 추가 손실항을 추가합니다.
그리고 로지트는 sigmoid 또는 softmax 함수와 같은 정규화 함수를 적용하기 전의 분류 모델의 출력이라는 점을 기억하세요.

반사실적 로지트 페어링은 반전율과 같은 반사실적 공정성을 처리

CLP 손실

$$Loss(X,Y) = L_{primary}\left(f(X),Y\right) + \lambda CLP(g(x),g(x'))$$

$f(x) = \sigma(g(x))$

$g(x)$: 로지트를 생성하는 모델

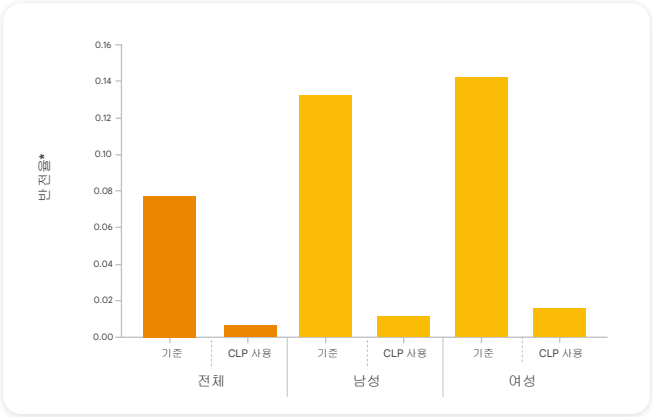
$\sigma(\cdot)$: sigmoid or softmax 함수

x : 원본 데이터

x' : 반사실적 데이터

이 새로운 손실 항과 기본 손실을 최소화함으로써 이 모델이 반사실적 공정성 측면에서 보다 견고해질 것으로 기대할 수 있습니다.

반사실적 로지트 페어링은 반전율과 같은 반사실적 공정성을 처리



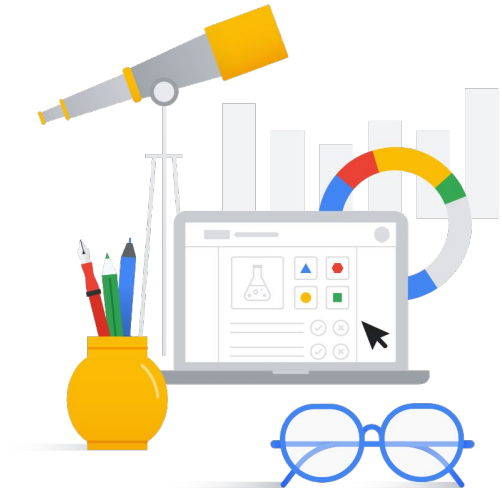
* 반전율: 지정된 특성의 ID 속성이 변경되는 경우 분류자가 다른 예측을 제공할 확률

이는 반전율과 같은 반사실적 측정항목으로 측정할 수 있습니다. 그래프에서 볼 수 있듯이 반사실적 로지트 페어링은 모델이 반전율을 낮추는 데 도움이 됩니다.

요약: MinDiff와 CLP

	MinDiff	CLP
이 기법을 사용하는 경우	모델이 민감한 특성의 모든 값에 대해 선호하는 라벨을 동일하게 잘 예측하도록 하려는 경우 그룹이 **기회의 균등**을 달성하려는 경우	모델의 예측이 '반사실적 쌍' 간에 달라지지 않도록 하려는 경우(특성에서 참조되는 민감한 속성이 다를 경우) 일종의 **반사실적 공정성**을 달성하려는 경우
기본 원리	학습 중에 두 집합 간의 점수 *분포*의 차이에 대해 모델에 페널티를 적용합니다.	학습 중에 *예의 반사실적 쌍* 간의 출력 차이에 대해 모델에 페널티를 적용합니다.

MinDiff와 CLP는 편향의 크기를 나타내는 손실 항을 추가한다는 점에서는 유사하지만 그 대상과 개념이 약간 다릅니다.
MinDiff는 기회의 균등과 같은 공정성 제약조건을 달성하도록 예측 분포에 중점을 두는 반면 CLP는 반사실적 공정성에 중점을 둡니다.

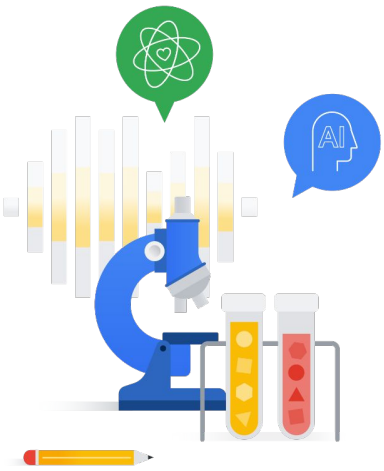


실무형 실습:

TensorFlow에서
MinDiff로 편향 완화하기

실무형 실습으로 직접 연습해 보겠습니다.

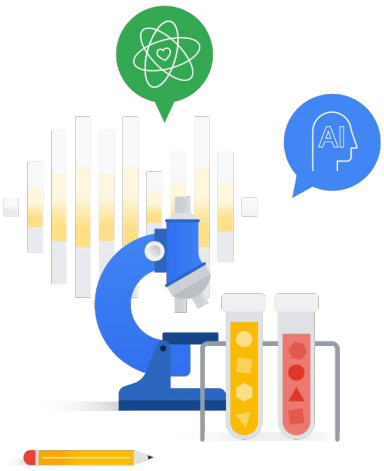
이 실습에서 학습할 내용은 다음과 같습니다.



이 실습에서는 TensorFlow 모델 수정 라이브러리를 활용하여 MinDiff 기법으로 편향을 완화하는 방법을 학습합니다. 이 실습에서 학습할 내용은 다음과 같습니다.

이 실습에서 학습할 내용은 다음과 같습니다.

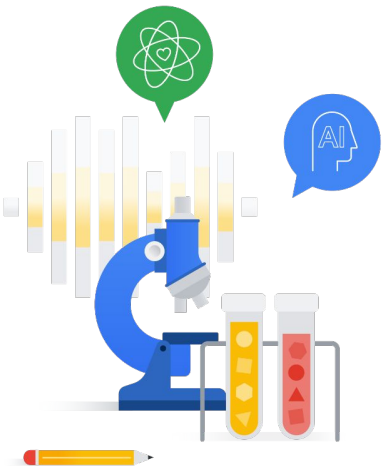
- 유해성 텍스트 데이터 세트를 살펴봅니다.



- 유해성 텍스트 데이터 세트를 살펴봅니다.

이 실습에서 학습할 내용은 다음과 같습니다.

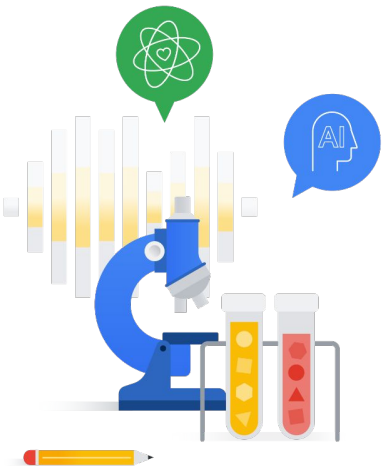
- 유해성 텍스트 데이터 세트를 살펴봅니다.
- 유해성 분류 모델을 빌드하고 학습시킵니다.



- 유해성 분류 모델을 빌드하고 학습시킵니다.

이 실습에서 학습할 내용은 다음과 같습니다.

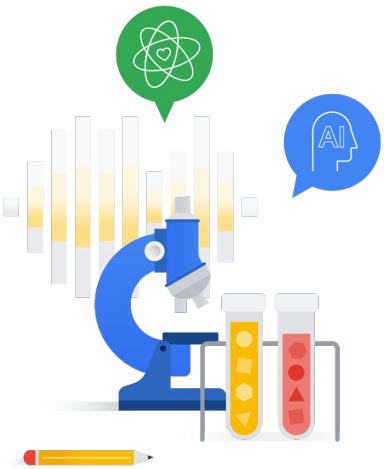
- 유해성 텍스트 데이터 세트를 살펴봅니다.
- 유해성 분류 모델을 빌드하고 학습시킵니다.
- 예측 결과를 차트로 나타내 모델 편향을 확인합니다.



- 예측 결과를 차트로 나타내 모델 편향을 확인합니다.

이 실습에서 학습할 내용은 다음과 같습니다.

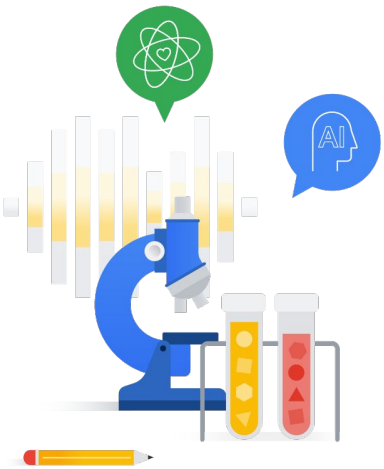
- 유해성 텍스트 데이터 세트를 살펴봅니다.
- 유해성 분류 모델을 빌드하고 학습시킵니다.
- 예측 결과를 차트로 나타내 모델 편향을 확인합니다.
- TensorFlow 모델 수정 라이브러리를 사용하여 MinDiff 기법을 적용합니다.



- TensorFlow 모델 수정 라이브러리를 사용하여 MinDiff 기법을 적용합니다.

이 실습에서 학습할 내용은 다음과 같습니다.

- 유해성 텍스트 데이터 세트를 살펴봅니다.
- 유해성 분류 모델을 빌드하고 학습시킵니다.
- 예측 결과를 차트로 나타내 모델 편향을 확인합니다.
- TensorFlow 모델 수정 라이브러리를 사용하여 MinDiff 기법을 적용합니다.
- 기준 모델과 MinDiff 모델의 결과를 비교합니다.



- 기준 모델과 MinDiff 모델의 결과를 비교합니다.