

AI 개인 정보 보호

AI 개인 정보 보호에 오신 것을 환영합니다.



01 AI 개인 정보 보호 개요

02 학습 데이터의 개인 정보 보호: 익명화 기법

03 학습 데이터의 개인 정보 보호: 무작위 순서 지정 기법

04 머신러닝 학습의 개인 정보 보호: DP-SGD

05 머신러닝 학습의 개인 정보 보호: 제휴 학습

06 Google Cloud의 시스템 보호

07 시스템 보안 및 생성형 AI

08 실습: TensorFlow Privacy를 사용한 머신러닝의 개인 정보 차등 보호

이 모듈은 8개의 강의로 구성되어 있습니다.

이 과정에서 배우는 내용



01	AI에서의 개인 정보 보호를 정의합니다.
02	개인 정보 보호에 대한 권장사항을 알아봅니다.
03	개인 정보 보호 관련 보안 유형을 설명합니다.
04	데이터 및 모델 보안을 위한 개인 정보 보호 기법과 도구를 살펴봅니다.
05	Google Cloud의 생성형 AI 보안 문제를 해결합니다.

학습할 내용

- AI에서의 개인 정보 보호를 정의합니다.
- 개인 정보 보호에 대한 권장사항을 알아봅니다.
- 개인 정보 보호 관련 보안 유형을 설명합니다.
- 데이터 및 모델 보안을 위한 개인 정보 보호 기법과 도구를 살펴봅니다.
- Google Cloud의 생성형 AI 모델에 관한 보안 권장사항을 적용하는 법을 설명합니다.



01 AI 개인 정보 보호 개요

02 학습 데이터의 개인 정보 보호: 익명화 기법

03 학습 데이터의 개인 정보 보호: 무작위 순서 지정 기법

04 머신러닝 학습의 개인 정보 보호: DP-SGD

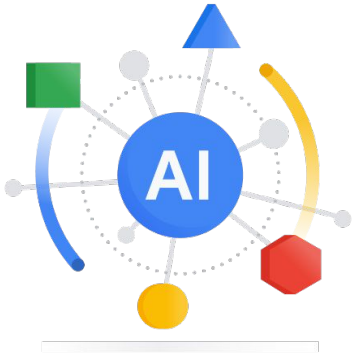
05 머신러닝 학습의 개인 정보 보호: 제휴 학습

06 Google Cloud의 시스템 보호

07 시스템 보안 및 생성형 AI

08 실습: TensorFlow Privacy를 사용한 머신러닝의 개인 정보 차등 보호

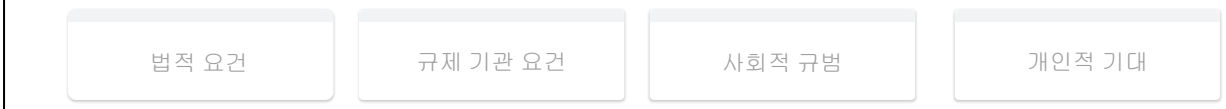
AI 개인 정보 보호에 대한 개요부터 시작해 보겠습니다.



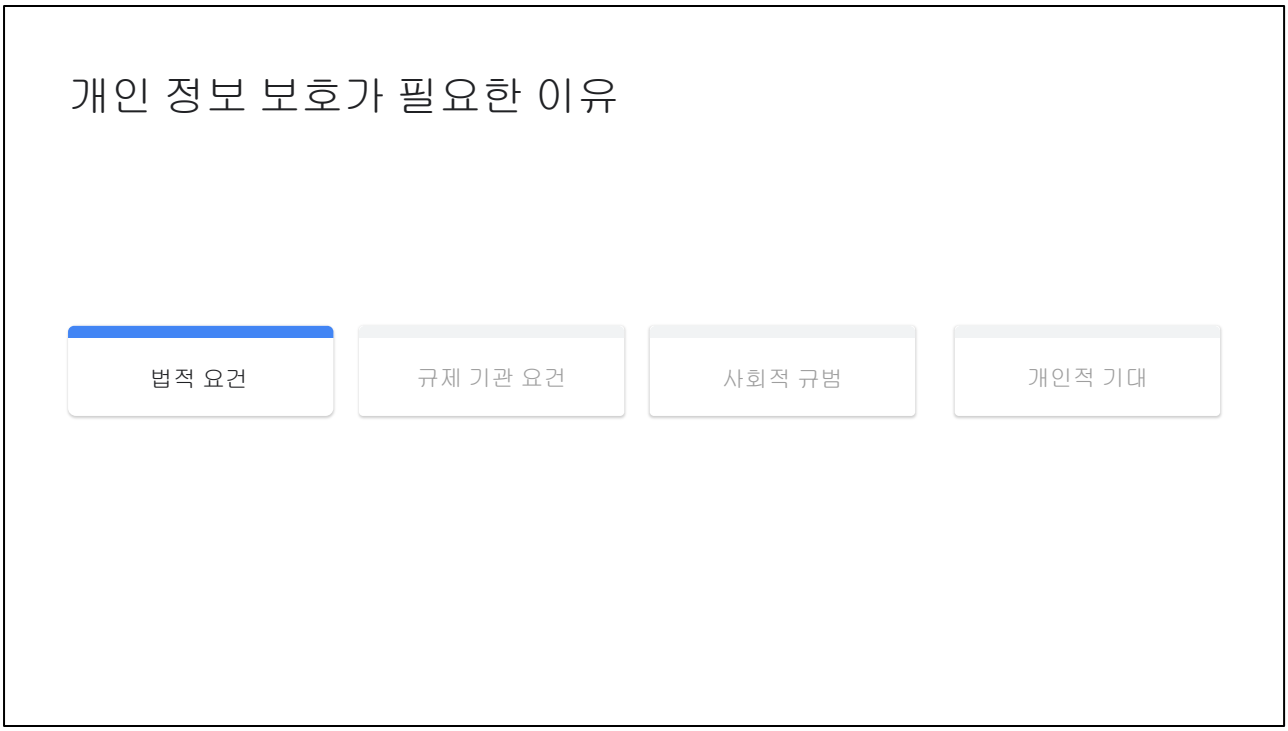
1. 사회에 도움이 되어야 합니다.
2. 불공정한 편향을 만들거나 강화해서는 안 됩니다.
3. 안전을 염두에 두고 개발되고 테스트되어야 합니다.
4. 사람에 대해 책임을 질 수 있어야 합니다.
5. 개인 정보 보호 적용 설계의 원칙이 반영되어야 합니다.
6. 과학적 우수성에 있어 엄격한 기준을 충족해야 합니다.
7. 이러한 원칙을 준수하는 사용자에게 제공되어야 합니다.

개인 정보 보호는 Google AI 5번째 원칙인 '개인 정보 보호 적용 설계의 원칙이 반영되어야 한다'와 관련이 있습니다. 하지만 원칙들은 교차하는 경우가 많습니다.

개인 정보 보호가 필요한 이유

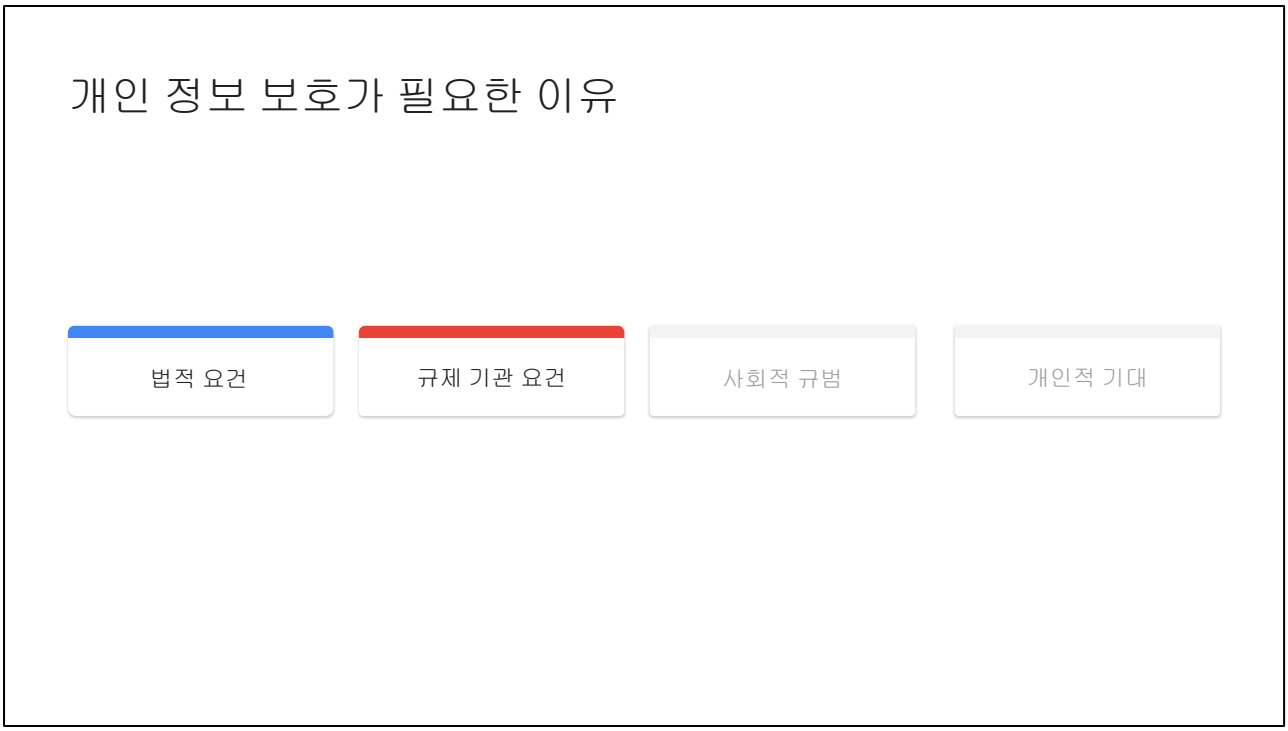


왜 개인 정보 보호를 고려해야 할까요? 몇 가지 이유가 있습니다.

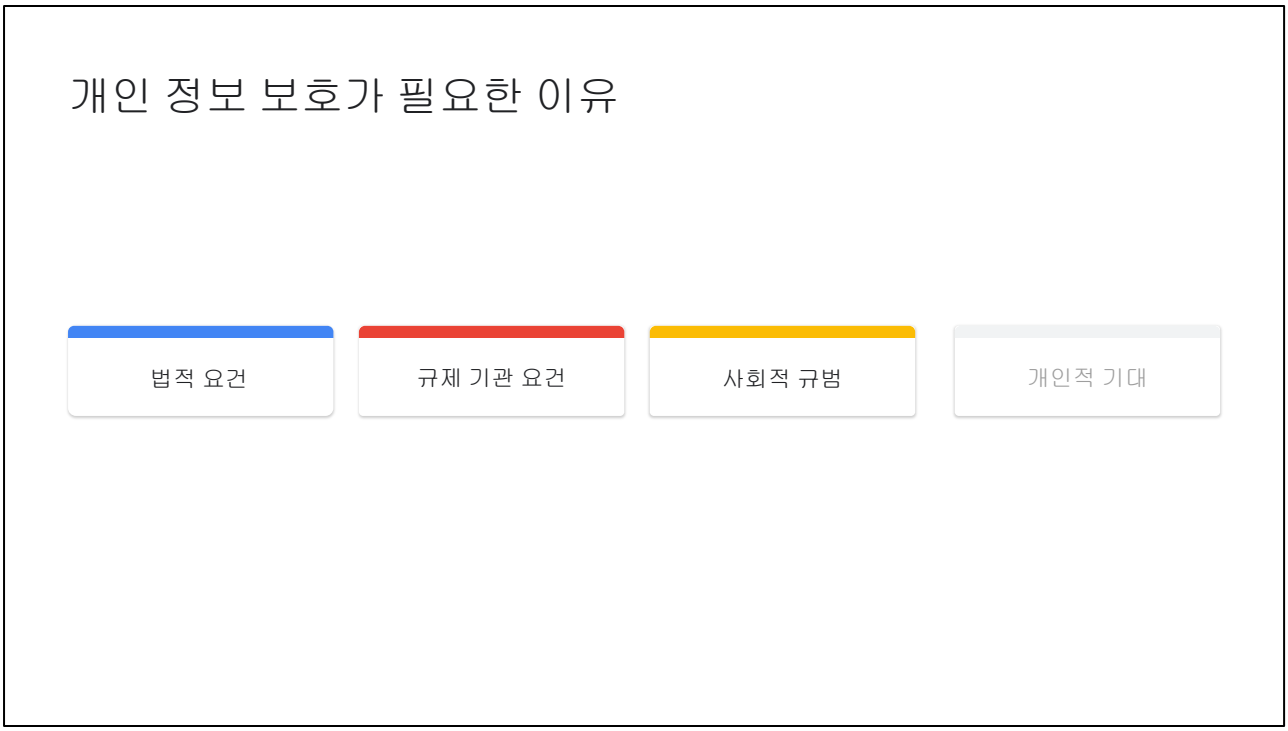


여기에는 법적 요건과

개인 정보 보호가 필요한 이유

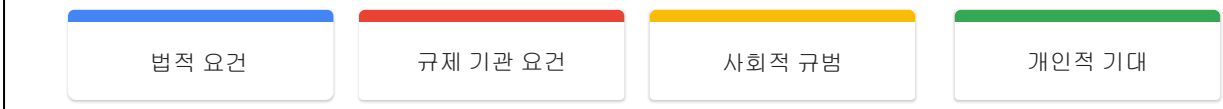


규제 기관 요건을 충족하는 것뿐만 아니라



사회적 규범과

개인 정보 보호가 필요한 이유



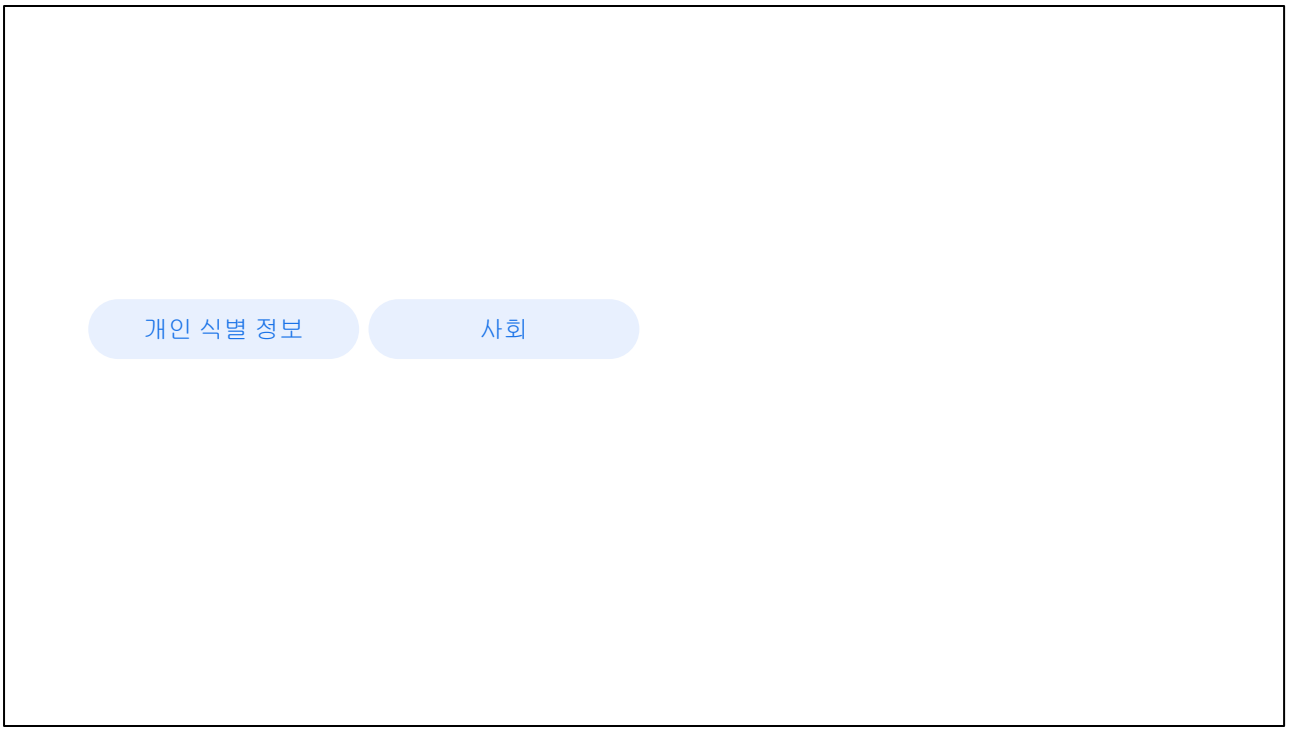
일반적인 개인의 기대를 고려하는 것도 포함됩니다.

민감한 속성은 법적, 윤리적, 사회적 또는 개인적 이유에 따른 특수한 고려사항이 될 수 있는 인간적 속성입니다.

민감한 속성은 법적, 윤리적, 사회적 또는 개인적 이유에 따라 특수한 고려사항이 될 수 있는 모든 인간적 속성입니다. 여기에는 다음과 같은 예가 포함되나 이에 국한되지는 않습니다.

개인 식별 정보

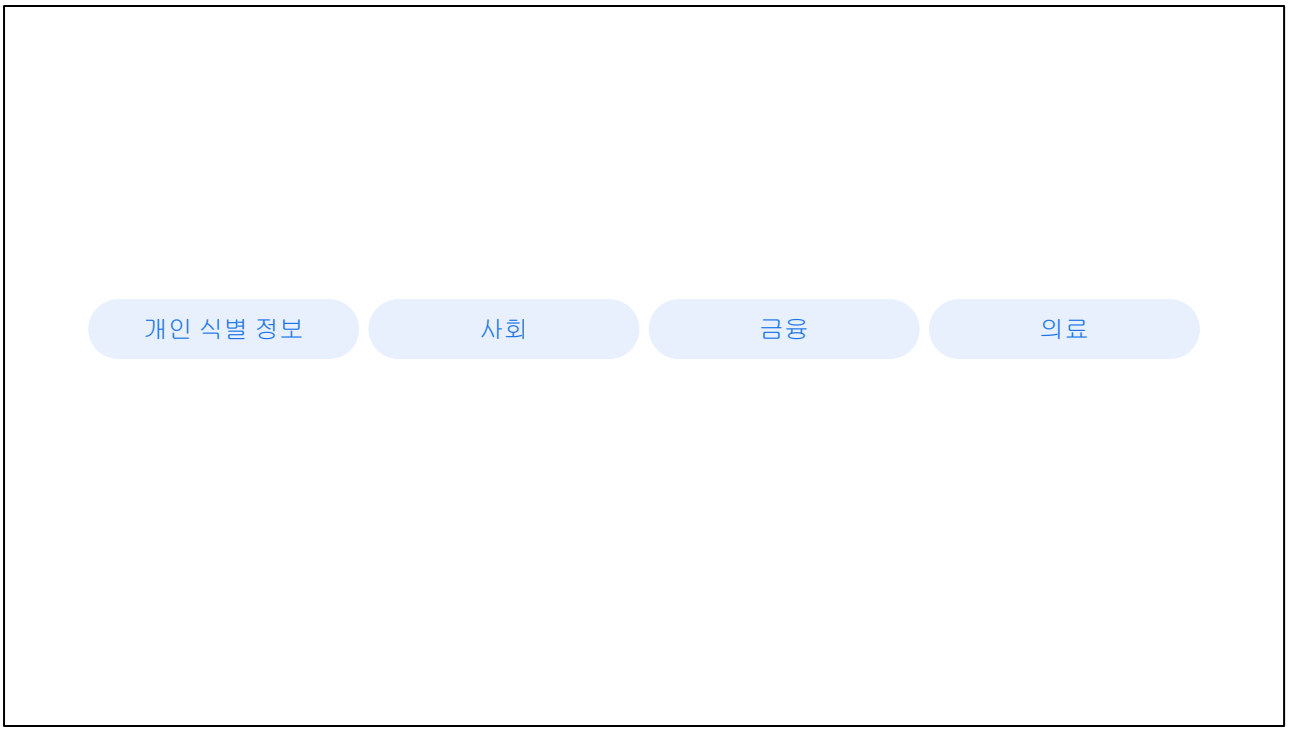
- 성명, 생년월일, 주소, 전화번호 등 개인 식별 정보



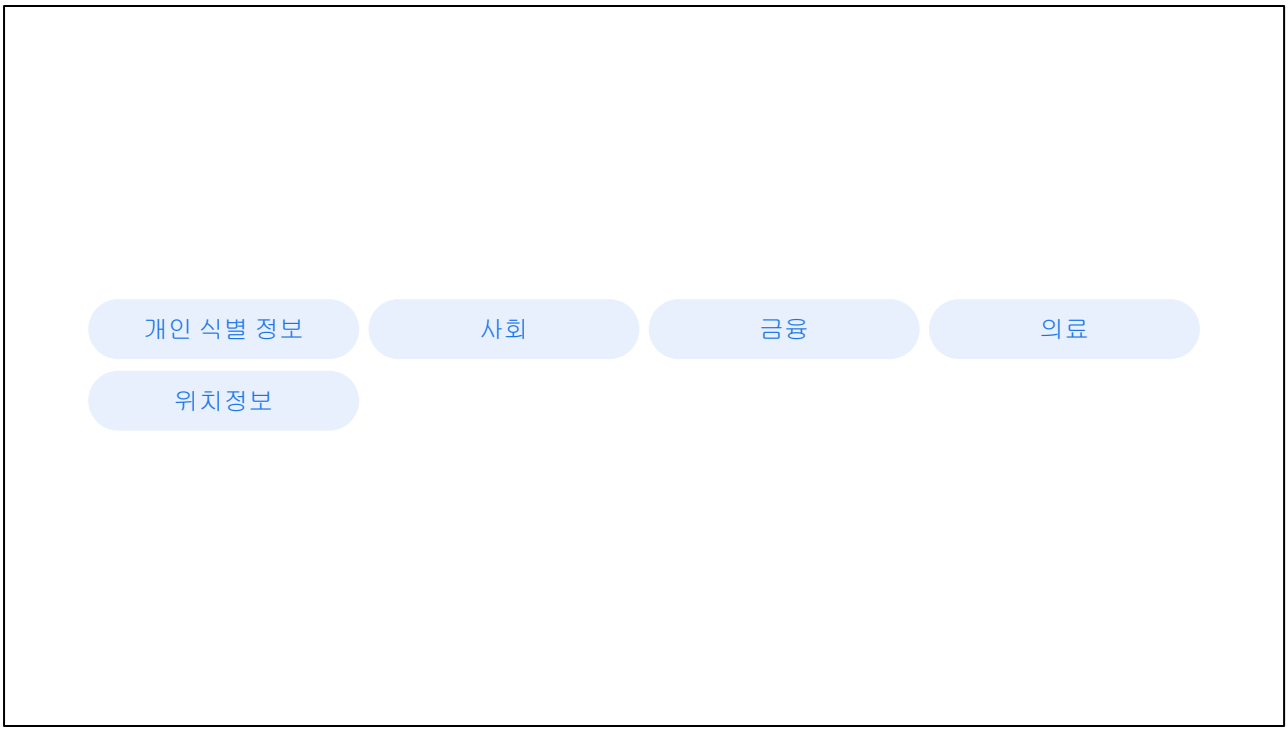
- 인종, 종교, 성적 지향, 정치적 준거 집단 등의 사회적 데이터



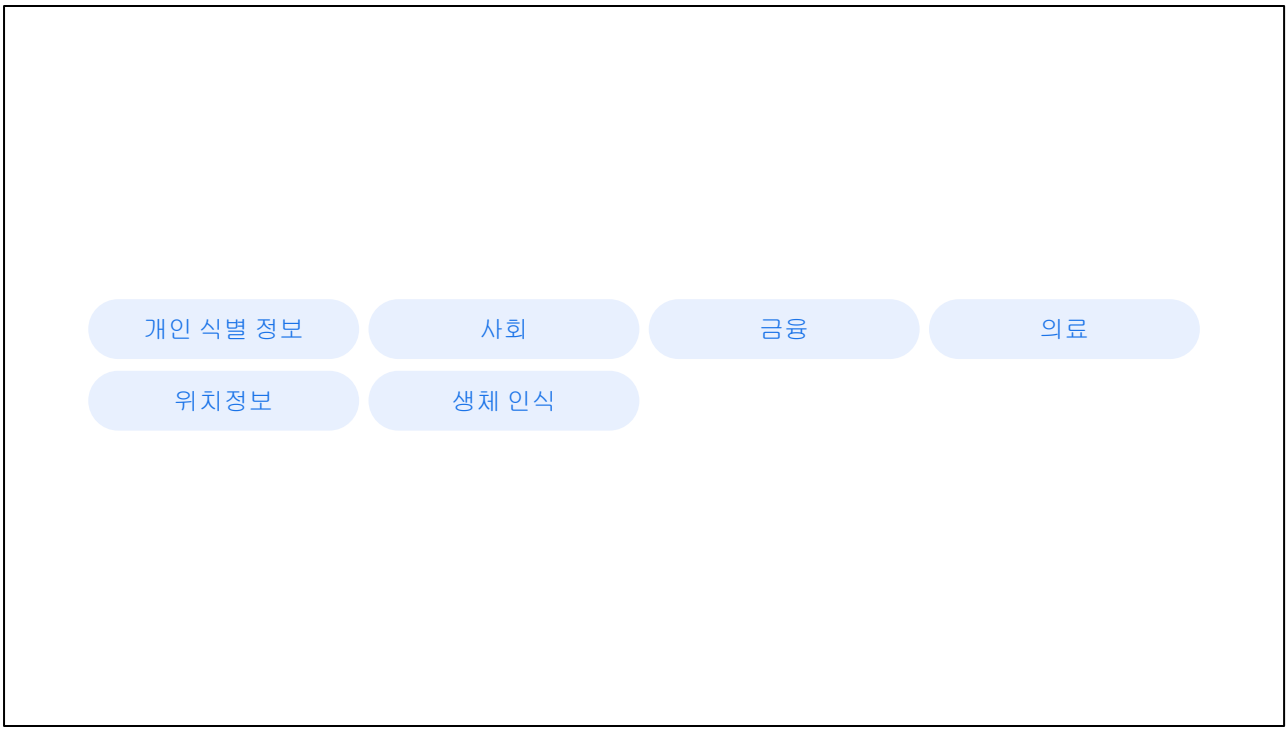
- 신용카드 번호, 소득 및 세금 기록과 같은 금융 데이터



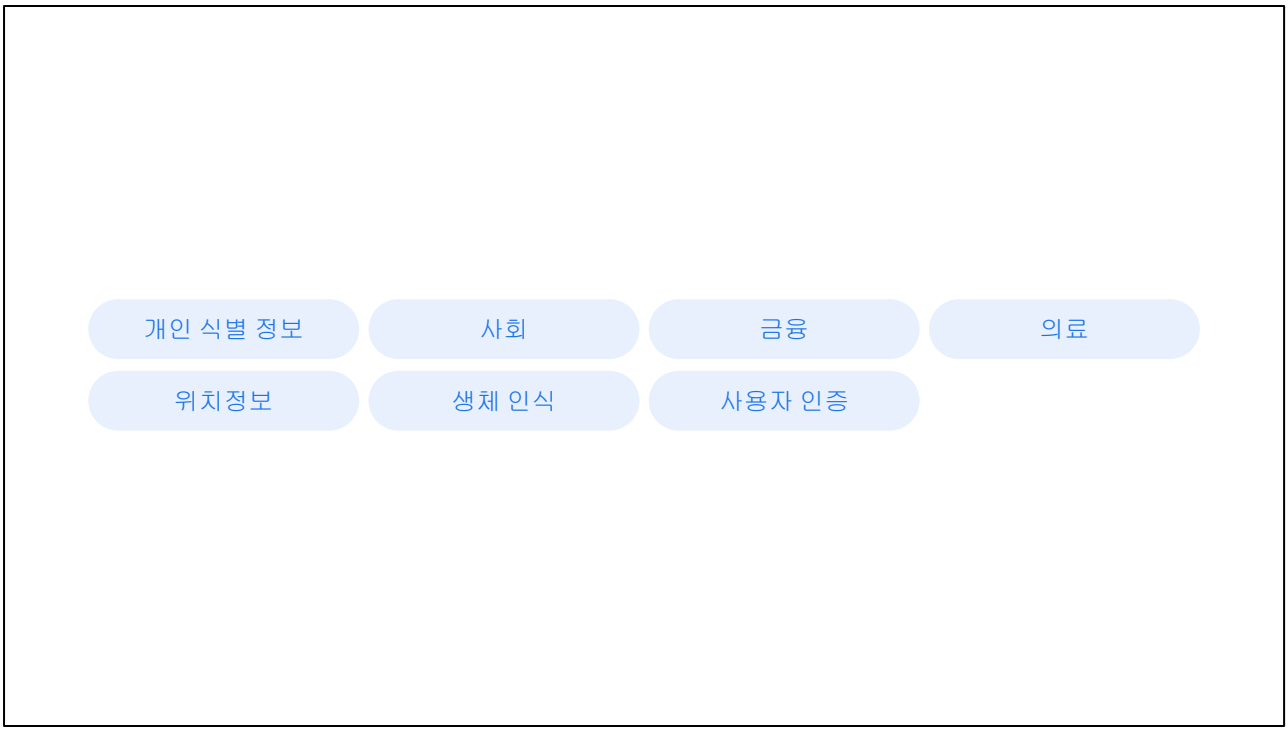
- 진단, 처방, 유전자 데이터와 같은 보건 및 의료 데이터



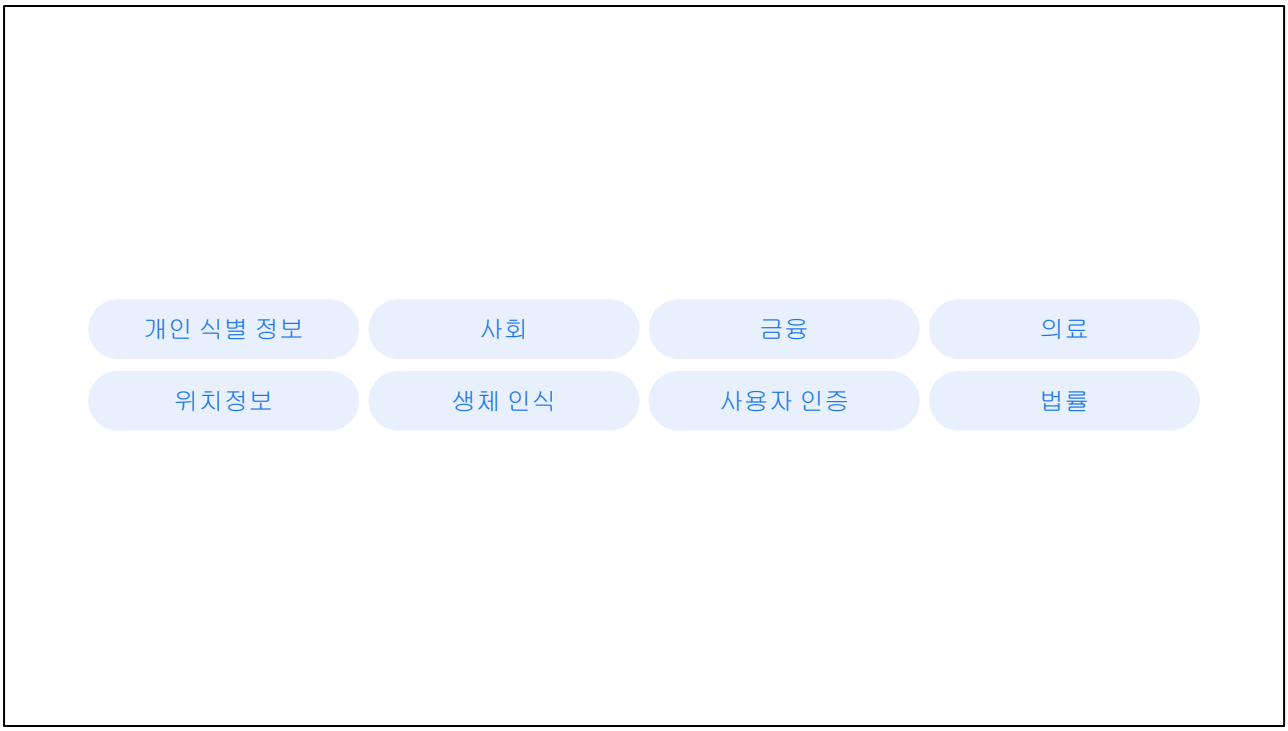
- 휴대기기의 추적 데이터와 같은 위치정보 데이터



- 얼굴 인식, 음성, 지문 등의 생체 인식 데이터



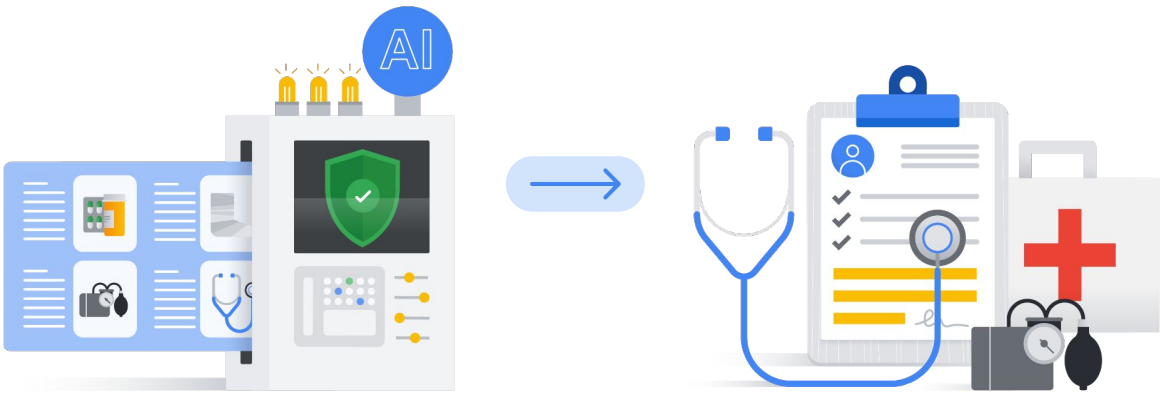
- 사용자 아이디, 비밀번호, 보안 질문 및 답변과 같은 사용자 인증 데이터



- 지식 재산 및 영업 비밀을 포함한 법률 데이터



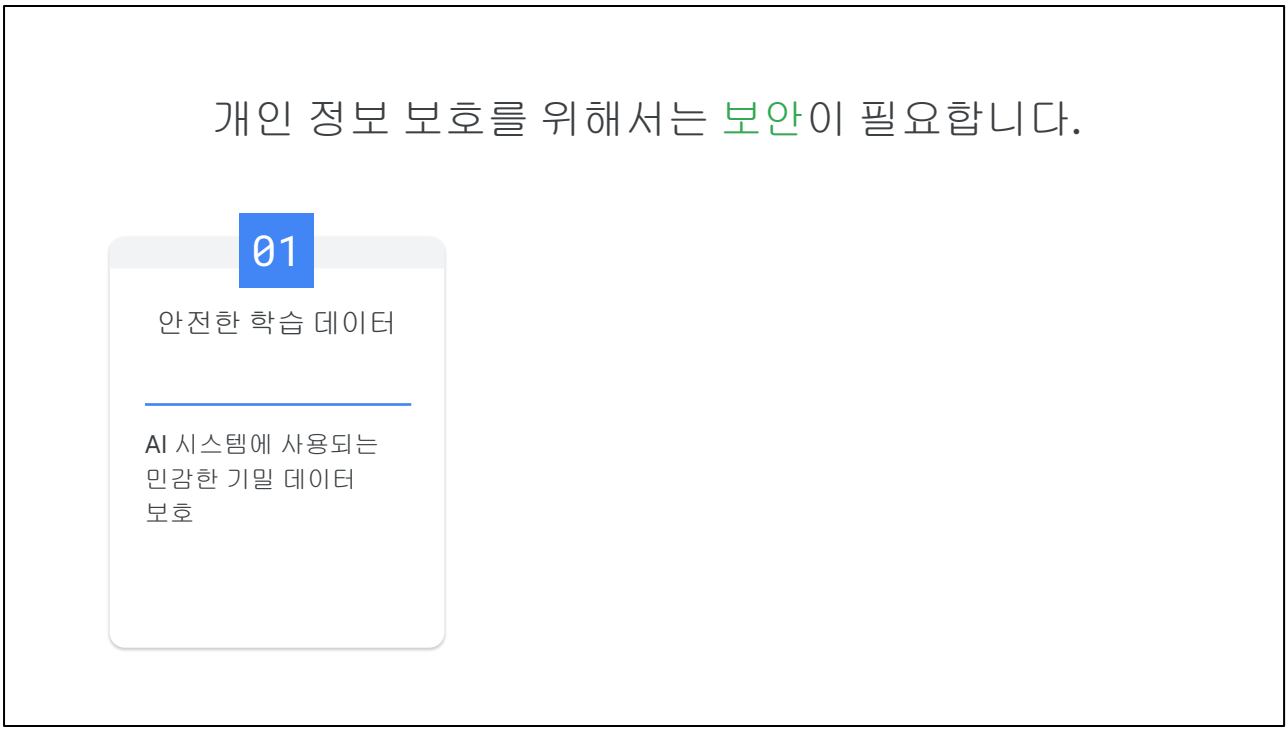
민감한 정보를 처리하는 모델을 빌드할 경우 엄청난 이점이 있을 수 있습니다. 예를 들어 전자 건강 기록을 학습한 AI 시스템은 개인의 만성질환 위험을 예측한 다음



개인화된 의료 권장사항을 제공할 수 있습니다. 하지만 민감한 정보를 사용할 때는 항상 잠재적인 개인 정보 보호 영향을 고려해야 합니다.

개인 정보 보호를 위해서는 보안이 필요합니다.

안전한 머신러닝 기반 시스템을 빌드 중인지 확인하려면 어떻게 해야 할까요? 몇 가지 고려해야 할 측면이 있습니다.



학습 데이터의 보안: 머신러닝은 항상 데이터 세트를 학습하므로 AI 시스템에 사용되는 민감한 기밀 데이터를 보호하는 것이 중요합니다.



학습 프로세스의 보안: 제휴 학습 및 DP-SGD(개인 정보 차등 보호 확률적 경사하강법)처럼 안전한 머신러닝 학습에 관한 권장사항을 채택하여 보안을 해결할 수 있습니다.



포괄적인 AI 시스템 보안을 위해서는 하드웨어, 소프트웨어, 커뮤니케이션 채널과 인프라 전반에 걸쳐 개인 정보 보호 기술을 구현하는 것이 중요합니다.

먼저 데이터 보안을 상세히 살펴본 다음 나머지 두 측면을 논의하겠습니다.



01 AI 개인 정보 보호 개요

02 학습 데이터의 개인 정보 보호: 익명화 기법

03 학습 데이터의 개인 정보 보호: 무작위 순서 지정 기법

04 머신러닝 학습의 개인 정보 보호: DP-SGD

05 머신러닝 학습의 개인 정보 보호: 제휴 학습

06 Google Cloud의 시스템 보호

07 시스템 보안 및 생성형 AI

08 실습: TensorFlow Privacy를 사용한 머신러닝의 개인 정보 차등 보호

학습 데이터의 개인 정보 보호를 살펴보겠습니다.

데이터 보안은 **ML**의 개인 정보 보호를
어떻게 뒷받침할까요**?**

익명화

무작위 지정

ML 개인 정보 보호의 맥락에서 데이터 보안은 AI 시스템에 사용되는 민감한 정보의 보호 조치를 의미합니다.

가능한 한 민감한 정보의 사용을 최소화하는 것이 좋습니다. 특히 데이터를 처리하는 도중이 아닌 합산 데이터를 수집하거나 개별 상호작용을 수집하는 등의 데이터 수집 단계에서 민감한 정보의 사용을 최소화하는 것이 좋습니다.

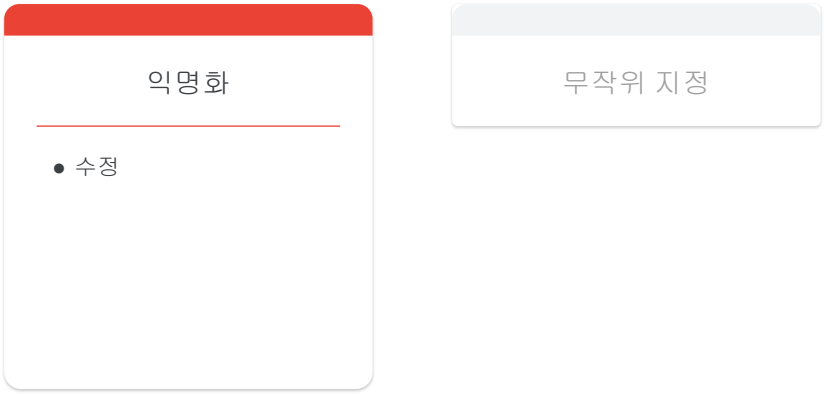
상이하지만 배타적이지 않은 두 가지 접근방식을 고려하는 것이 좋습니다.

데이터 보안은 **ML**의 개인 정보 보호를
어떻게 뒷받침할까요**?**



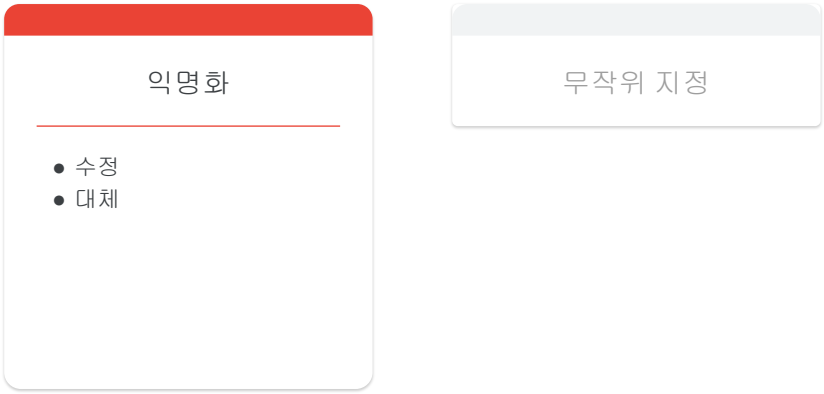
1. 다음과 같은 익명화 기법을 통해 데이터 익명화:

데이터 보안은 **ML**의 개인 정보 보호를
어떻게 뒷받침할까요**?**



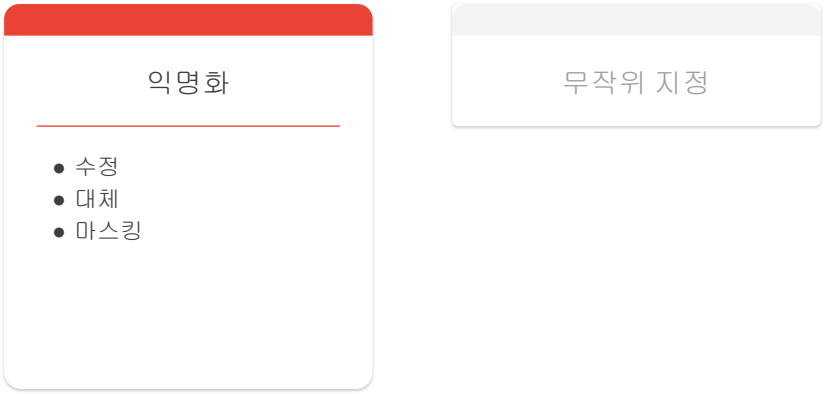
수정,

데이터 보안은 **ML**의 개인 정보 보호를
어떻게 뒷받침할까요**?**

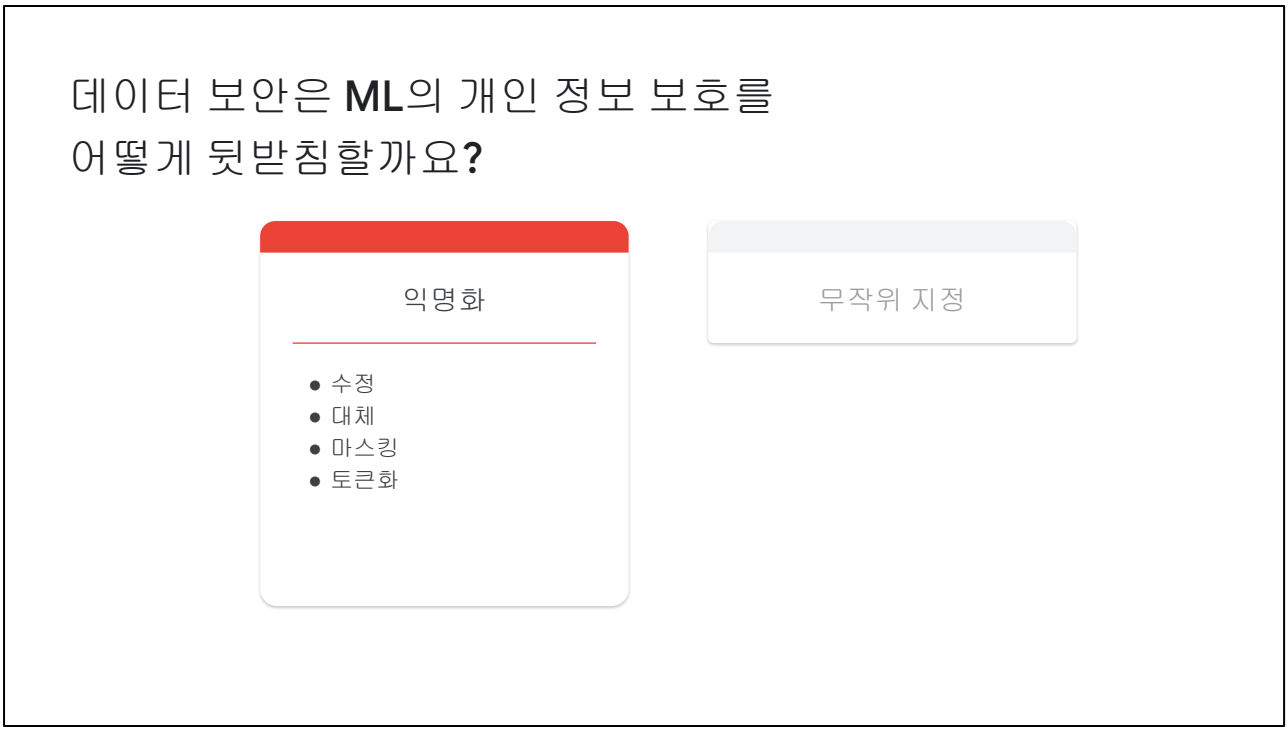


대체,

데이터 보안은 **ML**의 개인 정보 보호를
어떻게 뒷받침할까요**?**

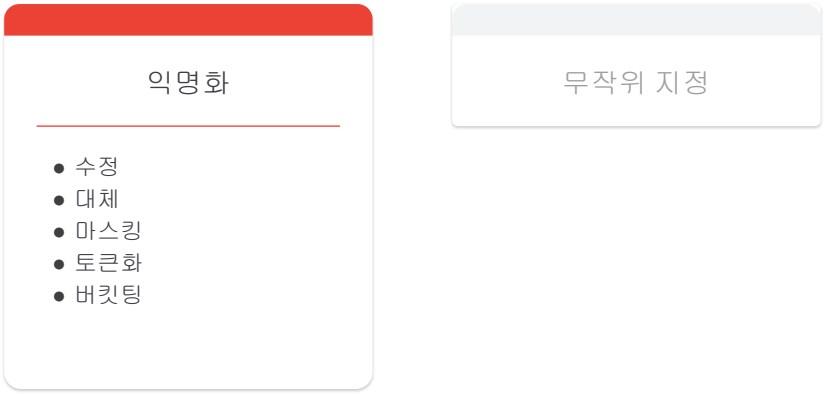


마스킹,



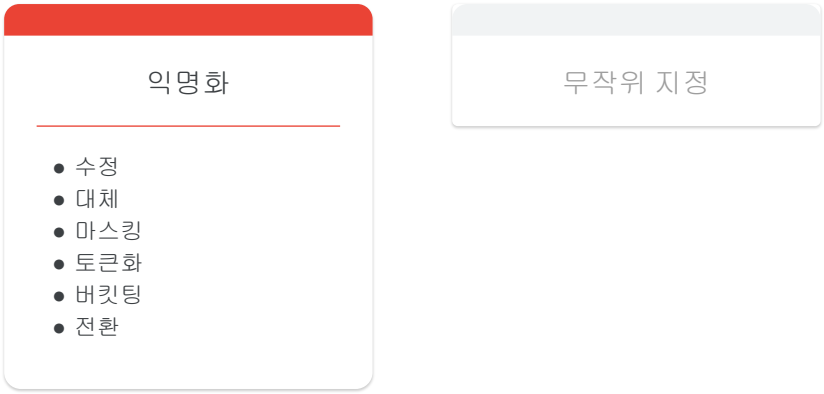
토큰화,

데이터 보안은 **ML**의 개인 정보 보호를
어떻게 뒷받침할까요**?**

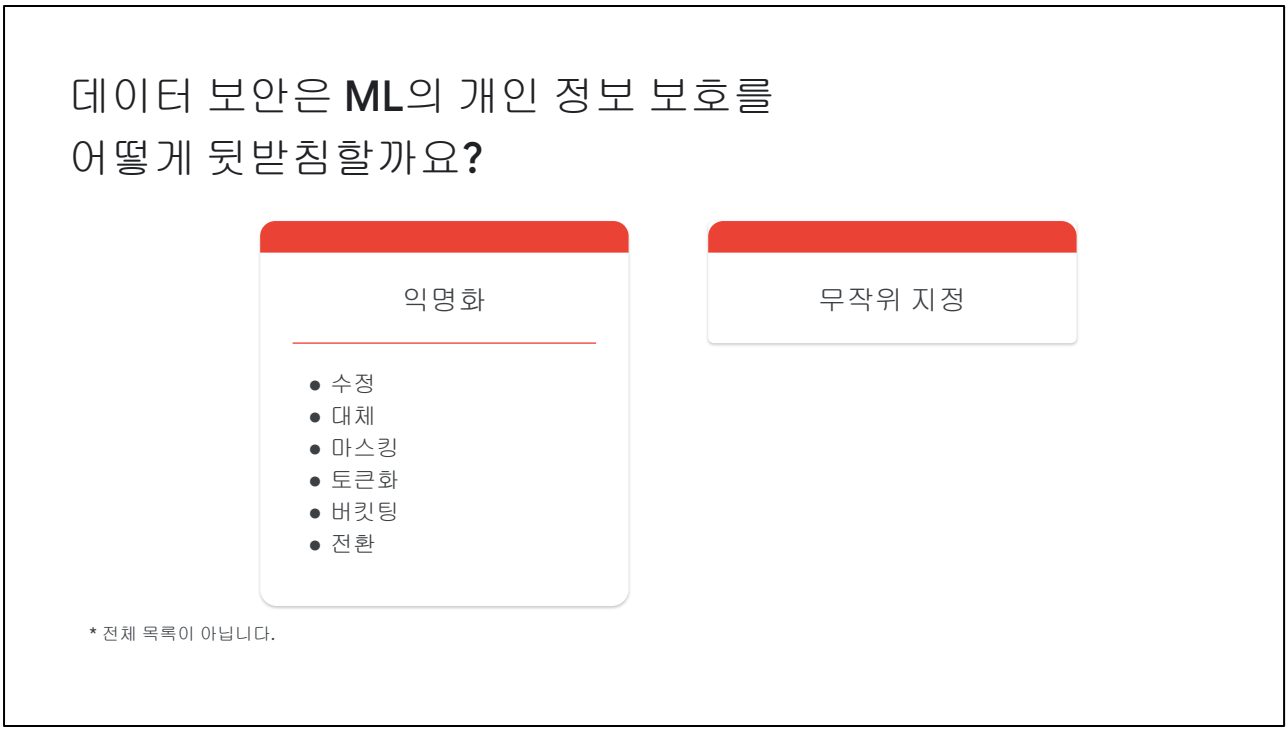


버킷팅,

데이터 보안은 **ML**의 개인 정보 보호를
어떻게 뒷받침할까요**?**



전환



2. 다음과 같은 방식을 통해 데이터 무작위 지정:

데이터 보안은 **ML**의 개인 정보 보호를 어떻게 뒷받침할까요**?**

익명화

- 수정
- 대체
- 마스킹
- 토큰화
- 버킷팅
- 전환

무작위 지정

- 데이터 섭동

* 전체 목록이 아닙니다.

데이터 섭동,

데이터 보안은 **ML**의 개인 정보 보호를 어떻게 뒷받침할까요**?**

익명화

- 수정
- 대체
- 마스킹
- 토큰화
- 버킷팅
- 전환

무작위 지정

- 데이터 섭동
- 개인 정보 차등 보호

* 전체 목록이 아닙니다.

개인 정보 차등 보호

ML의 개인 정보 보호에 관한 데이터 보안 방식



익명화 기법은 두 가지 요소로 평가할 수 있습니다.

익명화 접근방식은 두 가지 요소로 평가할 수 있습니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



익명화 기법은 두 가지 요소로 평가할 수 있습니다.

- 가역성.
  데이터를 재식별할 수 있는가?

a. 가역성: 되돌릴 수 있는 접근방식의 경우 데이터를 재식별할 수 있는가?

ML의 개인 정보 보호에 관한 데이터 보안 방식



익명화 기법은 두 가지 요소로 평가할 수 있습니다.

- 가역성.
  데이터를 재식별할 수 있는가?
- 참조 무결성.
  익명화 이후 레코드 간의 관계가 유지되는가?

b. 참조 무결성: 익명화 이후 레코드 간의 관계가 유지되는가?

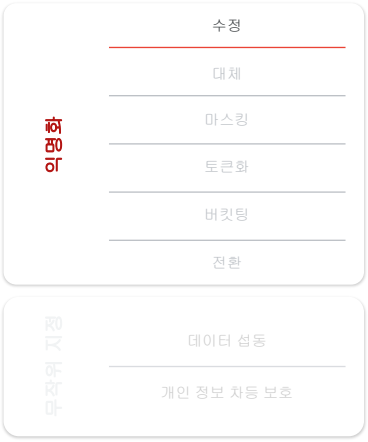
이러한 요소가 긍정적으로 작용할지, 잠재적인 위험으로 작용할지는 구체적인 사용 사례와 데이터 개인 정보 보호 요건에 따라 결정됩니다.

예를 들어 가역성은 감사 가능성 및 복구 측면에서 훌륭하지만 재식별로 알려진 데이터 유출로 쉽게 이어질 수 있습니다.
참조 무결성에도 동일한 위험이 드물게 존재하지만 보장될 경우 참조 무결성은 ML 성능 및 일관성 개선이라는 추가적인 이점을 지닙니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



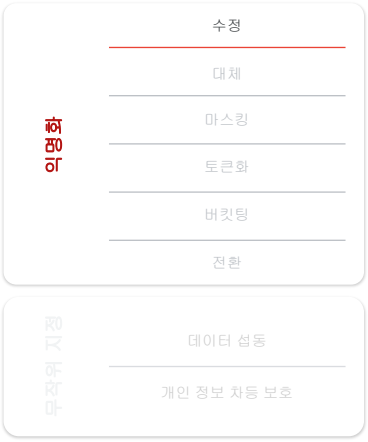
ML의 개인 정보 보호에 관한 데이터 보안 방식



수정은 민감한 값의 전체 또는 일부를 삭제합니다.

첫 번째 익명화 기술: 수정
수정은 민감한 값의 전체 또는 일부를 삭제하는 프로세스입니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식

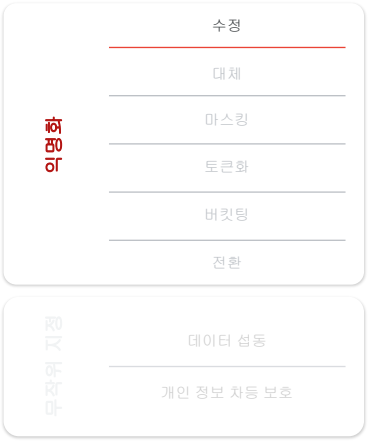


수정은 민감한 값의 전체 또는 일부를 삭제합니다.

‼ 되돌릴 수 없음

이 접근방식은 되돌릴 수 없으며

ML의 개인 정보 보호에 관한 데이터 보안 방식

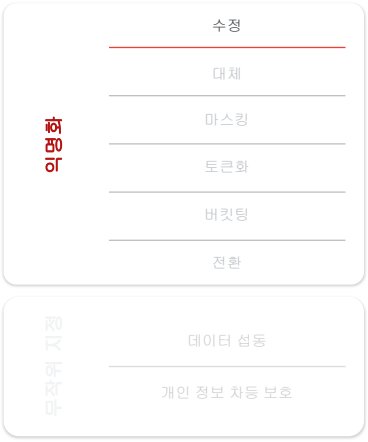


수정은 민감한 값의 전체 또는 일부를 삭제합니다.

‼ 되돌릴 수 없음
‼ 참조 무결성 없음

참조 무결성을 유지하지 않습니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



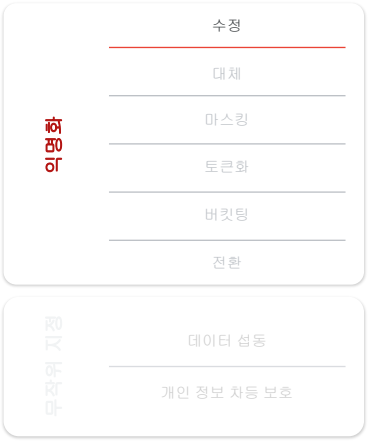
수정은 민감한 값의 전체 또는 일부를 삭제합니다.

‼ 되돌릴 수 없음
‼ 참조 무결성 없음

ID	날짜와 시간	$	이메일	제품
1493	2021년 1월 1일 09:12	56	john_snow@gmail.com	TV
4345	2021년 3월 2일 12:23	35	james_bond@gmail.com	휴대전화

예를 살펴보겠습니다. ID, 날짜와 시간, 금액(달러), 이메일과 제품을 포함하는 거래 데이터가 있다고 가정해 보겠습니다. 모든 익명화 기법에 이 예를 사용할 것입니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



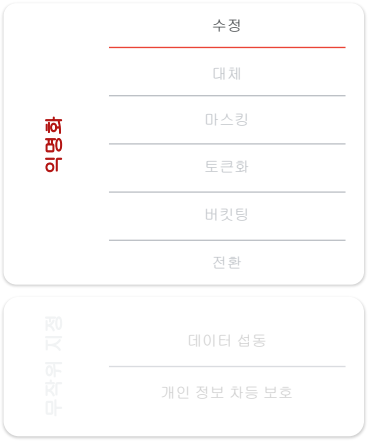
수정은 민감한 값의 전체 또는 일부를 삭제합니다.

‼ 되돌릴 수 없음
‼ 참조 무결성 없음

ID	날짜와 시간	$	이메일	제품
1493	2021년 1월 1일 09:12	56	john_snow@gmail.com	TV
4345	2021년 3월 2일 12:23	35	james_bond@gmail.com	휴대전화

'이메일' 열을 수정하고 싶다면 뷰에서 삭제하기만 하면 됩니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



수정은 민감한 값의 전체 또는 일부를 삭제합니다.

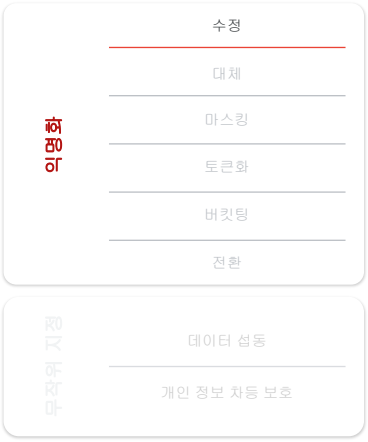
‼ 되돌릴 수 없음
‼ 참조 무결성 없음

ID	날짜와 시간	$	이메일	제품
1493	2021년 1월 1일 09:12	56	john_snow@gmail.com	TV
4345	2021년 3월 2일 12:23	35	james_bond@gmail.com	휴대전화

ID	날짜와 시간	$	제품
1493	2021년 1월 1일 09:12	56	TV
4345	2021년 3월 2일 12:23	35	휴대전화

수정 시 데이터가 삭제되면 머신러닝 모델에 중요할지도 모르는 정보의 손실로 이어질 수 있습니다. 이는 모델의 정확성, 일반화, 전반적인 효과에 영향을 미칠 수 있습니다.
예를 들어 데이터 세트에서 위치를 수정하면 이로 인해 모델의 지리정보 패턴 학습 능력이 저하될 수 있습니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



ML의 개인 정보 보호에 관한 데이터 보안 방식



대체는 민감한 값을 서로게이트로 바꿉니다.

두 번째 익명화 기법은 대체입니다. 이는 민감한 값을 사용자가 지정하는 서로게이트 값으로 바꾸는 것을 의미합니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



대체는 민감한 값을 서로게이트로 바꿉니다.

‼ 되돌릴 수 없음

이 값은 하나의 값이거나 값 목록에서 무작위로 선택한 값일 수 있습니다.
이 접근방식은 되돌릴 수 없으며

ML의 개인 정보 보호에 관한 데이터 보안 방식



대체는 민감한 값을 서로게이트로 바꿉니다.

‼ 되돌릴 수 없음
‼ 참조 무결성 없음

참조 무결성을 유지하지 않습니다. 대체는 데이터 손실로 인해 수정과 마찬가지로 모델의 학습 능력에 부정적인 영향을 미칠 수 있습니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



대체는 민감한 값을 서로게이트로 바꿉니다.

‼ 되돌릴 수 없음
‼ 참조 무결성 없음

ID	날짜와 시간	$	이메일	제품
1493	2021년 1월 1일 09:12	56	john_snow@gmail.com	TV
4345	2021년 3월 2일 12:23	35	james_bond@gmail.com	휴대전화

예를 들어 이메일 열에 대체를 적용한다고 가정해 보겠습니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



대체는 민감한 값을 서로게이트로 바꿉니다.

‼ 되돌릴 수 없음
‼ 참조 무결성 없음

ID	날짜와 시간	$	이메일	제품
1493	2021년 1월 1일 09:12	56	john_snow@gmail.com	TV
4345	2021년 3월 2일 12:23	35	james_bond@gmail.com	휴대전화

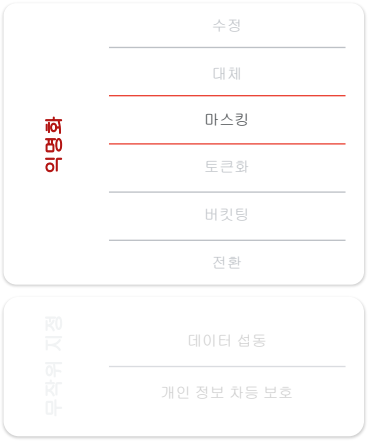
ID	날짜와 시간	$	이메일	제품
1493	2021년 1월 1일 09:12	56	EMAIL_ADDRESS	TV
4345	2021년 3월 2일 12:23	35	EMAIL_ADDRESS	휴대전화

이렇게 하면 모든 이메일을 EMAIL_ADDRESS와 같은 infoType으로 대체할 수 있습니다.
참고로 이 예시에서는 수정과 같은 효과를 지닙니다. 따라서 여기서는 데이터 손실이라는 동일한 한계점이 있다는 것을 알아야 합니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



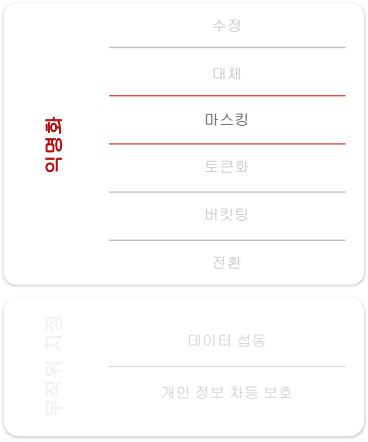
ML의 개인 정보 보호에 관한 데이터 보안 방식



마스킹은 민감한 값의 일부 또는 모든 문자를 서로게이트로 바꿉니다.

마스킹은 세 번째 익명화 기법입니다. 마스킹은 민감한 값의 일부 또는 모든 문자를 서로게이트로 바꿉니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식

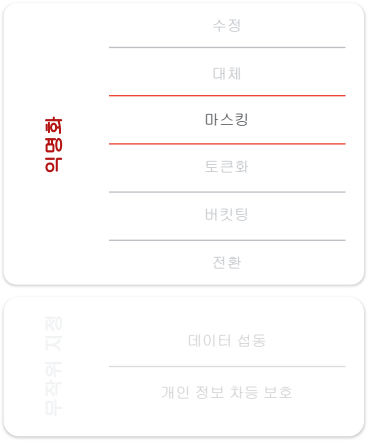


마스킹은 민감한 값의 일부 또는 모든 문자를 서로게이트로 바꿉니다.

‼ 되돌릴 수 없음

이 서로게이트 값은 원하는 경우 목록에서 무작위로 선택할 수 있지만 이 접근방식은 되돌릴 수 없습니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식

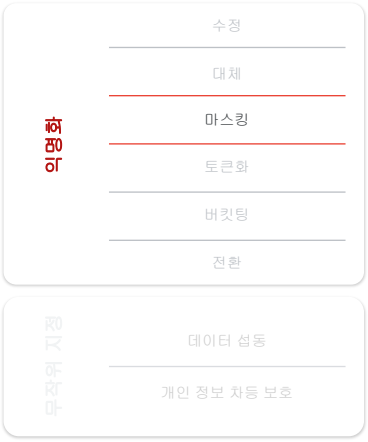


마스킹은 민감한 값의 일부 또는 모든 문자를 서로게이트로 바꿉니다.

‼ 되돌릴 수 없음
‼ 참조 무결성 없음

참조 무결성을 유지하지 않습니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



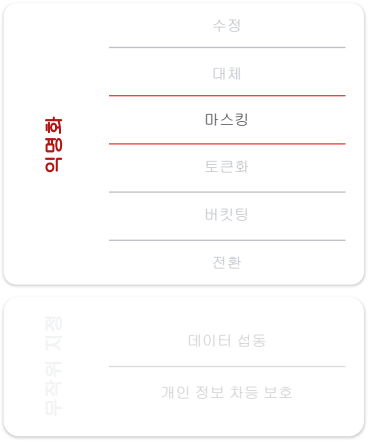
마스킹은 민감한 값의 일부 또는 모든 문자를 서로게이트로 바꿉니다.

‼ 되돌릴 수 없음
‼ 참조 무결성 없음

ID	날짜와 시간	$	이메일	제품
1493	2021년 1월 1일 09:12	56	john_snow@gmail.com	TV
4345	2021년 3월 2일 12:23	35	james_bond@gmail.com	휴대전화

예를 들어 이메일 열에 마스킹을 적용하여 이메일 도메인을 유지하지만 정확한 핸들은 유지하지 않는다고 가정해 보겠습니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



마스킹은 민감한 값의 일부 또는 모든 문자를 서로게이트로 바꿉니다.

‼ 되돌릴 수 없음
‼ 참조 무결성 없음

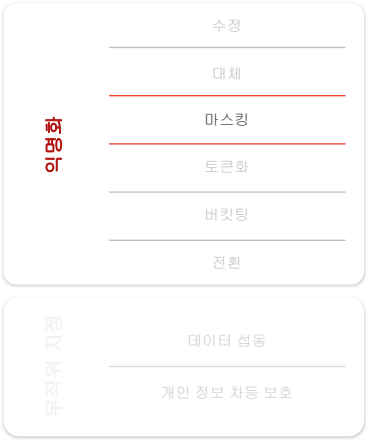
ID	날짜와 시간	$	이메일	제품
1493	2021년 1월 1일 09:12	56	john_snow@gmail.com	TV
4345	2021년 3월 2일 12:23	35	james_bond@gmail.com	휴대전화

ID	날짜와 시간	$	이메일	제품
1493	2021년 1월 1일 09:12	56	#########@gmail.com	TV
4345	2021년 3월 2일 12:23	35	##########@gmail.com	휴대전화

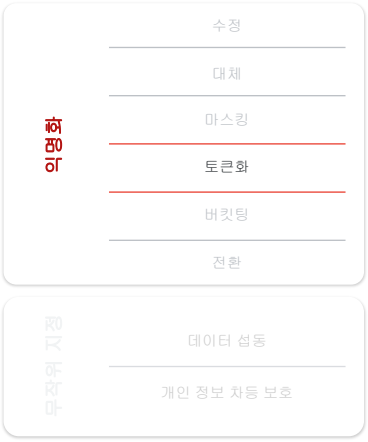
이 경우 '이메일' 열의 모든 값을 해시로 바꿀 수 있습니다.

대체와 마스킹은 비슷한 것 같지만 마스킹은 설정한 파라미터에 따라 기존 데이터의 일부 또는 전체를 덮는 반면 대체는 데이터를 완전히 삭제하고 값으로 바꿉니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



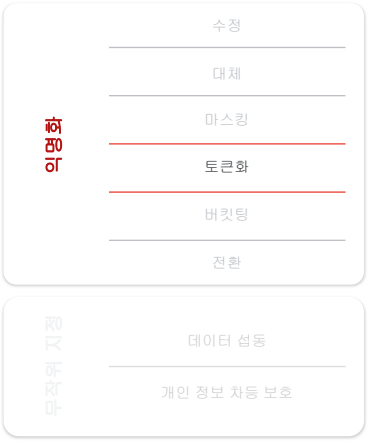
ML의 개인 정보 보호에 관한 데이터 보안 방식



토큰화는 민감한 값을 무작위로 생성된 토큰으로 바꿉니다.

토큰화는 범주형에 대해 살펴볼 마지막 익명화 기법입니다. 토큰화는 민감한 값을 무작위로 생성된 토큰으로 바꿉니다. 각 토큰은 익명화하는 값에 대해 고유합니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식

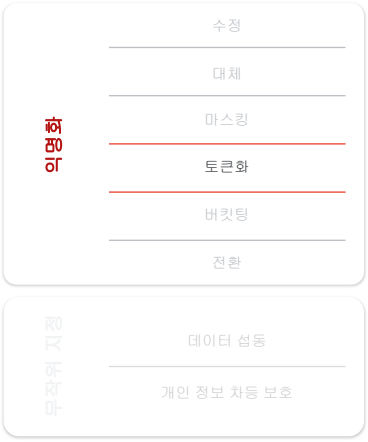


토큰화는 민감한 값을 무작위로 생성된 토큰으로 바꿉니다.

‼ 되돌릴 수 있음
‼ 참조 무결성

이 접근방식은 되돌릴 수 있으며 참조 무결성도 유지하므로 ML 모델이 토큰화된 특성의 정보를 계속 활용할 수 있습니다. 그러나 데이터를 원래의 정보로 되돌리려고 시도하는 악성 공격에 취약할 수 있습니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



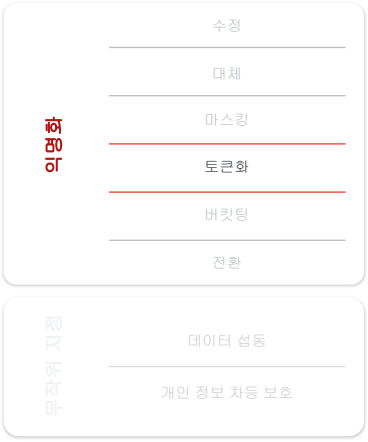
토큰화는 민감한 값을 무작위로 생성된 토큰으로 바꿉니다.

‼ 되돌릴 수 있음
‼ 참조 무결성

ID	날짜와 시간	$	이메일	제품
1493	2021년 1월 1일 09:12	56	john_snow@gmail.com	TV
4345	2021년 3월 2일 12:23	35	james_bond@gmail.com	휴대전화

예를 들어 이메일 열에 토큰화를 적용하면

ML의 개인 정보 보호에 관한 데이터 보안 방식



토큰화는 민감한 값을 무작위로 생성된 토큰으로 바꿉니다.

‼ 되돌릴 수 있음
‼ 참조 무결성

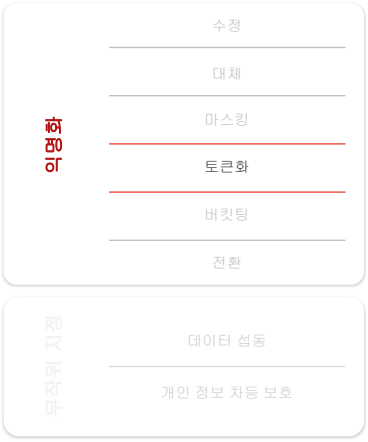
ID	날짜와 시간	$	이메일	제품
1493	2021년 1월 1일 09:12	56	john_snow@gmail.com	TV
4345	2021년 3월 2일 12:23	35	james_bond@gmail.com	휴대전화

ID	날짜와 시간	$	이메일	제품
1493	2021년 1월 1일 09:12	56	token-1234	TV
4345	2021년 3월 2일 12:23	35	token-5678	휴대전화

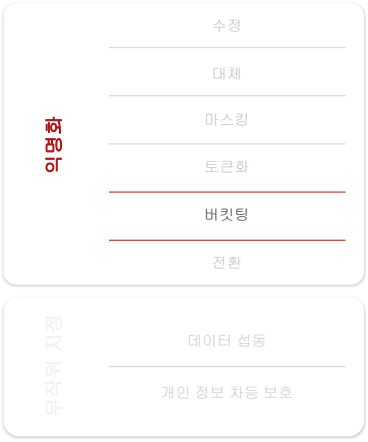
해당 값을 고유하게 식별하는 새로운 무작위 토큰을 얻게 됩니다.

토큰화를 통해 ML 모델은 토큰화된 특성의 정보를 계속 활용할 수 있습니다. 그러나 원래의 정보로 되돌리는 악성 공격에 취약할 수 있으므로 조심해야 합니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



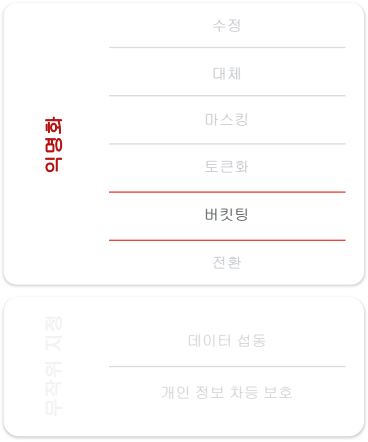
ML의 개인 정보 보호에 관한 데이터 보안 방식



버킷팅은 민감한 값을 값 범위로 바꿔 일반화합니다.

다음 익명화 접근방식인 버킷팅은 숫자 값에 사용되는 방식입니다.
버킷팅은 민감한 값을 값 범위로 바꿔 일반화합니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식

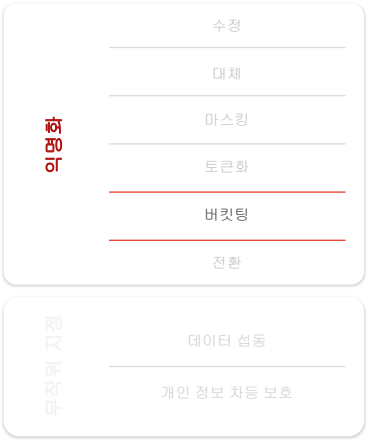


버킷팅은 민감한 값을 값 범위로 바꿔 일반화합니다.

‼ 되돌릴 수 없음

이 접근방식은 되돌릴 수 없으며

ML의 개인 정보 보호에 관한 데이터 보안 방식

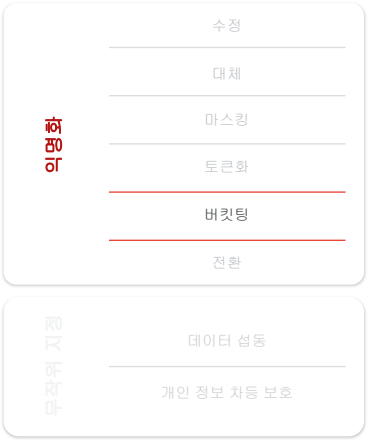


버킷팅은 민감한 값을 값 범위로 바꿔 일반화합니다.

‼ 되돌릴 수 없음
‼ 참조 무결성 없음

참조 무결성을 유지하지 않습니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



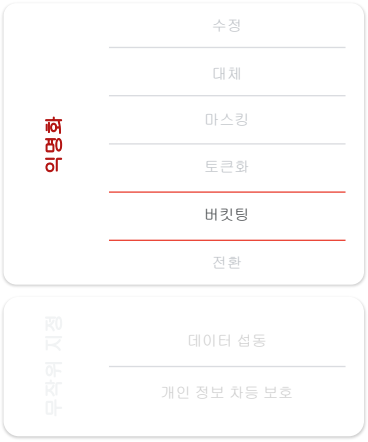
버킷팅은 민감한 값을 값 범위로 바꿔 일반화합니다.

‼ 되돌릴 수 없음
‼ 참조 무결성 없음

ID	날짜와 시간	$	이메일	제품
1493	2021년 1월 1일 09:12	56	john_snow@gmail.com	TV
4345	2021년 3월 2일 12:23	35	james_bond@gmail.com	휴대전화

예를 들어 금액(달러) 열에 버킷팅을 적용하고

ML의 개인 정보 보호에 관한 데이터 보안 방식



버킷팅은 민감한 값을 값 범위로 바꿔 일반화합니다.

‼ 되돌릴 수 없음
‼ 참조 무결성 없음

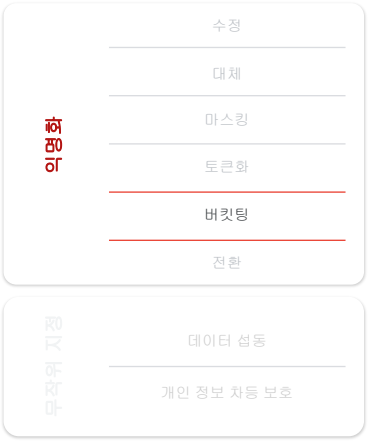
ID	날짜와 시간	$	이메일	제품
1493	2021년 1월 1일 09:12	56	john_snow@gmail.com	TV
4345	2021년 3월 2일 12:23	35	james_bond@gmail.com	휴대전화

ID	날짜와 시간	$	이메일	제품
1493	2021년 1월 1일 09:12	50~60	token-1234	TV
4345	2021년 3월 2일 12:23	30~40	token-5678	휴대전화

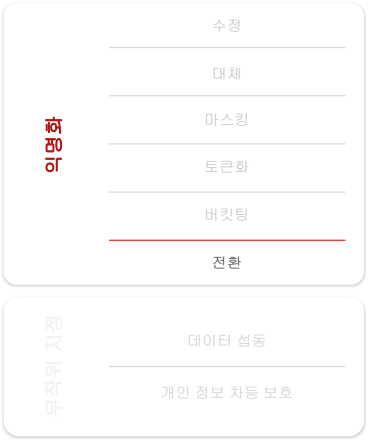
십 단위로 버킷팅하고 싶다고 가정해 보겠습니다. 그러면 프러시저는 각 항목을 올바른 버킷으로 대체하며, 예를 들어 **56**이 **50~60**으로 대체됩니다.

버킷이 정의된 범위에 따라 익명화된 데이터가 머신러닝 학습에 사용하기에 유용성이 떨어지거나 모델 성능에 영향을 미칠 수 있습니다. 범위의 크기 및 단위에 주의를 기울여 모델 성능과 개인 정보 보호 간의 적절한 균형을 찾아야 합니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



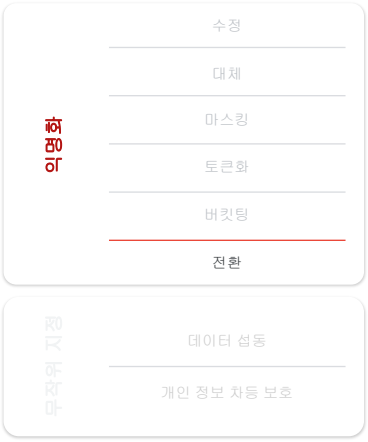
ML의 개인 정보 보호에 관한 데이터 보안 방식



전환은 민감한 날짜 및 시간 값을 임의의 시간만큼 이동시키는 방법입니다.

마지막으로 전환은 날짜와 시간 값에 사용되는 기법입니다.
이는 민감한 날짜 및 시간 값을 임의의 시간만큼 이동시키는 방법입니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식

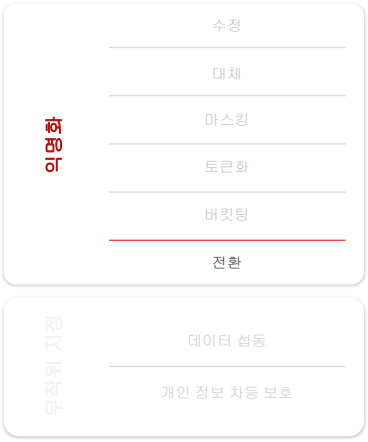


전환은 민감한 날짜 및 시간 값을 임의의 시간만큼 이동시키는 방법입니다.

‼ 되돌릴 수 있음

이러한 전환은 되돌릴 수 있으며

ML의 개인 정보 보호에 관한 데이터 보안 방식

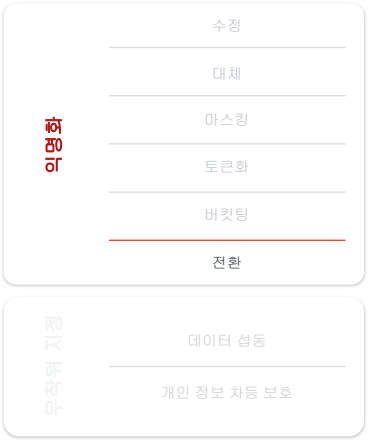


전환은 민감한 날짜 및 시간 값을 임의의 시간만큼 이동시키는 방법입니다.

‼ 되돌릴 수 있음
‼ 참조 무결성

순서와 기간이 유지되므로 참조 무결성을 유지합니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



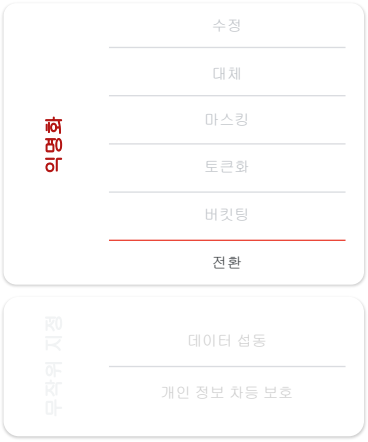
전환은 민감한 날짜 및 시간 값을 임의의 시간만큼 이동시키는 방법입니다.

‼ 되돌릴 수 있음
‼ 참조 무결성

ID	날짜와 시간	$	이메일	제품
1493	2021년 1월 1일 09:12	56	john_snow@gmail.com	TV
4345	2021년 3월 2일 12:23	35	james_bond@gmail.com	휴대전화

예를 들어 날짜와 시간 열에 전환을 적용하면

ML의 개인 정보 보호에 관한 데이터 보안 방식



전환은 민감한 날짜 및 시간 값을 임의의 시간만큼 이동시키는 방법입니다.

‼ 되돌릴 수 있음
‼ 참조 무결성

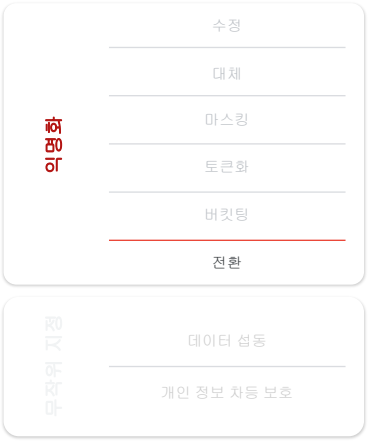
ID	날짜와 시간	$	이메일	제품
1493	2021년 1월 1일 09:12	56	john_snow@gmail.com	TV
4345	2021년 3월 2일 12:23	35	james_bond@gmail.com	휴대전화

ID	날짜와 시간	$	이메일	제품
1493	2021년 1월 2일 09:12	56	token-1234	TV
4345	2021년 3월 3일 12:23	35	token-5678	휴대전화

무작위로 1일을 이동 간격으로 선택하여 각 항목에 1일이 추가될 수 있습니다.

토큰화와 마찬가지로 무작위 전환이 식별되면 전환 역시 악성 공격에 취약할 수 있습니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



ML의 개인 정보 보호에 관한 데이터 보안 방식



재식별의 위험은 무엇일까요?

그렇다면 재식별의 위험은 무엇일까요?

이 중 어떠한 접근방식, 심지어는 되돌릴 수 없는 접근방식을 사용하더라도 데이터가 재식별될 수 없다고 100% 보장할 수는 없습니다. 대신 이러한 접근방식은 위험을 최소화하기 위한 것입니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



ML의 개인 정보 보호에 관한 데이터 보안 방식



재식별 위험 분석은 다음을 식별하는 데 도움이 될 수 있습니다.

재식별 위험 분석은 다음에 도움이 될 수 있습니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



재식별 위험 분석은 다음을 식별하는 데 도움이 될 수 있습니다.

I. 재식별의 위험

- 익명화 기법 수행 이후의 재식별 위험을 식별합니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식

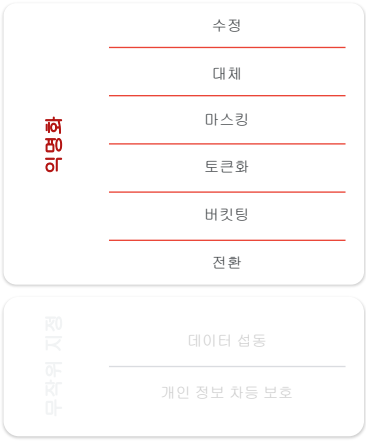


재식별 위험 분석은 다음을 식별하는 데 도움이 될 수 있습니다.

I. 재식별의 위험
II. 적용 가능한 최선의 익명화 전략

- 익명화 이전의 가장 효과적인 익명화 전략을 식별합니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



재식별 위험 분석은 다음을 식별하는 데 도움이 될 수 있습니다.

I. 재식별의 위험
II. 적용 가능한 최선의 익명화 전략

k-익명성 ℓ-다양성

이러한 위험 분석을 지원하는 기존의 두 가지 기법이 있습니다.

- k-익명성

ML의 개인 정보 보호에 관한 데이터 보안 방식



재식별 위험 분석은 다음을 식별하는 데 도움이 될 수 있습니다.

I. 재식별의 위험
II. 적용 가능한 최선의 익명화 전략

k-익명성

데이터 세트는 데이터 세트에 있는 민감한 특성값의 모든 조합이 k개 이상의 상이한 레코드에 표시되면 k-익명성을 가집니다.

ℓ-다양성

데이터 세트는 데이터 세트에 있는 민감한 특성값의 모든 조합이 **k**개 이상의 상이한 레코드에 표시되면 **k**-익명성을 가집니다.
여기서 알 수 있는 중요한 점이 있습니다. 특성에는 상관관계가 있을 수 있으며, 심지어 민감한 값을 익명화하는 경우에도 다른 특성과의 관계를 고려하여 계속해서 재식별될 수 있습니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



재식별 위험 분석은 다음을 식별하는 데 도움이 될 수 있습니다.

I. 재식별의 위험
II. 적용 가능한 최선의 익명화 전략

k-익명성

데이터 세트는 데이터 세트에 있는 민감한 특성값의 모든 조합이 k개 이상의 상이한 레코드에 표시되면 k-익명성을 가집니다.

ℓ-다양성

- L-다양성

ML의 개인 정보 보호에 관한 데이터 보안 방식



재식별 위험 분석은 다음을 식별하는 데 도움이 될 수 있습니다.

I. 재식별의 위험
II. 적용 가능한 최선의 익명화 전략

k-익명성

데이터 세트는 데이터 세트에 있는 민감한 특성값의 모든 조합이 k개 이상의 상이한 레코드에 표시되면 k-익명성을 가집니다.

ℓ-다양성

민감한 각 속성의 고유 값이 ℓ개 이상 있으면 데이터 세트는 익명화된 모든 그룹에 대해 ℓ-다양성을 가집니다.

이는 익명화된 각 그룹이 민감한 각 속성에 대해 L개 이상의 고유 값을 포함하도록 보장하는 k-익명성의 확장입니다.
l-다양성은 민감한 정보의 다양성을 측정한 것입니다.

익명화 및 데이터 섭동 기법을 적용하여 특정 k에서 k-익명성을 달성하거나 특정 l에서 l-다양성을 달성할 수 있습니다. k-익명성과 l-다양성을 조합하면 특히 데이터 유형이 혼합되어 있는 데이터 세트 시나리오에서 개인 정보 보호에 대해 보다 포괄적으로 이해할 수 있습니다.



01 AI 개인 정보 보호 개요

02 학습 데이터의 개인 정보 보호: 익명화 기법

03 학습 데이터의 개인 정보 보호: 무작위 순서 지정 기법

04 머신러닝 학습의 개인 정보 보호: DP-SGD

05 머신러닝 학습의 개인 정보 보호: 제휴 학습

06 Google Cloud의 시스템 보호

07 시스템 보안 및 생성형 AI

08 실습: TensorFlow Privacy를 사용한 머신러닝의 개인 정보 차등 보호

데이터의 개인 정보 보호 학습을 위한 무작위 순서 지정 기법으로 넘어가 보겠습니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



무작위 순서 지정 기법은 데이터에 노이즈나 섭동을 추가하여 데이터 개인 정보를 보호하는 것을 목표로 합니다.

무작위 순서 지정 기법은 데이터에 노이즈나 섭동을 추가하여 데이터 개인 정보를 보호하는 것을 목표로 합니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



무작위 순서 지정 기법은 데이터에 노이즈나 섭동을 추가하여 데이터 개인 정보를 보호하는 것을 목표로 합니다.

선택:

- 편리한 구현을 위한 데이터 섭동

데이터 개인 정보를 보호할 때는 데이터 섭동이나 개인 정보 차등 보호와 같은 기법을 적용할 수 있습니다. 데이터 섭동은 쉽게 구현할 수 있는 기법입니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



무작위 순서 지정 기법은 데이터에 노이즈나 섭동을 추가하여 데이터 개인 정보를 보호하는 것을 목표로 합니다.

선택:

- 편리한 구현을 위한 데이터 섭동
- 좀 더 엄격하고 강력한 개인 정보 보호 보장을 위한 개인 정보 차등 보호**(DP)**

반면에 개인 정보 차등 보호는 더 엄격한 개인 정보 보호를 보장합니다.

이러한 각 기법을 방식별로 살펴보겠습니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



ML의 개인 정보 보호에 관한 데이터 보안 방식



데이터 섭동은 무작위 노이즈를 도입하거나
약간의 수정을 통해 민감한 값을 난독화합니다.

데이터 섭동은 무작위 노이즈를 도입하거나 약간의 수정을 통해 민감한 값을 난독화합니다.
섭동 데이터는 계속해서 원본 데이터 세트에 존재하는 일반적인 트렌드와 패턴을 반영하는 동시에 개인의 직접적인 식별은 방지합니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



데이터 섭동은 무작위 노이즈를 도입하거나
약간의 수정을 통해 민감한 값을 난독화합니다.

	숫자	범주형
무작위 노이즈 추가	✔	
무작위 교환		
무작위 반올림		
무작위 카테고리 매핑		
...		

데이터 섭동 기법의 몇 가지 예시:

- 무작위 노이즈 추가: 작은 범위의 무작위 값을 데이터 세트의 각 데이터 포인트에 추가합니다. 이 기법은 숫자 값에 적용됩니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



데이터 섭동은 무작위 노이즈를 도입하거나
약간의 수정을 통해 민감한 값을 난독화합니다.

	숫자	범주형
무작위 노이즈 추가	✔	
무작위 교환	✔	✔
무작위 반올림		
무작위 카테고리 매핑		
...		

- 무작위 교환: 여러 데이터 포인트의 값을 무작위로 교환합니다. 숫자 값과 범주형 값 둘 다에 적용됩니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



데이터 섭동은 무작위 노이즈를 도입하거나
약간의 수정을 통해 민감한 값을 난독화합니다.

	숫자	범주형
무작위 노이즈 추가	✔	
무작위 교환	✔	✔
무작위 반올림	✔	
무작위 카테고리 매핑		
...		

- 무작위 반올림: 데이터 포인트를 무작위 정밀도 수준으로 반올림합니다. 이 기법은 숫자 값에 적용됩니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



데이터 섭동은 무작위 노이즈를 도입하거나
약간의 수정을 통해 민감한 값을 난독화합니다.

	숫자	범주형
무작위 노이즈 추가	✔	
무작위 교환	✔	✔
무작위 반올림	✔	
무작위 카테고리 매핑		✔
...		

- 무작위 카테고리 매핑: 범주형 값을 같은 변수 내의 상이한 카테고리로 무작위 매핑합니다.

섭동 정도는 개인 정보 보호 기능과 데이터 유용성 간의 균형을 맞춤으로써 데이터가 합법적인 분석 목적으로 유용성과 가치를 유지할 수 있도록 해야 합니다.

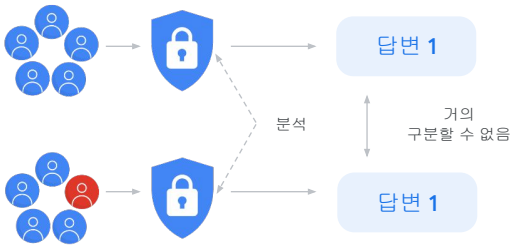
ML의 개인 정보 보호에 관한 데이터 보안 방식



ML의 개인 정보 보호에 관한 데이터 보안 방식

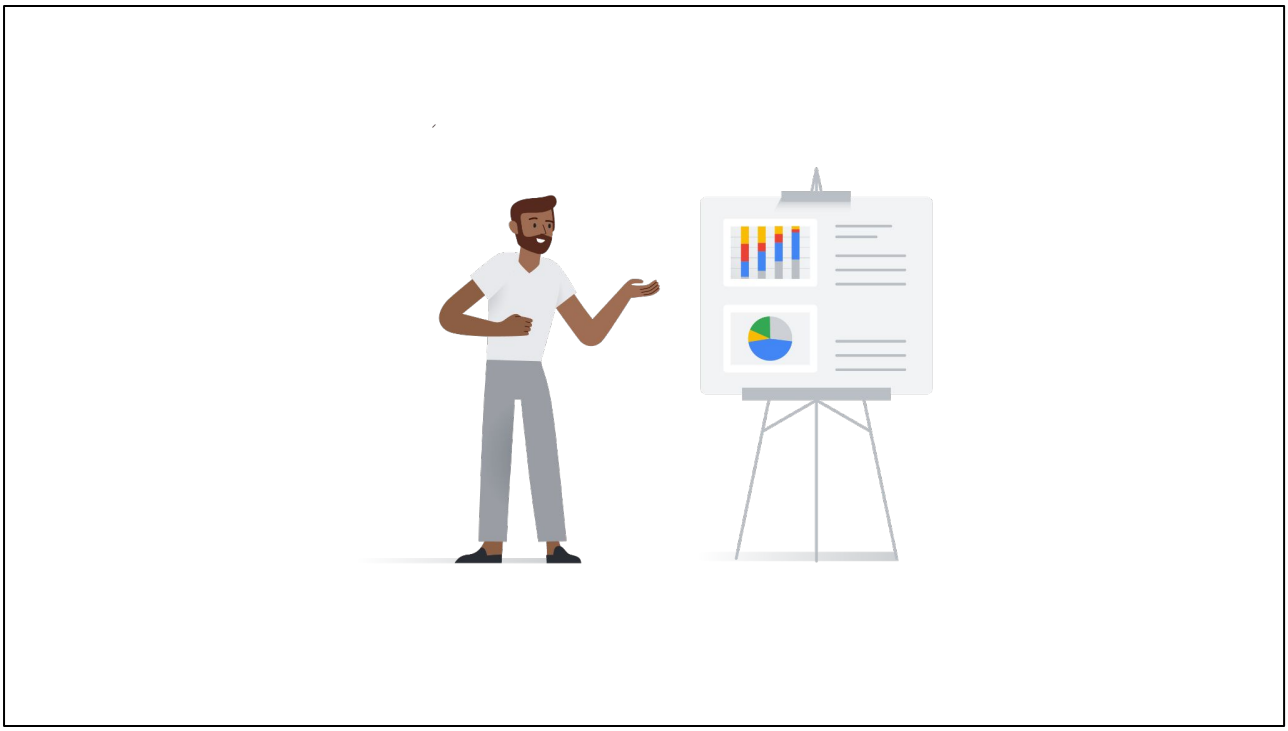


개인 정보 차등 보호는 개인의 데이터를 포함하거나 제외할 경우 분석 결과에 중대한 영향이 미치지 않도록 합니다.

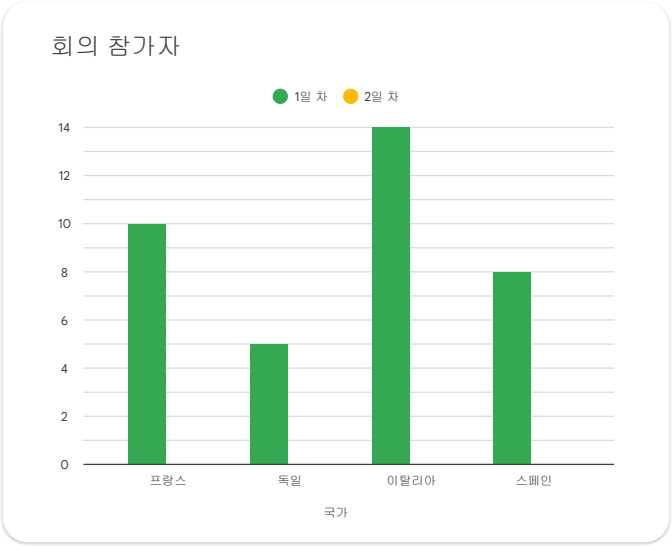


개인 정보 차등 보호는 개인의 데이터를 포함하거나 제외할 때 출력이나 분석 결과에 중대한 영향이 미치지 않도록 합니다. 이 방식은 데이터를 공유하고 싶거나 여러 그룹의 사람들에 대한 추론을 허용하는 동시에 누군가가 개인에 대한 정보를 습득하지 못하도록 하고 싶은 경우에 특히 유용합니다.

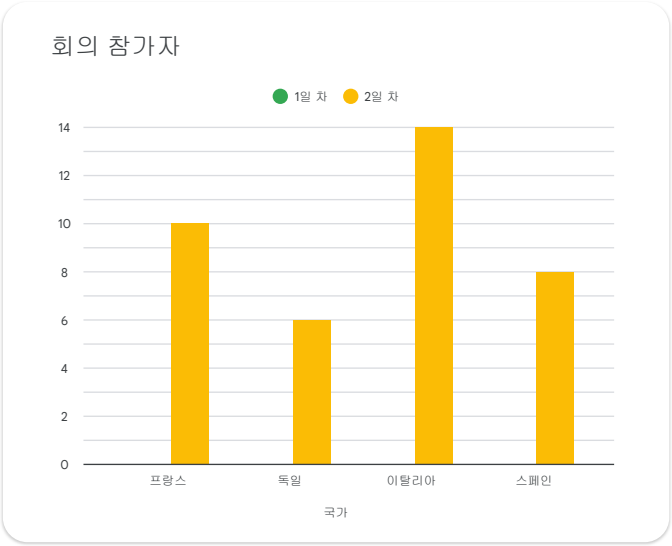
강력하고 검증 가능한 개인 정보 보호를 보장하므로 이를 '엄격한' 접근방식이라고 부릅니다.



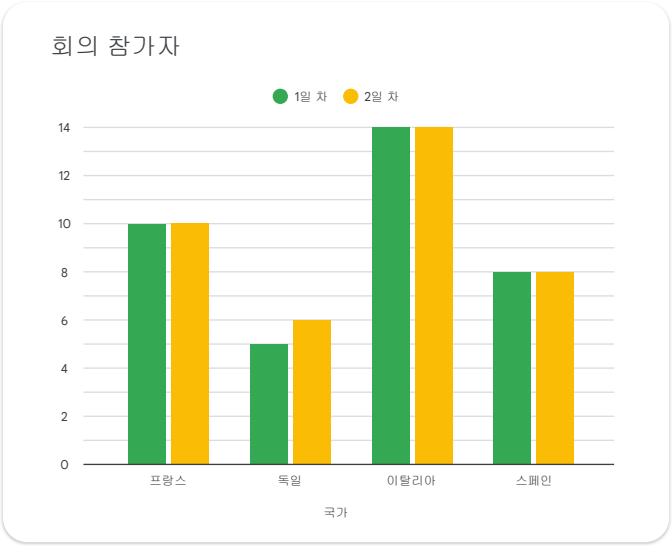
개인 정보 차등 보호를 적용하는 예시를 살펴보겠습니다.
여러분이 회의에 참석 중이고 사회자가 청중과 관련된 정보를 공유한다고 가정해 보겠습니다.



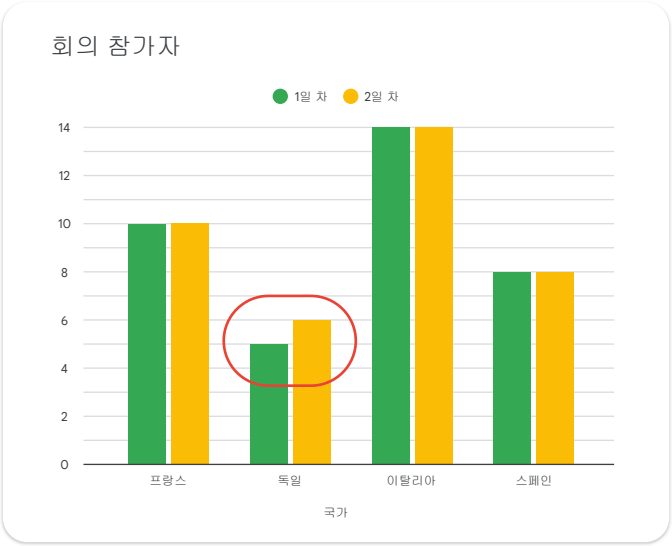
1일 차에 사회자가 회의에 참석한 사람들의 출신 국가를 보여줍니다. 데이터는 회의에 참석한 개인에 대한 어떠한 정보도 드러내지 않는 방식으로 합산됩니다. 데이터에 따르면 가장 참석자 수가 많은 국가는 이탈리아이며 가장 적은 국가는 독일입니다. 프랑스와 스페인의 참가자 수는 중간 정도입니다.



2일 차에 사회자가 그날의 통계를 보여줍니다. 1일 차의 차트와 매우 유사해 보입니다.



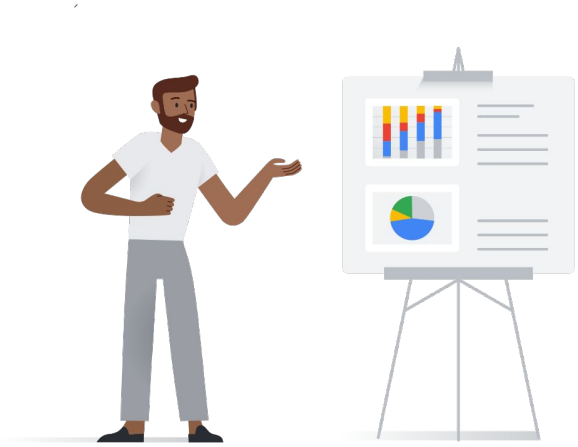
하지만 2일 차 세션이 시작되기 전에 여러분은 1일 차에 참석하지 않았지만 2일 차에는 참석한 누군가를 만났습니다. 이 정보를 아는 상태에서 두 날의 데이터를 함께 비교합니다. 데이터 세트를 토대로 새로운 참석자의 출신 국가를 파악할 수 있을까요?



맞습니다. 새로운 참석자는 독일 출신입니다.

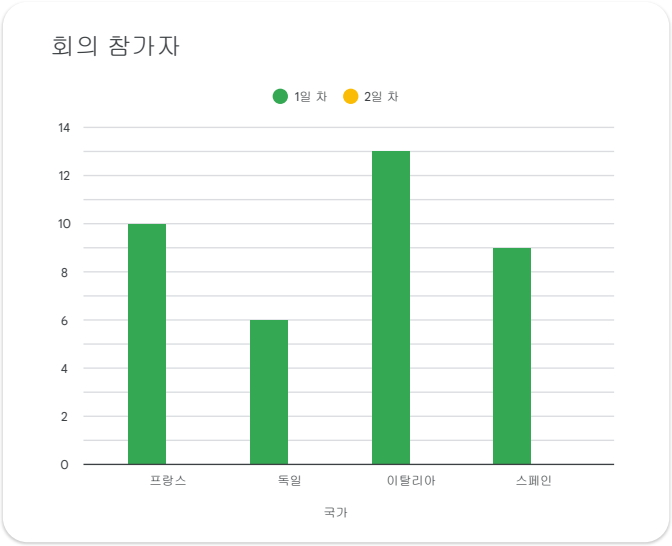
이는 합산 데이터 세트 두 개가 주어졌을 때 사회자가 특정 참가자의 개인 정보를 보호하지 않았음을 보여주는 예입니다.

“청중에 대한 정보를 공유하려고 하며, 개인 정보 보호를 위해 약간의 수치를 무작위로 변경하겠습니다.”

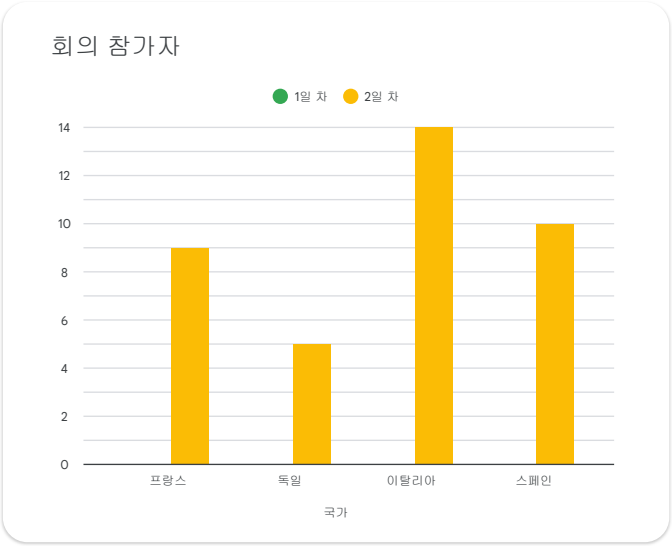


데이터 개인 정보 유출 문제를 해결하기 위해서는 사회자에게 새로운 접근방식이 필요합니다.

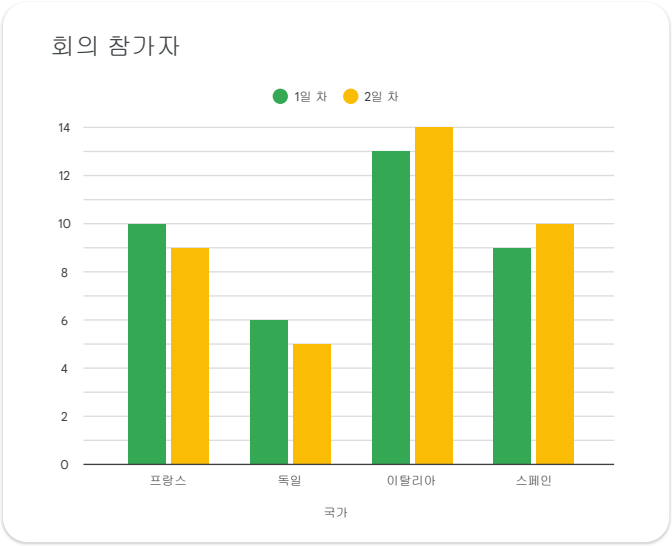
데이터 개인 정보 보호 개선을 위해 약간의 수치를 무작위로 변경해 보겠습니다.



그리고 이제 **1**일 차 통계가 실제 수치와 어떻게 비교되는지 살펴보세요. 약간 다릅니다. 정확성은 덜하지만 통계 추세에 대한 유용한 정보는 동일하게 제공됩니다.

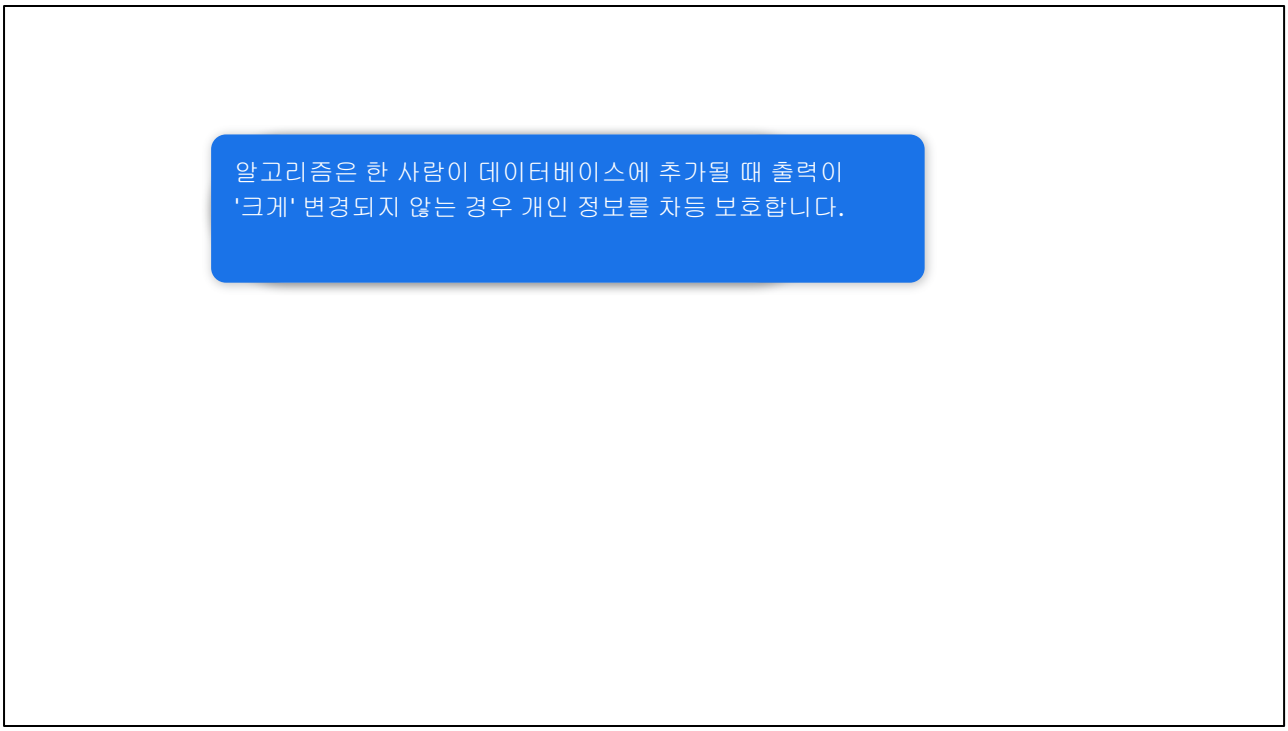


2일 차 데이터에도 동일한 접근방식이 적용됩니다.



그리고 이제 1일 차와 2일 차의 통계를 비교할 때 한 명의 새로운 참석자가 어느 국가의 출신인지 알 수 없으며, 수치가 약간 변경되었음을 알고 있으므로 출신 국가를 파악하려고 노력해도 소용이 없습니다.

이것이 개인 정보 차등 보호의 기본 원칙입니다. 개인 정보 차등 보호는 적절한 양의 노이즈를 데이터에 적용합니다. 따라서 통계적으로 중요한 유용한 정보를 가져올 수 있으며, 동시에 특정 개인의 정보가 계산에 사용되었는지 누구도 알 수 없게 합니다. 이 원칙의 가장 좋은 점은 원칙이 수학적으로 검증되었다는 것입니다.



개인 정보 차등 보호는 이 식을 따릅니다. 기본적으로는 한 사람이 데이터베이스에 추가될 때 출력이 '크게' 변경되지 않는 경우 개인 정보가 차등 보호된다는 의미입니다.

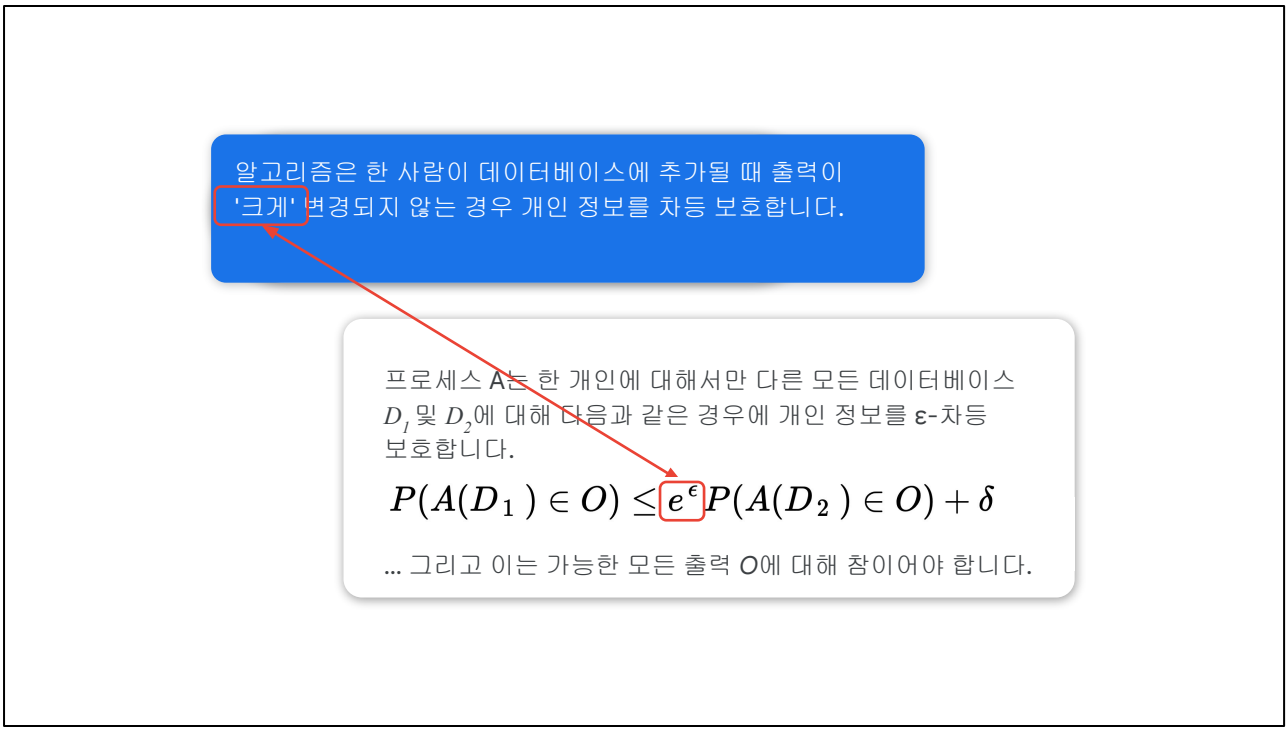
알고리즘은 한 사람이 데이터베이스에 추가될 때 출력이 '크게' 변경되지 않는 경우 개인 정보를 차등 보호합니다.

프로세스 A는 한 개인에 대해서만 다른 모든 데이터베이스 D_1 및 D_2에 대해 다음과 같은 경우에 개인 정보를 ε-차등 보호합니다.

$$P(A(D_1) \in O) \leq e^{\epsilon} P(A(D_2) \in O) + \delta$$

... 그리고 이는 가능한 모든 출력 *O*에 대해 참이어야 합니다.

이전 예로 돌아가면



새로운 참가자가 추가될 때 개인 정보 차등 보호가 적용된 차트는 참가자에 대한 많은 정보를 알려 주지 않습니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



개인 정보 차등 보호는 개인의 데이터를 포함하거나 제외할 때 출력에 중대한 영향이 미치지 않도록 합니다.

개인 정보 차등 보호는 두 가지 주요 파라미터가 특징입니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



개인 정보 차등 보호는 개인의 데이터를 포함하거나 제외할 때 출력에 중대한 영향이 미치지 않도록 합니다.

개인 정보 보호 파라미터 ε

민감도

- 개인 정보 보호 파라미터 ε(Epsilon)은

ML의 개인 정보 보호에 관한 데이터 보안 방식



개인 정보 차등 보호는 개인의 데이터를 포함하거나 제외할 때 출력에 중대한 영향이 미치지 않도록 합니다.

개인 정보 보호 파라미터 ε

개인 정보 보호 수준을 정량화합니다. 작을수록 개인 정보 보호가 강력해집니다.

민감도

개인 정보 차등 보호 메커니즘에 의해 제공되는 개인 정보 보호 수준을 정량화하는 음이 아닌 값입니다. ε 값이 작을수록 강력한 개인 정보 보호를 나타내지만 쿼리 결과에 과도하게 노이즈가 추가되어 데이터 유용성이 감소할 위험이 있습니다.

ML의 개인 정보 보호에 관한 데이터 보안 방식



개인 정보 차등 보호는 개인의 데이터를 포함하거나 제외할 때 출력에 중대한 영향이 미치지 않도록 합니다.

개인 정보 보호 파라미터 ε

개인 정보 보호 수준을 정량화합니다. 작을수록 개인 정보 보호가 강력해집니다.

민감도

- 민감도는

ML의 개인 정보 보호에 관한 데이터 보안 방식



개인 정보 차등 보호는 개인의 데이터를 포함하거나 제외할 때 출력에 중대한 영향이 미치지 않도록 합니다.

개인 정보 보호 파라미터 ε

개인 정보 보호 수준을 정량화합니다. 작을수록 개인 정보 보호가 강력해집니다.

민감도

개인 데이터를 포함하거나 제외함에 따라 출력이 얼마나 다를 수 있는지를 정량화합니다.

개인의 데이터가 데이터 세트에서 삭제되거나 추가될 때 쿼리의 출력이 구체적으로는 오차의 최대 절댓값을 얼마만큼 바꿀 수 있는지를 측정합니다. 민감도는 개인 정보 보호를 보장하기 위해 추가해야 하는 노이즈의 양을 파악하는 데 중요합니다.

익명화 및 무작위 순서 지정의 기법은 민감한 정보를 보호하는 데 사용됩니다. 이러한 기법은 AI 모델의 학습 데이터에서 개인 정보 보호를 개선하는 데 도움을 줍니다.

익명화 및 무작위 순서 지정의 기법은 민감한 정보를 보호하는 데 사용됩니다. 이러한 기법은 AI 모델의 학습 데이터에서 개인 정보 보호를 개선하는 데 도움을 줍니다.



01 AI 개인 정보 보호 개요

02 학습 데이터의 개인 정보 보호: 익명화 기법

03 학습 데이터의 개인 정보 보호: 무작위 순서 지정 기법

04 머신러닝 학습의 개인 정보 보호: DP-SGD

05 머신러닝 학습의 개인 정보 보호: 제휴 학습

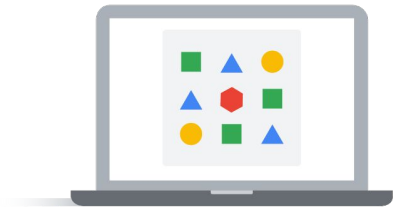
06 Google Cloud의 시스템 보호

07 시스템 보안 및 생성형 AI

08 실습: TensorFlow Privacy를 사용한 머신러닝의 개인 정보 차등 보호

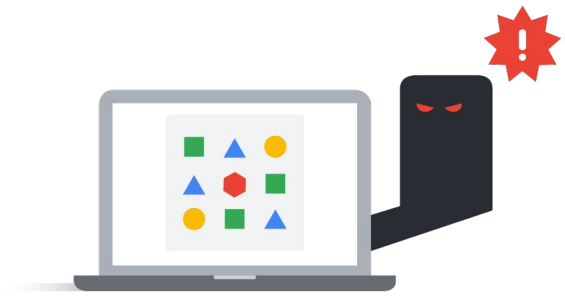
머신러닝 학습의 개인 정보 보호에 대해 알아보겠습니다.

보안을 염두에 둔 **ML** 모델 학습 방법



머신러닝 모델을 빌드한 후에는 사용자에게 공개하기 전에 보안 조치를 신중하게 고려하는 것이 중요합니다.

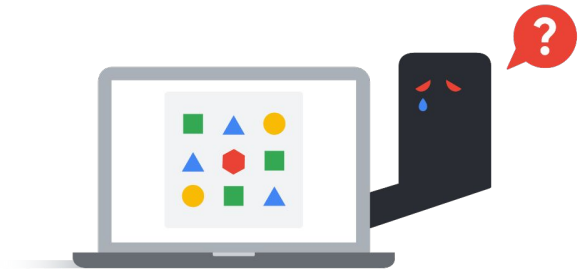
보안을 염두에 둔 **ML** 모델 학습 방법



공격자가 민감한 정보를 추출하거나 모델의 취약점을 악용하기 위해 다양한 공격을 시도할 수 있기 때문입니다.

보안을 염두에 둔 **ML** 모델 학습 방법

제휴 학습

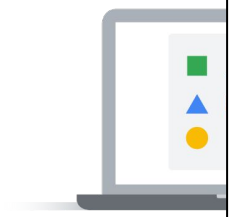


수많은 유형의 공격, 그리고 이를 방지하기 위해 취할 수 있는 수많은 조치가 있습니다.

보안을 염두에 둔 **ML** 모델 학습 방법

DP-SGD

제휴 학습



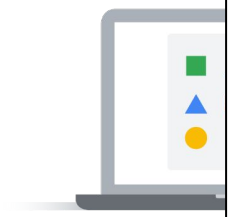
많은 방법이 있지만 안전한 모델을 위해 널리 사용되는 두 가지 방법은

보안을 염두에 둔 ML 모델 학습 방법

DP-SGD

개인 정보 차등 보호를 SGD에 통합하기 위한 방식입니다. 학습 프로세스 도중 경사에 노이즈를 추가하는 식으로 작동합니다.

제휴 학습



DP-SGD라고도 하는 개인 정보 차등 보호 확률적 경사하강법과

보안을 염두에 둔 **ML** 모델 학습 방법

DP-SGD	제휴 학습
개인 정보 차등 보호를 SGD에 통합하기 위한 방식입니다. 학습 프로세스 도중 경사에 노이즈를 추가하는 식으로 작동합니다.	스마트폰과 같은 기기에 상주하는 분산화된 예시를 사용하여 머신러닝 모델을 학습시키는 분산식 머신러닝 접근방식입니다.

제휴 학습입니다.

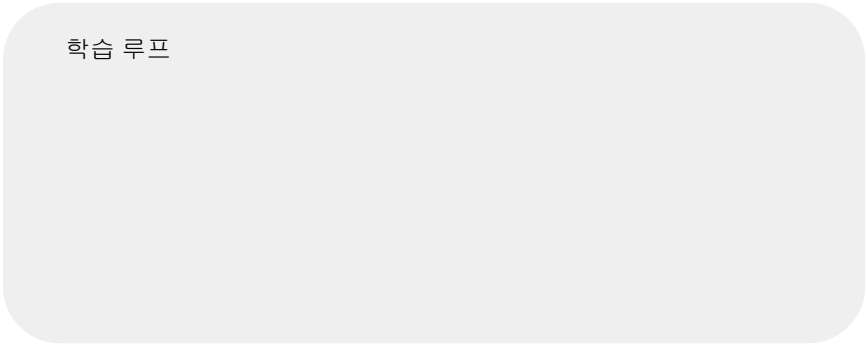
DP-SGD는 개인 정보 차등 보호를 SGD(확률적 경사하강법)에 통합하여 모델을 더 안전하게 학습시키기 위한 안전한 최적화 전략입니다.

DP-SGD는 개인 정보 차등 보호를 SGD(확률적 경사하강법)에 통합하여 모델을 더 안전하게 학습시키기 위한 안전한 최적화 전략입니다.
앞서 언급했듯이 개인 정보 차등 보호는 안전한 방식으로 정보를 합산하는 다양한 사용 사례에 사용될 수 있습니다.

데이터 샘플 그룹에 대한 모델 파라미터의 경사를 계산하여 모델 파라미터를 업데이트하는 SGD 등의 머신러닝 최적화 전략은 합산 알고리즘으로 볼 수 있습니다. 이는 개인 정보 차등 보호를 SGD와 같은 최적화 알고리즘에 통합하여 학습 프로세스 도중 민감한 정보를 보호할 수 있음을 의미합니다.

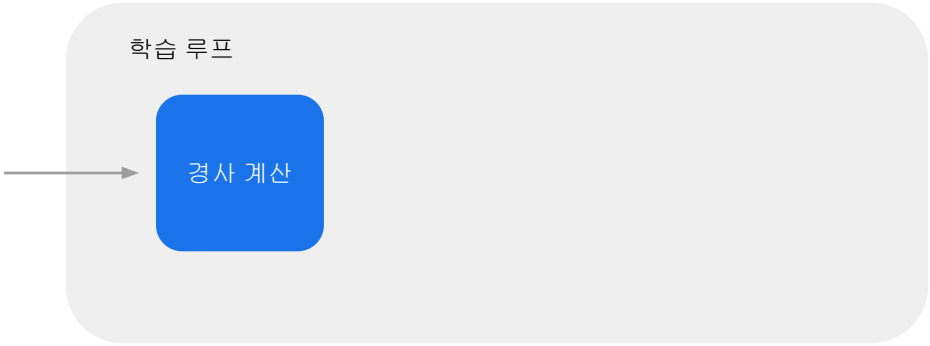
여러 구현이 있지만 여기서는 가장 단순한 DP-SGD 알고리즘을 살펴보겠습니다.

일반적인 확률적 경사하강법



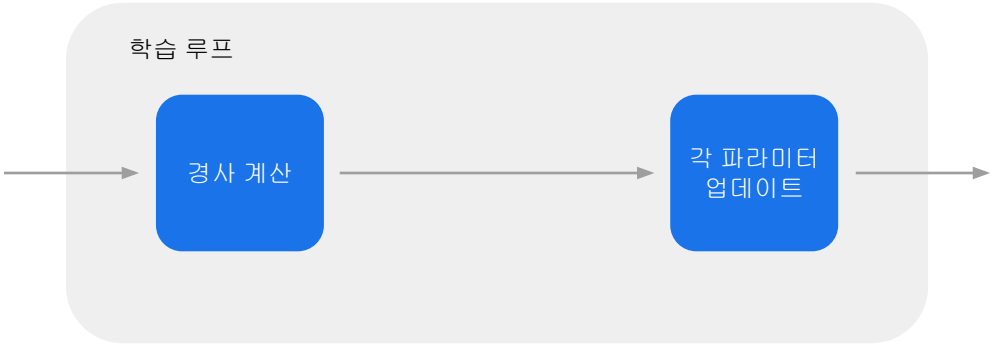
DP-SGD는 일반적인 SGD 알고리즘의 확장으로

일반적인 확률적 경사하강법

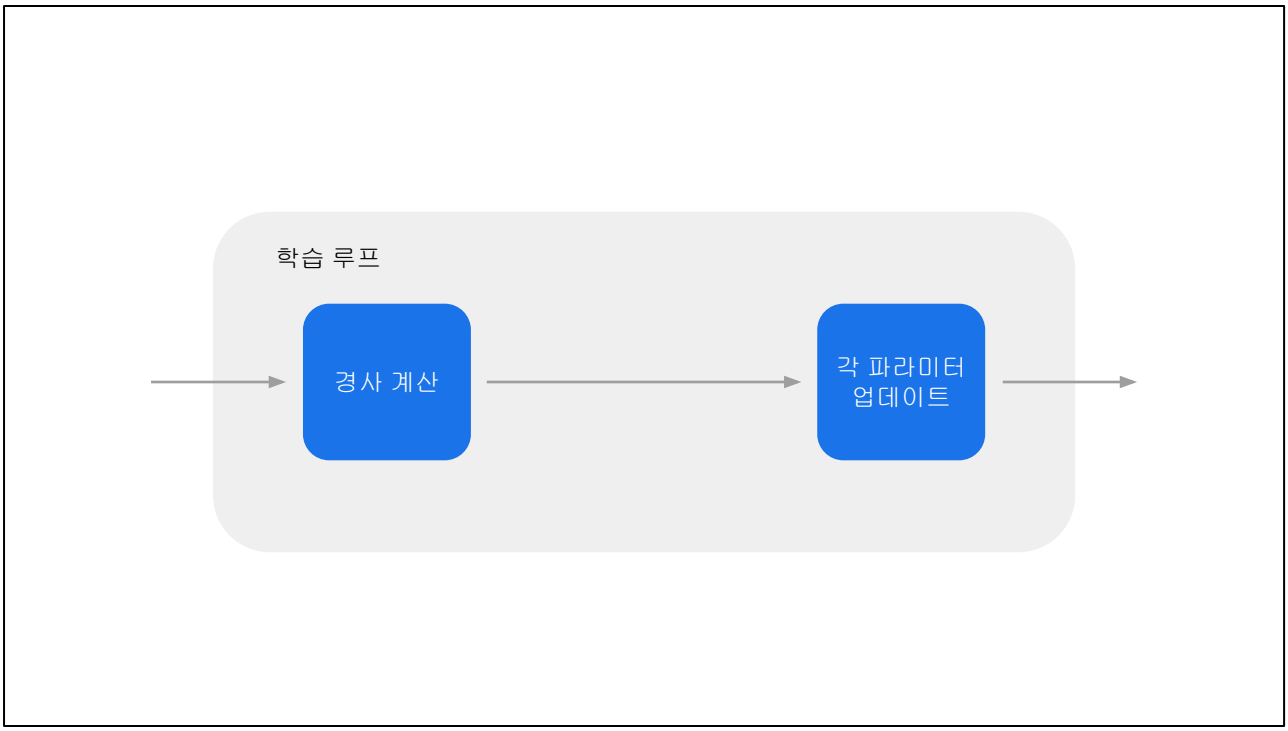


각 파라미터의 경사를 계산하고

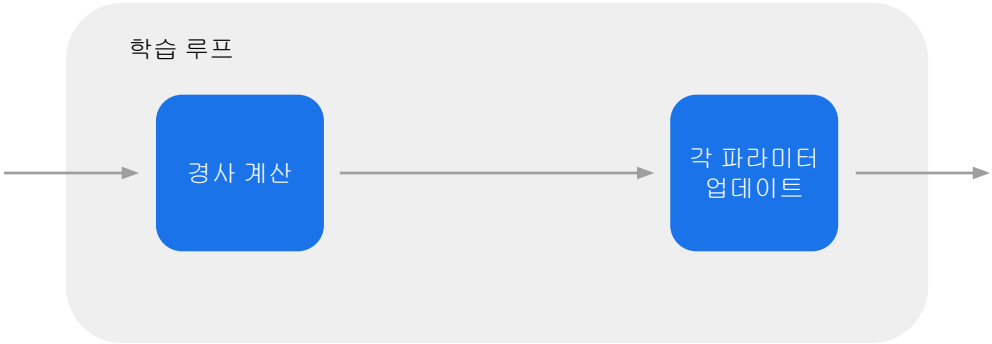
일반적인 확률적 경사하강법



경사를 사용하여 이를 업데이트합니다.

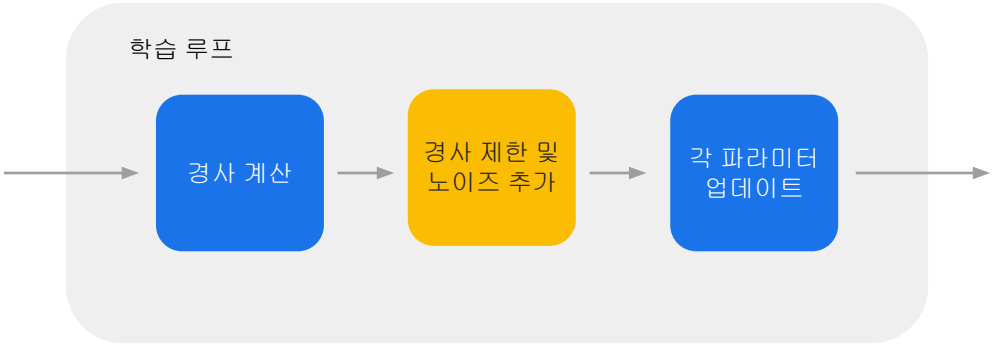

학습 루프
경사 계산
각 파라미터
업데이트

개인 정보 차등 보호 채택을 위한 **DP-SGD** 알고리즘 및 노이즈

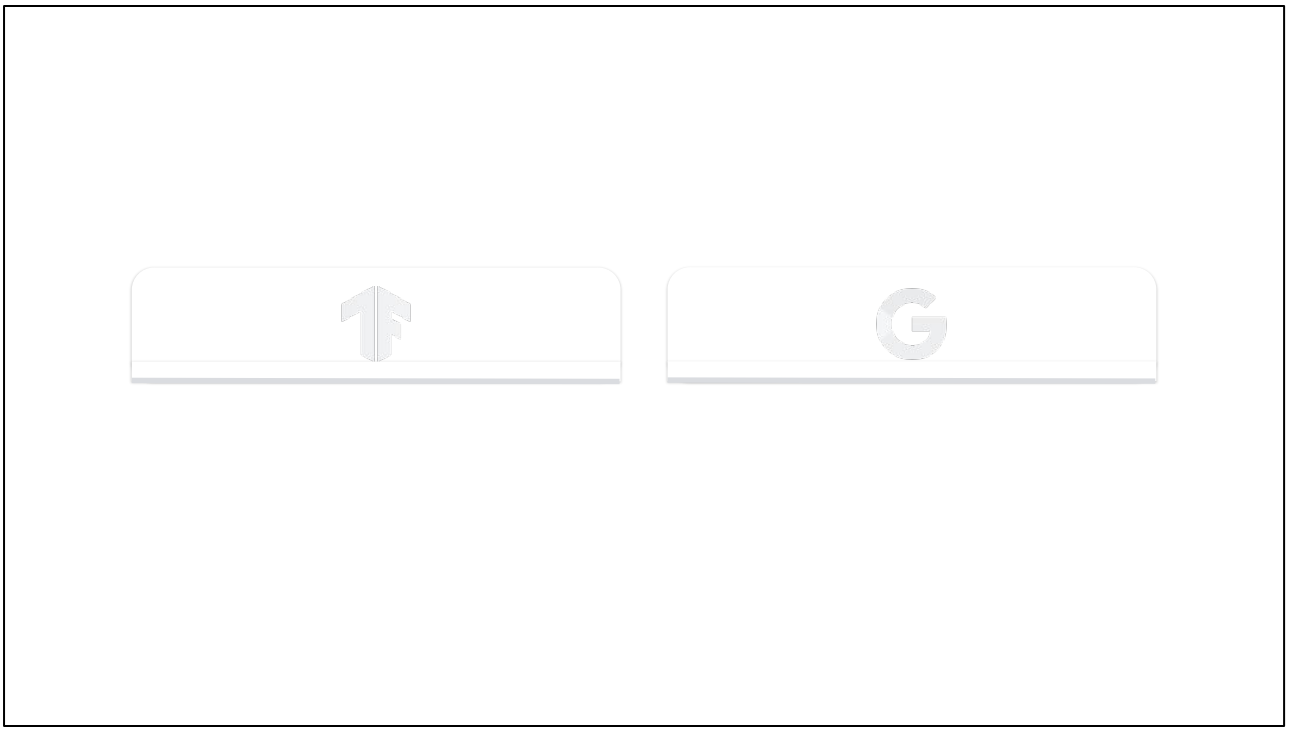


DP-SGD는 경사 제한 및 노이즈 추가를 통해 개인 정보 차등 보호를 위한 추가적인 단계를 더합니다. 노이즈의 양은 샘플링 분포를 통해 제어할 수 있습니다. 노이즈가 많을수록 더 안전하지만 모델 성능이 저하될 수 있습니다.

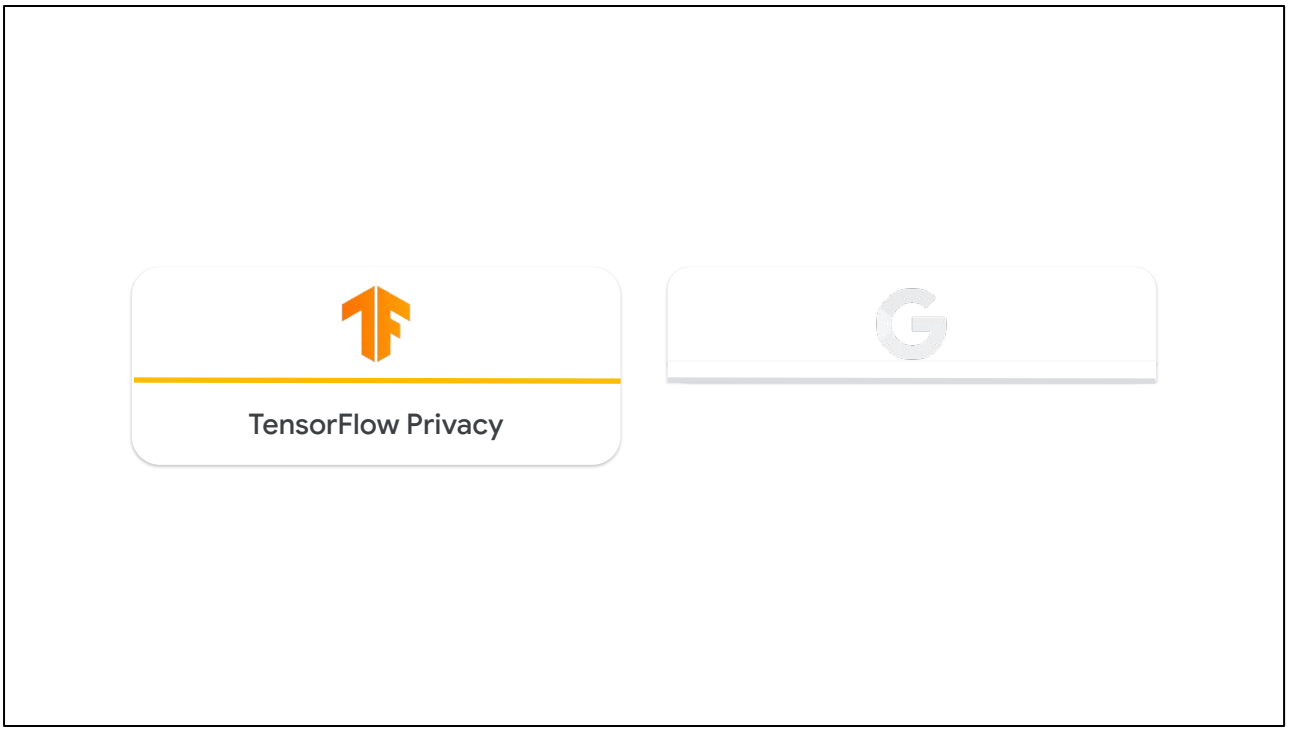
개인 정보 차등 보호 채택을 위한 **DP-SGD** 알고리즘 및 노이즈



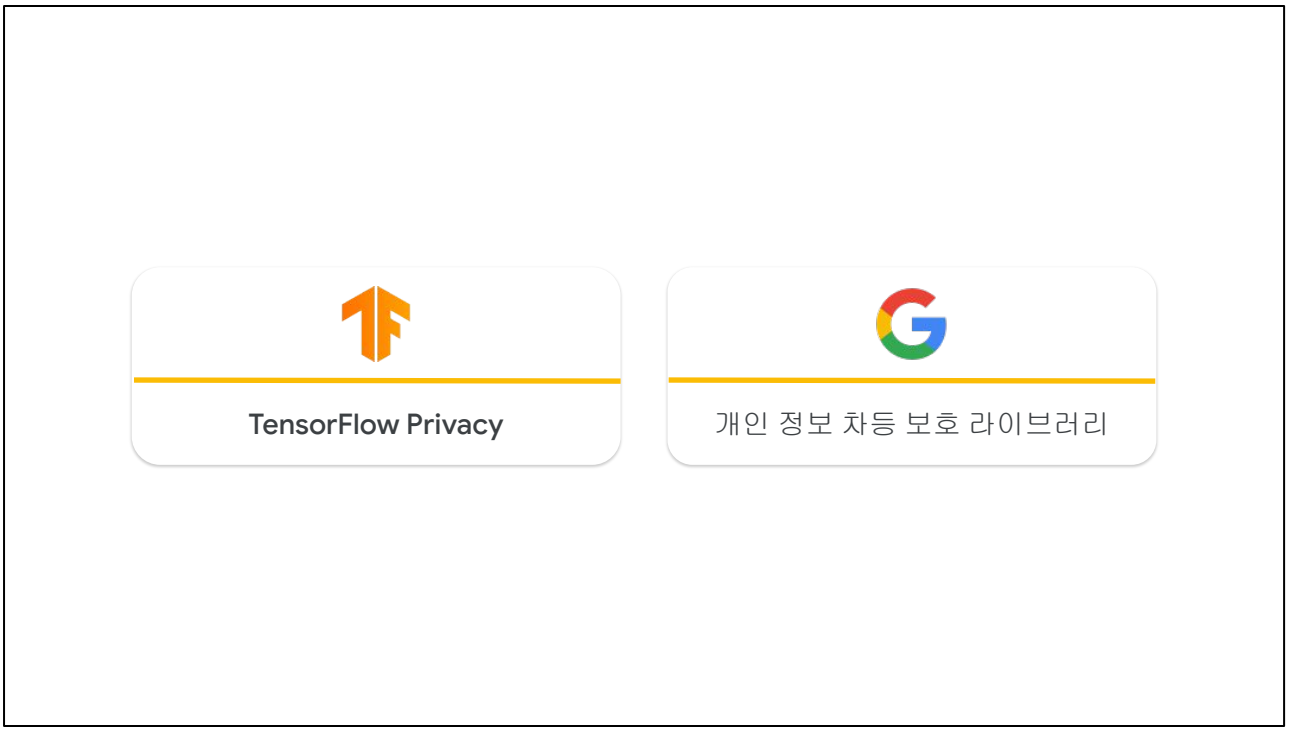
이 추가 단계를 통해 보다 안전한 방식으로 학습에 최적화를 적용할 수 있습니다.



머신러닝 학습에서 개인 정보 차등 보호에 대해 여러 개선사항과 추가 고려사항이 있지만 기존 구현을 사용하여 이를 쉽게 채택할 수 있습니다.



여기에는 TensorFlow Privacy 및



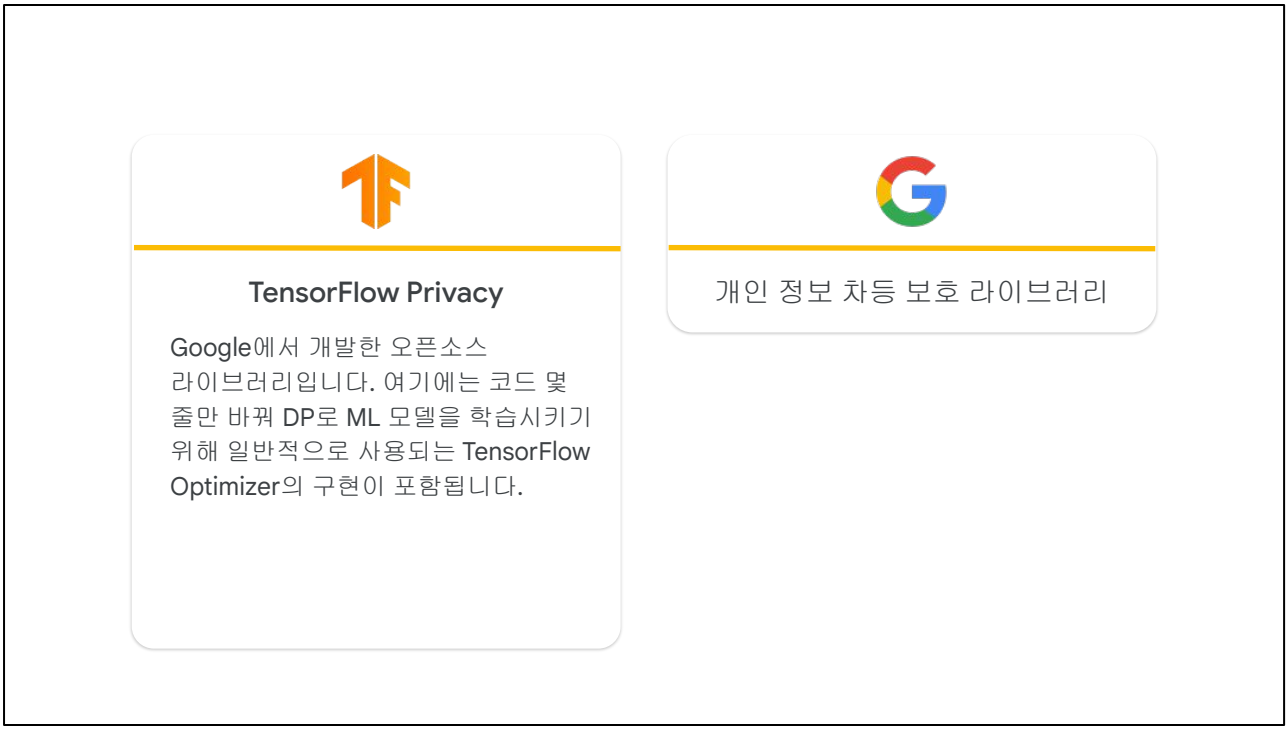
Google의 개인 정보 차등 보호 라이브러리가 포함됩니다.



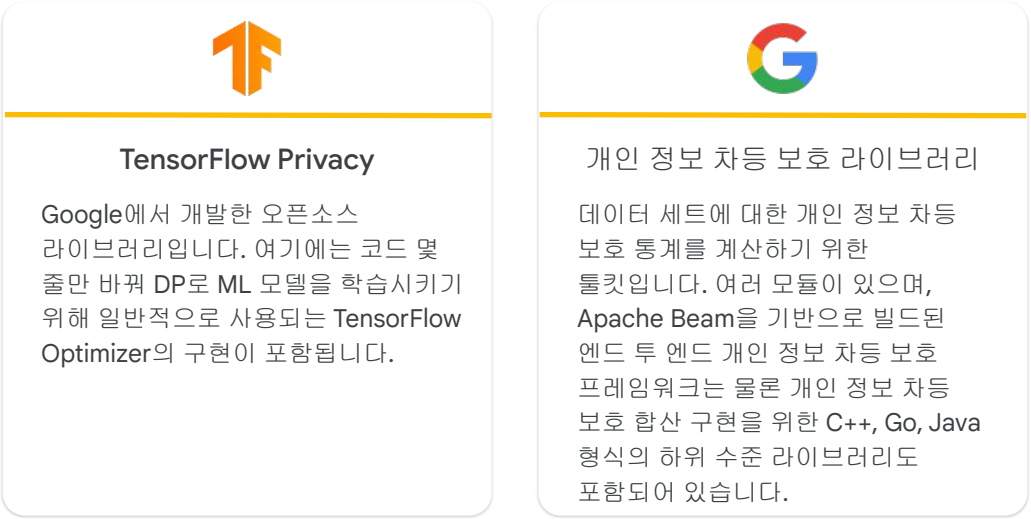
TensorFlow Privacy



개인 정보 차등 보호 라이브러리



TensorFlow Privacy는 TensorFlow 생태계와 잘 통합된 라이브러리입니다. 이 라이브러리를 사용하면 DP-SGD 등의 개인 정보 차등 보호 옵티마이저를 TensorFlow 모델에 쉽게 적용할 수 있습니다.



Google의 개인 정보 차등 보호 라이브러리는 보다 일반적인 라이브러리로 머신러닝 목적으로만 사용되는 것이 아닙니다. 여기에는 Apache Beam을 기반으로 빌드된 엔드 투 엔드 개인 정보 차등 보호 프레임워크는 물론 개인 정보 차등 보호 합산 구현을 위한 C++, Go, Java 형식의 하위 수준 라이브러리도 포함되어 있습니다.



01 AI 개인 정보 보호 개요

02 학습 데이터의 개인 정보 보호: 익명화 기법

03 학습 데이터의 개인 정보 보호: 무작위 순서 지정 기법

04 머신러닝 학습의 개인 정보 보호: DP-SGD

05 머신러닝 학습의 개인 정보 보호: 제휴 학습

06 Google Cloud의 시스템 보호

07 시스템 보안 및 생성형 AI

08 실습: TensorFlow Privacy를 사용한 머신러닝의 개인 정보 차등 보호

이제 다음 방법인 제휴 학습으로 넘어가 보겠습니다.



제휴 학습은 원시 데이터를 공유할 필요가 없어 데이터 개인 정보를 보호하면서

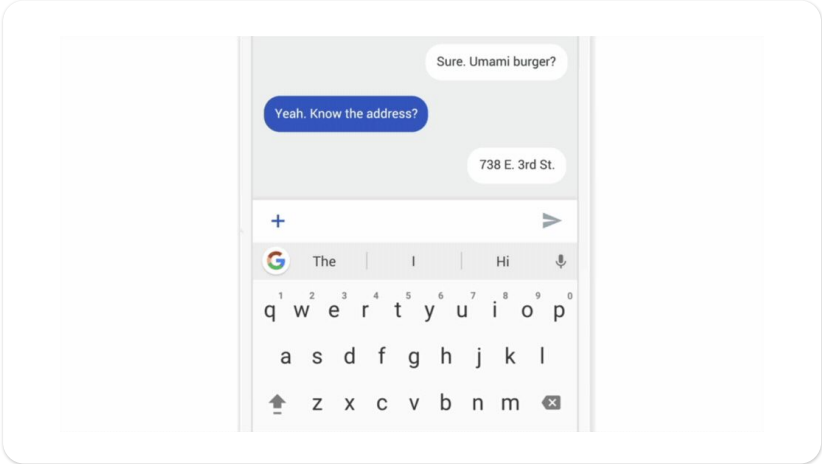


스마트폰과 같은 에지 기기를 사용하여



대규모 머신러닝 모델을 학습시키는 데 유용한 방법입니다.

Gboard의 제휴 학습



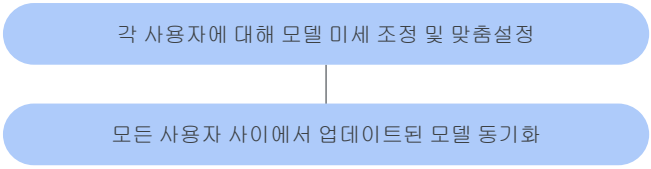
이 기법은 Gboard를 포함한 다수의 Google 서비스 및 애플리케이션에 채택되었습니다.
Gboard에는 사용자 입력을 기반으로 스마트폰에서 사용자의 입력 경험을 향상시키기 위한

Gboard의 제휴 학습

각 사용자에 대해 모델 미세 조정 및 맞춤설정

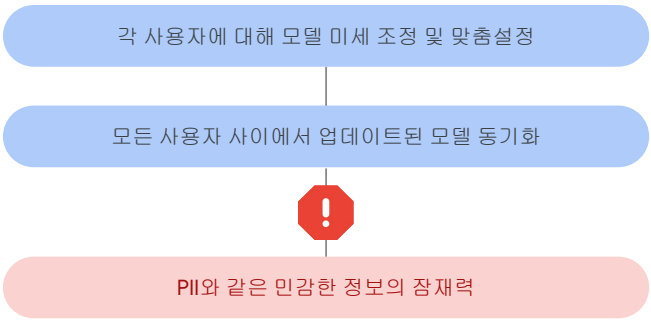
여러 머신러닝 모델이 있습니다.
사용자마다 사용량과 요구사항이 다르므로 사용자별로 모델을 미세 조정하고
맞춤설정하는 것은 고유한 요구를 지원하는 데 매우 중요하며

Gboard의 제휴 학습



모든 사용자 사이에서 업데이트된 모델을 동기화하여 제품 자체를 개선하는 것도 중요합니다.

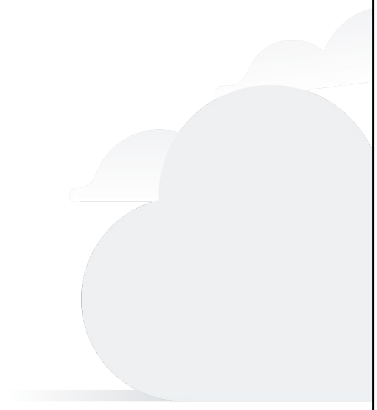
Gboard의 제휴 학습



하지만 타이핑 입력에는 사용자가 머신러닝 학습을 위해 중앙 서버로 전송하고 싶어 하지 않는 PII 등의 민감한 정보가 포함될 수 있습니다.

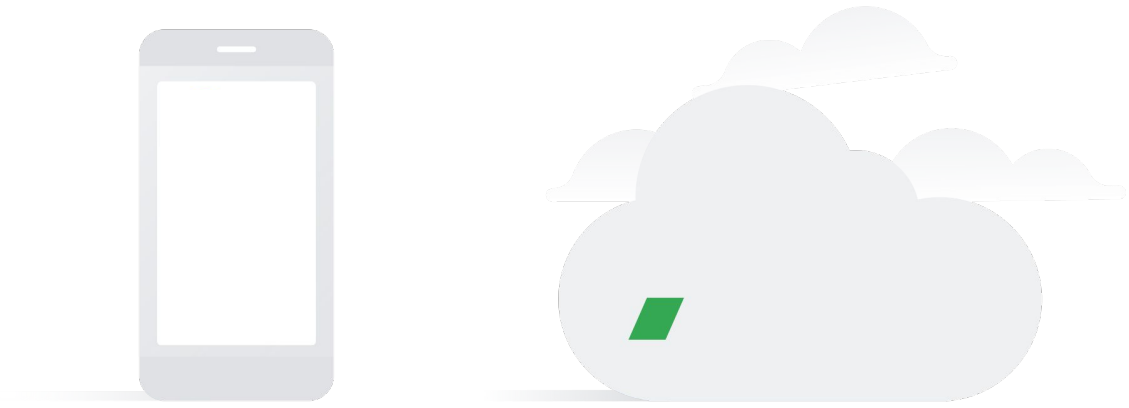
이 사용 사례에서 제휴 학습은 개인 정보 보호와 맞춤설정을 모두 만족하는 중요한 방법입니다. Google은 그동안 이 기술을 사용하는 많은 시스템을 구현했습니다.

제휴 학습



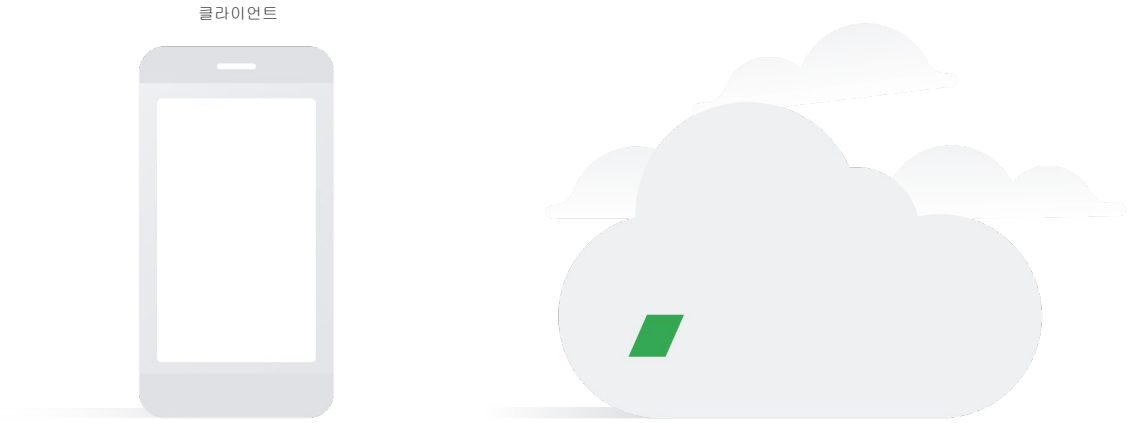
어떻게 작동하는지 살펴보겠습니다.

제휴 학습



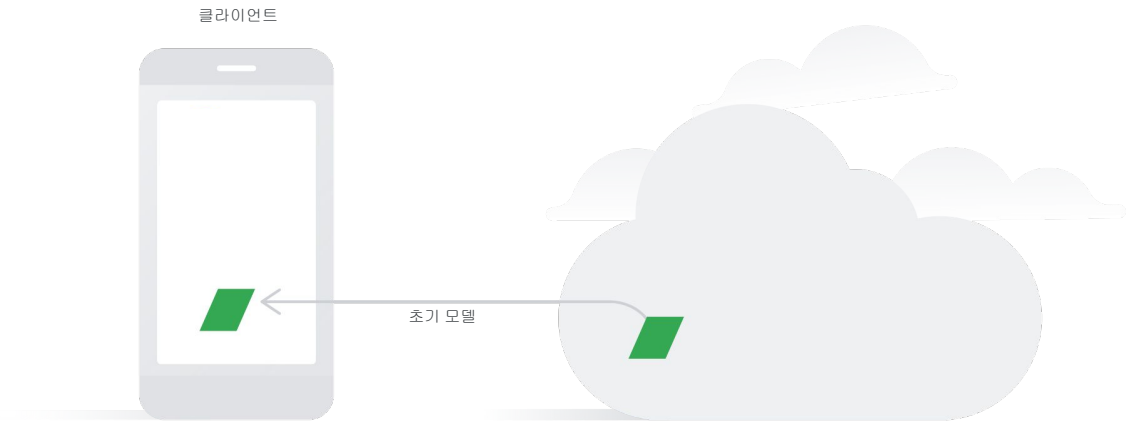
머신러닝 모델이 포함된 모바일 애플리케이션을 빌드했다고 상상해 보세요.

제휴 학습



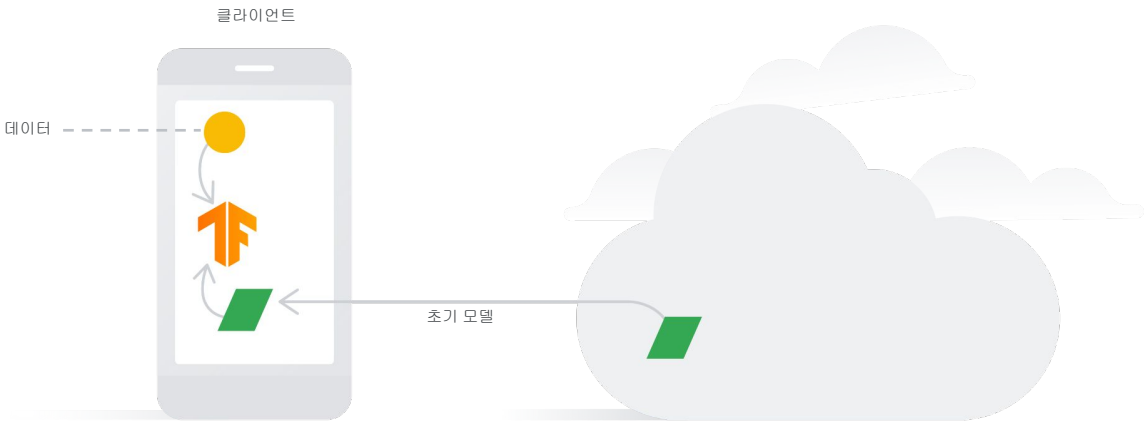
표준 데이터 세트로 첫 번째 모델을 학습시키고

제휴 학습



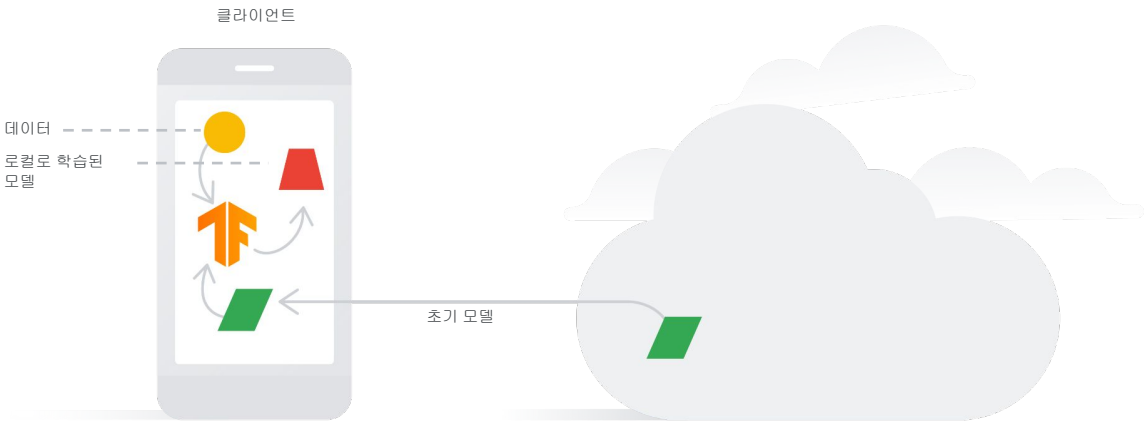
사용자 기기에 앱을 배포했습니다.

제휴 학습



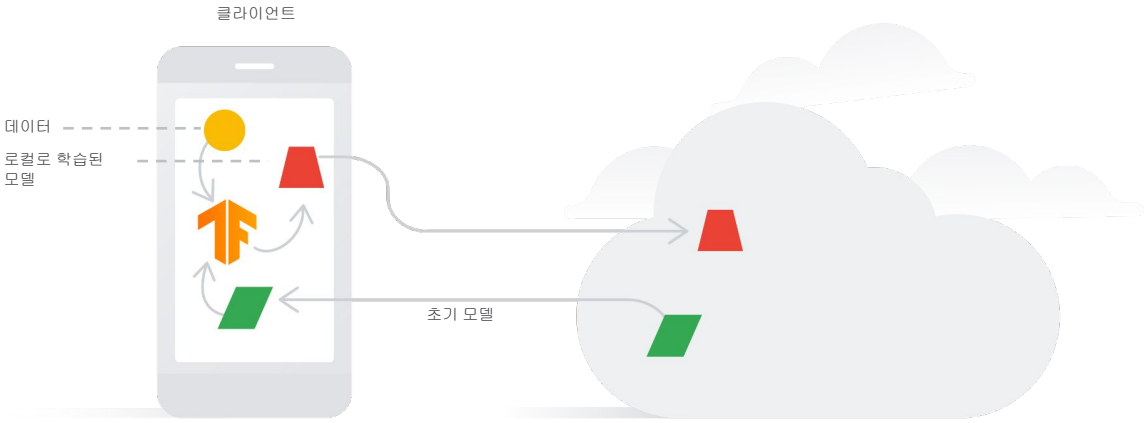
Gboard 맞춤설정이 작동하는 방식과 마찬가지로 제휴 학습은

제휴 학습



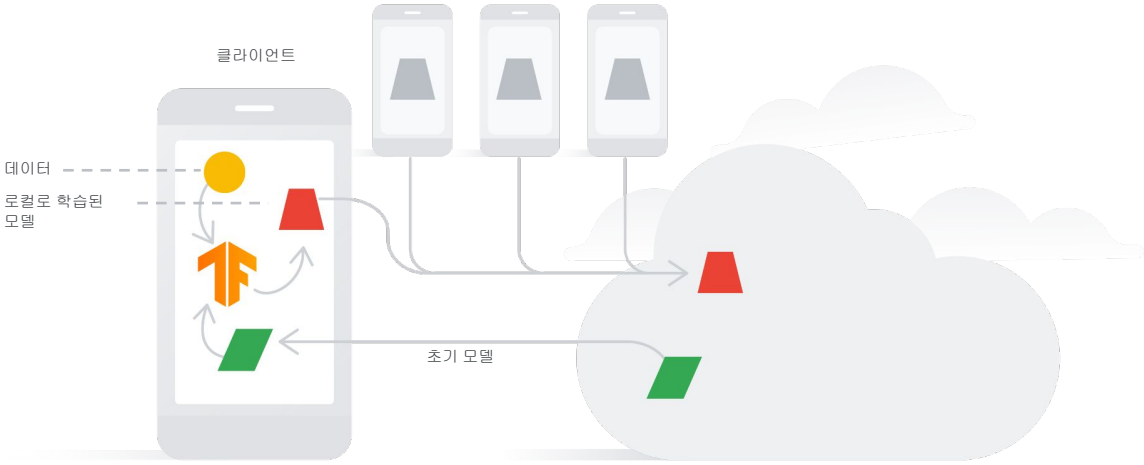
자체 데이터를 사용하여 스마트폰과 같은 사용자 기기의 머신러닝 모델을 업데이트할 수 있습니다.

제휴 학습



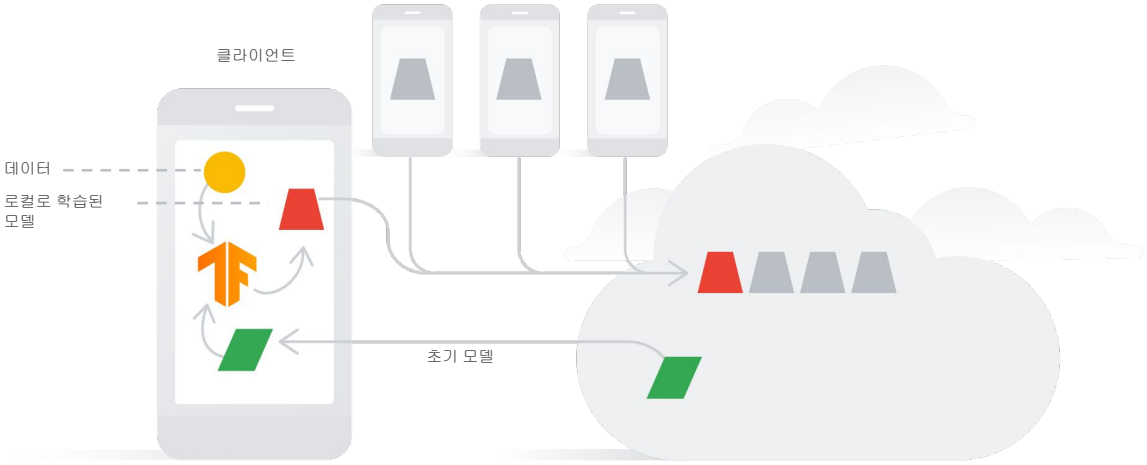
로컬 업데이트 이후에는 변경사항이 중앙 모델이 반영될 수 있도록 개선된 모델 파라미터(경사)가 중앙 서버와 공유됩니다. 그러면 중앙 모델은 개인 정보 보호를 손상시키지 않으면서 모든 사용자에게 이점을 제공하는 최신 데이터를 사용하여 업데이트된 모델을 통해 개선됩니다.

제휴 학습



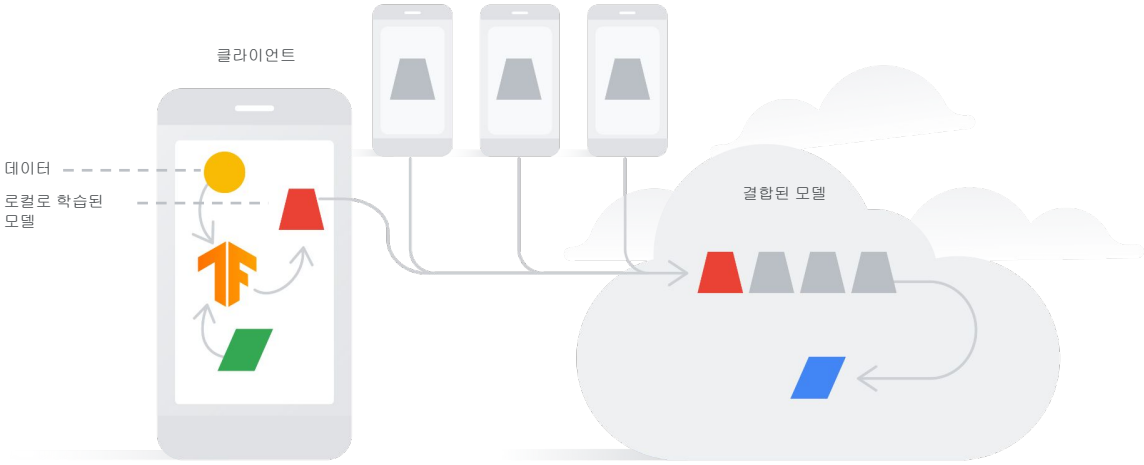
사용자 기기에서 원시 데이터를 수집하지 않고도 수많은 기기에서 많은 업데이트 정보가 수집됩니다.

제휴 학습



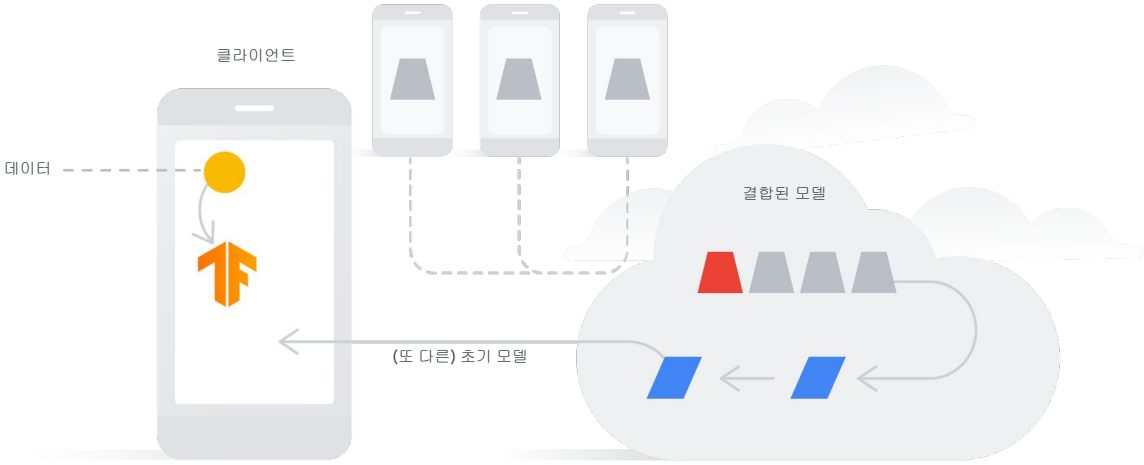
실제 사례에서는 데이터 왜도와 같은 의도하지 않은 결과를 방지하려면 사용자 샘플링 방법을 신중하게 설계해야 합니다.

제휴 학습



그런 다음 경사를 합산하여 중앙 모델을 업데이트합니다.

제휴 학습



이러한 제휴 학습 단계를 따르면 실제 사용자의 데이터를 사용하여 모델을 업데이트하는 동시에 각 기기에 이를 유지할 수 있습니다.
이러한 과정을 반복하여 모델을 업데이트할 수 있습니다.

TensorFlow Federated(TFF)는 분산된 데이터에 대한 제휴 학습을 위한 **OSS**입니다



제휴 학습의 개념은 단순해 보일 수 있지만 여러 시스템이 함께 작동해야 하는 만큼 구현하고 구성하기가 까다롭습니다.

TensorFlow Federated(TFF)는 이러한 목적에 맞는 유용한 도구 상자를 제공합니다.

TensorFlow Federated(TFF)는 분산된 데이터에 대한 제휴 학습을 위한 OSS입니다



- 사용자의 모델 및 데이터에 대한 제휴 학습 알고리즘을 시뮬레이션합니다.

TFF를 사용하면 제휴 학습 환경을 빠르게 시뮬레이션하고

TensorFlow Federated(TFF)는 분산된 데이터에 대한 제휴 학습을 위한 **OSS**입니다



- 사용자의 모델 및 데이터에 대한 제휴 학습 알고리즘을 시뮬레이션합니다.
- 새로운 제휴 학습 알고리즘을 실험합니다.

복잡하고 새로운 알고리즘을 적용할 수 있습니다.

TensorFlow Federated(TFF)는 분산된 데이터에 대한 제휴 학습을 위한 OSS입니다



- 사용자의 모델 및 데이터에 대한 제휴 학습 알고리즘을 시뮬레이션합니다.
- 새로운 제휴 학습 알고리즘을 실험합니다.
- 제휴 분석과 같은 비학습 계산을 구현하는 데에도 TFF를 사용할 수 있습니다.

심지어는 모든 사용자 행동의 평균을 계산하는 등의 머신러닝 외 학습 용도로도 TFF를 사용할 수 있습니다. 이를 제휴 분석이라고 합니다.

일반적인 제휴 학습의 여러 문제점



제휴 학습 기법은 멋지게 들리지만 여전히 몇 가지 문제를 해결해야 합니다. 예를 들면 다음과 같습니다.

일반적인 제휴 학습의 여러 문제점

멤버십 추론 공격	민감한 재산 침해	모델 포이즈닝
서버에서 사용자의 경사 업데이트를 검사할 수 있으며, 경사 업데이트의 원본 데이터를 재구성하거나 추론할 수 있습니다.		

멤버십 추론 공격: 이는 머신러닝 모델에 대한 개인 정보 중심의 공격입니다. 이 공격에서 경사(또는 중앙 모델 제공업체)에 액세스할 수 있는 공격자는 특정 데이터 레코드나 데이터 포인트가 경사의 추론을 토대로 대상 모델을 학습시키는 데 사용되었는지 파악하려고 시도합니다.

일반적인 제휴 학습의 여러 문제점

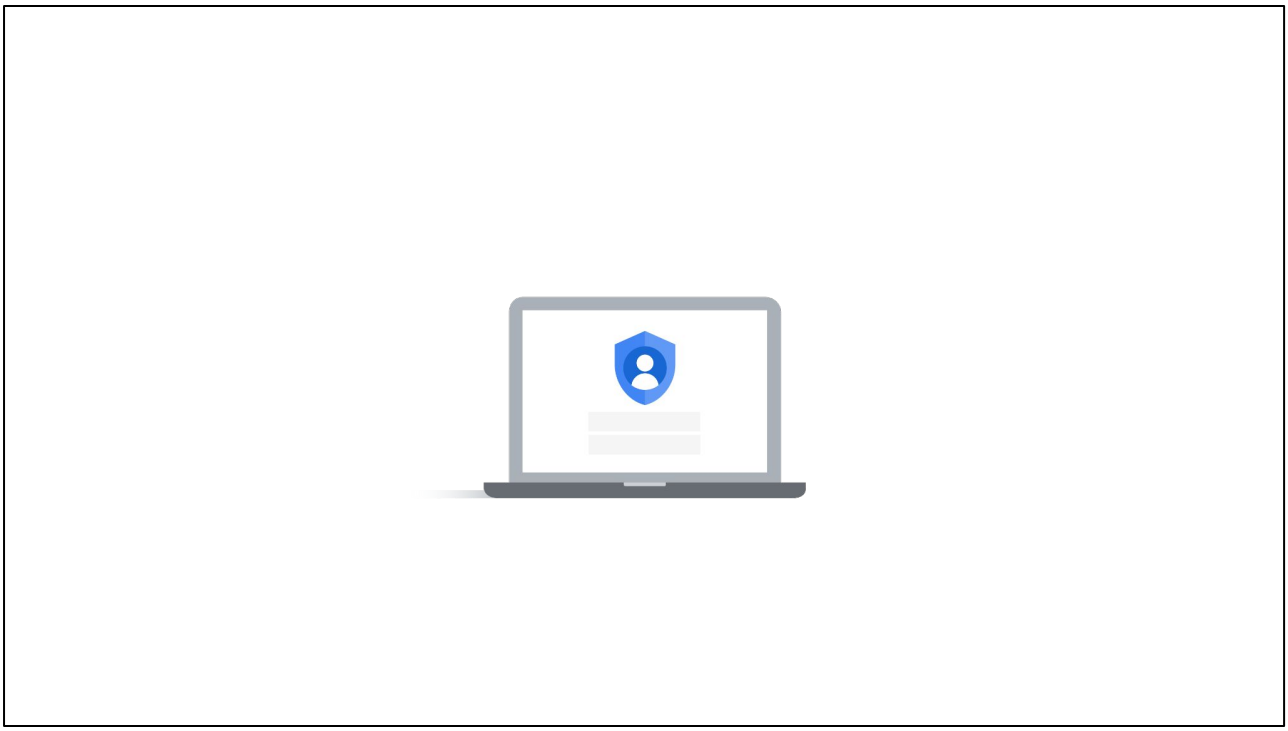
멤버십 추론 공격	민감한 재산 침해	모델 포이즈닝
서버에서 사용자의 경사 업데이트를 검사할 수 있으며, 경사 업데이트의 원본 데이터를 재구성하거나 추론할 수 있습니다.	합산된 모델은 민감한 정보를 기억할 수 있습니다.	

민감한 재산 침해: 이 공격은 멤버십 추론 공격과 유사하지만 모델이 학습한 민감한 특성이나 패턴이 노출된다는 점이 다릅니다. 이러한 노출은 경사의 민감한 특성을 재구성하는 과정에서 발생합니다.

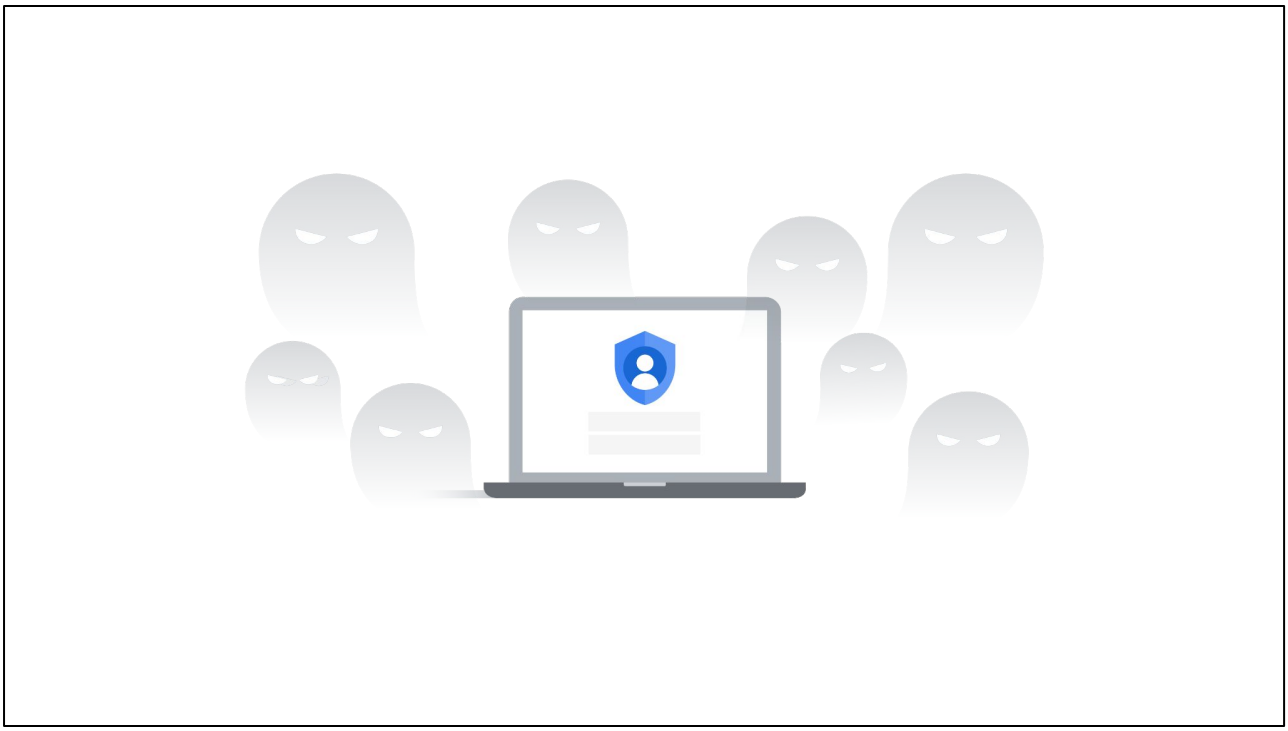
일반적인 제휴 학습의 여러 문제점

멤버십 추론 공격	민감한 재산 침해	모델 포이즈닝
서버에서 사용자의 경사 업데이트를 검사할 수 있으며, 경사 업데이트의 원본 데이터를 재구성하거나 추론할 수 있습니다.	합산된 모델은 민감한 정보를 기억할 수 있습니다.	악의적인 사용자는 의도적으로 모델이 오염된 데이터를 학습하게 하고 업데이트를 중앙 서버로 보내어 추론에 개입할 수 있습니다.

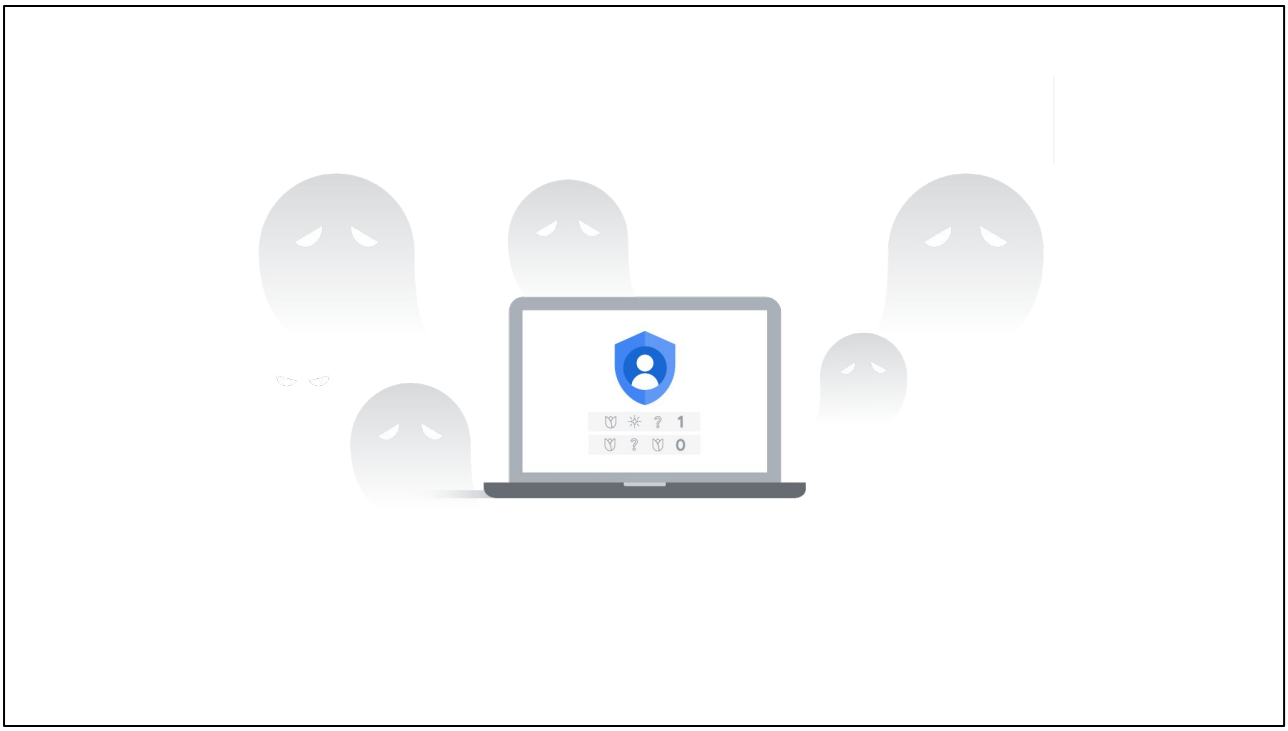
모델 포이즈닝: 이는 제휴 학습 프로세스에 참여하는 사용자가 모델 행동을 조작하고 의도적으로 '오염된' 데이터 포인트를 기기에 생성하여 모델 성능을 저하시킴으로써 잘못된 예측을 하거나 공격자에게 득이 되는 동작을 일으키려는 경우에 발생합니다. 공유된 경사에 이상 감지를 적용하더라도 공급업체가 데이터 자체를 알 수 없으므로 일련의 경사가 악의적인 사용자로부터 온 것인지 아니면 고유한 행동을 가진 사용자로부터 온 것인지 구별하기 어렵습니다.



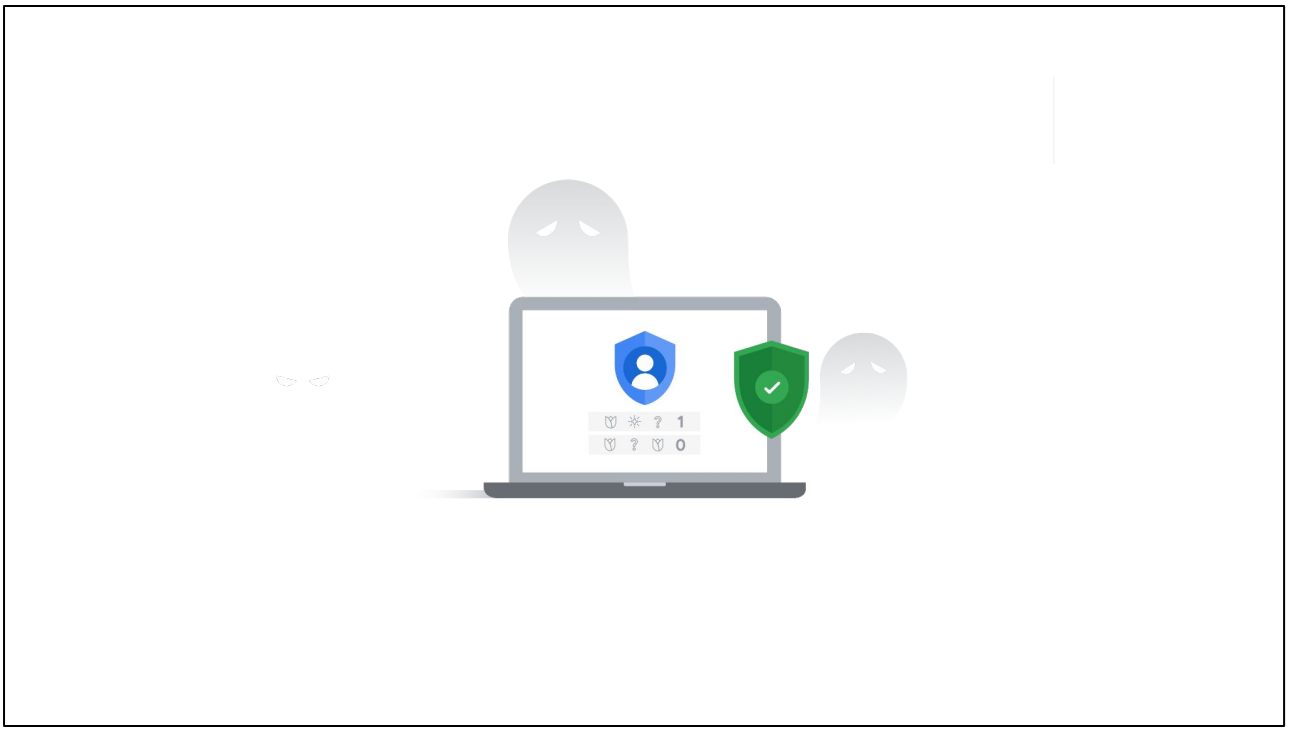
모든 문제를 한 번에 해결할 수 있는 완벽한 솔루션은 없지만



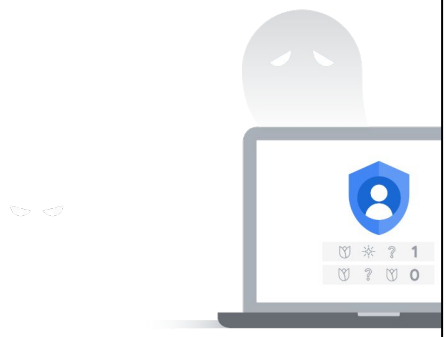
보안 집계 방법을 사용하면 멤버십 추론 공격과 민감한 재산 침해를 피하는 데 도움이 될 수 있습니다.



보안 집계는 데이터를 서버로 전송하기 전에 암호화하여

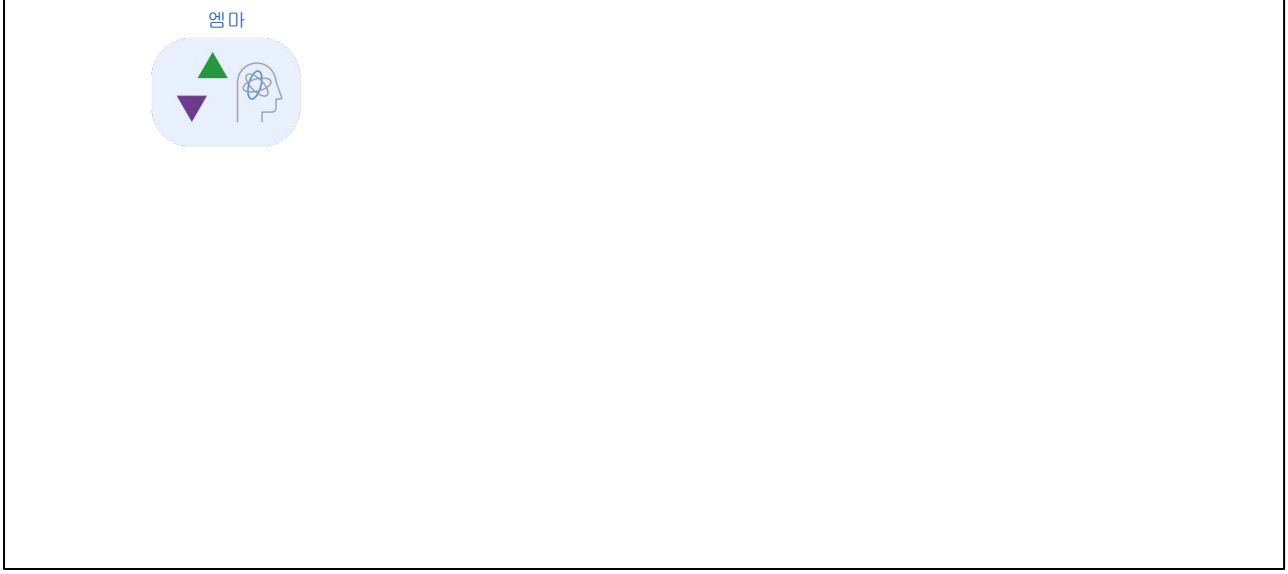


안전한 방식으로 여러 데이터를 합산하는 데 사용되는 암호화 방식입니다.


1
0

엠마





엠마, 타쿠미, 닉의 데이터 포인트 3개를 합한 값을

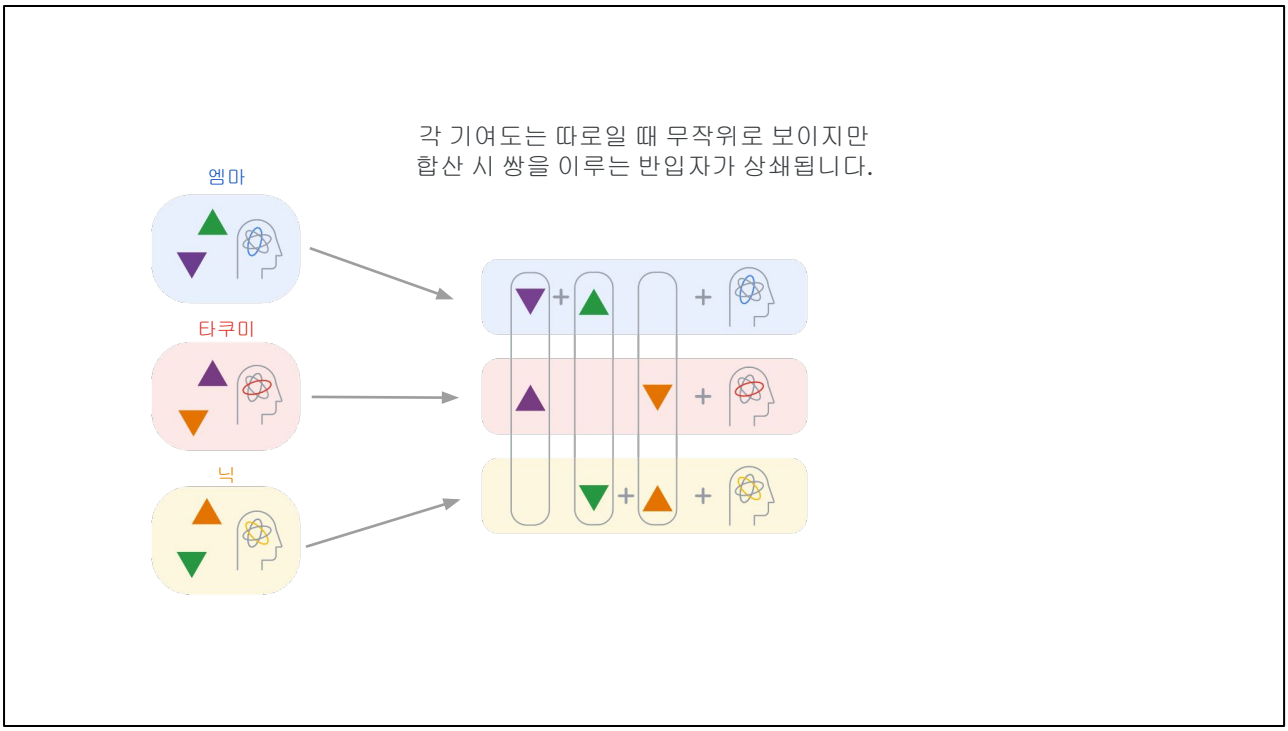


계산한다고

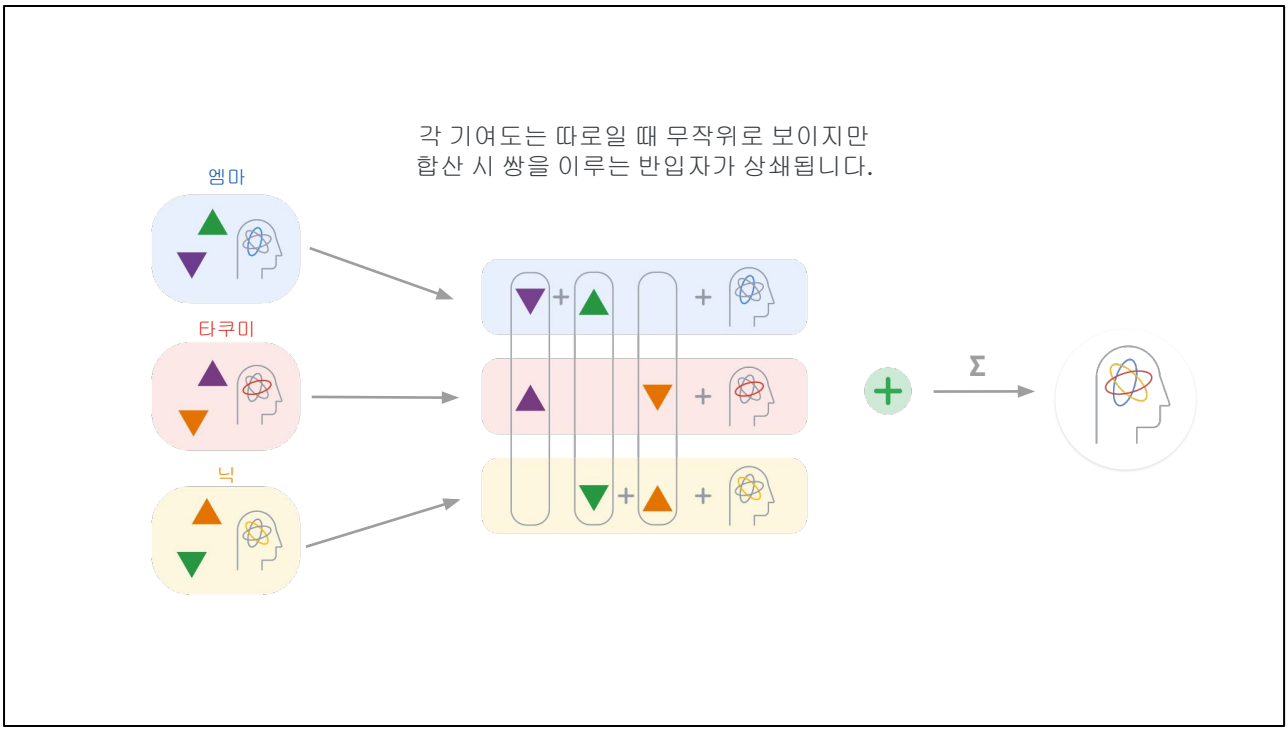
각 기여도는 따로일 때 무작위로 보입니다.



가정해 보겠습니다. 보안 집계에서는 단순히 데이터를 중앙 서버에 추가하는 것이 아니라 참가자가 다른 참가자와 공유된 값을 추가하여 값을 약간 수정합니다. 페어링된 두 값의 합계는 최대 0입니다.



이 경우 엠마와 닉은 초록색 값 쌍을 공유하고 엠마와 타쿠미는 보라색을 공유하며 타쿠미와 닉은 주황색을 공유합니다.



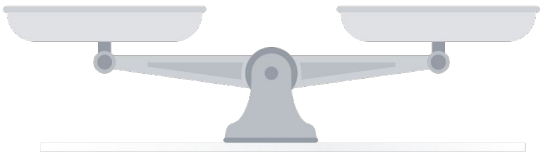
서버는 이러한 섭동 값을 수신하여 합산합니다. 쌍은 최대 0으로 합산되므로 값은 합산 결과에 영향을 미치지 않습니다. 하지만 서버에서 원본 데이터를 재구성하기는 수정으로 인해 훨씬 어렵습니다.

보안 집계를 추가할 경우 보다 안전한 방식으로 제휴 학습을 적용할 수 있습니다.

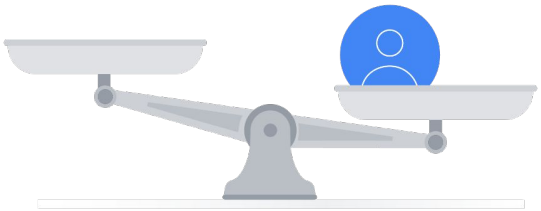


또한 제휴 학습에서도 개인 정보 차등 보호를 사용할 수 있습니다.
클라이언트가 경사에 노이즈를 추가하거나 서버가 이를 처리할 수 있습니다.

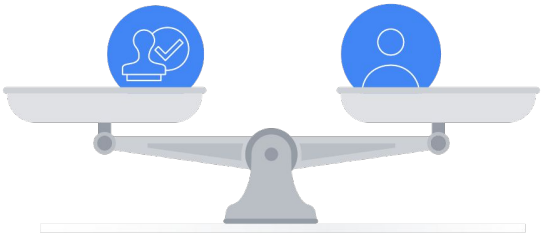
제휴 학습에 개인 정보 차등 보호를 적용하면 경사로 인해 특정 사용자의 민감한 정보가 공개될 위험이 완화됩니다. 또한 데이터 포이즈닝 방지를 위한 더 견고한 업데이트 전략을 세울 수 있습니다.



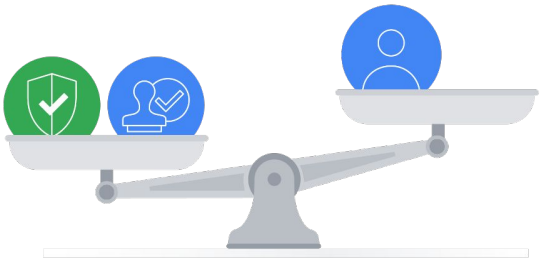
하지만 완벽한 솔루션은 없으며, 기법마다 여러 요소 간의 장단점이 있음을 인지해야 합니다.



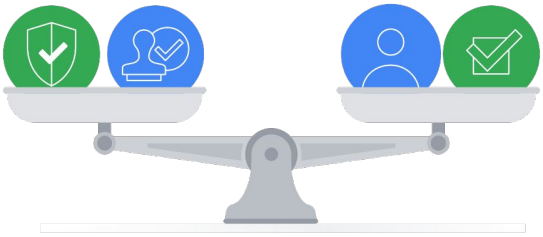
이러한 요소로는 개인 정보 보호,



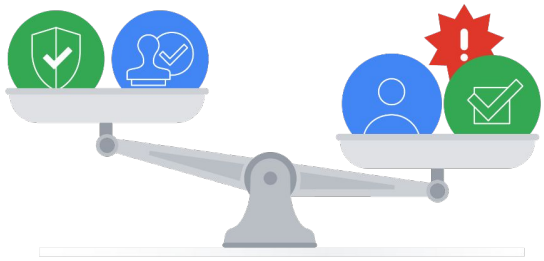
성능,



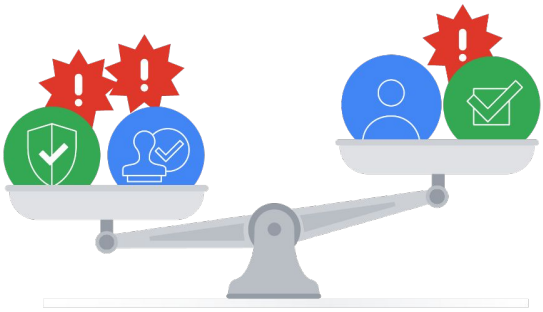
견고성,



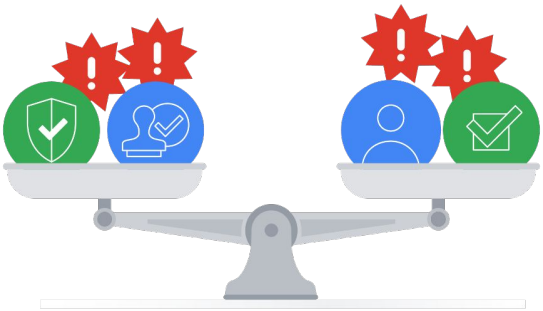
공정성 등이 있습니다.



더 강력한 개인 정보 보호를 위해 개인 정보 차등 보호를 사용하는 대규모 노이즈를 적용할 경우 성능에 영향을 미칠 수 있습니다.



개인 정보 차등 보호는 프로세스를 견고하게 할 수 있지만 이로 인해 시스템에서 고유했거나 나머지 데이터에 비해 소수에 속했던 사용자의 데이터가 우선순위에서 제외될 수도 있습니다. 이는 잠재적으로 편향 문제로 이어질 수 있습니다



요약하자면, 머신러닝 모델의 강력한 개인 정보 보호를 보장하기 위해서는 시스템 요건을 이해한 다음



제대로 된 여러 측정항목과 기준을 사용하여 시스템을 평가하는 것이 중요합니다.



01 AI 개인 정보 보호 개요

02 학습 데이터의 개인 정보 보호: 익명화 기법

03 학습 데이터의 개인 정보 보호: 무작위 순서 지정 기법

04 머신러닝 학습의 개인 정보 보호: DP-SGD

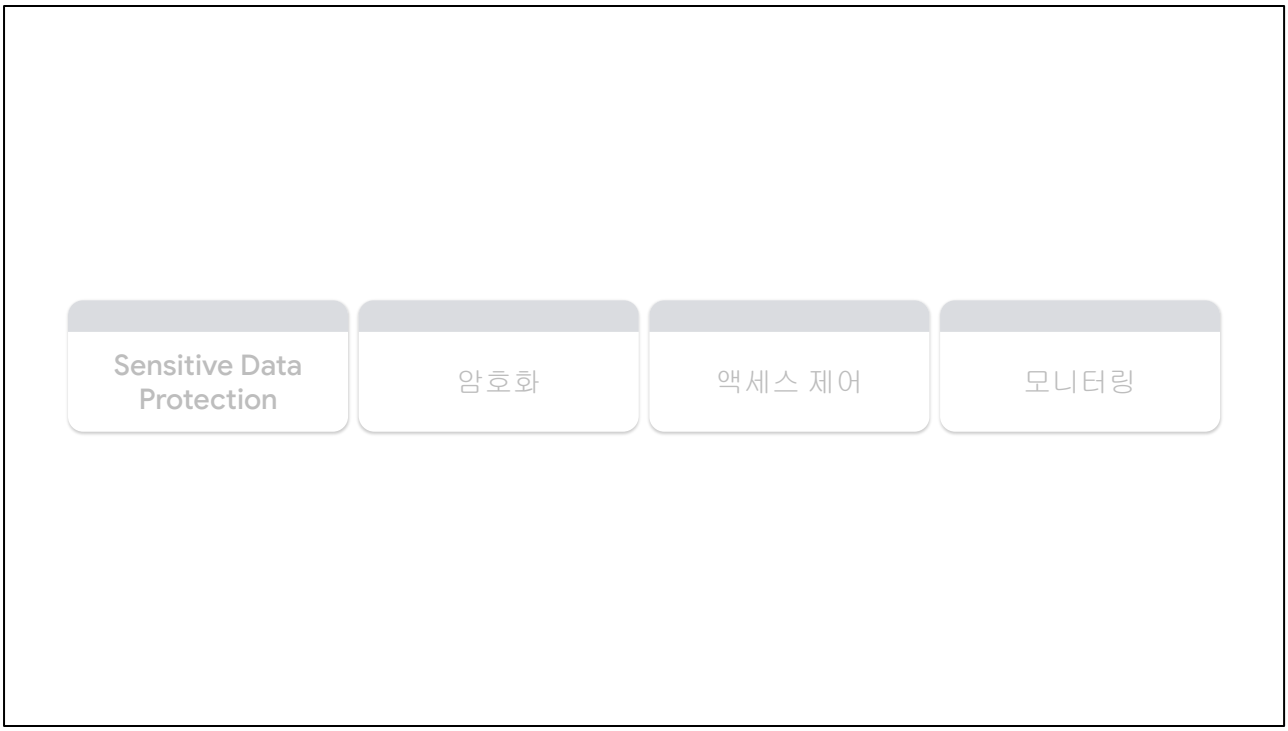
05 머신러닝 학습의 개인 정보 보호: 제휴 학습

06 Google Cloud의 시스템 보호

07 시스템 보안 및 생성형 AI

08 실습: TensorFlow Privacy를 사용한 머신러닝의 개인 정보 차등 보호

지금까지 데이터 및 모델 학습의 개인 정보 보호를 살펴봤습니다. 이제 Google Cloud의 시스템 보안을 살펴보는 시간을 가져보겠습니다.



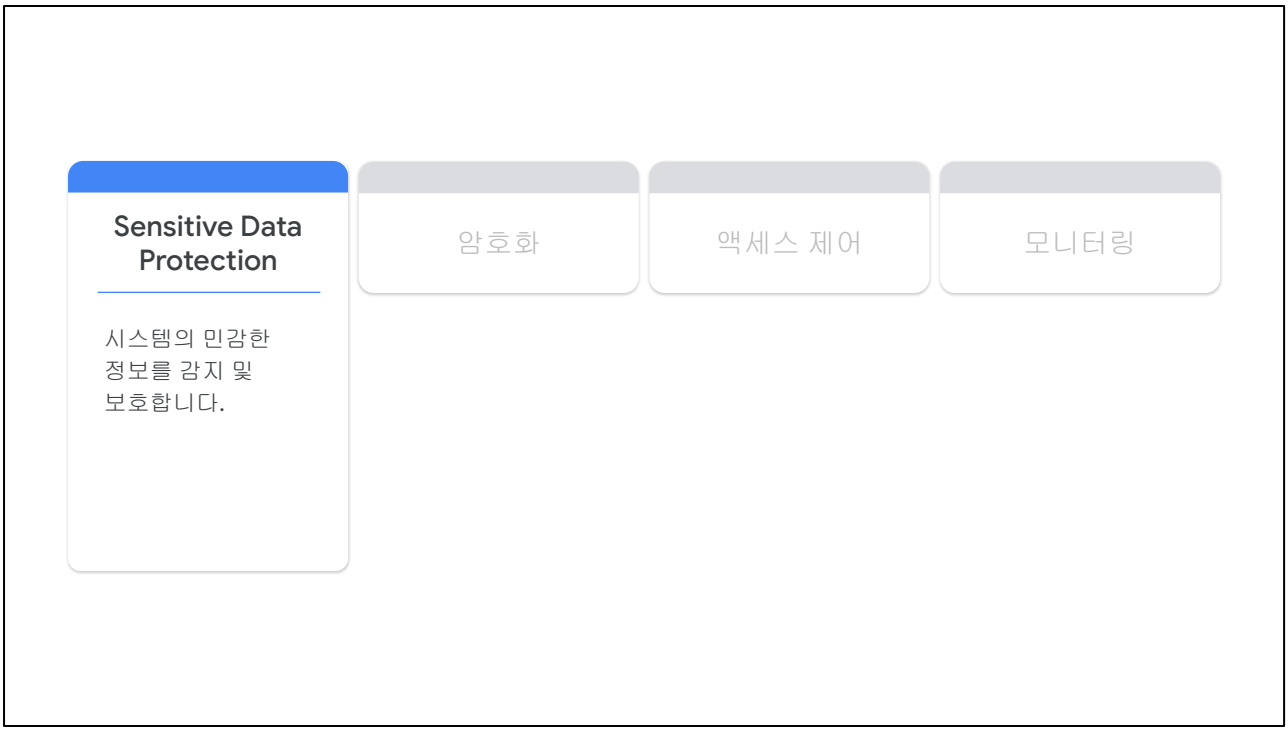
데이터 및 모델 학습의 개인 정보 보호 고려사항에 대해 생각해 보는 것이 중요하지만 액세스 제어 및 모니터링을 포함한 표준적인 시스템 보안 권장사항을 따르는 것도 그에 못지않게 중요합니다.

Sensitive Data Protection

암호화

액세스 제어

모니터링



- Sensitive data protection: 개인 정보가 안전하다고 확신할 수 있도록 온라인 위협을 자동으로 감지 및 예방하는 시스템을 통합합니다.



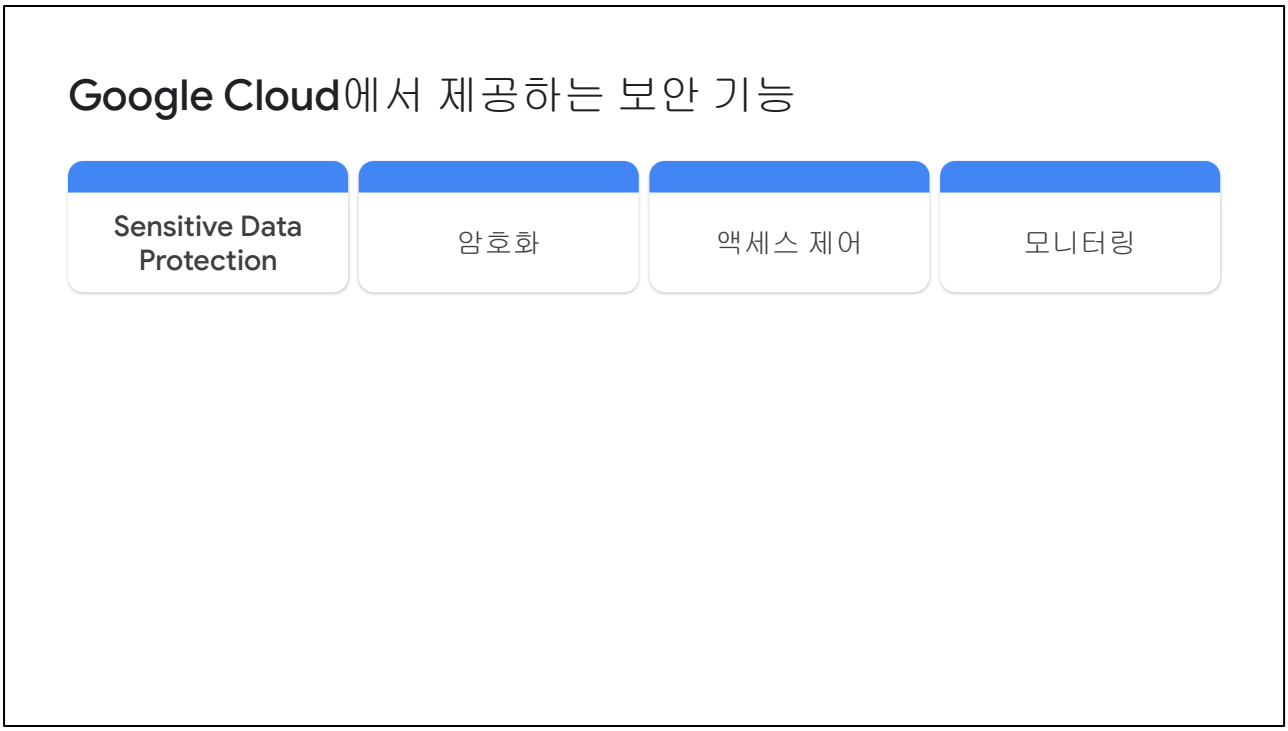
- 암호화: 전송 중이나 저장 중에도 데이터를 비공개로 안전하게 유지합니다.



- 액세스 제어: 최소 권한 액세스 구성을 따르세요. 사람과 사람이 아닌 모두 개인 정보에 대해 필요한 최소한의 접근 권한을 부여받도록 할 수 있습니다.



- 모니터링: 특정 시점 이슈 분석 및 사전 보안 경고를 구현하면 예상치 못한 동작에 대해 신속하게 대응하여 개인 정보를 보호하는 데 도움이 됩니다.



Google Cloud는 매우 포괄적인 보안 제품을 제공합니다.

Google Cloud에서 제공하는 보안 기능

Sensitive Data Protection	암호화	액세스 제어	모니터링
 Sensitive Data Protection 서비스			

Sensitive Data Protection은 Cloud Data Loss Prevention(DLP) API를 통해 제공되며,

Google Cloud에서 제공하는 보안 기능

Sensitive Data Protection	암호화	액세스 제어	모니터링
			
Sensitive Data Protection 서비스	키 관리 서비스		

암호화는 Cloud Key Management Service(KMS)를 통해,

Google Cloud에서 제공하는 보안 기능

Sensitive Data Protection	암호화	액세스 제어	모니터링
			
Sensitive Data Protection 서비스	키 관리 서비스	IAM	

액세스 제어는 Identity & Access Management(IAM)를 통해,

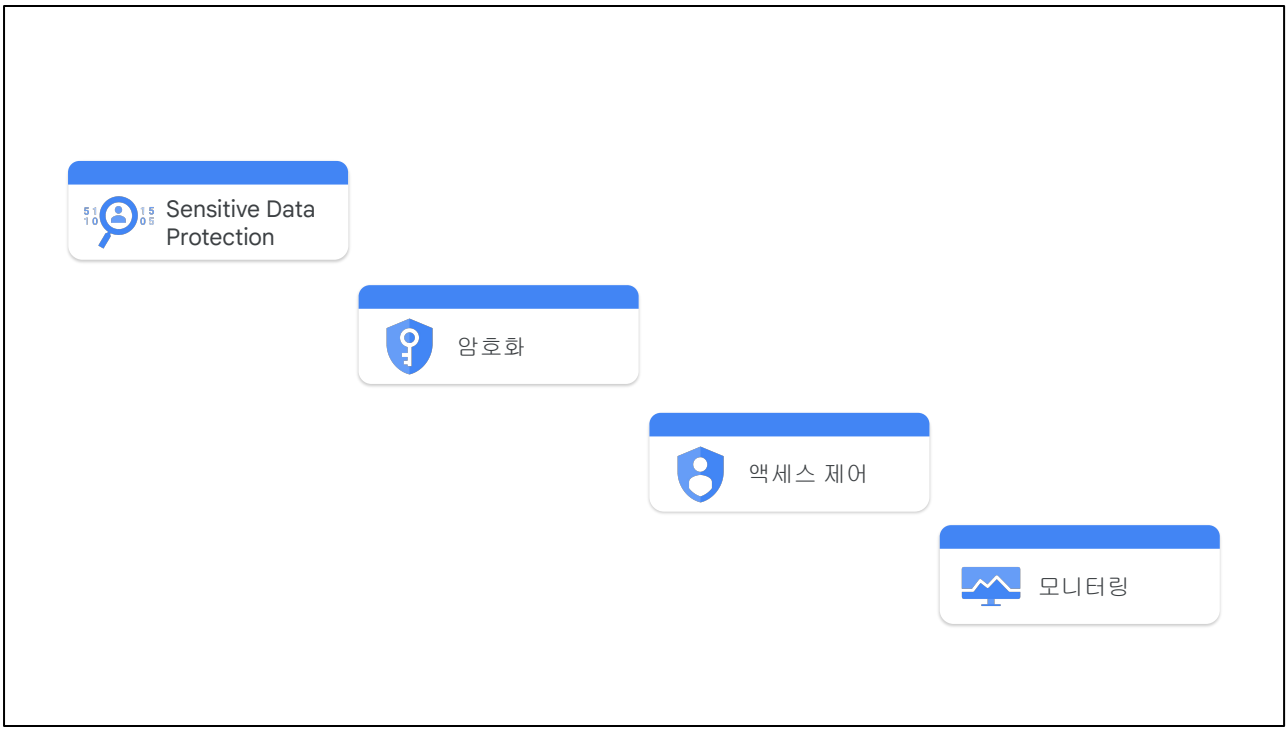
Google Cloud에서 제공하는 보안 기능

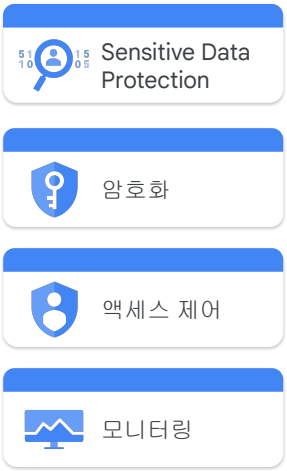
Sensitive Data Protection	암호화	액세스 제어	모니터링
			
Sensitive Data Protection 서비스	키 관리 서비스	IAM	Cloud Monitoring

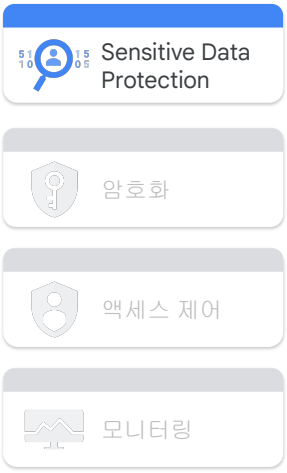
모니터링은 Cloud Monitoring을 통해 제공됩니다.

Google Cloud에서 제공하는 보안 기능



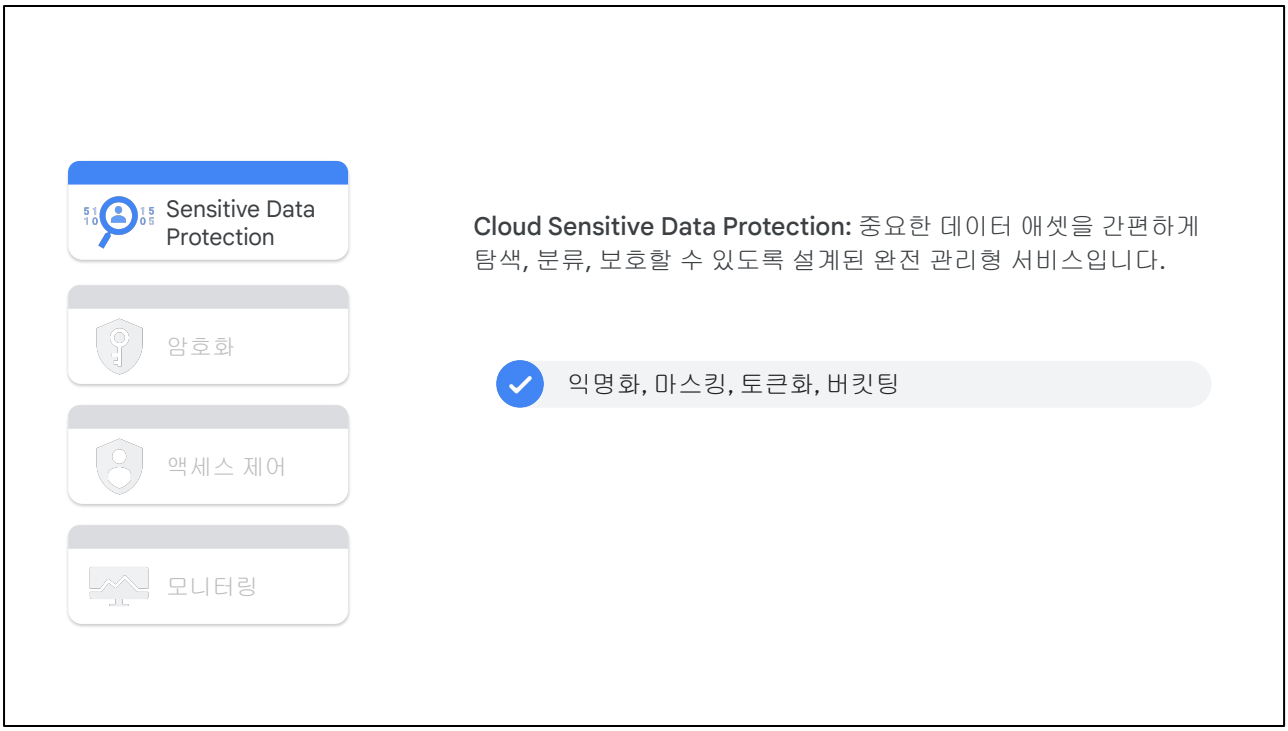

Sensitive Data Protection
암호화
액세스 제어
모니터링


Sensitive Data Protection
암호화
액세스 제어
모니터링

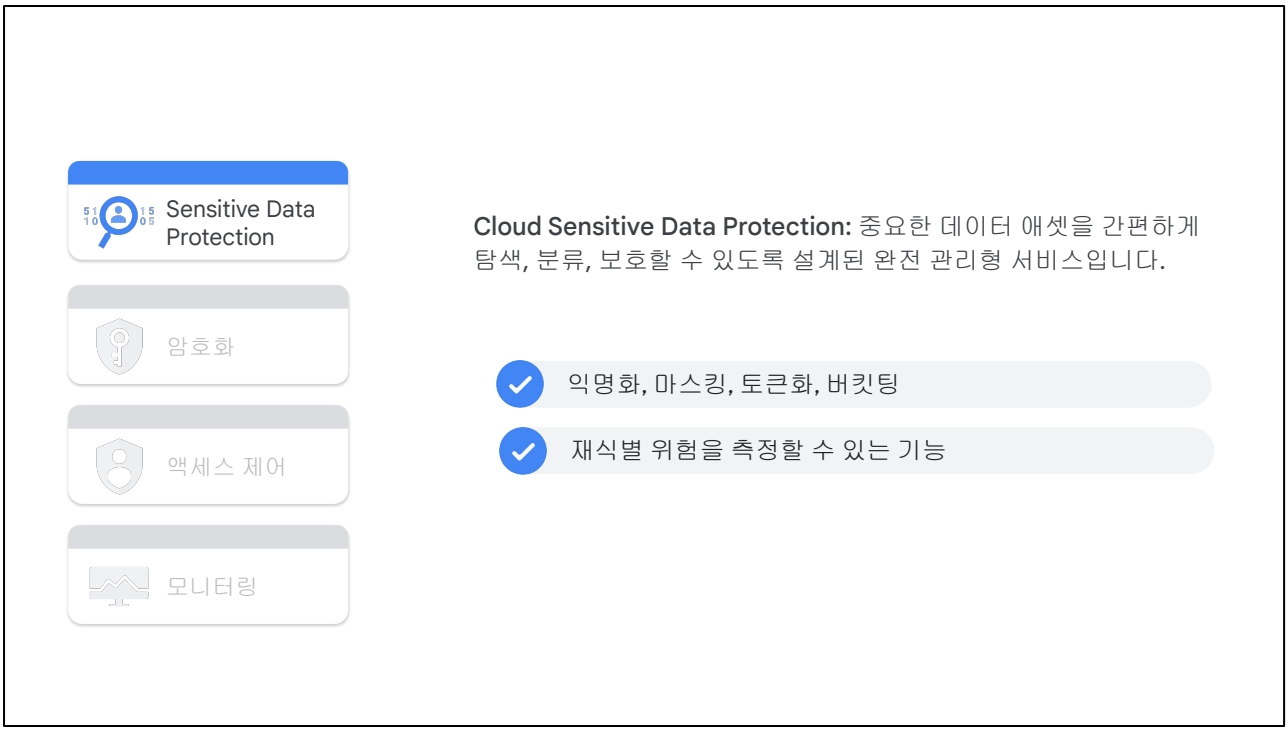


Cloud Sensitive Data Protection: 중요한 데이터 애셋을 간편하게 탐색, 분류, 보호할 수 있도록 설계된 완전 관리형 서비스입니다.

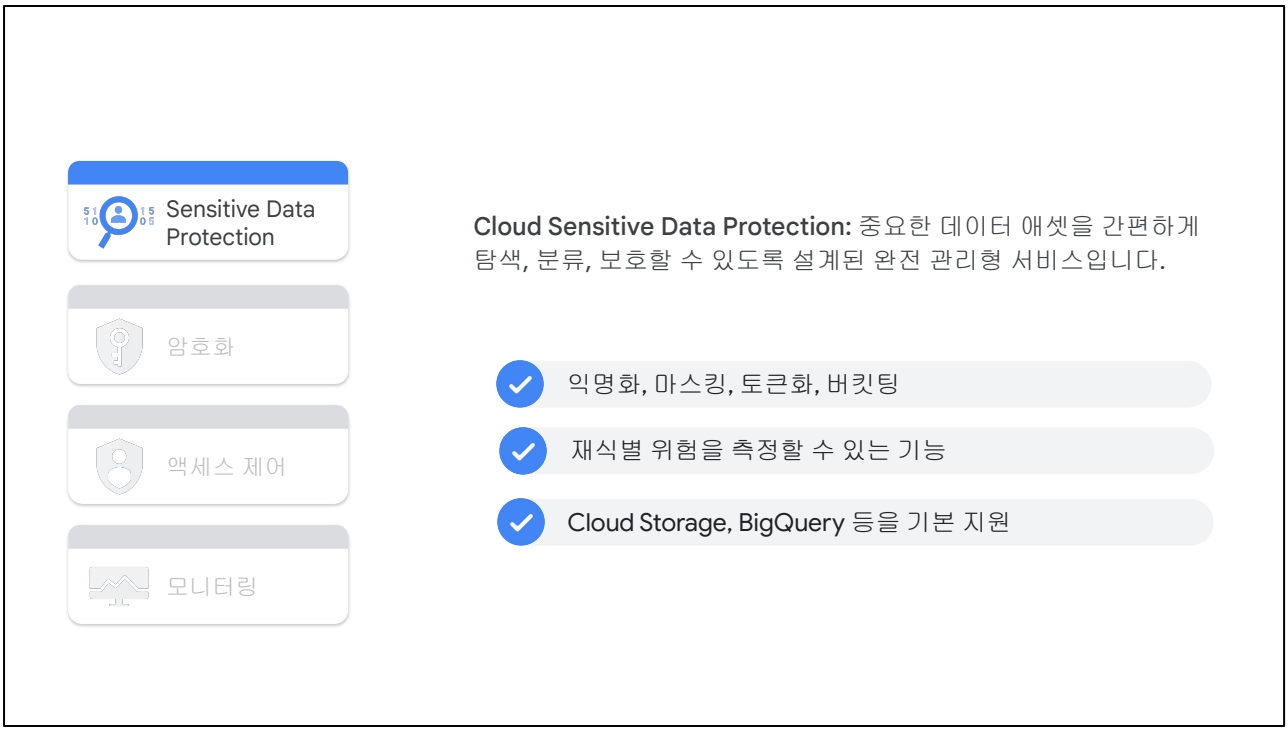
Cloud Data Loss Prevention 서비스를 통한 Sensitive Data Protection은 생태계 전반의 민감한 정보를 탐색하고 제어하고 보고할 수 있게 도와줍니다.
서비스를 통해 제공되는 기능:



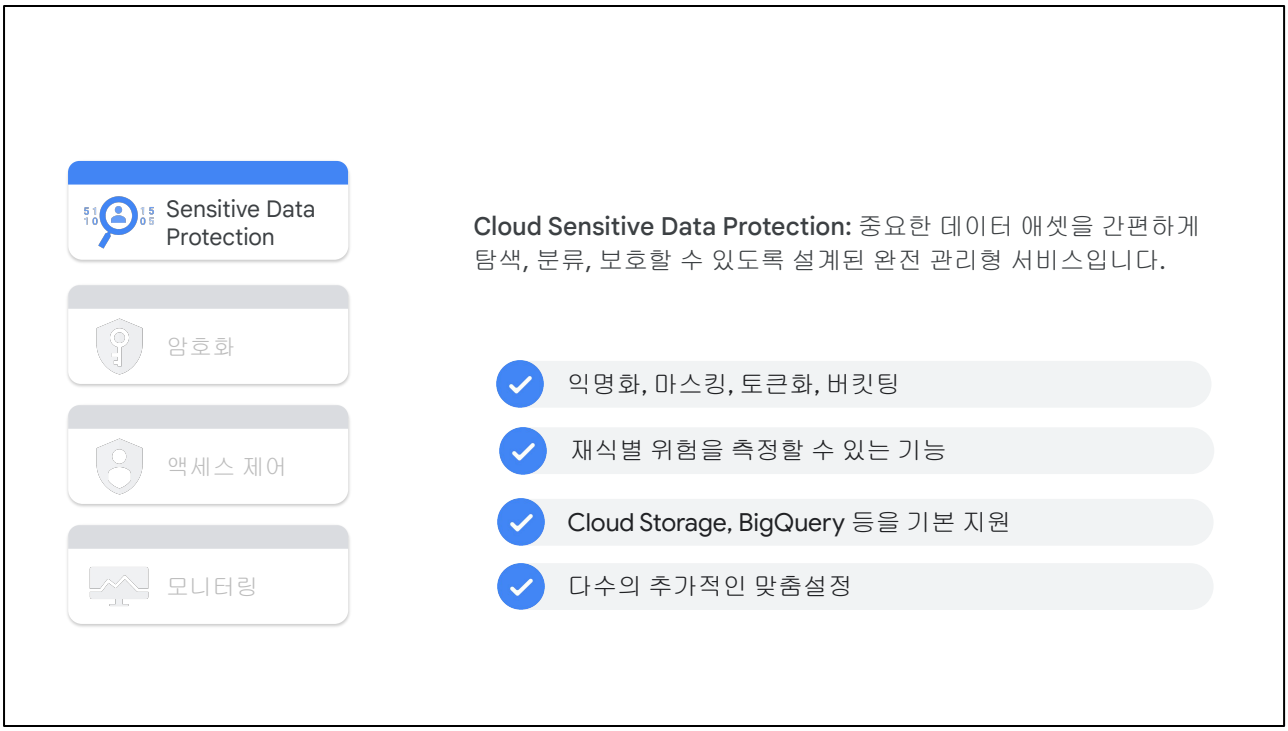
- 마스킹 및 토큰화 등의 익명화 기술과 정형 및 비정형 데이터에 대한 지원.



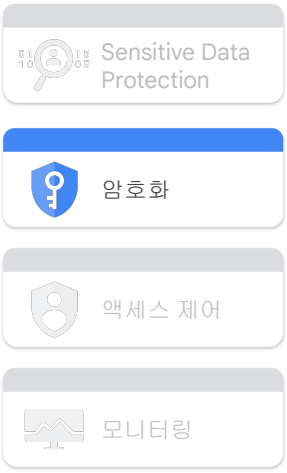
- 정형 데이터의 재식별 위험을 측정할 수 있는 기능.



- 150개 이상의 내장된 정보 유형('infoType') 감지기, 그리고 민감한 정보에 관한 자동 검사를 위해 자체 감지기를 정의할 수 있는 기능. 추가적인 소스 및 워크로드에 대한 지원이 가능하도록 Cloud Storage, BigQuery, BigLake, Cloud SQL을 기본 지원.



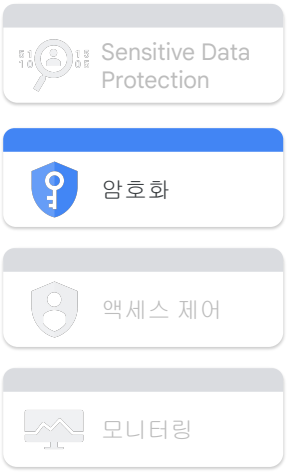
- 감지 기준 조정 및 감지 규칙 생성과 같은 다수의 추가적인 맞춤설정.



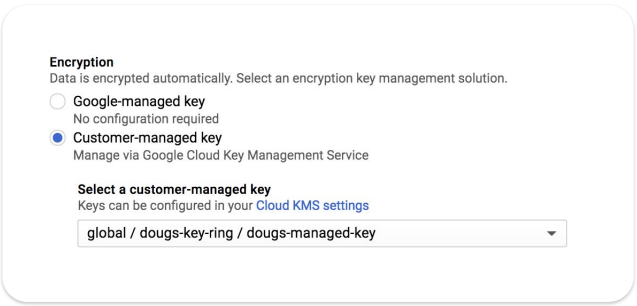
키 관리 서비스**(KMS):** 클라우드 서비스의 대칭 및 비대칭 암호화 키를 관리할 수 있게 해주는 클라우드에서 호스팅되는 키 관리 서비스.

암호화의 경우 Google은 AI 데이터 세트의 개인 정보 보호에 필수적인 기본 저장 데이터 암호화를 제공합니다. 전송 중인 데이터도 기본적으로 TLS를 사용하여 암호화됩니다.
Google Cloud는 데이터를 디스크에 쓰기 전에 서버 측에서 추가 요금 없이 데이터를 암호화합니다. 원하는 경우 이 데이터를 보다 앞서 암호화할 수 있습니다.

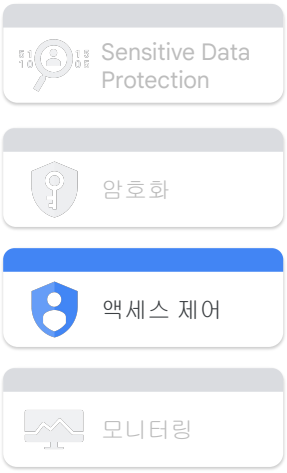
VO 추가: Google Cloud의 키 관리 서비스는 클라우드 서비스를 위한 대칭 및 비대칭 암호화 키를 관리할 수 있게 해주는 클라우드에서 호스팅되는 서비스입니다.



키 관리 서비스**(KMS):** 클라우드 서비스의 대칭 및 비대칭 암호화 키를 관리할 수 있게 해주는 클라우드에서 호스팅되는 키 관리 서비스.

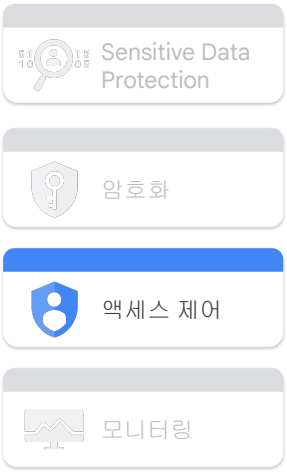


Cloud KMS를 사용하여 암호화 키에 대한 제어를 확장할 수 있습니다. 그러면 하나의 중앙 집중식 클라우드 서비스에서 암호화 키를 만들고, 가져오고, 관리하며 암호화 작업을 수행할 수 있습니다.



Identity and Access Management(IAM): 관리자가 사용자에게 특정 리소스에 조치를 취할 수 있는 권한을 부여할 수 있어 Google Cloud 리소스를 중앙에서 관리하는 데 필요한 완전한 제어와 가시성을 얻을 수 있습니다.

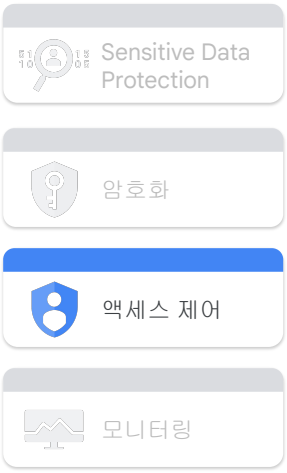
액세스 제어를 위해 Google은 IAM 서비스를 사용하여 Google Cloud 리소스를 중앙에서 관리하기 위한 온전한 제어성과 가시성을 부여합니다.



Identity and Access Management(IAM): 관리자가 사용자에게 특정 리소스에 조치를 취할 수 있는 권한을 부여할 수 있어 Google Cloud 리소스를 중앙에서 관리하는 데 필요한 완전한 제어와 가시성을 얻을 수 있습니다.

- 단일 액세스 제어 인터페이스

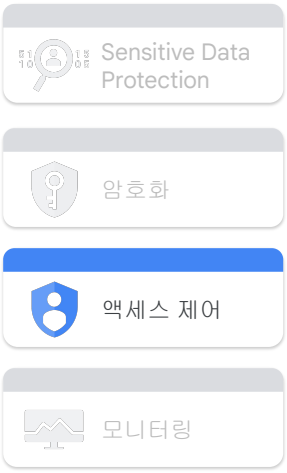
IAM은 하나의 액세스 인터페이스 내에서 액세스 관리에 대해 사용자가 기대하는 모든 기능을 제공합니다.



Identity and Access Management(IAM): 관리자가 사용자에게 특정 리소스에 조치를 취할 수 있는 권한을 부여할 수 있어 Google Cloud 리소스를 중앙에서 관리하는 데 필요한 완전한 제어와 가시성을 얻을 수 있습니다.

- 단일 액세스 제어 인터페이스
- 유연하고 세분화된 역할 제어

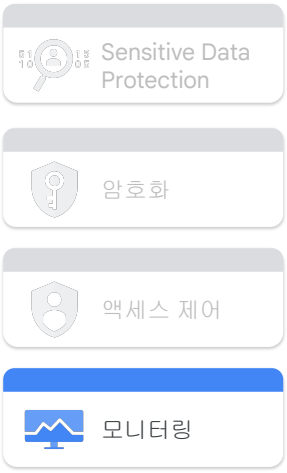
세분화된 역할, 내장된 감사 추적 기능, 외부 제공업체까지 사용하기 위한 직원 ID 제휴 등을 예로 들 수 있습니다.



Identity and Access Management(IAM): 관리자가 사용자에게 특정 리소스에 조치를 취할 수 있는 권한을 부여할 수 있어 Google Cloud 리소스를 중앙에서 관리하는 데 필요한 완전한 제어와 가시성을 얻을 수 있습니다.

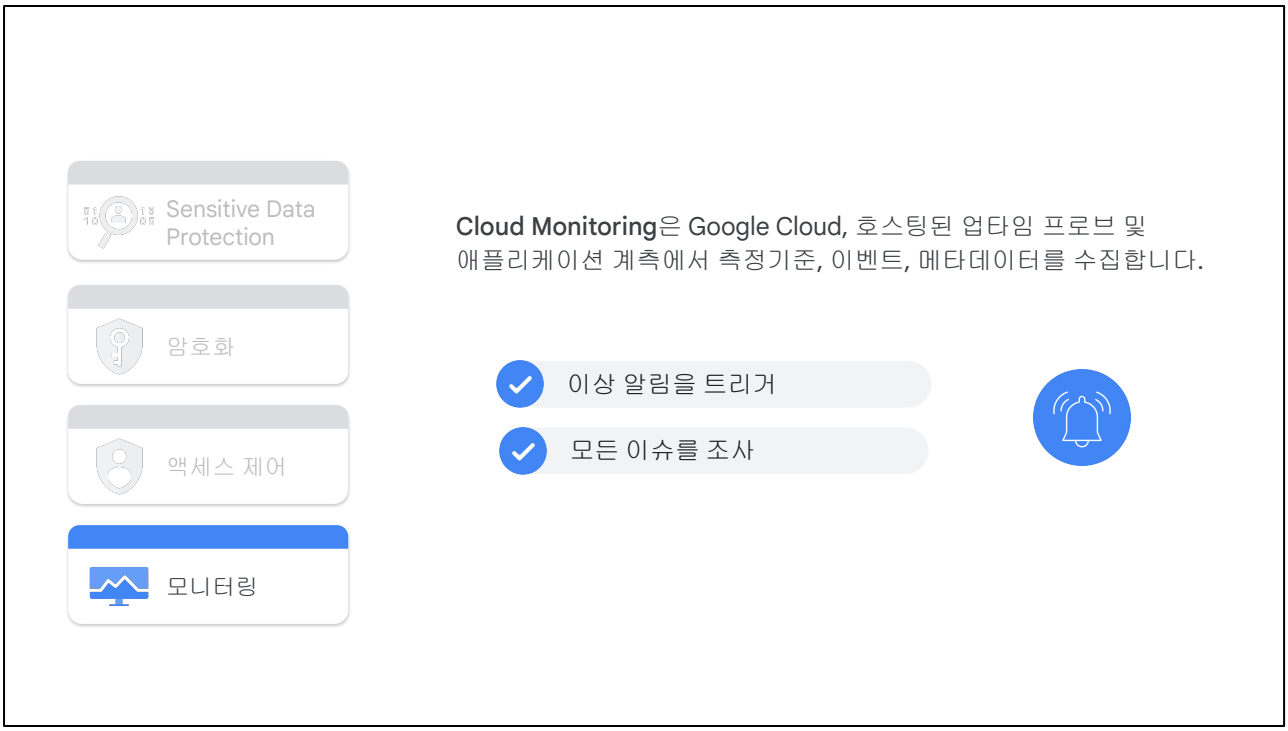
- 단일 액세스 제어 인터페이스
- 유연하고 세분화된 역할 제어
- 컨텍스트 인식 액세스

ML 애플리케이션을 보호하려면 최소 권한의 원칙에 따라 데이터, 모델과 서빙 엔드포인트에 대한 IAM 권한을 설정하세요.



Cloud Monitoring은 Google Cloud, 호스팅된 업타임 프로브 및 애플리케이션 계측에서 측정기준, 이벤트, 메타데이터를 수집합니다.

Cloud Monitoring은 Google Cloud, 호스팅된 업타임 프로브 및 애플리케이션 계측에서 측정기준, 이벤트와 메타데이터를 수집합니다.



보안 관점에서 흥미로운 점은 모든 요청이 로깅된다는 것입니다. 이러한 추적성은 커스텀 규칙 및 정책에 따라 이상에 대한 알림을 수신할 수 있는 기능을 부여하므로 모든 이슈를 조사할 수 있습니다.



01 AI 개인 정보 보호 개요

02 학습 데이터의 개인 정보 보호: 익명화 기법

03 학습 데이터의 개인 정보 보호: 무작위 순서 지정 기법

04 머신러닝 학습의 개인 정보 보호: DP-SGD

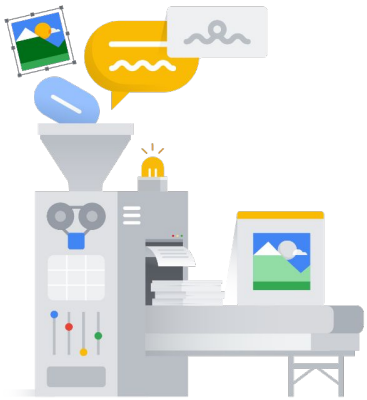
05 머신러닝 학습의 개인 정보 보호: 제휴 학습

06 Google Cloud의 시스템 보호

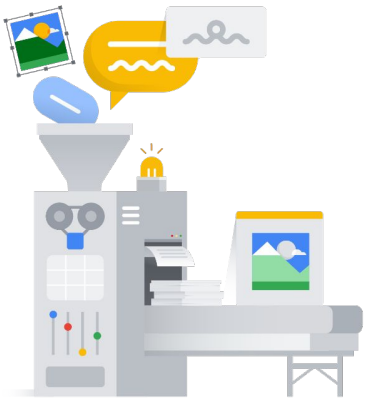
07 시스템 보안 및 생성형 AI

08 실습: TensorFlow Privacy를 사용한 머신러닝의 개인 정보 차등 보호

시스템 보안을 살펴보고, 이것이 생성형 AI와 어떤 관련이 있는지 알아보겠습니다.

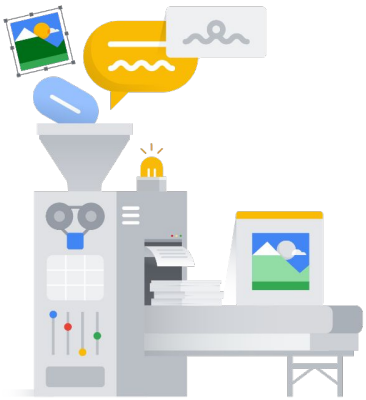


생성형 AI 모델은 다양한 소스에서 가져오게 되는 방대한 비정형 데이터 소스를 학습합니다.



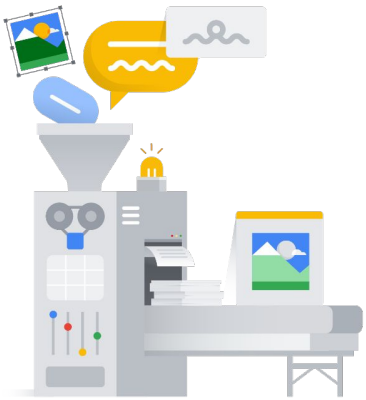
생성형 AI 모델은 학습 데이터의 민감한 정보를 유지할 수 있습니다.

일부 민감한 정보가 포함될 가능성이 높으며



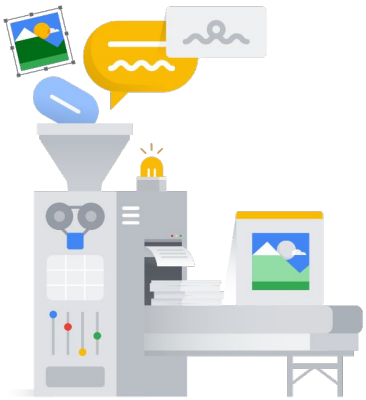
- 생성형 AI 모델은 학습 데이터의 민감한 정보를 유지할 수 있습니다.
- 이러한 민감한 정보는 모델의 출력에 반영될 수 있습니다.

이러한 개인 세부정보 중 일부를 출력에 반영할 수 있는 가능성이 있습니다.



- 생성형 AI 모델은 학습 데이터의 민감한 정보를 유지할 수 있습니다.
- 이러한 민감한 정보는 모델의 출력에 반영될 수 있습니다.
- 언어 모델이 클수록 학습 데이터를 기억하기 쉽습니다.

실제로 언어 모델이 클수록 학습 데이터를 기억하기가 훨씬 쉽습니다.
간단한 쿼리를 통해



- 생성형 AI 모델은 학습 데이터의 민감한 정보를 유지할 수 있습니다.
- 이러한 민감한 정보는 모델의 출력에 반영될 수 있습니다.
- 언어 모델이 클수록 학습 데이터를 기억하기 쉽습니다.
- 쿼리는 기억된 학습 데이터를 추출하여 개인 정보 보호 위험을 야기할 수 있습니다.

모델이 기억하고 있는 특정 학습 데이터를 추출할 수 있다는 것은 알려진 사실입니다. 따라서 생성형 AI 모델은 학습 데이터 추출 공격에 특히 민감합니다.

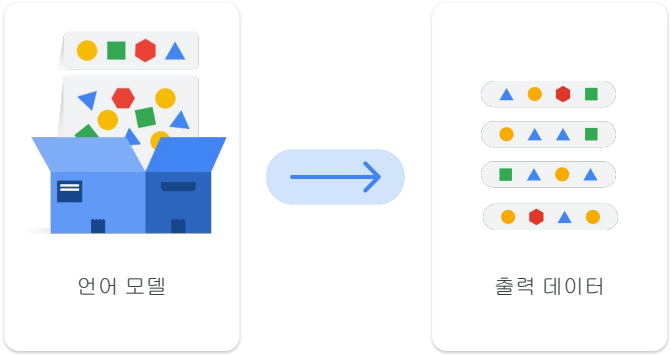
학습 데이터 추출 공격이란?

공격자는 개별 학습 예시를 의도적으로 추출하기 위해 제작된 프롬프트 또는 일련의 프롬프트를 반복적으로 입력합니다.



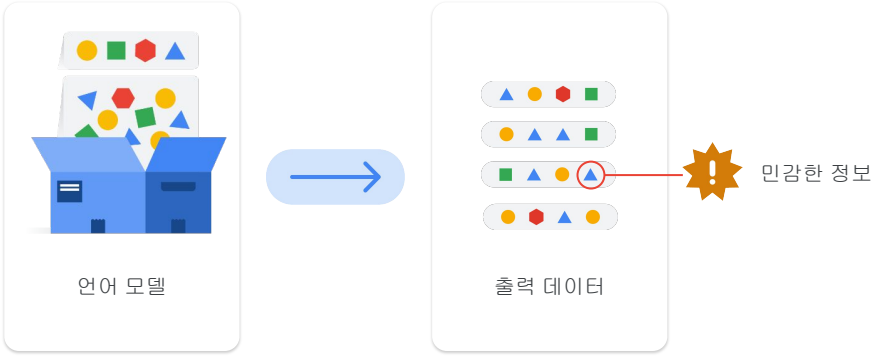
학습 데이터 추출 공격 시 공격자는 의도적으로 개별 모델 학습 예를 추출하기 위해 제작된 프롬프트 또는 일련의 프롬프트를 반복적으로 입력합니다.
이러한 유형의 공격은 모든 사용자에게 제공되는 모델에 적용될 경우 피해를 줄 가능성이 매우 크지만 학습에 사용되는 데이터 세트는 모든 사용자에게 제공되지 않습니다.

학습 데이터 추출 공격이란?



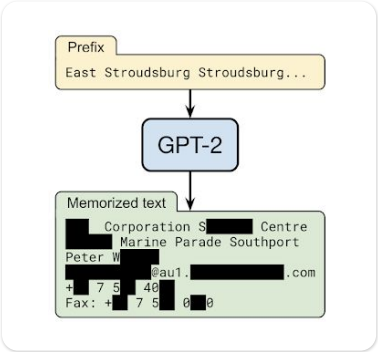
기본적으로 언어 모델은 대량의 출력 데이터를 아주 쉽게 생성할 수 있습니다. 무작위의 짧은 문구로 모델을 시드함으로써 모델은 문장을 완성할 수 있는 문구처럼 수백만 개의 연속 문구를 생성할 수 있습니다. 대부분의 경우 이러한 연속은 적절한 텍스트로 구성된 무해한 문자열입니다.

학습 데이터 추출 공격이란?



그러나 때로는 민감한 정보를 유출할 수 있습니다.

학습 데이터 추출 공격이란?



이러한 적대적 공격을 분석하기 위한 최초 논문 중 하나에서 가져온 예시를 살펴보겠습니다. 사용자가 GPT-2 언어 모델에 'East Stroudsburg Stroudsburg...'라는 프롬프트를 입력합니다. 모델은 GPT-2의 학습 데이터에 특정인의 성명, 전화번호, 이메일 주소와 실제 주소를 포함하는 긴 텍스트 블록을 자동완성합니다. 그런데 GPT-2의 학습 데이터에는 해당인의 정보가 포함되어 있습니다. 이로 인해 사용자가 모델을 통해 민감한 정보를 획득할 수 있게 됩니다.

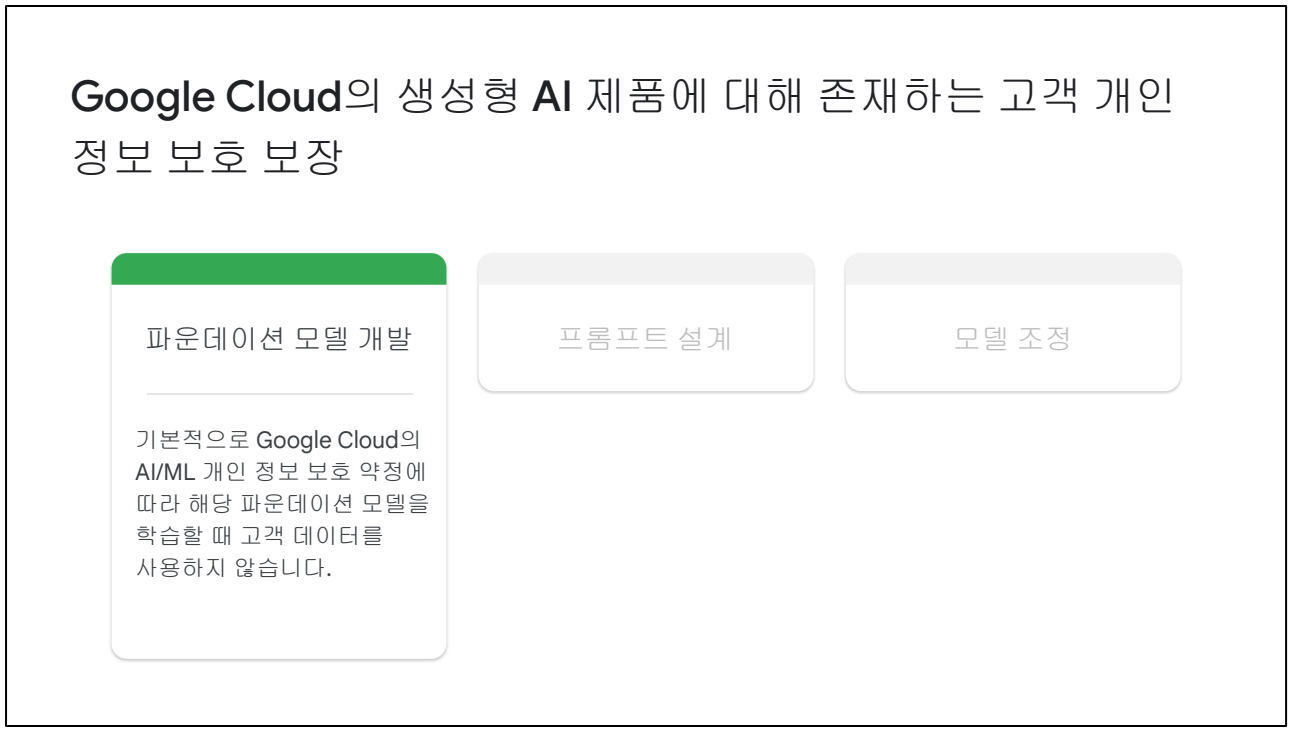
Google Cloud AI/ML 개인 정보 보호 노력의 일환으로, Google Cloud 모델은 고객 데이터를 포함하지 않습니다. 이는 유해한 상황을 피하기 위함입니다.

Google에서 데이터 거버넌스는 개인 정보 보호의 핵심 요소입니다. Google Cloud AI/ML 개인 정보 보호 노력의 일환으로, Google Cloud 모델은 고객 데이터를 포함하지 않습니다. 이는 이렇게 유해한 상황을 피하기 위함입니다.

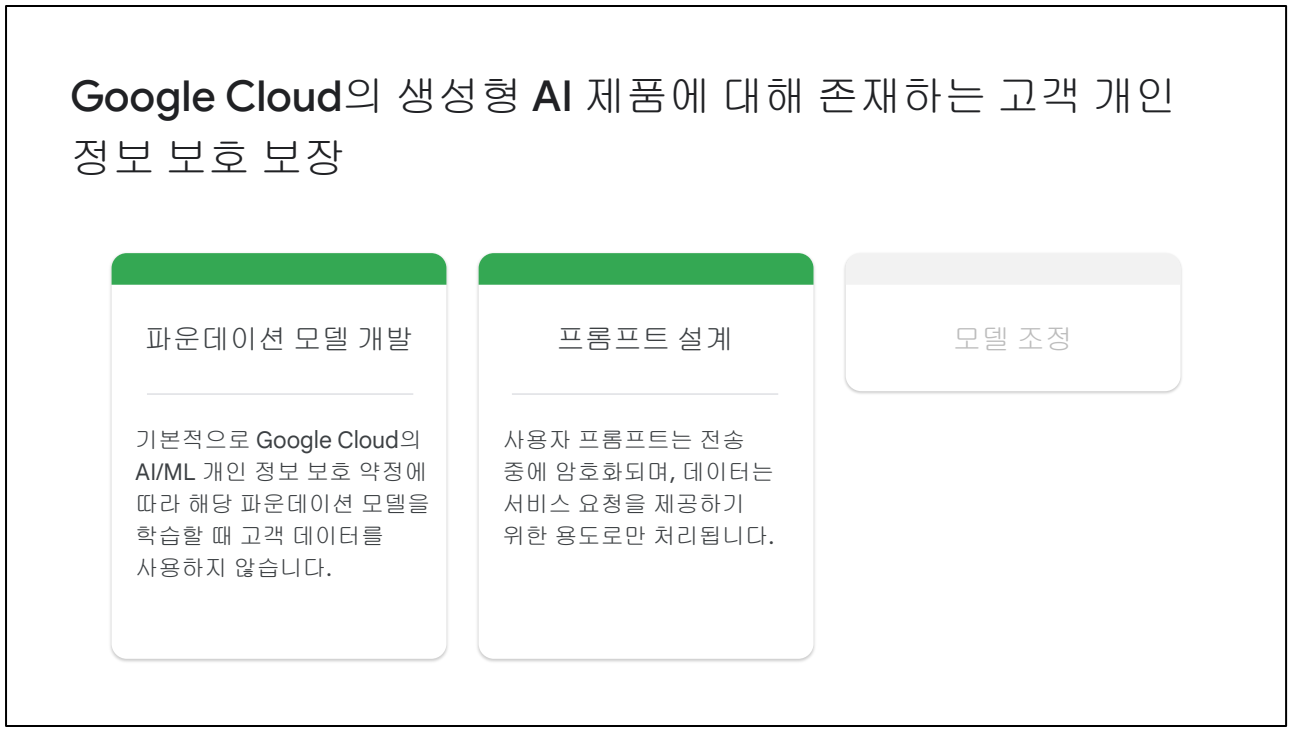
Google Cloud의 생성형 AI 제품에 대해 존재하는 고객 개인 정보 보호 보장



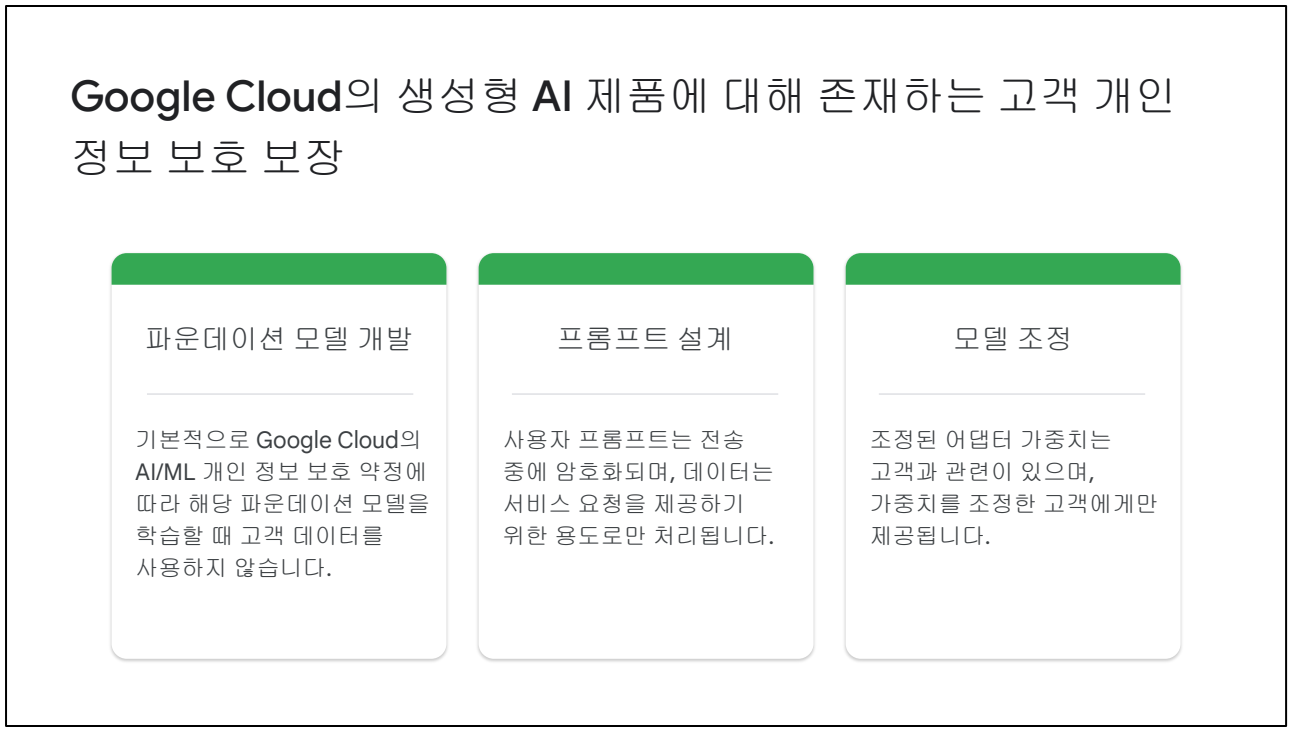
Google의 개인 정보 보호 노력은 Google Cloud 생성형 AI 제품 및 솔루션으로 확대됩니다. Google Cloud는 다음을 보장합니다.



1. 파운데이션 모델 개발은 개인 정보 보호를 준수합니다. 기본적으로 Google Cloud의 AI/ML 개인 정보 보호 약정에 따라 해당 파운데이션 모델을 학습할 때 고객 데이터를 사용하지 않습니다.

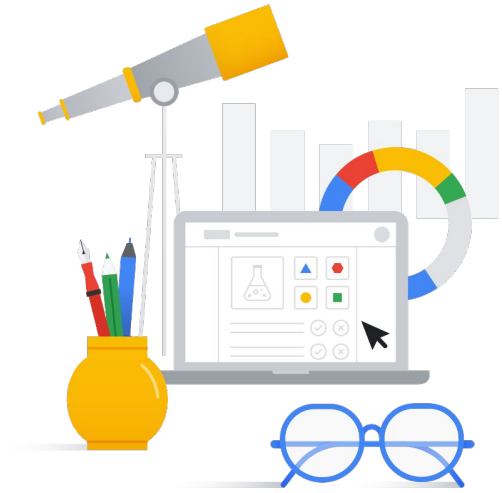


2. 프롬프트를 통해 Google Cloud의 파운데이션 모델에 요청이 제출되면 고객 데이터가 전송 중에 암호화되고 파운데이션 모델에 입력되어 응답을 산출합니다. Google은 요청된 서비스를 제공하기 위한 목적으로만 고객 데이터를 처리합니다.



3. 어댑터 가중치는 고객과 관련이 있으며, 가중치를 조정한 고객에게만 제공됩니다. 추론 중에 파운데이션 모델은 어댑터 가중치를 얻고, 요청을 실행하고, 결과를 반환하지만 파운데이션 모델을 수정하거나 요청을 저장하지는 않습니다. 입력 데이터는 고객 데이터이며 모든 단계에서 저장 및 전송 중에 항상 암호화된 상태로 안전하게 저장됩니다. 또한 조정된 가중치도 안전하게 저장되며 조정된 모델을 사용할 수 있는 액세스 권한은 고객에게만 부여됩니다. 고객은 고객 관리 암호화 키(CMEK)를 사용해서 저장된 어댑터 암호화를 제어할 수 있으며 언제든지 어댑터 가중치를 삭제할 수 있습니다.

이렇게 Google Cloud는 머신러닝 모델 학습 과정에서 개인 정보 보호에 보안 권장사항이 적용되도록 도와줍니다.

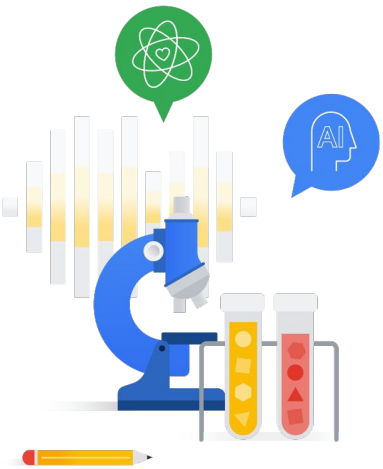


실무형 실습:

TensorFlow Privacy를 사용한 머신러닝의 개인 정보 차등 보호

이제 실무형 실습으로 직접 연습해 보겠습니다.

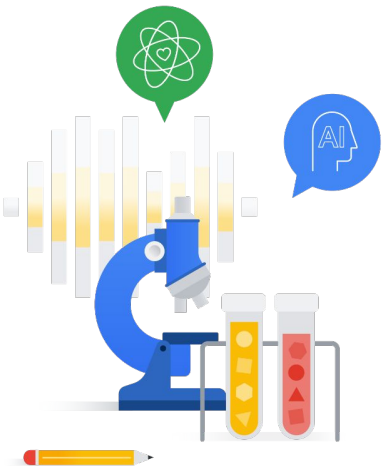
이 실습에서 학습할 내용은 다음과 같습니다.



이 실습에서는 TensorFlow Privacy를 통해 머신러닝에서 개인 정보 차등 보호를 사용하는 방법을 알아봅니다. 이 실습에서 학습할 내용은 다음과 같습니다.

이 실습에서 학습할 내용은 다음과 같습니다.

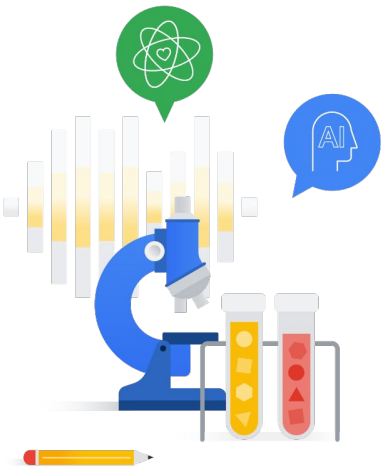
TensorFlow Privacy를 사용하여 기존 옵티마이저를 개인 정보 차등 보호 기능으로 래핑합니다.



- TensorFlow Privacy를 사용하여 기존 옵티마이저를 개인 정보 차등 보호 기능으로 래핑합니다.

이 실습에서 학습할 내용은 다음과 같습니다.

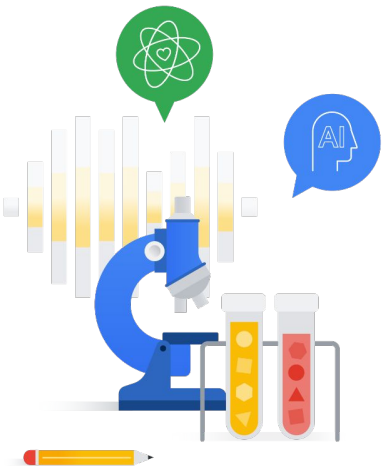
- TensorFlow Privacy를 사용하여 기존 옵티마이저를 개인 정보 차등 보호 기능으로 래핑합니다.
- 개인 정보를 차등 보호하는 머신러닝에서 도입되는 하이퍼파라미터를 검사하는 연습을 합니다.



- 개인 정보를 차등 보호하는 머신러닝에서 도입되는 하이퍼파라미터를 검사하는 연습을 합니다.

이 실습에서 학습할 내용은 다음과 같습니다.

- TensorFlow Privacy를 사용하여 기존 옵티마이저를 개인 정보 차등 보호 기능으로 래핑합니다.
- 개인 정보를 차등 보호하는 머신러닝에서 도입되는 하이퍼파라미터를 검사하는 연습을 합니다.
- TensorFlow Privacy에 포함된 분석 도구를 사용하여 제공된 개인 정보 보호 보증을 측정합니다.



- TensorFlow Privacy에 포함된 분석 도구를 사용하여 제공된 개인 정보 보호 보증을 측정합니다.