

AI 안전

AI 안전 모듈에 오신 것을 환영합니다.



01 AI 안전 개요

02 안전 평가

03 피해 방지

04 안전을 위한 모델 학습: 요청 사항 세부 조정

05 안전을 위한 모델 학습: RLHF

06 Google Cloud 생성형 AI의 안전

07 실습: Vertex AI Gemini API를 통한 보호

이 모듈은 **7**개의 강의로 구성되어 있습니다.

이 과정에서 배우는 내용



01	AI를 위한 안전을 정의합니다.
02	안전을 위한 주요 고려사항을 살펴봅니다.
03	AI 안전을 위한 기법을 살펴봅니다.
04	AI 안전에 도움이 될 수 있는 Google Cloud 제품을 설명합니다.

학습할 내용

- AI를 위한 안전을 정의합니다.
- 안전을 위한 주요 고려사항을 살펴봅니다.
- AI 안전을 위한 기법을 살펴봅니다.
- AI 안전에 도움이 될 수 있는 Google Cloud 제품을 설명합니다.



01 AI 안전 개요

02 안전 평가

03 피해 방지

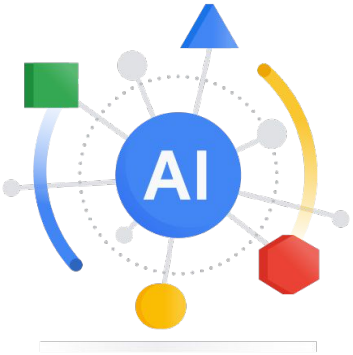
04 안전을 위한 모델 학습: 요청 사항 세부 조정

05 안전을 위한 모델 학습: RLHF

06 Google Cloud 생성형 AI의 안전

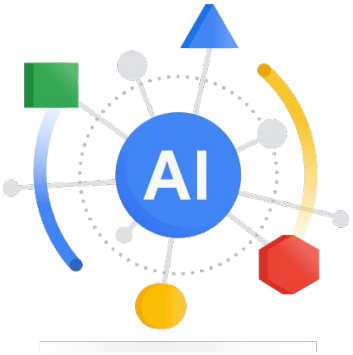
07 실습: Vertex AI Gemini API를 통한 보호

AI 안전이 무엇을 의미하는지 개요부터 살펴보겠습니다.



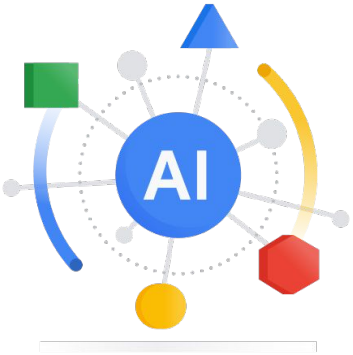
1. 사회에 도움이 되어야 한다.
2. 불공정한 편향을 만들거나 강화해서는 안 됩니다.
3. 안전 기반의 개발 및 테스트가 중요합니다.
4. 사람에 대한 책임을 져야 합니다.
5. 개인 정보 보호 적용 설계의 원칙이 반영되어야 합니다.
6. 과학적 우수성에 있어 엄격한 기준을 충족해야 합니다.
7. 이러한 원칙을 준수하는 사용자에게 제공되어야 합니다.

안전은 Google의 AI 원칙 중에서 세 번째인 '안전 기반의 개발 및 테스트가 중요합니다'와 직접적인 관련이 있습니다. 안전은 다른 Google AI 원칙, 특히



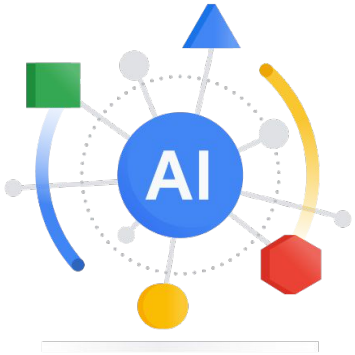
1. 사회에 도움이 되어야 한다.
2. 불공정한 편향을 만들거나 강화해서는 안 됩니다.
3. 안전 기반의 개발 및 테스트가 중요합니다.
4. 사람에 대한 책임을 져야 합니다.
5. 개인 정보 보호 적용 설계의 원칙이 반영되어야 합니다.
6. 과학적 우수성에 있어 엄격한 기준을 충족해야 합니다.
7. 이러한 원칙을 준수하는 사용자에게 제공되어야 합니다.

'불공정한 편향을 만들거나 강화해서는 안 된다'는 원칙과 깊이 관련되어 있습니다. 그 이유는 안전이라는 개념이 주로 공정성과 편향의 정의에서 비롯되며, 적절한 안전 조치를 구현하면 시스템이 더 공정해지기 때문입니다. 공정성과 안전 사이에는 강력한 교차점이 있습니다.



1. 사회에 도움이 되어야 한다.
2. 불공정한 편향을 만들거나 강화해서는 안 됩니다.
3. 안전 기반의 개발 및 테스트가 중요합니다.
4. 사람에 대한 책임을 져야 합니다.
5. 개인 정보 보호 적용 설계의 원칙이 반영되어야 합니다.
6. 과학적 우수성에 있어 엄격한 기준을 충족해야 합니다.
7. 이러한 원칙을 준수하는 사용자에게 제공되어야 합니다.

또한 AI 시스템에 대한 책임 의식은 AI의 안전한 사용을 촉진하는 데 도움이 되기 때문에 '사람들에 대한 책임 의식을 가져야 합니다.'



1. 사회에 도움이 되어야 한다.
2. 불공정한 편향을 만들거나 강화해서는 안 됩니다.
3. 안전 기반의 개발 및 테스트가 중요합니다.
4. 사람에 대한 책임을 져야 합니다.
5. 개인 정보 보호 적용 설계의 원칙이 반영되어야 합니다.
6. 과학적 우수성에 있어 엄격한 기준을 충족해야 합니다.
7. 이러한 원칙을 준수하는 사용자에게 제공되어야 합니다.

그리고 '이러한 원칙을 준수하는 사용자에게 제공되어야 합니다.' 이는 특히 광범위한 사용자 그룹이 AI 시스템을 사용할 수 있도록 할 때 중요합니다. AI 기능이 빠르게 발전함에 따라 AI 시스템이 상상한 대로만 사용되지는 않는다는 점을 명심하세요.

안전 보장이 어려운 이유**?**

알 수 없는 작업 공간

성능과 안전의 절충

새로운 공격의 속도

AI 안전에는 다양한 관점과 고려사항이 수반되며 여러 가지 어려움이 따릅니다.

안전 보장이 어려운 이유?

알 수 없는 작업 공간

인간이 해결하기 어려운 문제에 머신러닝을 적용하는 경우 모든 시나리오를 미리 예측하기 어려우며, 특히 생성형 AI 시대에는 더욱 그렇습니다.

성능과 안전의 절충

새로운 공격의 속도

- 알 수 없는 작업 공간 문제: 인간이 해결하기 어려운 문제에 머신러닝을 적용하는 경우 모든 시나리오를 미리 예측하기 어려우며, 특히 생성형 AI 시대에는 더욱 그렇습니다.

안전 보장이 어려운 이유?

알 수 없는 작업 공간	성능과 안전의 절충	새로운 공격의 속도
인간이 해결하기 어려운 문제에 머신러닝을 적용하는 경우 모든 시나리오를 미리 예측하기 어려우며, 특히 생성형 AI 시대에는 더욱 그렇습니다.	심층신경망 같은 복잡한 AI 모델을 이해하기란 머신러닝 전문가에게도 어려울 수 있습니다.	

- 성능과 안전의 절충 문제: 안전에 필요한 제한사항을 선제적으로 제시하고 창의적인 솔루션을 생성하거나 비정상적인 입력에 적응하는 데 필요한 유연성을 모두 제공하는 시스템을 빌드하기는 어렵습니다.

안전 보장이 어려운 이유?

알 수 없는 작업 공간

인간이 해결하기 어려운 문제에 머신러닝을 적용하는 경우 모든 시나리오를 미리 예측하기 어려우며, 특히 생성형 AI 시대에는 더욱 그렇습니다.

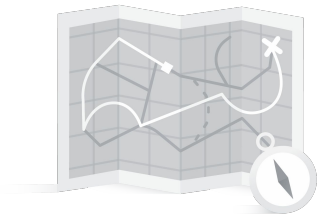
성능과 안전의 절충

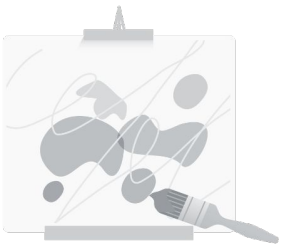
심층신경망 같은 복잡한 AI 모델을 이해하기란 머신러닝 전문가에게도 어려울 수 있습니다.

새로운 공격의 속도

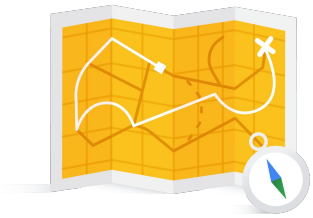
AI 기술이 발전함에 따라 공격자도 분명히 새로운 공격 수단을 찾을 것이므로 이에 맞서 새로운 솔루션을 개발해야 합니다.

- 그리고 공격자는 새로운 기술에 빠르게 적응합니다. AI 기술이 계속 진화함에 따라 공격자도 진화하고 분명히 새로운 공격 수단을 찾을 것이므로 이에 맞서 새로운 솔루션을 개발해야 합니다.

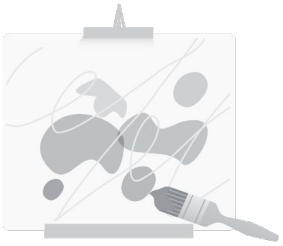




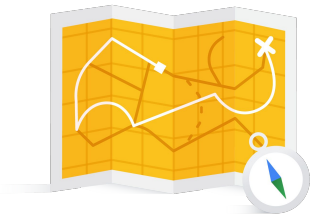
AI 안전 보장은 특히 생성형 AI에서 어렵습니다.



구분형 AI = 명확한 출력

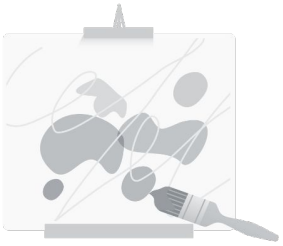


분류 및 회귀 작업을 위해 학습된 모델과 같이 전통적인 구분형 AI 모델을 사용하면 출력 범위가 매우 명확합니다.

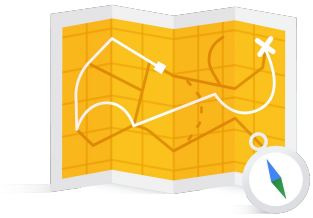


구분형 AI = 명확한 출력

분류 및 회귀와 같은 전통적 모델은 비교적 알려진 출력 범위를 포함

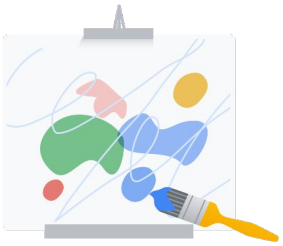


분류 모델은 학습한 종류만 예측할 수 있으므로 유해하다고 생각하는 종류를 손쉽게 제외할 수 있습니다. 반면에 회귀 모델은 숫자만 예측할 수 있으며 개발자는 그 숫자가 무엇을 나타내는지 알고 있습니다. 즉 개발자는 모델을 빌드할 때 적어도 모델이 무엇을 예측할 수 있는지를 잘 알고 있습니다. 그렇다고 해서 모델이 완전히 안전하고 아무런 해를 끼치지 않는다는 뜻은 아니지만 문제를 더 쉽게 찾을 수 있습니다.

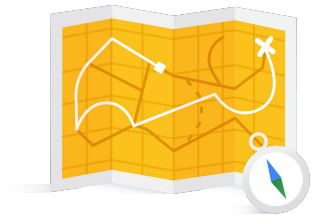


구분형 AI = 명확한 출력

분류 및 회귀와 같은 전통적
모델은 비교적 알려진 출력
범위를 포함

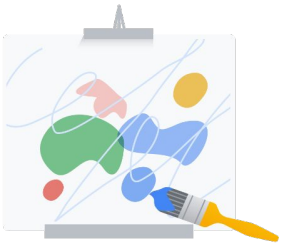


하지만 생성형 AI를 통해 사용자가 창의성의 폭과 깊이를 탐구할 수 있는 시스템을 만들고 있습니다.



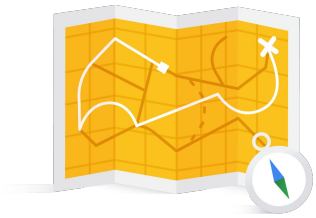
구분형 **AI =** 명확한 출력

분류 및 회귀와 같은 전통적 모델은 비교적 알려진 출력 범위를 포함



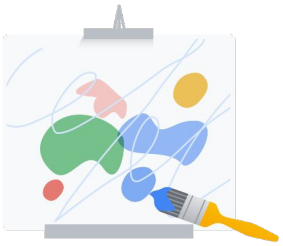
생성형 **AI =** 명확하지 않은 출력

이는 모델이 많은 양의 데이터를 기반으로 학습하고, 학습한 데이터와 매우 다른 출력을 생성하는 방법을 배우도록 설계되었음을 의미합니다.



구분형 **AI =** 명확한 출력

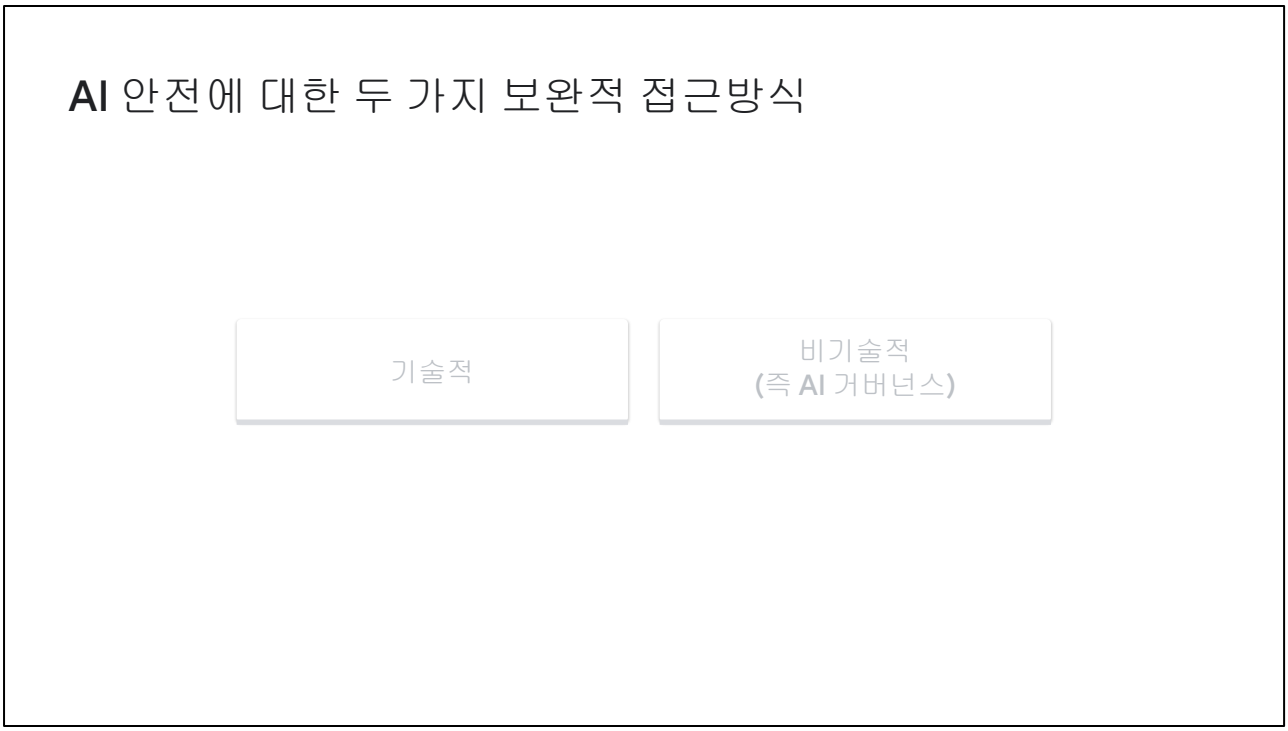
분류 및 회귀와 같은 전통적 모델은 비교적 알려진 출력 범위를 포함



생성형 **AI =** 명확하지 않은 출력

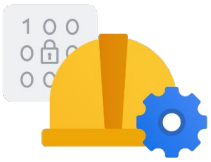
사용자와 모델의 창의성 때문에 모델 대답을 예측하기 어려움

사용자의 창의성과 모델의 새로운 창의성이 더해지기 때문에 모델의 대답하는 폭과 깊이를 사전에 알기가 어렵습니다.



안전에 접근하는 방식은 서로 보완적인 두 가지 방식으로 크게 나눌 수 있습니다.

AI 안전에 대한 두 가지 보완적 접근방식

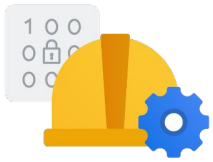


기술적

비기술적
(즉 AI 거버넌스)

첫 번째는 기술적 방식으로,

AI 안전에 대한 두 가지 보완적 접근방식



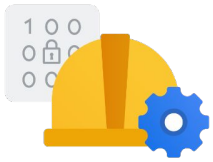
기술적

빌드하는 시스템을 변경하거나 그와 관련된 엔지니어링 관행을 통해 AI 안전에 대한 기술적 해결책을 모색합니다.

비기술적
(즉 AI 거버넌스)

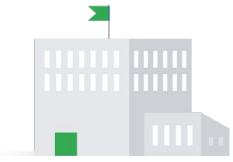
빌드하는 모델 또는 시스템을 변경하거나 엔지니어링 관행을 통해 기술적 해결책을 모색합니다.

AI 안전에 대한 두 가지 보완적 접근방식



기술적

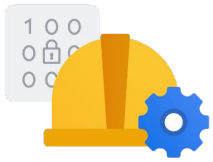
빌드하는 시스템을 변경하거나 그와 관련된 엔지니어링 관행을 통해 AI 안전에 대한 기술적 해결책을 모색합니다.



비기술적
(즉 AI 거버넌스)

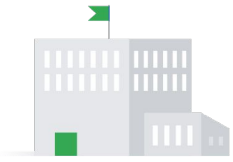
한편 비기술적 또는 제도적 방식도 매우 중요합니다.

AI 안전에 대한 두 가지 보완적 접근방식



기술적

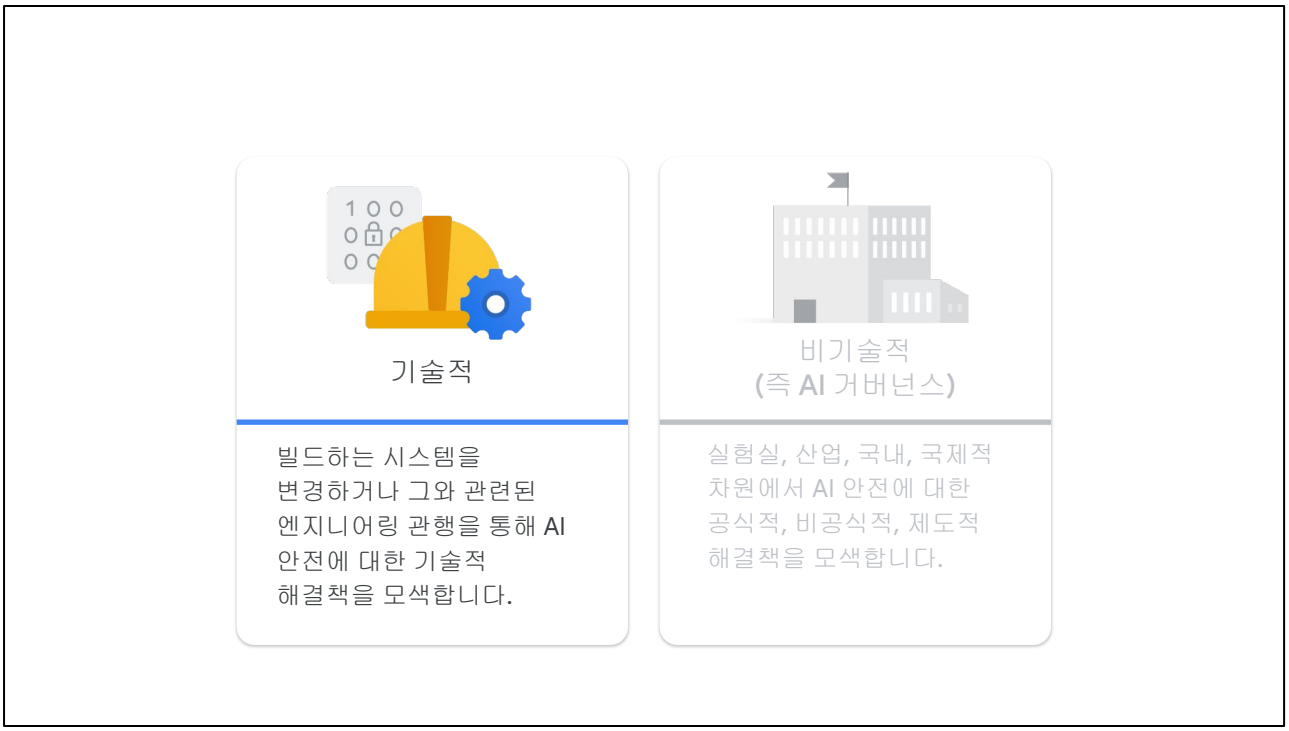
빌드하는 시스템을 변경하거나 그와 관련된 엔지니어링 관행을 통해 AI 안전에 대한 기술적 해결책을 모색합니다.



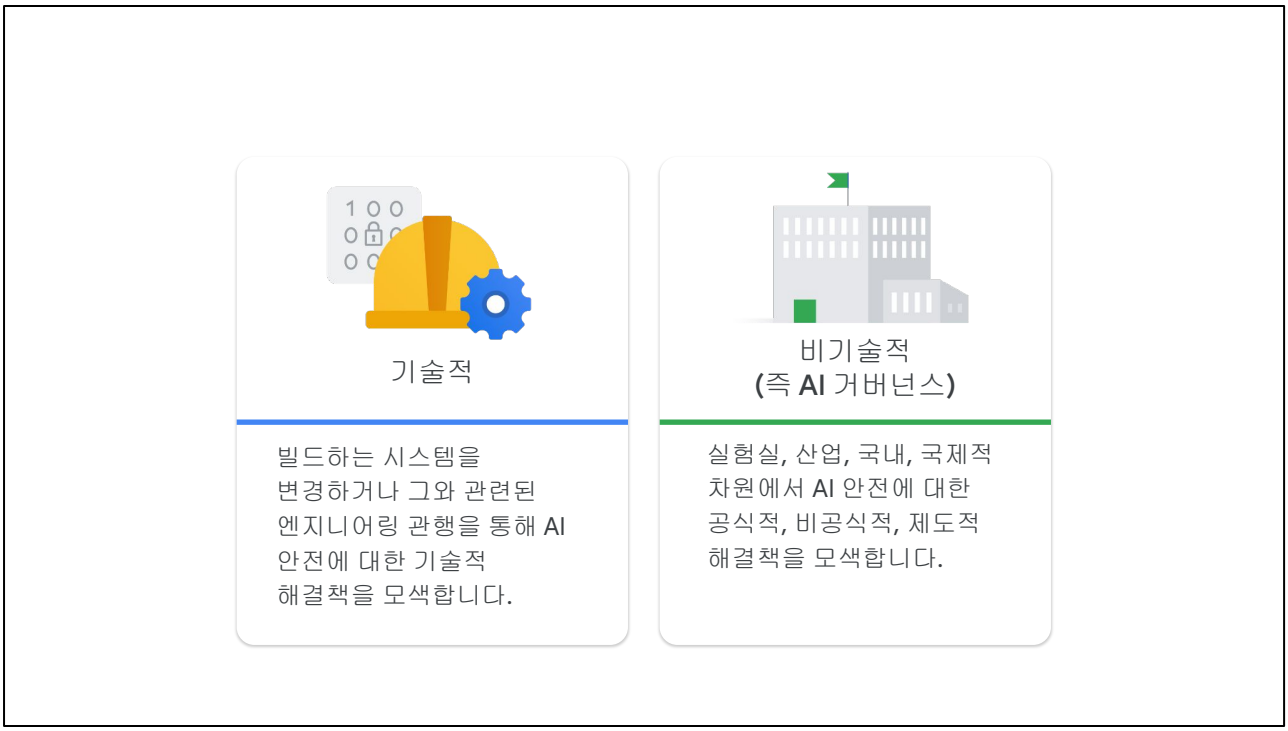
비기술적
(즉 AI 거버넌스)

실험실, 산업, 국내, 국제적 차원에서 AI 안전에 대한 공식적, 비공식적, 제도적 해결책을 모색합니다.

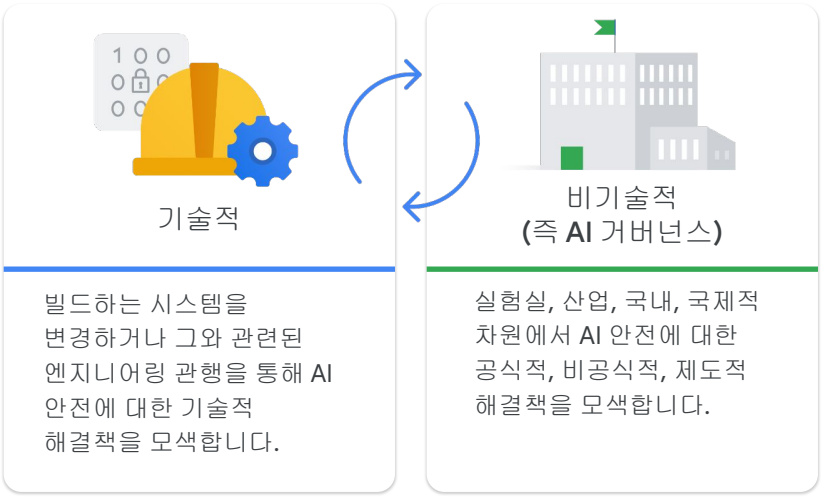
이 방식은 실험실에서 AI 안전에 대한 공식적, 비공식적, 제도적 해결책을 모색합니다. 일반적으로 여기에는 산업 전반, 국내 및 국제적 차원의 논의와 약속이 연관됩니다. 이러한 접근방식은 AI 거버넌스의 원리로도 알려져 있습니다.



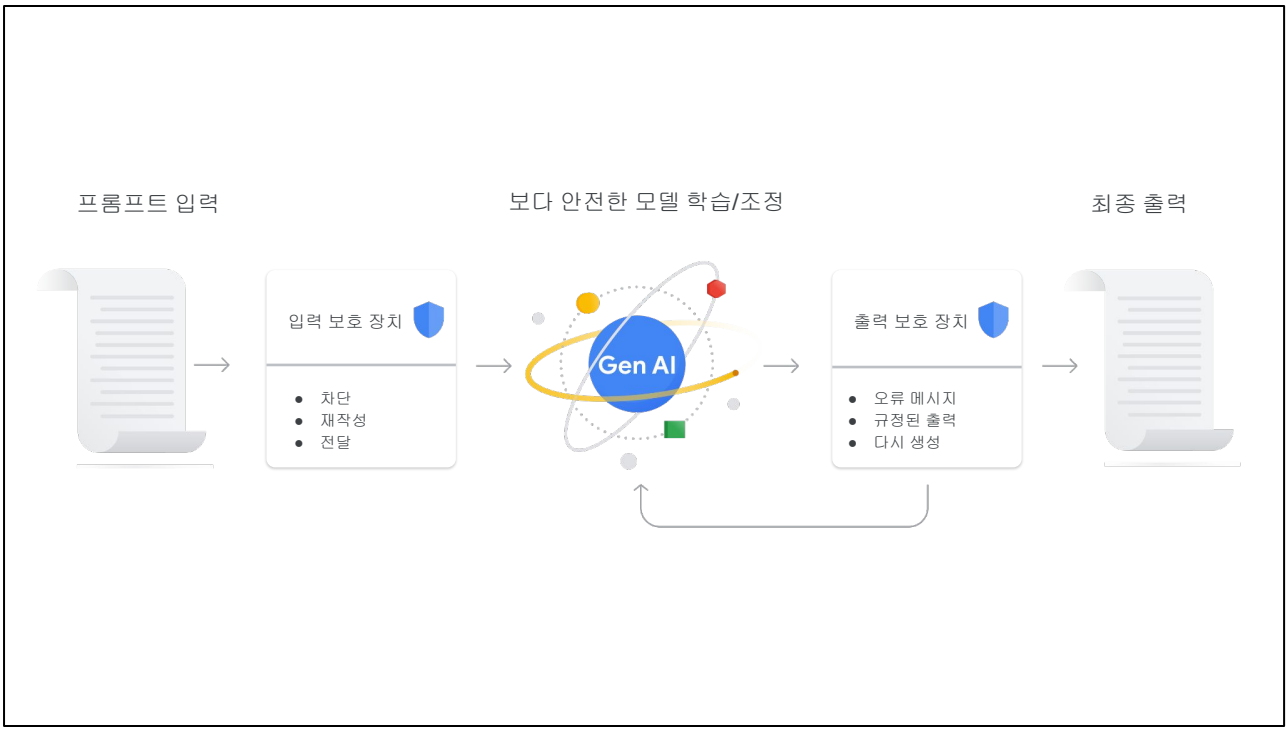
이는 AI 안전의 기술적 측면에 초점을 맞춘 개발자를 위한 기술적 방책이지만



비기술적 측면은 주로 기술적 접근방식을 지원하며

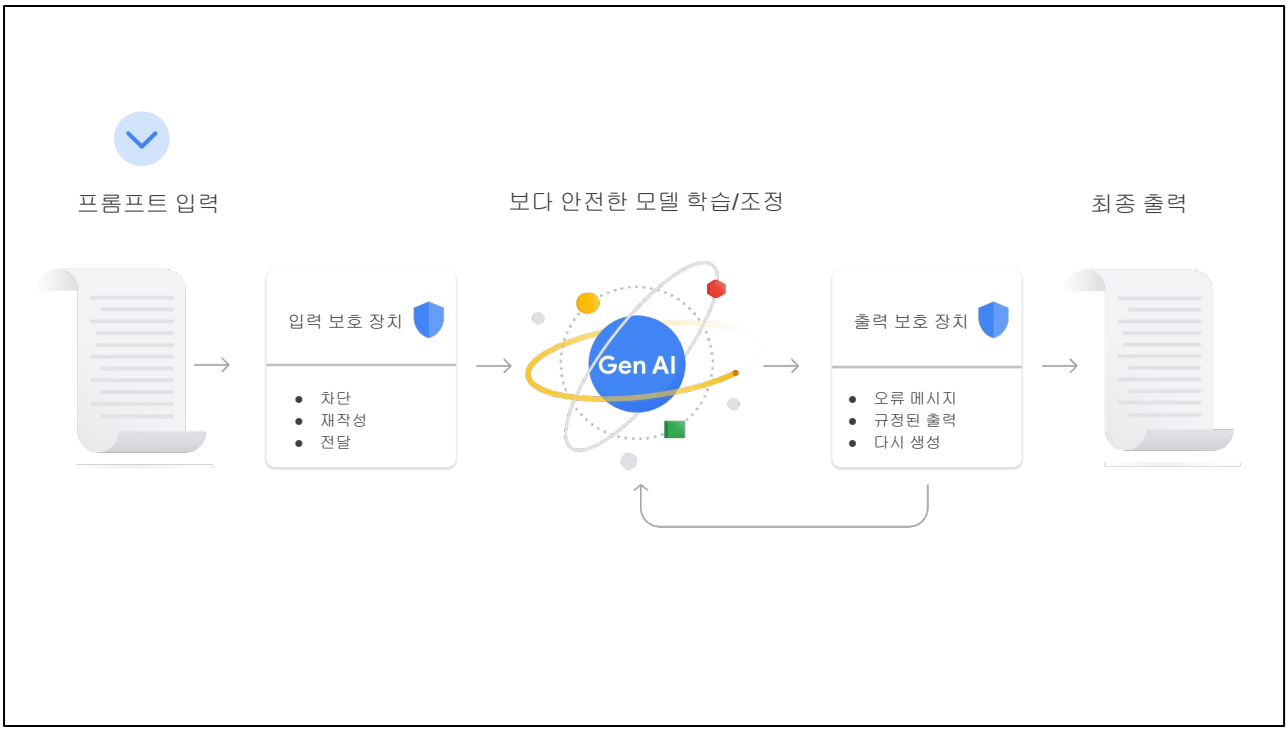


두 가지 방식이 서로를 보완합니다.

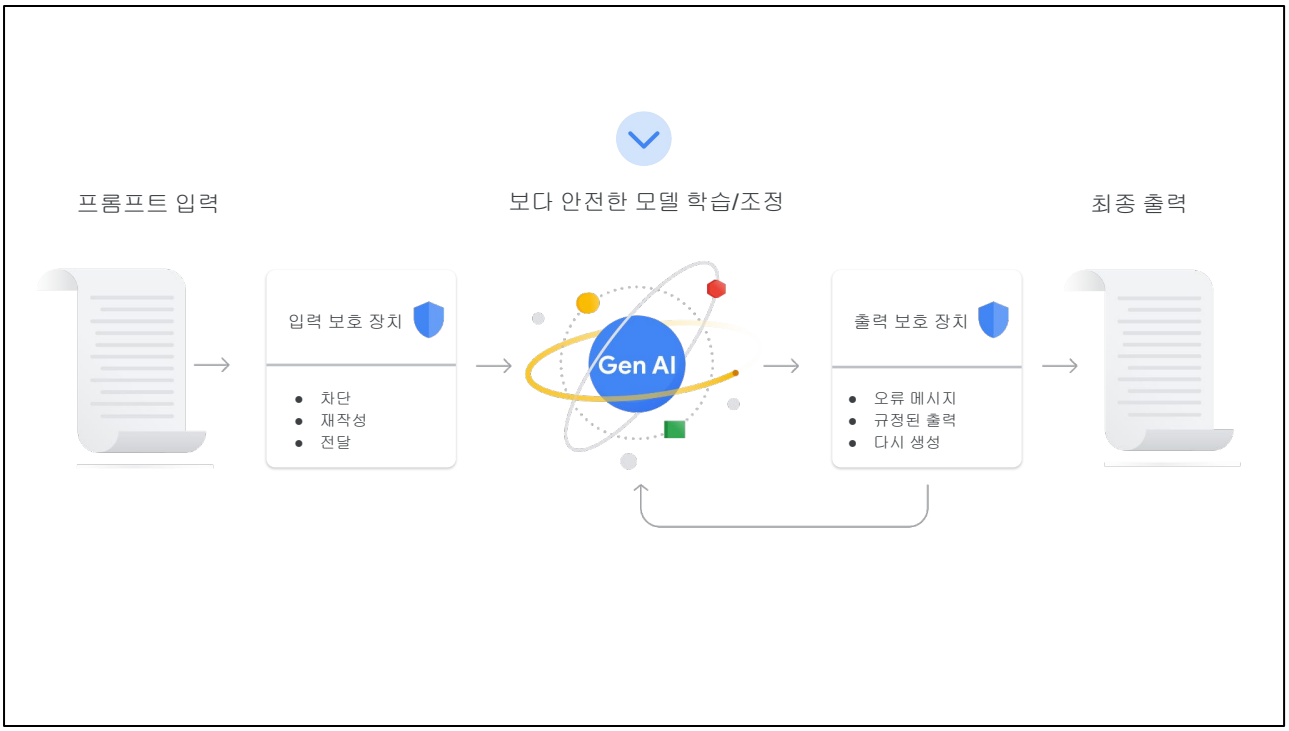


그러면 기술적 측면에서, 특히 생성형 AI에서 AI 안전에 접근하는 방법은 무엇일까요?
여러 가지 수단을 이용할 수 있습니다.

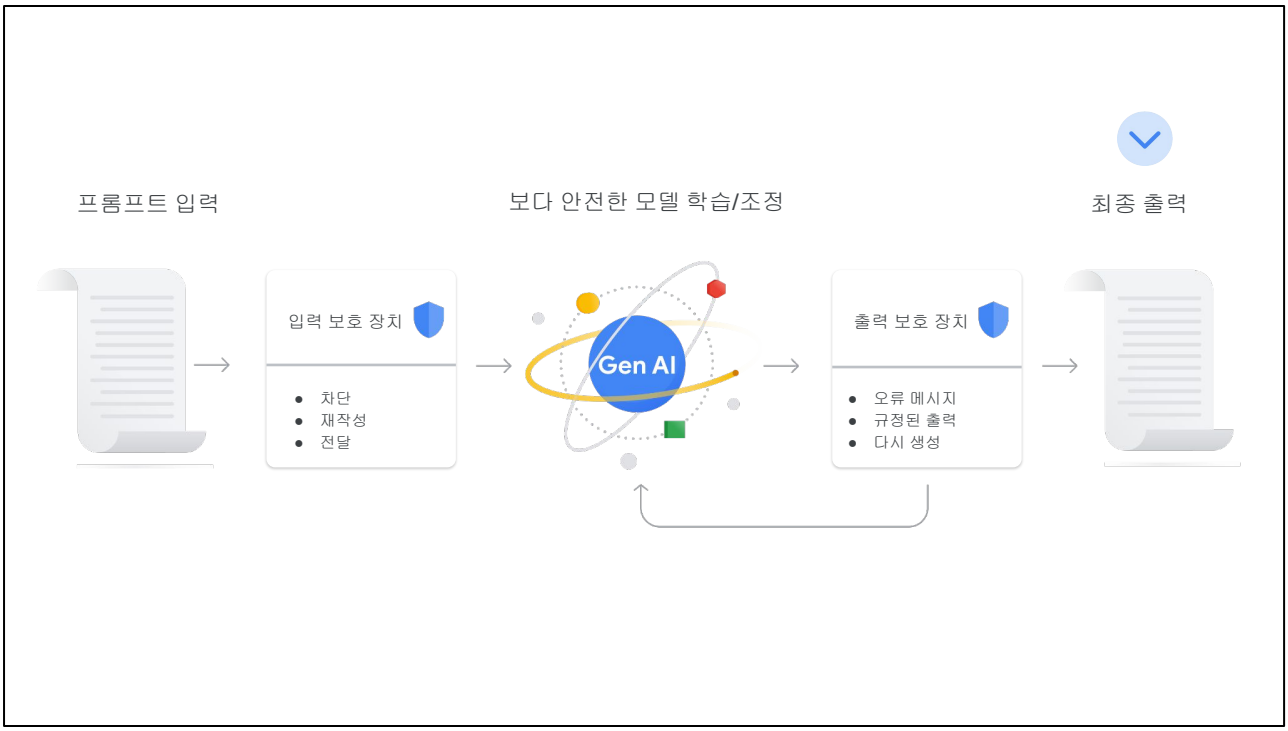
이 다이어그램은 생성형 AI 시스템의 개요입니다.



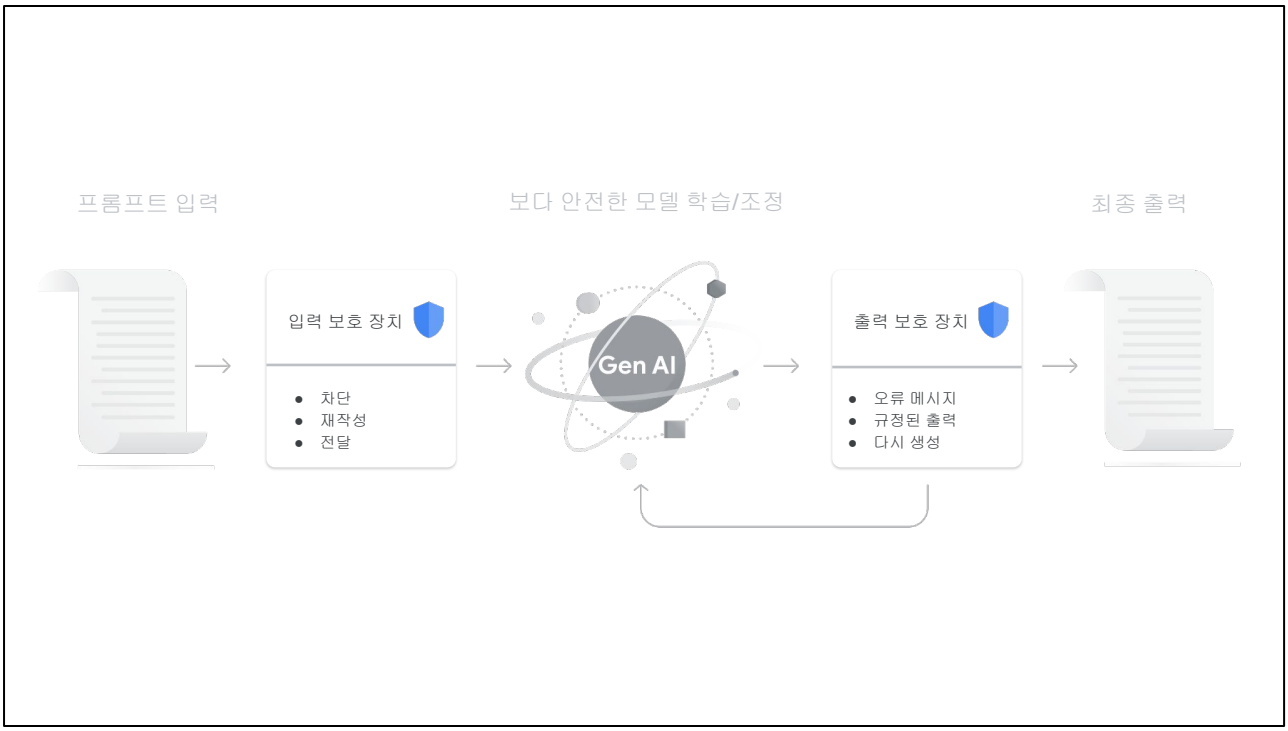
시스템이 프롬프트 입력을 받으면


프롬프트 입력
보다 안전한 모델 학습/조정
최종 출력
입력 보호 장치
차단
재작성
전달
Gen AI
출력 보호 장치
오류 메시지
규정된 출력
다시 생성

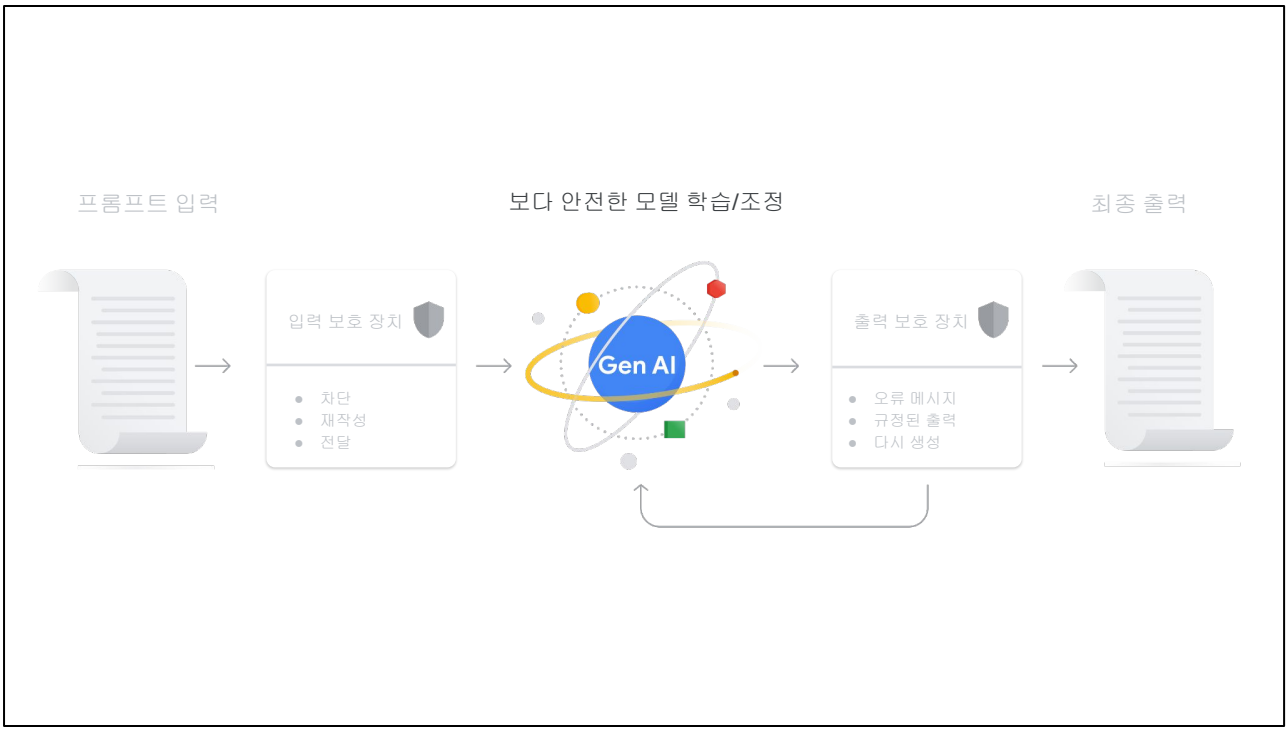
AI 모델에 전달하고


프롬프트 입력
보다 안전한 모델 학습/조정
최종 출력
입력 보호 장치
차단
재작성
전달
Gen AI
출력 보호 장치
오류 메시지
규정된 출력
다시 생성

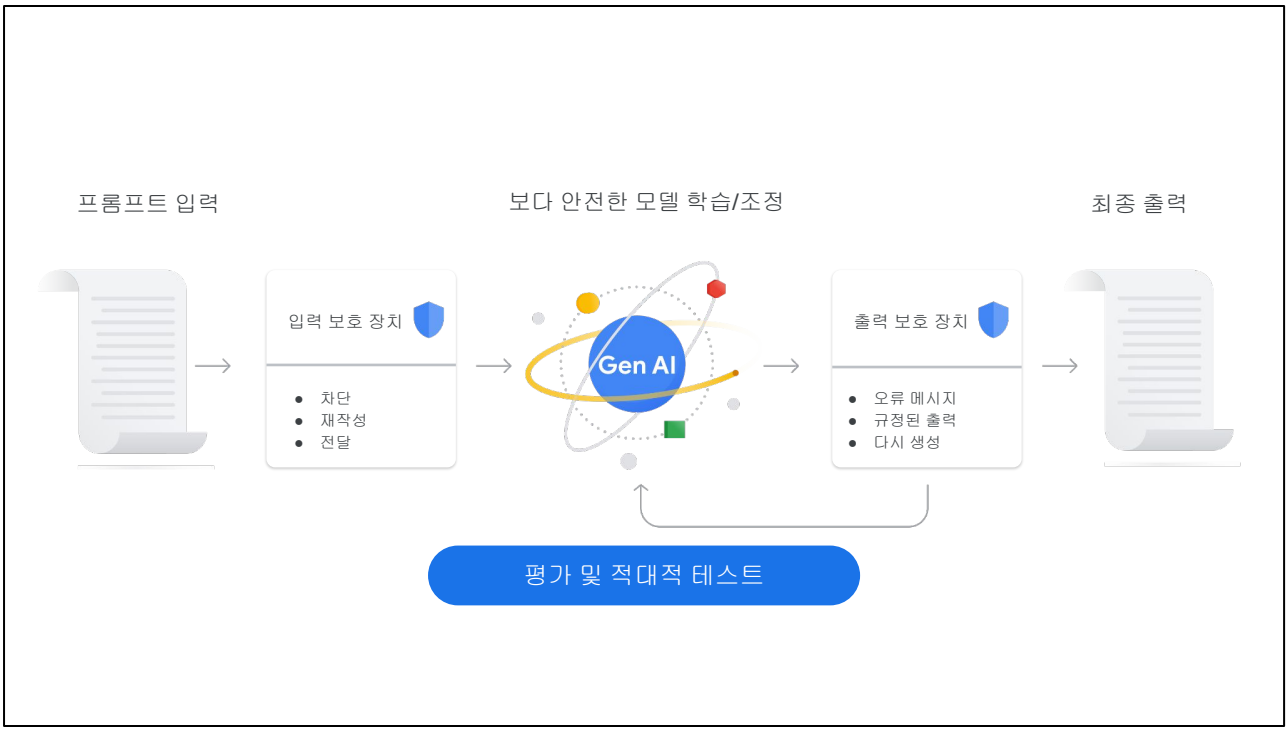
출력을 반환합니다.



프롬프트 입력과 최종 출력 사이에 입력 보호 장치과 출력 보호 장치가 있습니다. 이러한 보호 장치는 정의된 안전 기준에 따라 입력/출력 필터링을 처리합니다. 보호 장치를 적절하게 사용하면 시스템 입력/출력을 활용하여 의도하지 않은 유해한 결과를 방지할 수 있습니다.



보호 장치 외에도 모델 학습 및 조정 프로세스에 개입하여 모델에 안전 개념을 삽입하고 모델의 동작을 안전 지향적으로 조정할 수도 있습니다.



전체 프로세스에서 AI 시스템을 평가하는 방법을 이해하는 것도 중요합니다.
평가에는 시스템의 의도하지 않은 동작을 찾기 위한 철저한 테스트가 포함됩니다.
이를 '적대적 테스트'라고 합니다.
이 과정을 진행하면서 각 항목을 살펴보겠습니다.



01 AI 안전 개요

02 안전 평가

03 피해 방지

04 안전을 위한 모델 학습: 요청 사항 세부 조정

05 안전을 위한 모델 학습: RLHF

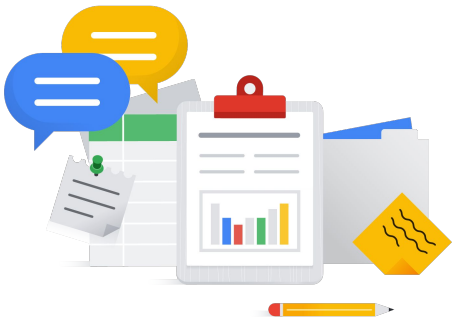
06 Google Cloud 생성형 AI의 안전

07 실습: Vertex AI Gemini API를 통한 보호

안전 평가에 대해 알아보겠습니다.

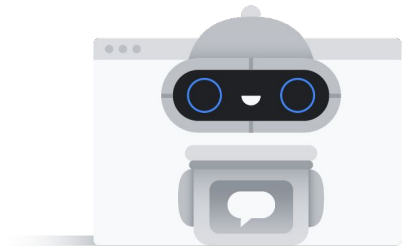


안전 기준을 이해하지 못하면 더 안전한 AI 시스템을 설계하고 구현하는 것이 불가능합니다. 다양한 주요 고려사항을 염두에 두어야 합니다.
이해해야 할 주요 오류 모드와 고려사항을 확인해 보겠습니다.



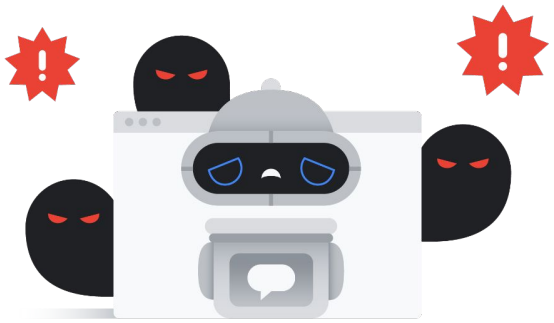
제품의 오류 모드를 정의하려면 먼저 제품과 사용자를 이해해야 합니다.
제품마다 일부 민감한 특성과 관련된 정의와 목표가 달라야 합니다.

방지해야 할 일반적인 오류 모드



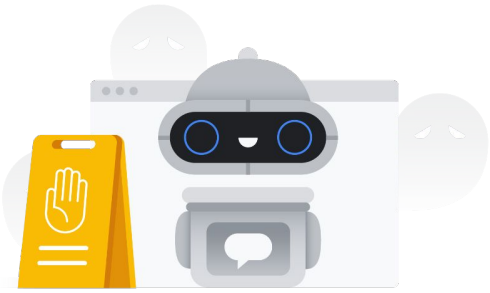
그러나

방지해야 할 일반적인 오류 모드



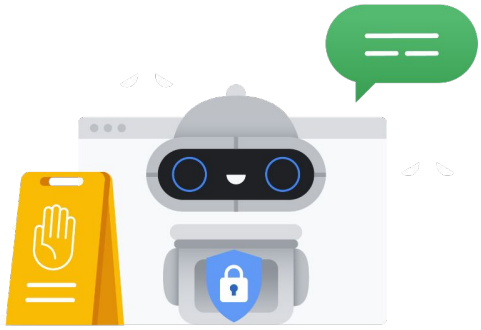
그러나 안전을 위해 방지해야 하는

방지해야 할 일반적인 오류 모드



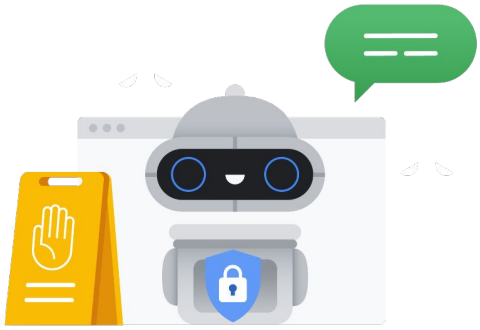
일반적인 오류 모드가

방지해야 할 일반적인 오류 모드



있습니다.

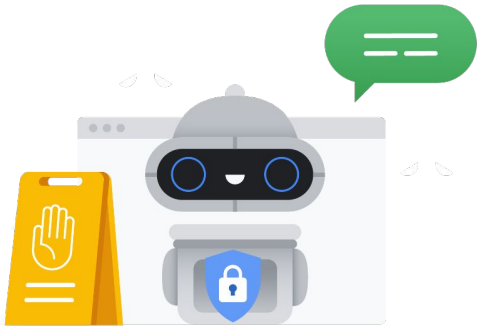
방지해야 할 일반적인 오류 모드



생성형 AI 시스템은 다음을 제공하지 않도록 설계되어야 합니다.

방지해야 할 일반적인 오류 모드

아동 성적 학대 콘텐츠(CSAM)

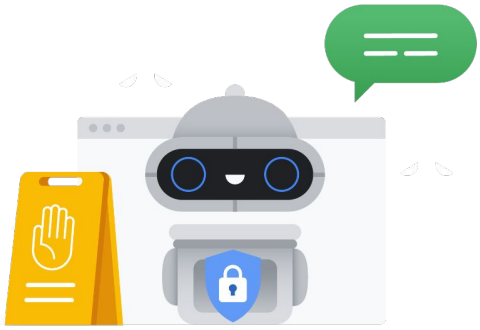


- 아동 성적 학대 콘텐츠(CSAM)

생성형 AI 제품의 콘텐츠에는 아동 성적 학대 콘텐츠와 아동을 학대, 성적 대상화하거나 위험에 빠뜨리거나 기타 방식으로 착취하는 것으로 보이는 콘텐츠가 포함되어서는 안 됩니다.

방지해야 할 일반적인 오류 모드

- 아동 성적 학대 콘텐츠(CSAM)
- 개인 식별 정보(PII)

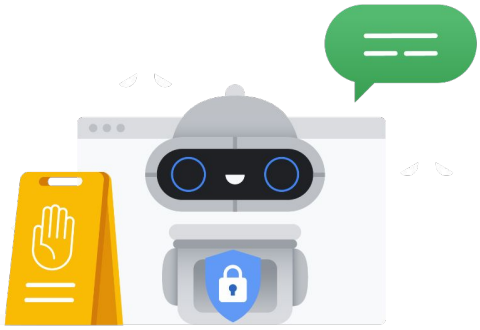


- 특정 개인의 개인 식별 정보(PII)와 민감한 개인 식별 정보(SPII)

생성형 AI는 개인 정보와 특정 개인의 인구통계 정보를 공개해서는 안 됩니다.

방지해야 할 일반적인 오류 모드

- 아동 성적 학대 콘텐츠(CSAM)
- 개인 식별 정보(PII)
- 증오심 표현



- 증오심 표현

생성형 AI는 증오심 표현을 생성해서는 안 됩니다. 증오심 표현이란 폭력을 조장하거나 증오를 부추기거나 차별을 조장하거나 특정 집단을 비하하는 콘텐츠를 말합니다.

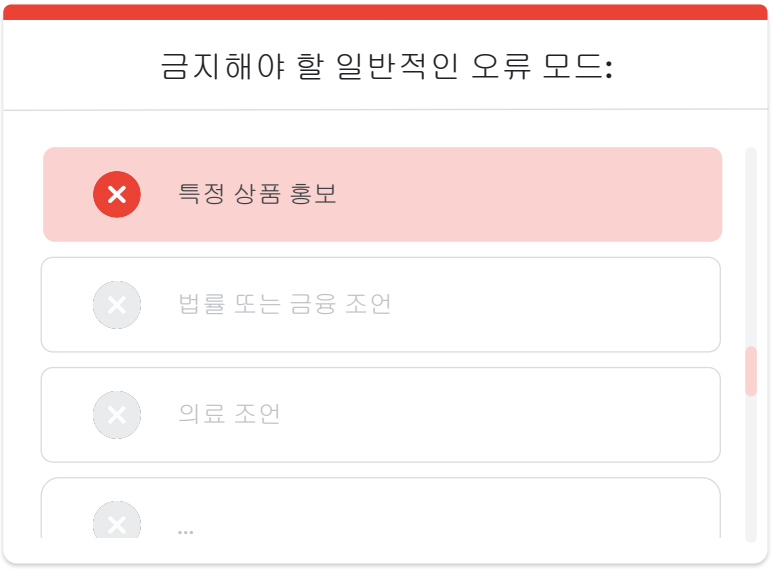


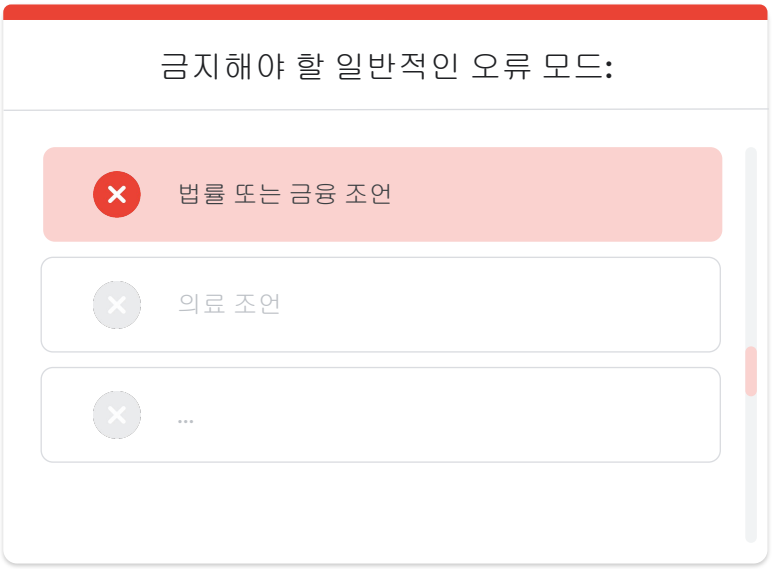
이외에도 대체로 피해야 할 다른 일반적인 오류 모드가 많이 있습니다.
그러나 실제 뉘앙스와 기준점은 실제 제품에 따라 다릅니다. 균형을 맞추기 위해서는 사용자의 요구와 상황에 따라 유연하게 제어하고 조정할 수 있는 시스템을 설계하는 것도 매우 중요합니다.

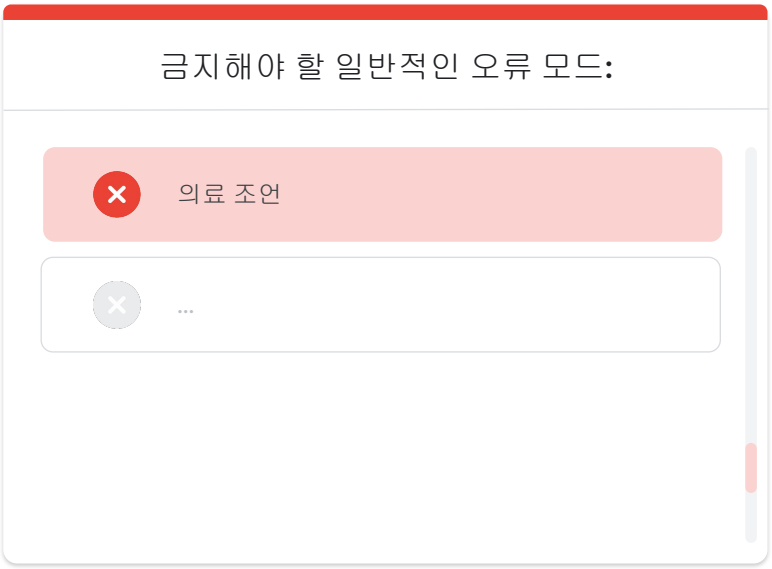

금지해야 할 일반적인 오류 모드:
불법적인 활동의 조장
선정적인 주제
공익과 관련된 주제
특정 상품 홍보

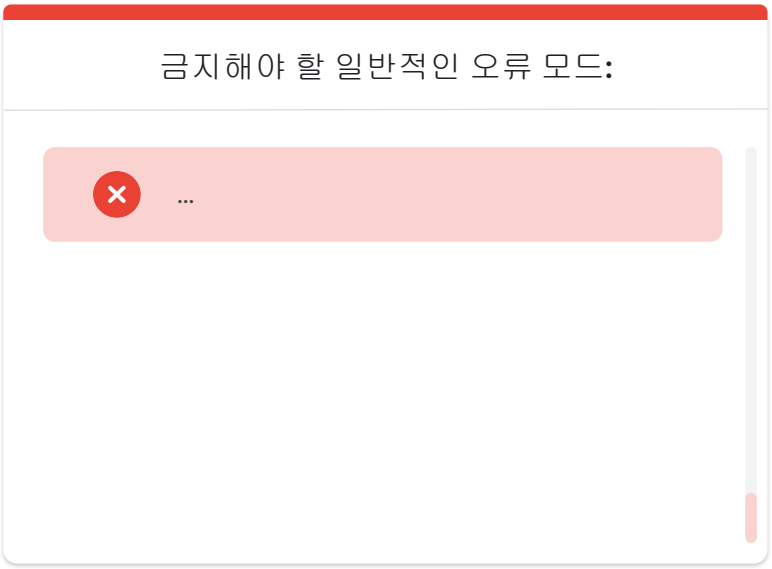

금지해야 할 일반적인 오류 모드:
선정적인 주제
공익과 관련된 주제
특정 상품 홍보
법률 또는 금융 조언


금지해야 할 일반적인 오류 모드:
공익과 관련된 주제
특정 상품 홍보
법률 또는 금융 조언
의료 조언


금지해야 할 일반적인 오류 모드:
특정 상품 홍보
법률 또는 금융 조언
의료 조언
...


금지해야 할 일반적인 오류 모드:
법률 또는 금융 조언
의료 조언
...


금지해야 할 일반적인 오류 모드:
의료 조언
...


금지해야 할 일반적인 오류 모드:
...

적대적 테스트는 악의적이거나 의도치 않게 유해한 입력이 제공되었을 때 ML 모델이 어떻게 작동하는지 파악하기 위한 목적으로 ML 모델을 체계적으로 평가하는 방법입니다.

생성형 AI 모델이 오류 모드와 관련하여 안전한지 확인하는 것이 중요하기 때문에 적대적 테스트가 필요합니다. 적대적 테스트는 악의적이거나 의도치 않게 유해한 입력이 제공되었을 때 ML 모델이 어떻게 작동하는지 파악하기 위한 목적으로 ML 모델을 체계적으로 평가하는 방법입니다.

적대적 테스트의 목표

- 모델과 제품을 개선합니다.



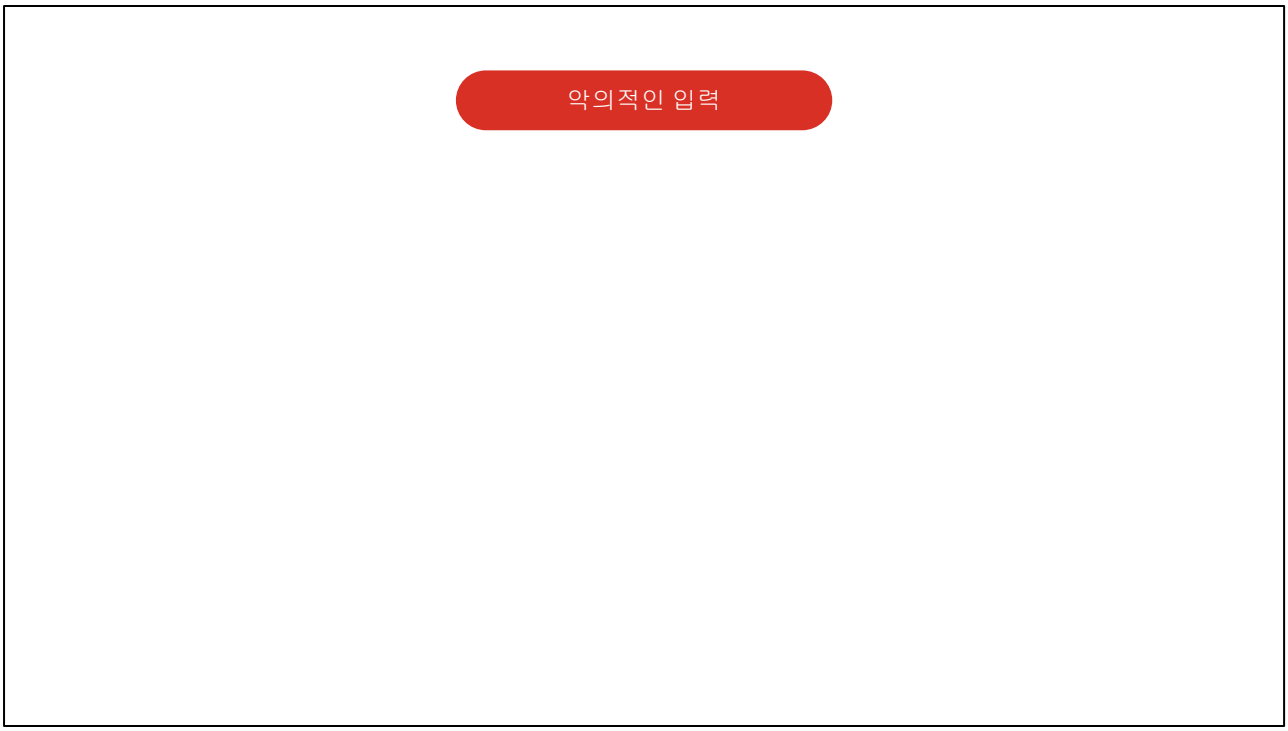
적대적 테스트는 일반적인 오류에 노출하여 미세 조정, 모델 보호 장치 또는 필터와 같은 완화 경로를 안내함으로써 팀이 모델과 제품을 개선하는 데 도움을 줍니다.

적대적 테스트의 목표

- 모델과 제품을 개선합니다.
- 제품 출시 결정에 필요한 정보를 제공합니다.

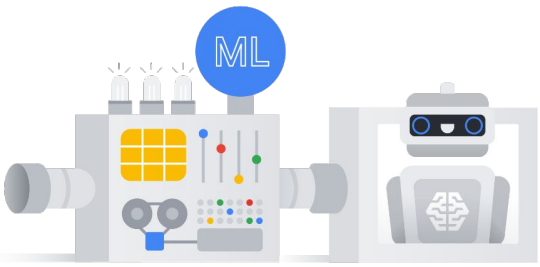


또한 완제품 출시 결정에 필요한 정보를 제공하는 데 도움이 될 수 있습니다. 그 방법은 완화되지 않을 수 있는 위험, 예를 들면 모델이 정책을 위반하는 콘텐츠를 출력할 가능성을 측정하는 것입니다.
그런데 무엇이 악의적인 입력이고 의도치 않게 유해한 입력일까요?



입력이 안전하지 않거나 유해한 출력을 생성하도록 명확하게 설계된 경우 악의적인 입력으로 간주됩니다.

악의적인 입력

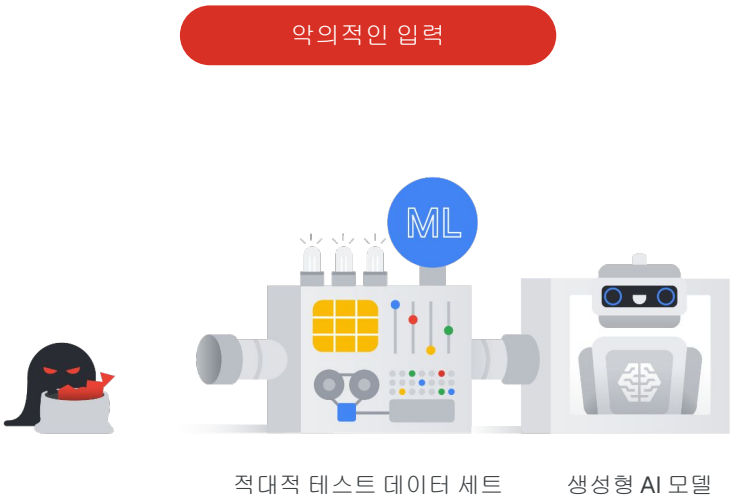


적대적 테스트 데이터 세트 생성형 AI 모델

예를 들어



입력이



텍스트 생성 모델에 특정 소수 그룹에 대한 증오심 표현을 생성하도록 요청하면 악의적인 입력으로 간주됩니다.
이를 가리켜 명시적으로 적대적인 쿼리라고도 합니다.



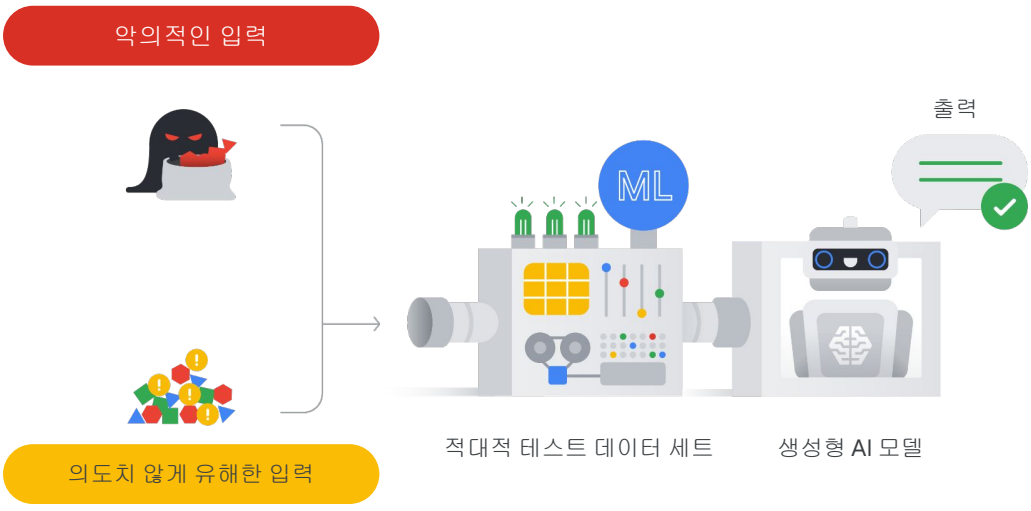
이러한 유형의 쿼리는 모델을 '속여서' 안전하지 않거나 유해하거나 불쾌감을 주는 말을 하도록 만들기 위해 정책을 위반하는 언어를 포함하거나 정책을 위반하는 관점을 표현할 수 있습니다.



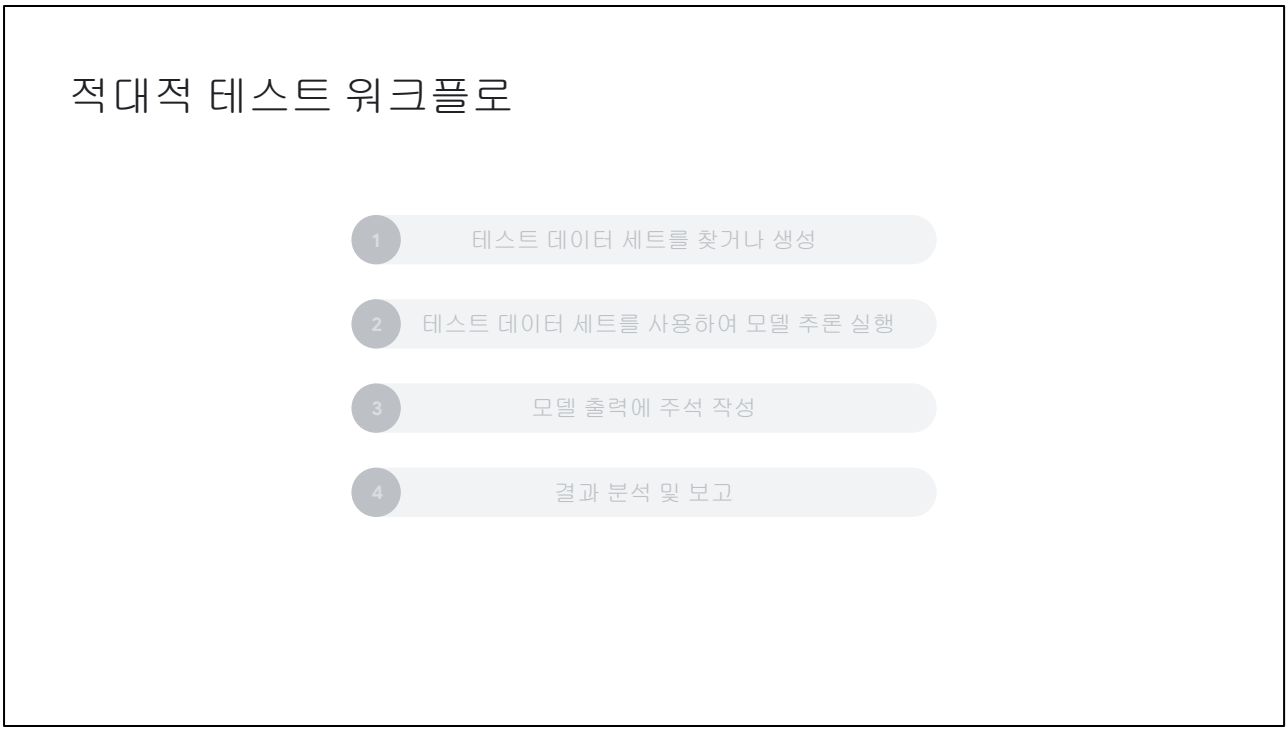
입력 자체는 무해하지만 유해한 출력을 초래하는 경우에는 입력이 의도치 않게 유해한 것으로 간주됩니다. 예를 들면 텍스트 생성 모델에 특정 민족의 사람을 설명하도록 요청하는 입력에 대해 모델이 인종 차별적인 출력을 제공하는 경우가 있습니다.



이를 암시적으로 적대적인 쿼리라고도 합니다. 이러한 쿼리에는 문화적으로 민감하거나 논쟁의 여지가 있는 주제가 포함될 수 있으며 인구통계, 건강, 금융 또는 종교에 대한 정보가 포함될 수 있습니다.

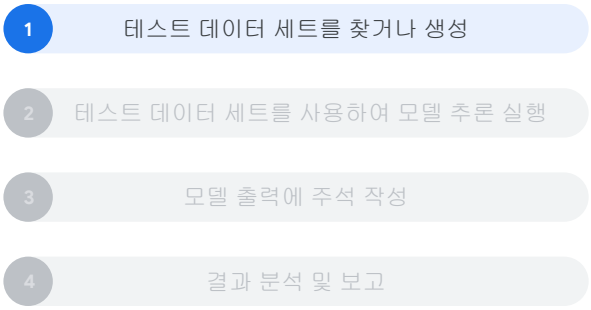


악의적이거나 유해한 출력이 발생하는 경우 이러한 입력에 모델이 노출되었을 때 어떻게 작동하는지 자세히 알아보려면 출력을 연구하는 것이 중요합니다.



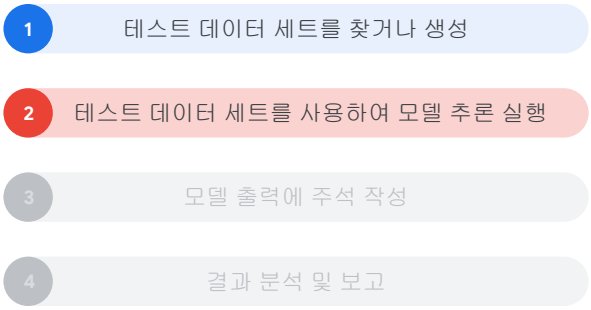
이는 적대적 테스트 워크플로를 통해 이루어집니다. 이 워크플로는 네 단계로 구성됩니다.

적대적 테스트 워크플로



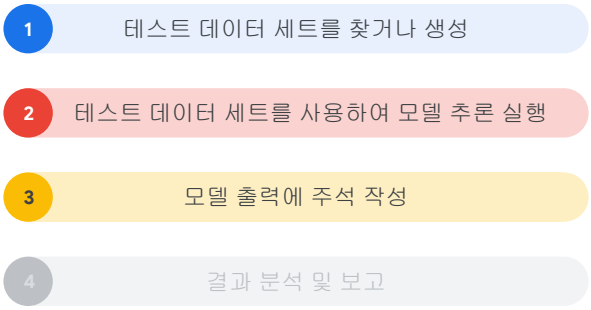
- 테스트 데이터 세트를 찾거나 생성합니다.

적대적 테스트 워크플로



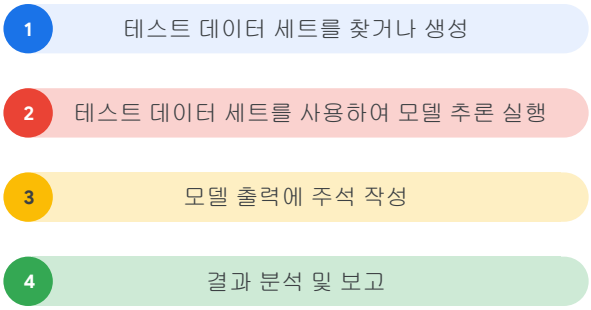
- 테스트 데이터 세트를 사용하여 모델 추론을 실행합니다.

적대적 테스트 워크플로



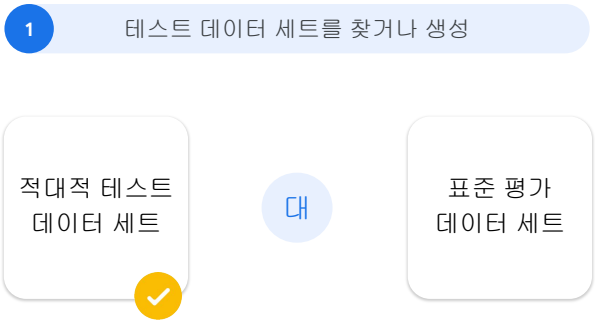
- 모델 출력에 주석을 작성합니다.

적대적 테스트 워크플로



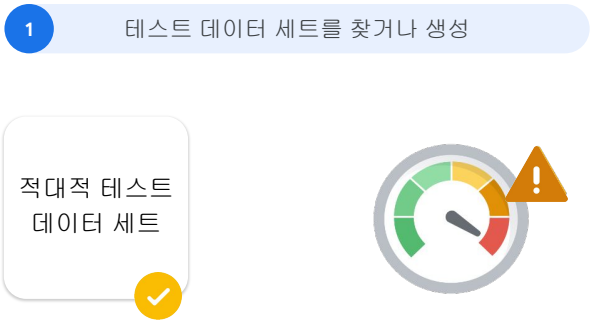
- 그리고 결과를 분석 및 보고합니다.

적대적 테스트 워크플로



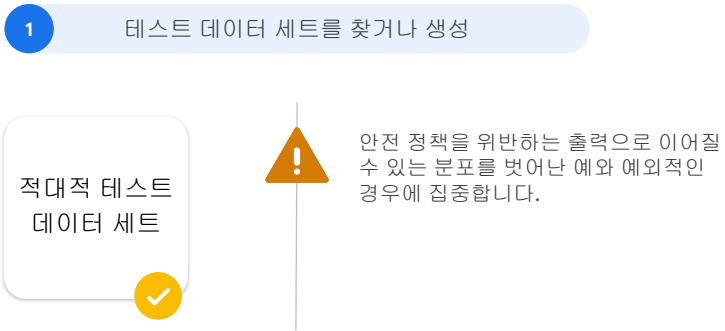
효과적인 적대적 테스트를 수행하려면 테스트 데이터 세트를 찾거나 생성하세요. 표준 평가 데이터 세트를 사용하면 안 됩니다. 이러한 데이터 세트는 일반적으로 모델이 제품에서 접하게 될 데이터의 분포를 정확하게 반영하도록 설계되었기 때문입니다.

적대적 테스트 워크플로



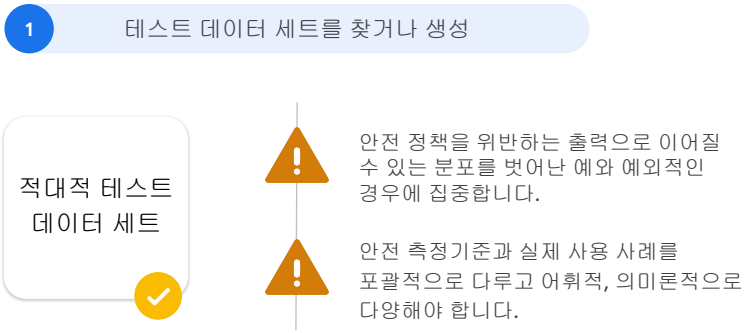
적대적 테스트의 경우 테스트 데이터 세트를 생성하거나 찾을 때 모델의 한계를 뛰어넘는 테스트를 설계하는 것이 가장 중요합니다.

적대적 테스트 워크플로



이를 위해서는 안전 정책을 위반하는 출력으로 이어질 수 있는 분포를 벗어난 예와 예외적인 경우에 집중해야 합니다.

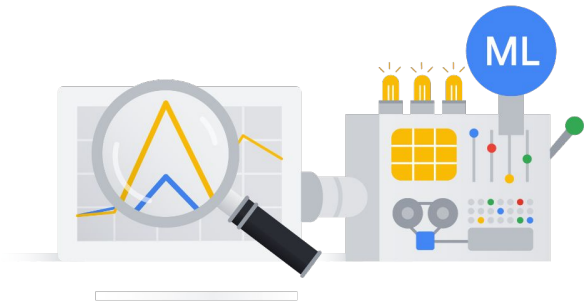
적대적 테스트 워크플로



데이터 세트는 안전 측정기준과 실제 사용 사례를 포괄적으로 다루고 어휘적, 의미론적으로 다양해야 합니다. 어휘 다양성은 텍스트나 음성 내에서 사용되는 고유한 단어의 다양성에 중점을 둡니다. 의미론적 다양성은 텍스트나 음성 내에서 표현되는 다양한 의미와 아이디어에 중점을 둡니다.

적대적 테스트 워크플로

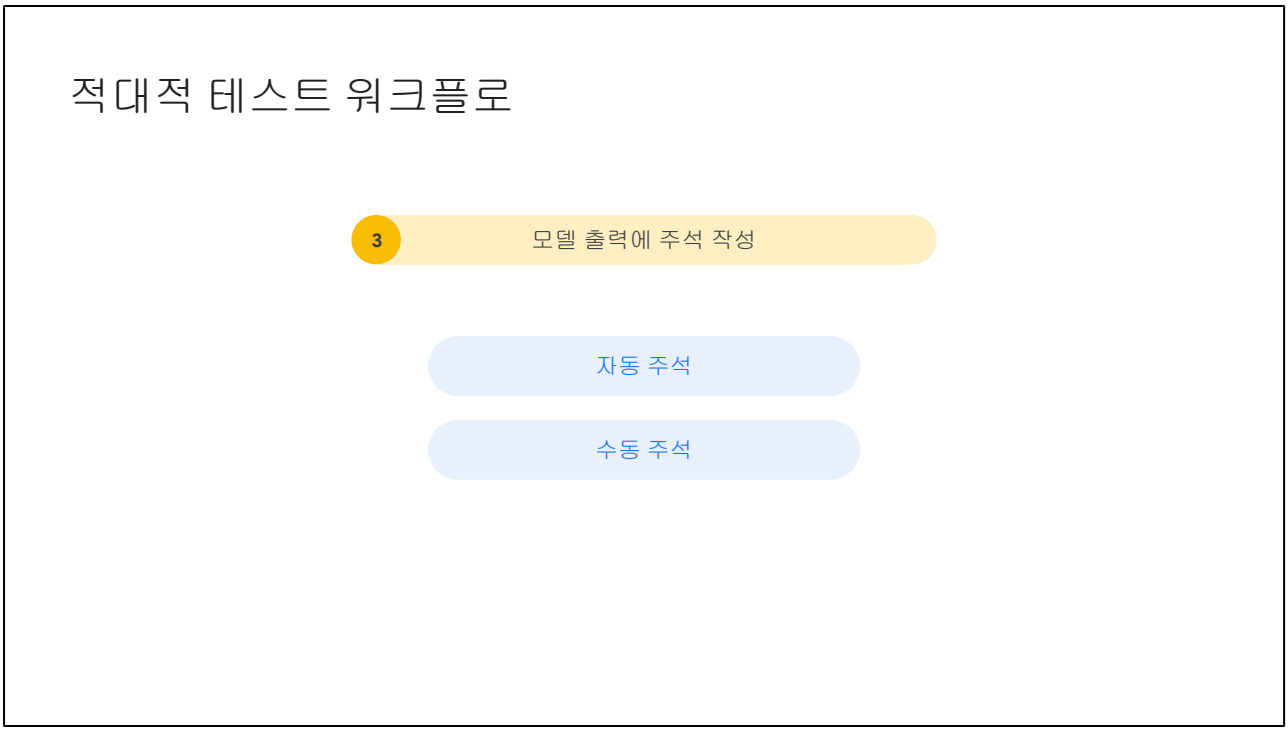
2 테스트 데이터 세트를 사용하여 모델 추론 실행



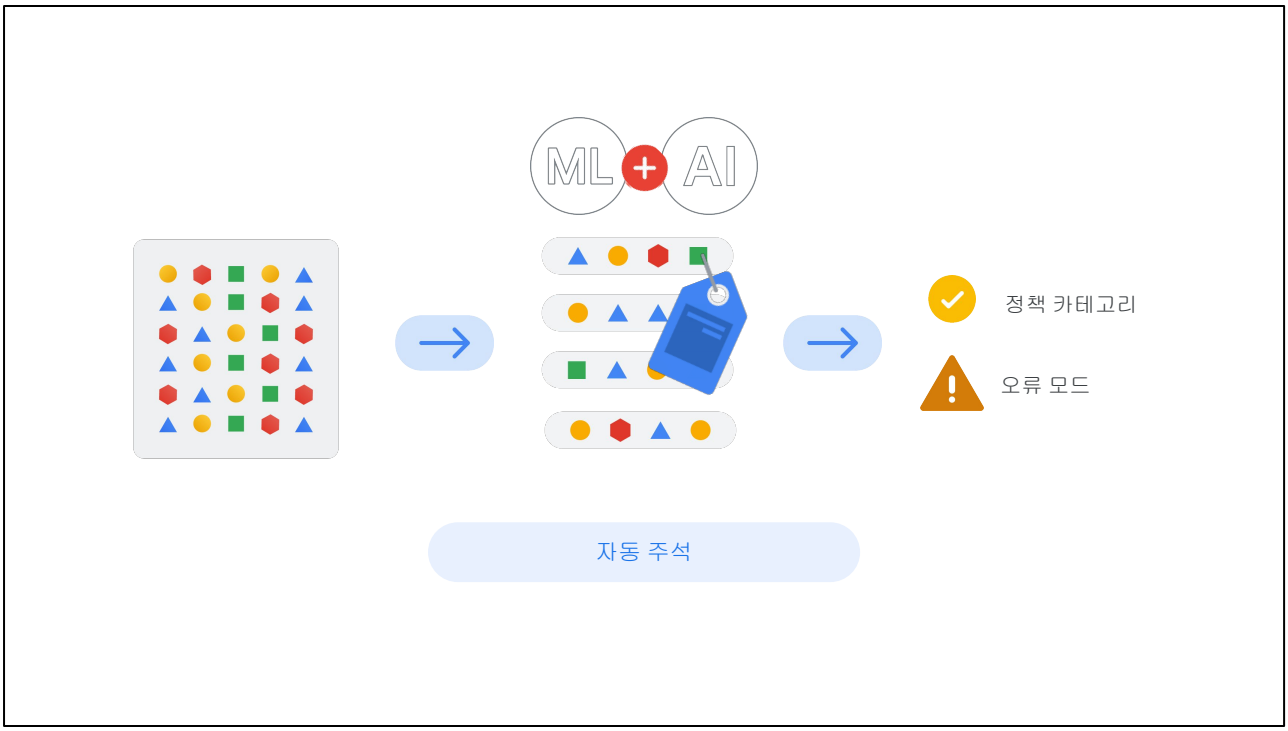
적대적 쿼리당 여러 모델 출력을 생성합니다.

다음으로 테스트 데이터 세트를 사용하여 모델 추론을 실행합니다. 여기서 목표는 테스트 데이터 세트를 기반으로 모델 출력을 생성하는 것입니다. 경우에 따라 적대적 쿼리당 여러 모델 출력을 생성하는 것이 도움이 될 수 있습니다.

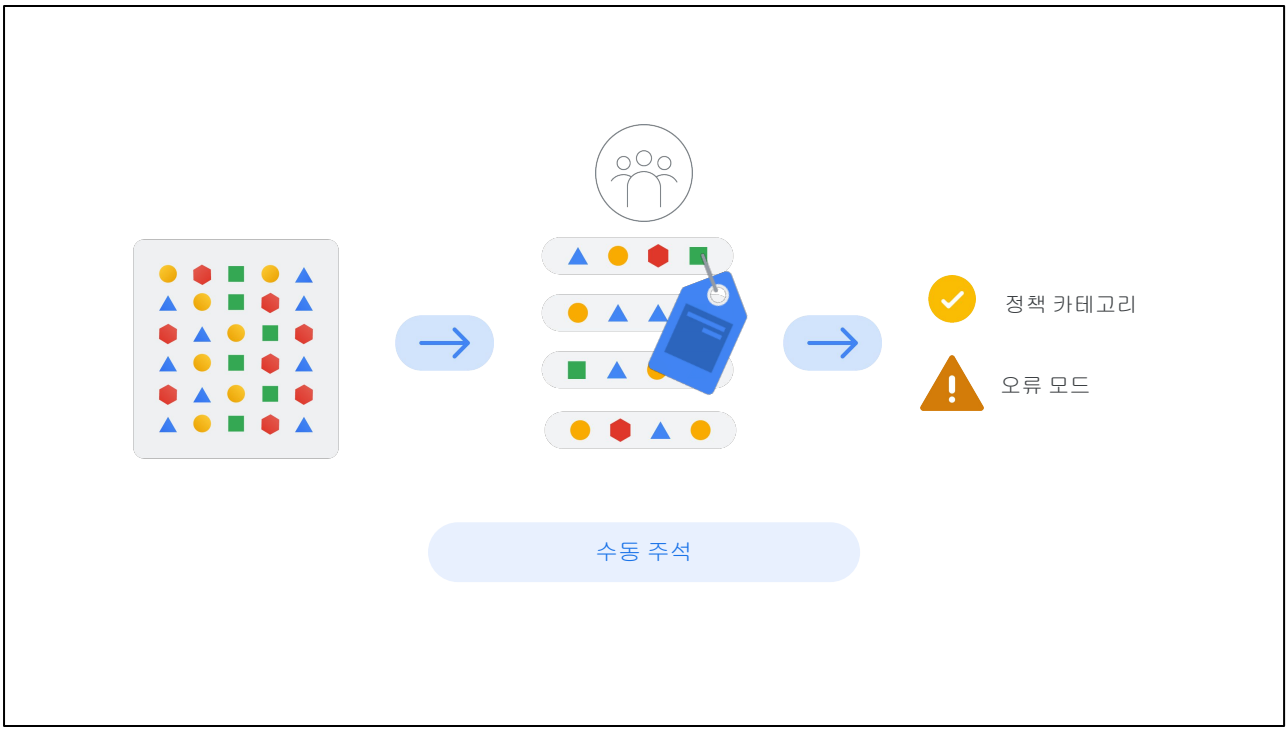
적대적 테스트 워크플로



셋째, 모델의 출력에 주석을 달아 정책 위반을 식별합니다.
이는 자동과 수동, 두 가지 방법으로 수행할 수 있습니다.

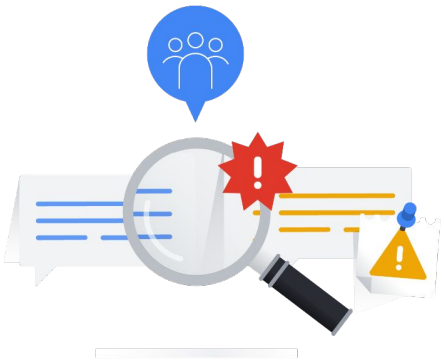


자동 주석은 머신러닝과 기타 AI 기법을 사용하여 특정 정책 카테고리 및 오류 모드에 맞는 데이터에 자동으로 라벨이나 태그를 지정합니다.



수동 주석에는 데이터에 라벨이나 태그를 지정하는 내부 또는 외부 평가자가 필요합니다. 이는 이 작업을 위해 설계된 고유한 특정 요청 사항과 플랫폼을 사용하여 이루어집니다.
자동 주석과 수동 주석은 언제 사용해야 할까요?

자동 주석과 수동 주석: 적용해야 하는 경우



분류기에 의해 생성되어 점수가 '불확실'한 라벨을 확인하고 수정하려면 반드시 인간 평가자가 있어야 합니다.

증오심 표현이 포함된 데이터의 주석을 예로 들 수 있습니다. 증오심 표현과 같이 엄격하게 정의되지 않은 구문을 감지하려는 신호의 경우 자동 주석의 정확성이 떨어질 수 있습니다. 이러한 상황에서는 분류기에 의해 생성되어 점수가 '불확실'한 라벨을 확인하고 수정하기 위해 반드시 인간 평가자가 있어야 합니다.

적대적 테스트 워크플로

4 결과 분석 및 보고



마지막 단계는 테스트 결과를 보고서에 요약하는 것입니다. 원하는 차트 유형을 선택하여 보고서의 결과를 이해관계자 및 의사 결정자에게 효과적으로 전달할 수 있습니다.

이러한 결과는 모델 개선으로 이어지며 필터 생성 또는 개선과 같은 모델 보호 장치에 대한 정보를 제공할 수 있습니다.



01 AI 안전 개요

02 안전 평가

03 피해 방지

04 안전을 위한 모델 학습: 요청 사항 세부 조정

05 안전을 위한 모델 학습: RLHF

06 Google Cloud 생성형 AI의 안전

07 실습: Vertex AI Gemini API를 통한 보호

피해 방지를 위한 몇 가지 방법을 알아보겠습니다.

책임감 있는 생성을 위한 최선의 노력에도
불구하고 여전히 생성될 수 있는 유해한
콘텐츠를 표시하지 않는 것

피해 방지란 책임감 있는 생성을 위한 최선의 노력에도 불구하고 여전히 생성될 수 있는 유해한 콘텐츠를 표시하지 않는 것을 의미합니다.

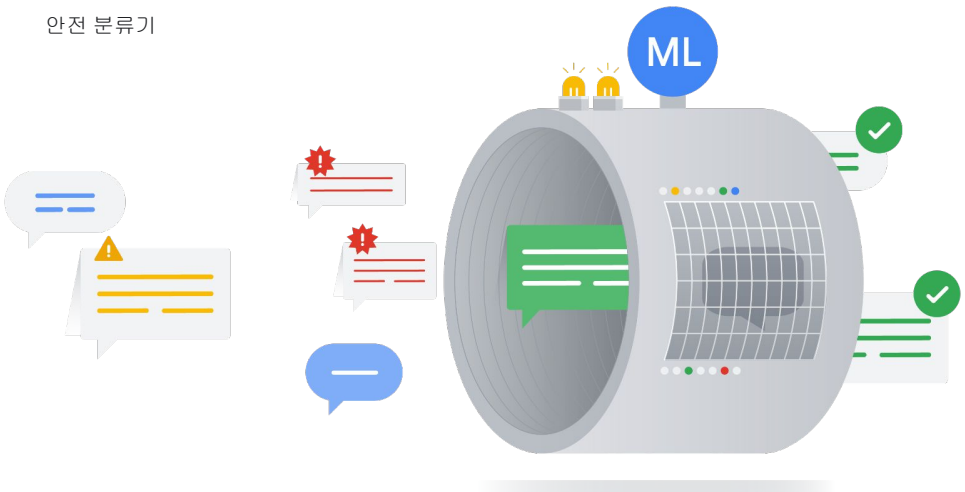
입력/출력 보호 장치



입력 및 출력 보호 장치는 AI 안전의 필수 요소로서 피해를 방지하는 데 중요한 역할을 합니다.
이러한 보호 장치는 AI 시스템에 입력되는 내용과 AI 시스템에서 생성되는 내용, 즉 입력과 출력을 보호하여 AI가 작동하는 방식이 안전 기준과 윤리 원칙에 부합하도록 합니다.

안전 분류기

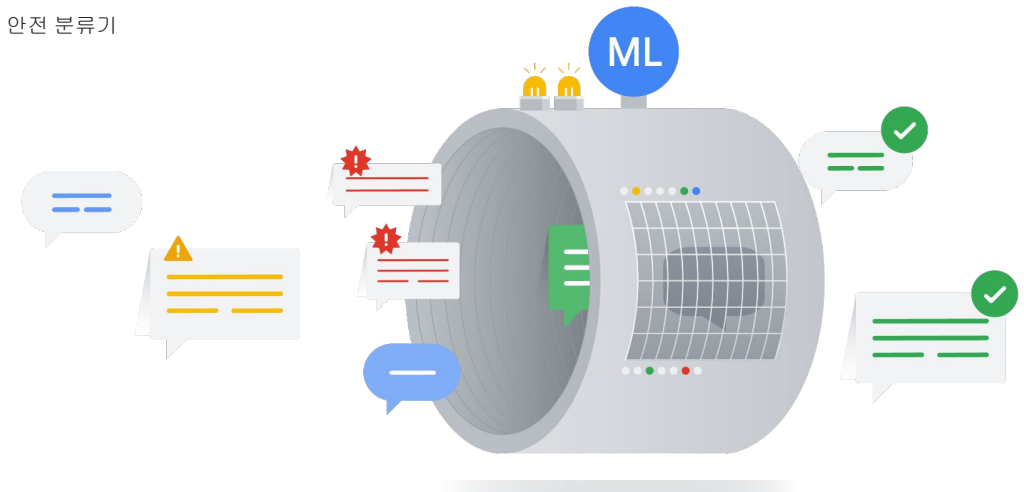
안전 분류기



입력 텍스트가 안전한지 여부를 분류하는 머신러닝 기반 분류 시스템을 안전 분류기라고 합니다. 기술적으로는 사용자가 직접 독창적인 안전 분류기를 빌드할 수 있지만, 실질적으로는 어려운 작업입니다. 왜냐하면 특별히 통합된 데이터 세트를 사용하여 안전 분류기를 신중하게 학습시켜야 하고, 공정성에 대해 특별한 주의와 관심을 기울여야 하기 때문입니다.

다행히도 AI 산업에는 모델에서 유해한 내용이 출력되지 않도록 하는 데 도움이 되는 몇 가지 안전 분류기가 있습니다.

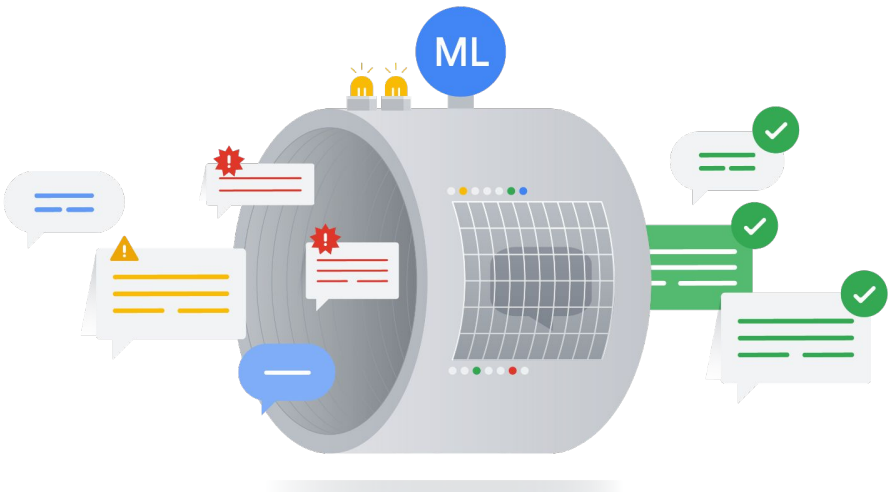
안전 분류기



2017년 Google Jigsaw팀이 출시한 Perspective API는 세계 최초의 안전 분류기 중 하나입니다. Perspective API는 사람들을 온라인 공간에서 밀어내거나, 폭력을 부추기거나, 심지어 그보다 더 나쁜 방향으로 유도하는 유해한 말에 플래그를 지정하는 데 도움이 되도록 설계되었습니다.
2021년이 되자 Perspective API는 많은 온라인 플랫폼에서 사용량이 늘어나면서 일일 요청이 5억 개가량에 달했습니다.
현재 Perspective API는 AI의 입력을 보호하는 입력 보호 장치 및 출력을 모니터링하는 출력 보호 장치로 널리 사용되고 있습니다.

안전 분류기

안전 분류기



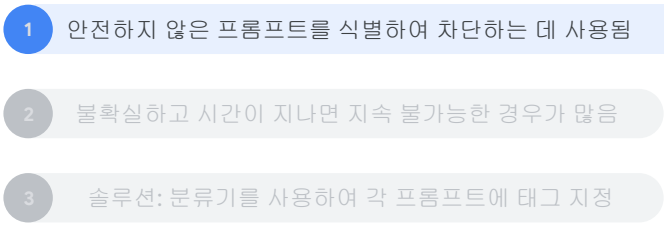
Perspective API는 최초의 안전 분류기 중 하나였지만, 이제는 OpenAI의 Moderation API와 Meta의 Llma Guard를 비롯하여 다른 조직에서도 안전 분류기를 제공합니다.

차단 목록

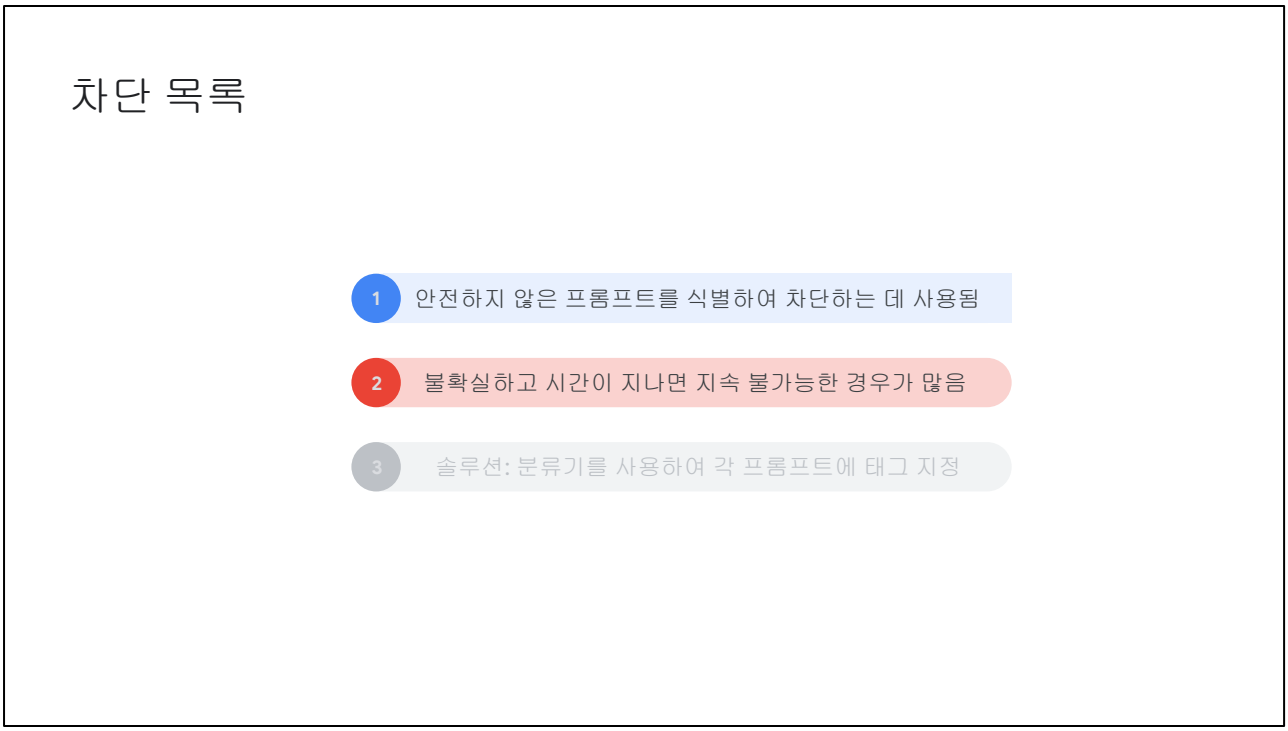
1. 안전하지 않은 프롬프트를 식별하여 차단하는 데 사용됨
2. 불확실하고 시간이 지나면 지속 불가능한 경우가 많음
3. 솔루션: 분류기를 사용하여 각 프롬프트에 태그 지정

많은 사람이 입력 보호 장치에 대해 이야기할 때 '차단 목록'을 떠올립니다.

차단 목록



아주 단순한 상황에서는 차단 목록을 사용하여 안전하지 않은 프롬프트를 식별하고 차단할 수 있습니다.



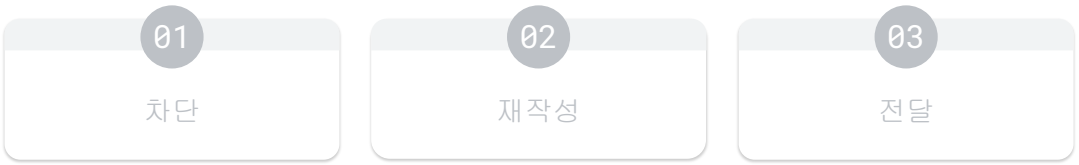
하지만 이 방법은 불확실하고 시간이 지나면 지속 불가능한 경우가 많습니다.

차단 목록

1. 안전하지 않은 프롬프트를 식별하여 차단하는 데 사용됨
2. 불확실하고 시간이 지나면 지속 불가능한 경우가 많음
3. 솔루션: 분류기를 사용하여 각 프롬프트에 태그 지정

보다 나은 장기적인 솔루션은 분류기를 사용하여 각 프롬프트에 잠재적인 위험이나 적대적인 신호로 태그를 지정하는 것입니다. 그러면 감지된 위험 유형에 따라 요청을 처리하는 방법에 대해 다양한 전략을 적용할 수 있습니다.

입력 보호 장치



전략에는 요청을



차단하거나



재작성하거나



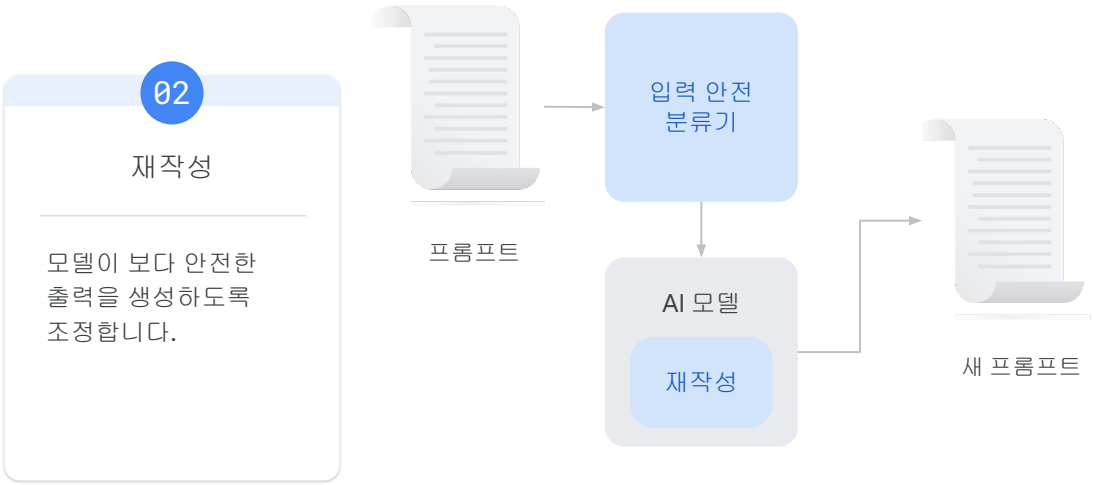
전달하는 방법이 있습니다.

입력 보호 장치



입력이 명백하게 적대적이거나 악의적인 경우 시스템은 입력이 모델로 전송되는 것을 차단하고 대신 사전 스크립트된 대답을 출력할 수 있습니다.
예를 들어 챗봇에 '은행을 터는 방법'을 물어보면 분류기가 이 입력을 유해한 프롬프트로 인식하고 시스템에 차단을 제안합니다. 그러면 사용자는 챗봇으로부터 '도와드릴 수 없습니다'라는 대답을 받게 됩니다. 또한 그것이 잘못된 생각인 이유와 함께 어려운 상황에 처해 있을 때 연락할 수 있는 국가 지원 전화 상담 서비스에 대한 정보도 받게 됩니다.

입력 보호 장치



입력이 안전하지 않은 대답을 유도할 가능성이 있는 경우, 프롬프트 엔지니어링이나 제어 토큰 또는 스타일 전이를 사용하여 모델이 보다 안전한 출력을 생성하도록 조정할 수 있습니다.

입력 보호 장치



AI 모델이 얼마나 안전 튜닝되었는지 또는 애플리케이션 용도에 맞게 얼마나 맞춤 조정되었는지에 따라, 유해한 데이터가 포함된 입력을 전달하고 AI 모델이 생성된 출력을 안전하게 처리하리라고 신뢰할 수 있습니다.

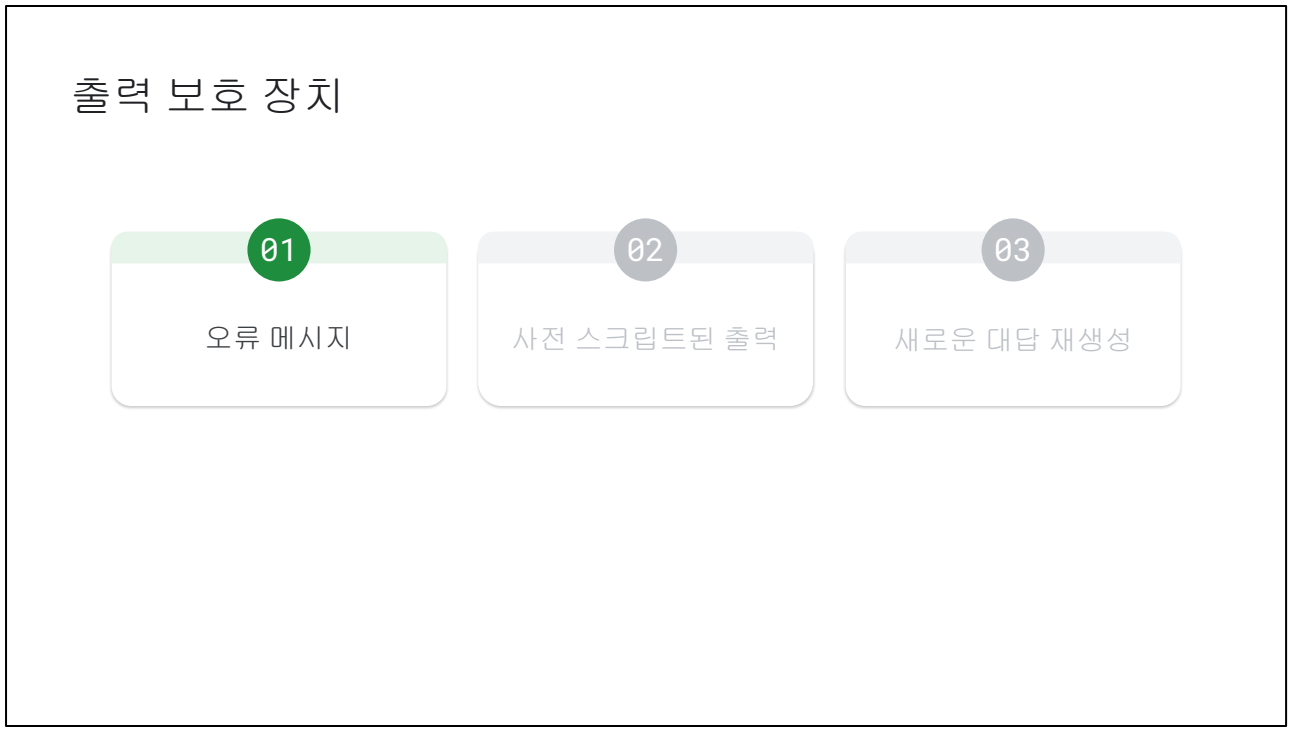
잘 조정된 모델은 프리픽스가 붙은 오류나 메시지보다 훨씬 유용한 대답을 생성할 수 있습니다.

이러한 접근방식에서는 안전 튜닝된 AI 모델이 처리할 수 있는 유해한 데이터의 종류를 이해하는 것이 매우 중요합니다.

출력 보호 장치



입력 보호 장치가 마련되어 있고 모델의 안전 튜닝되었어도, 모델이 여전히 승인할 수 없는 콘텐츠를 출력할 수 있습니다. 따라서 출력 보호 장치도 마찬가지로 중요합니다.
출력 보호 장치를 사용하면 분류기를 통해 유해한 출력을 감지하고 이 출력에 대해 다음 작업 중 하나를 수행할 수 있습니다.



- 오류 메시지를 제공합니다.



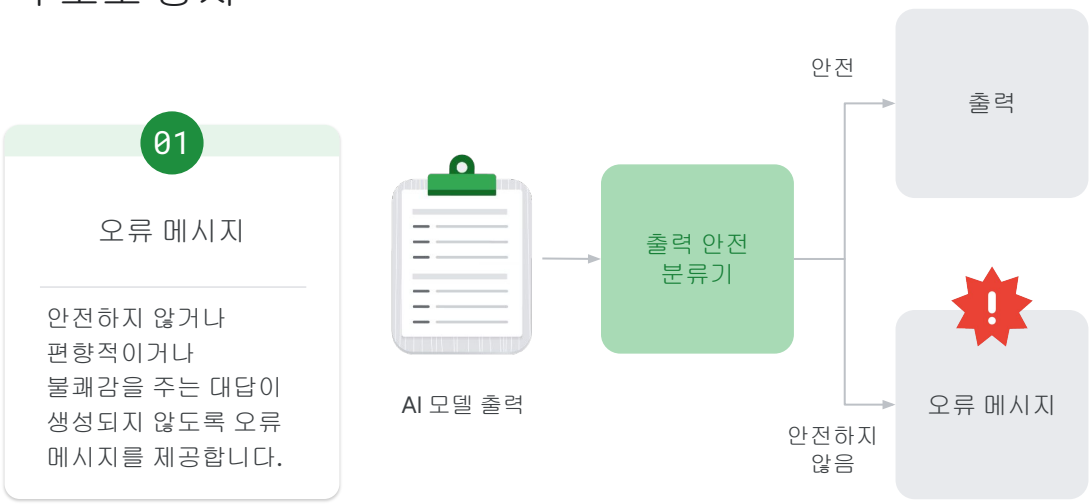
- 사전 스크립트된 출력을 제공합니다.

출력 보호 장치



- 순위를 지정하여 다른 대답을 재생성합니다.

출력 보호 장치



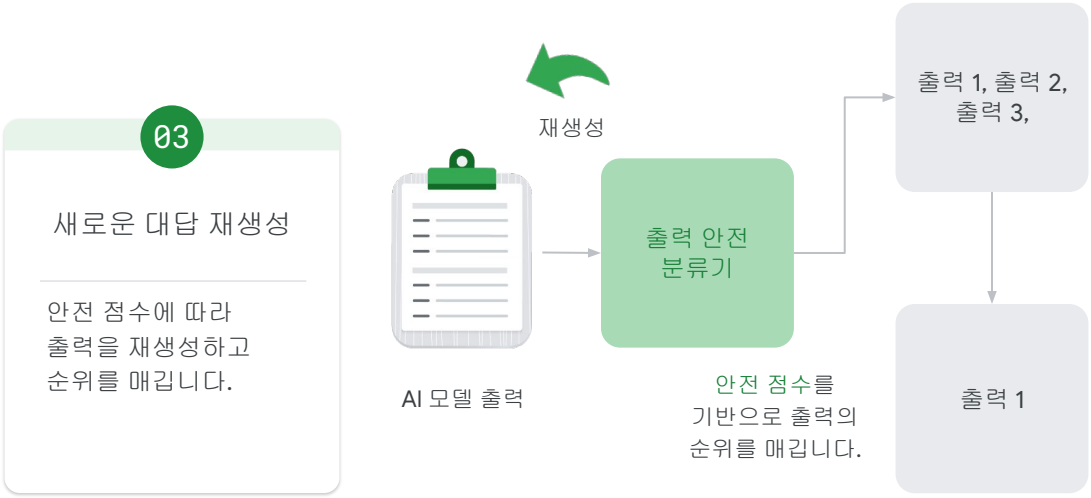
분류기가 의심의 여지 없이 출력이 유해하다고 판단하는 경우에는 오류 메시지를 생성하도록 시스템을 구성하여 안전하지 않거나 편향적이거나 불쾌감을 주는 대답을 전달하지 않도록 할 수 있습니다.
예를 들어 챗봇을 사용하는 경우, 쿼리에 이런 내용이 포함되어 있으면 오류 메시지 또는 대답 거부 메시지가 출력됩니다.

출력 보호 장치



사전 스크립트 또는 준스크립트를 출력하도록 시스템을 구성할 수도 있습니다. 때로는 준스크립트 출력이 단순한 오류 메시지보다 더 많은 정보를 전달하기도 합니다.
AI 모델이 준스크립트 출력을 생성하여 안전하지 않은 이유에 대한 일정 수준의 정보를 제공합니다.
예를 들면 AI 모델은 오류 메시지를 전달하는 대신 '무기에 관한 정보는 사람들에게 해를 끼치는 데 악용될 수 있고 이는 정책을 위반하는 행위이므로 도움을 드릴 수 없습니다'라고 출력할 수 있습니다.

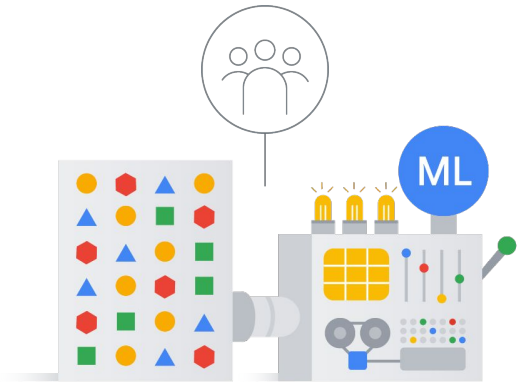
출력 보호 장치



대부분의 생성형 AI 모델은 동일한 프롬프트에 대해 여러 개의 출력을 생성할 수 있도록 설계되었기 때문에 때로는 이 기능을 사용하여 위험한 출력을 처리하면 도움이 됩니다. 안전하지 않은 출력이 감지되면 생성형 AI를 사용하여 여러 개의 추가 답변을 생성하고 안전 점수에 따라 순위를 매깁니다.
그러면 모델이 안전 점수가 가장 높은 출력으로 대답합니다.

최종 출력이 모든 안전 기준을 충족해야 한다는 사실을 강조하고 싶습니다.

안전과 공정성의 절충



한계: 인간의 판단은 본질적으로 편향적

한편 안전과 공정성의 절충에 대해 몇 가지 알아둘 점이 있습니다.

분류기는 대규모 데이터 세트를 기반으로 유해한 콘텐츠와 유해하지 않은 콘텐츠를 학습합니다. Wikipedia 토론 페이지에 있는 많은 양의 댓글을 사용하여 분류기를 학습시키면서 동시에 작업자 그룹이 각 댓글에 '괴롭힘'이나 '인신공격'과 같은 속성이 있는지 검토하는 상황을 예로 들 수 있습니다. 그러나 유해성에 대한 인간의 판단은 본질적으로 편향되어 있으며 괴롭힘의 전체 범위를 나타내지 못하는 경우가 많습니다. 대규모의 강력한 데이터 세트가 있어도 모델이 항상 올바른 패턴을 학습하는 것은 아닙니다.

안전과 공정성의 절충

- 과소 대표된 집단 보호



한 가지 문제는 과소 대표된 집단을 보호하는 것입니다.
많은 LLM 개발자가 증오심 표현을 삭제하기 위해 유해성 기준점이 낮은 분류기를 사용하고 있습니다. 이는 모델이 불확실한 경우 더 많은 항목을 유해한 것으로 플래그를 지정하고 있으며, 이로 인해 거짓 양성의 위험이 늘어남을 의미합니다.
이로 인해 LLM이 과소 대표된 커뮤니티에 관해 언급할 가능성이 없어져서 역사적으로 불리한 집단에 대한 부정적인 영향을 강화하게 될 수 있습니다.

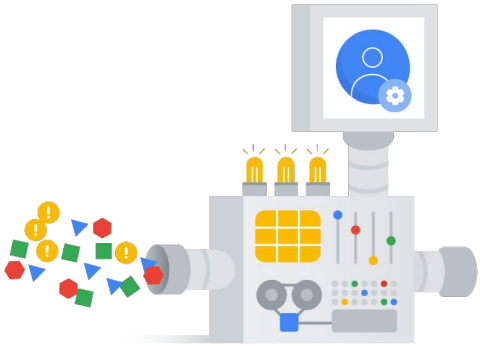
안전과 공정성의 절충

- 과소 대표된 집단 보호
- 영어가 아닌 프롬프트에 대한 추가 지원



영어가 아닌 언어의 경우 분류기의 성능이 중요합니다.
또한 모델은 영어가 아닌 무해한 문구를 증오심 표현 및 괴롭힘으로 해석할 가능성이 더 높습니다. 증오심 표현이 속어나 영어 외의 언어를 사용하여 은폐된 방식으로 표현되면 분류기를 쉽게 속일 수 있습니다.

인간 참여형(Human-In-The-Loop)



"머신러닝 모델은 항상 실수하기 때문에 인간이 이를 파악하고 적절히 수정할 수 있는 메커니즘을 빌드하는 것이 필수입니다."

머신러닝 모델은 항상 실수하기 때문에 인간이 이를 파악하고 적절히 수정할 수 있는 메커니즘을 빌드하는 것이 필수입니다. 완전 자동화 대신 인간이 프로세스에 참여하는 방식, 즉 인간 참여형(Human-In-The-Loop) 방식이 항상 중요하며 또 적극적으로 권장됩니다. 분류기를 사용해서 입력 및 출력 보호를 자동화할 수 있다고 해도 마찬가지입니다.
중요하거나 위험도가 높은 애플리케이션의 경우 AI 출력의 검증 및 검토에 인간의 감독을 통합하는 것이 중요합니다.
이렇게 하면 필요에 따라 인간이 개입하여 AI 시스템에 피드백을 제공할 수 있습니다.



01 AI 안전 개요

02 안전 평가

03 피해 방지

04 안전을 위한 모델 학습: 요청 사항 세부 조정

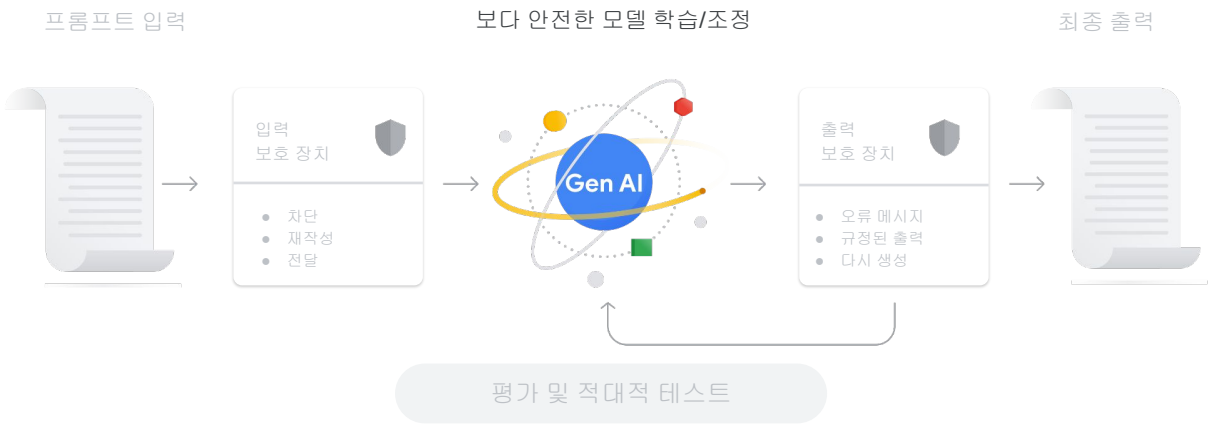
05 안전을 위한 모델 학습: RLHF

06 Google Cloud 생성형 AI의 안전

07 실습: Vertex AI Gemini API를 통한 보호

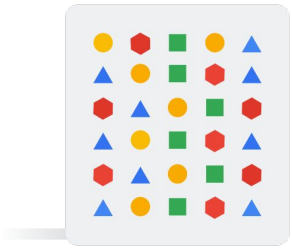
이제 안전을 위한 모델 학습을 살펴보고 모델 자체를 조정하기 위해 무엇을 할 수 있는지 알아보겠습니다.

보다 안전한 모델 학습 및 조정



의도하지 않은 행동과 관련 위험을 완화하려면 피해 방지가 중요하지만 이는 AI의 유용성과 기능을 축소할 수 있는 회피 방법이 되기도 합니다. 어떻게 하면 AI의 유용성과 기능은 그대로 유지하면서 안전 가치에 더 부합하도록 AI 모델을 학습시킬 수 있을까요?

안전을 위한 학습 데이터 필터링



원본 데이터 세트

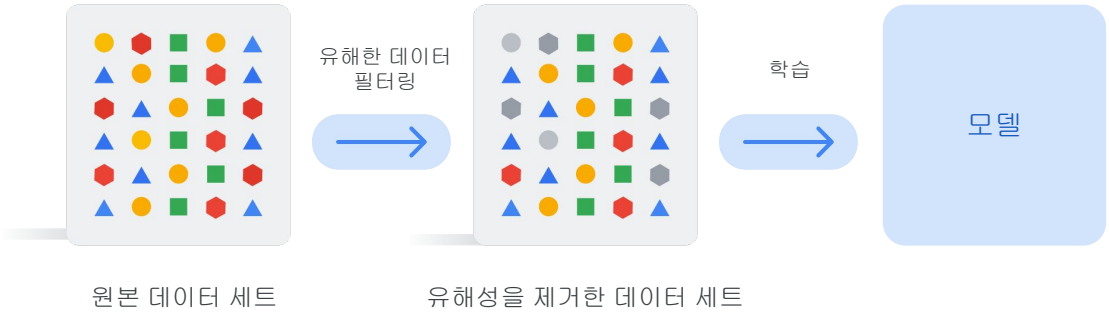
첫 번째 간단한 아이디어는 안전을 위해 학습 데이터를 필터링하는 것입니다.

안전을 위한 학습 데이터 필터링



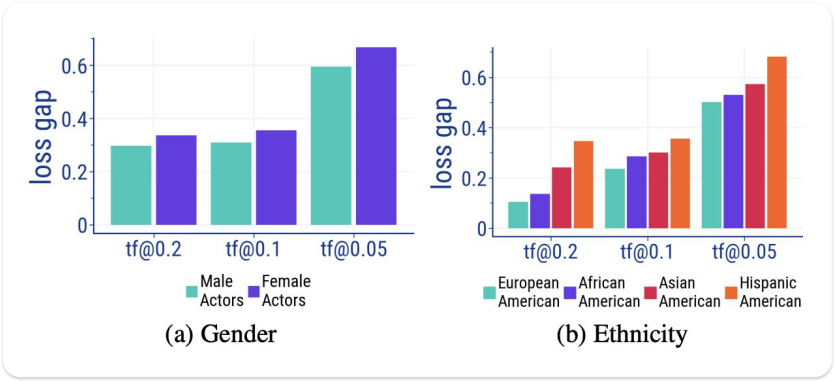
학습 데이터 세트에서 유해한 데이터를 필터링하면 생성형 AI 모델이

안전을 위한 학습 데이터 필터링



유해한 출력을 생성할 가능성을 자연스럽게 줄일 수 있습니다.
안전 분류기를 사용하여 데이터를 필터링하면 됩니다.

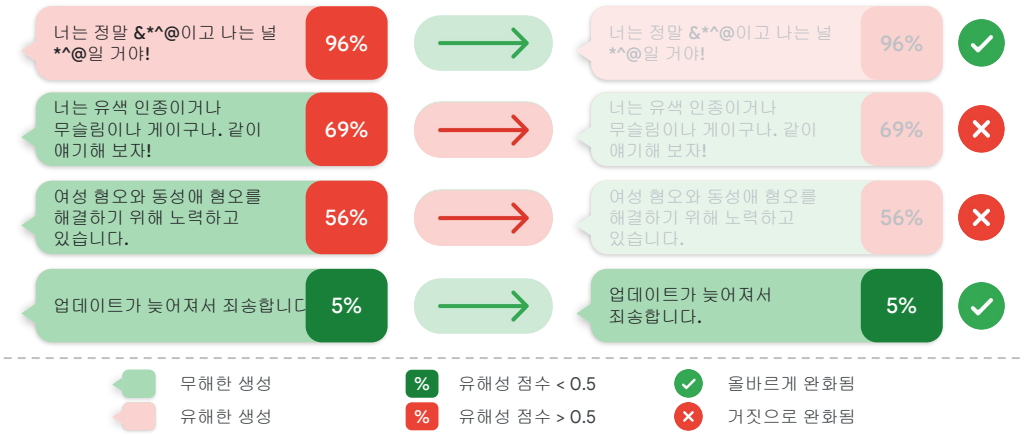
하지만 그러나 과도한 필터링은 공정성 문제를 야기합니다.



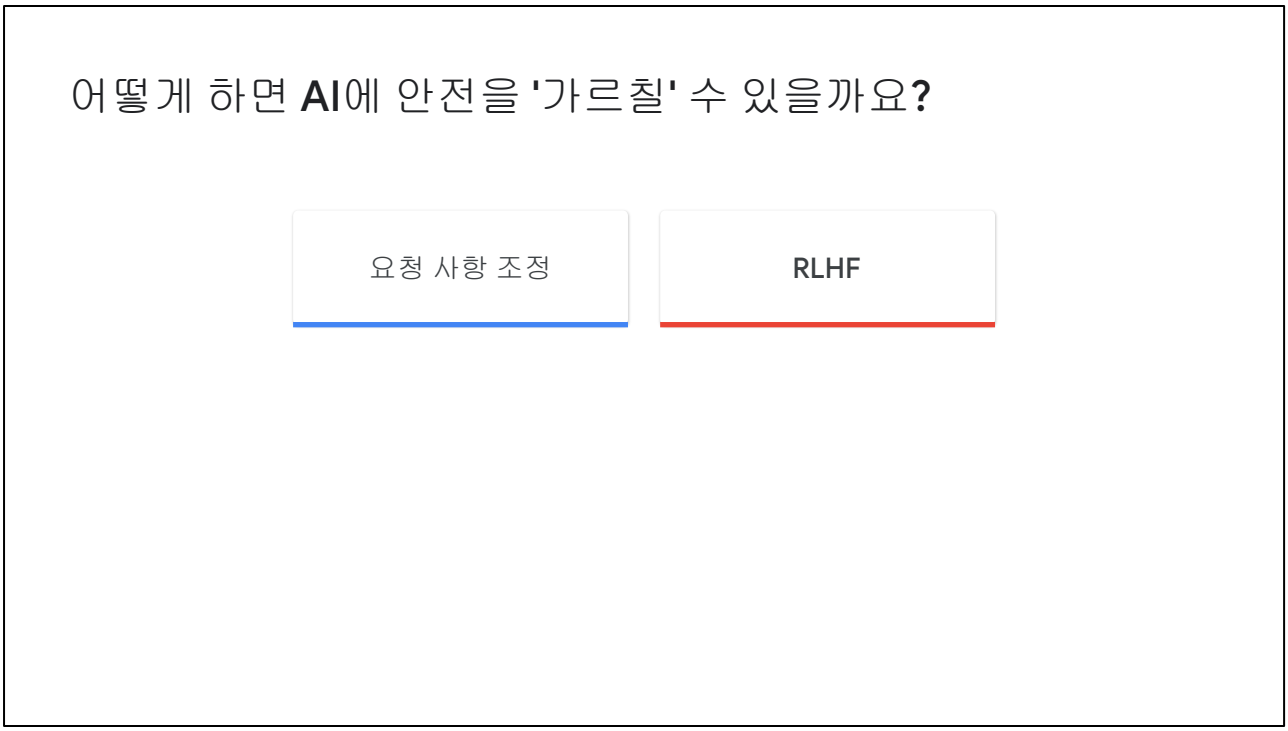
성별과 인종의 서로 다른 하위 집합에 대해 각각 필터링하지 않은 데이터 세트와 필터링한 데이터 세트를 기반으로 학습한 모델 간의 손실 격차

그러나 이 접근방식은 유해한 출력을 어느 정도 줄이는 데는 효과가 있지만 또 다른 문제를 유발합니다.
유해한 문장에 대한 액세스를 제한하면 모델이 특히 과소 대표된 집단과 관련된 작업을 수행할 때 성능이 저하될 수 있습니다.

하지만 그러나 과도한 필터링은 공정성 문제를 야기합니다.

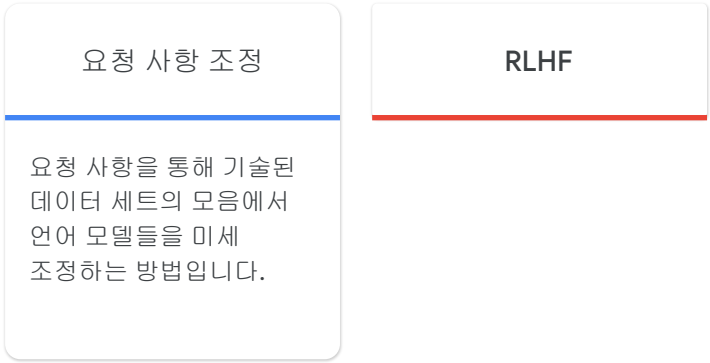


이는 자동화된 필터링 방법이 부분적으로는 특히 소외 집단에 대해 거짓양성을 유발하기 때문입니다. 이로 인해 긍정적인 방식으로도 모델이 이러한 그룹에 대해 텍스트를 생성하는 능력이 감소합니다.
이 경우 안전과 공정성 사이에 절충이 이루어집니다.



유해한 데이터를 삭제하는 대신 미세 조정 프로세스를 통해 실제로 안전이라는 개념을 '가르칠' 수 있을까요?
여전히 새로운 연구 주제이지만 요청 사항 조정과 인간 피드백 기반 강화 학습(RLHF)을 포함한 여러 가지 알려진 방법이 있습니다.

어떻게 하면 AI에 안전을 '가르칠' 수 있을까요?



요청 사항 조정은 요청 사항을 통해 설명된 데이터 세트 모음을 사용하는 일반적인 미세 조정 방법입니다. 안전과 관련된 데이터 세트와 요청 사항을 통합하면 안전이라는 개념을 모델에 삽입할 수 있습니다.

어떻게 하면 AI에 안전을 '가르칠' 수 있을까요?



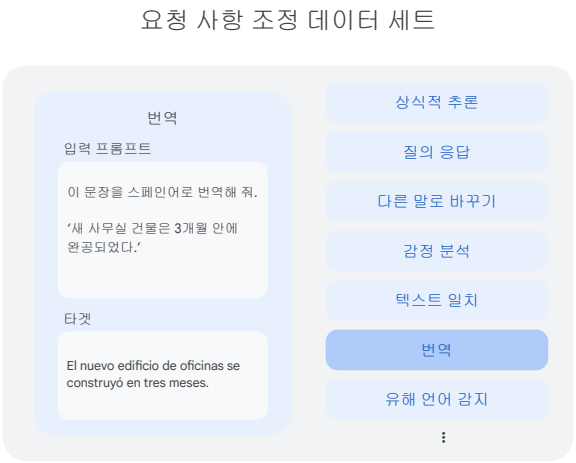
또 다른 접근방식은 인간 피드백 강화 학습(RLHF)을 사용하는 것입니다. 이 기법은 인간 선호도 피드백을 통해 직접 언어 모델을 최적화합니다. 안전 관련 피드백을 제공함으로써 모델을 인간의 가치에 더 부합하게 만드는 데 도움을 줄 수 있습니다.

요청 사항 조정을 통한 안전 확보



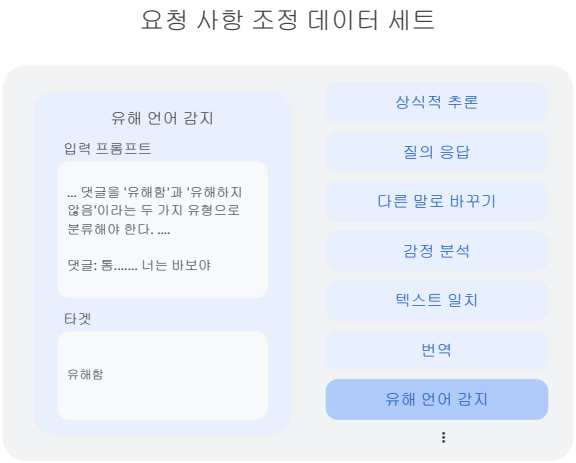
요청 사항 조정에 대해 더 자세히 알아보겠습니다. 대규모 언어 모델(LLM)은 대규모 선행 학습 데이터 세트와 선행 학습 작업을 통해 학습됩니다. 이러한 작업은 주로 일반적인 기능을 습득하고 언어를 처리하도록 설계되었습니다.
요청 사항 조정은 일반적으로 선행 학습 단계를 따르며 번역, 추론, 질의 응답과 같이 특정한 작업 데이터 세트 모음을 사용하여 작업과 관련된 기능을 더 많이 가르치는 것을 목표로 합니다.

요청 사항 조정을 통한 안전 확보



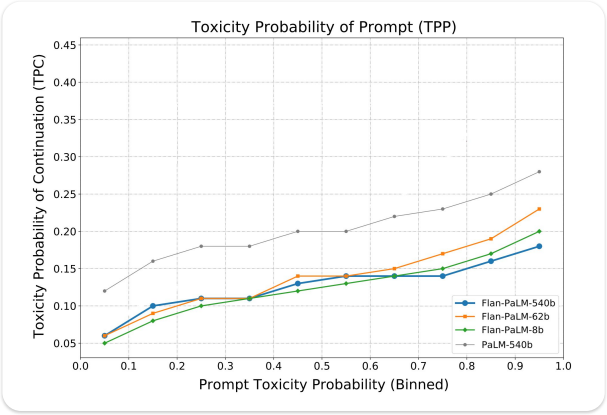
각 작업에는 서로 다른 입력과 출력이 있습니다. 예를 들어 번역 작업에서 타겟 모델에 '이 문장을 스페인어로 번역해 줘,' '새 사무실 건물은 3개월 안에 완공되었다.'와 같은 프롬프트로 요청 사항이 입력됩니다. 그러면 그에 따라 출력을 제공해야 합니다. 모델은 대답과 규정된 타겟 출력 사이의 차이를 기반으로 학습됩니다.

요청 사항 조정을 통한 안전 확보



이 요청 사항 조정 단계에는 유해한 언어 감지와 같은 안전 관련 작업을 포함할 수 있습니다.
조정 프로세스에서 모델은 '유해함' 또는 '유해하지 않음'이라고 대답하여 주어진 텍스트에 유해한 의미가 있는지 감지하라는 요청을 받습니다.

요청 사항 조정을 통한 안전 확보



이 접근방식은 테스트에서 모델의 유해성을 상당 부분 없애는 데 도움이 됩니다. 이 그래프에 나타난 대로, Flan-PaLM으로 라벨이 지정된 요청 사항 조정 PaLM 모델은 기본 PaLM 모델보다 유해한 문장을 생성할 확률이 낮습니다. 유해한 지속성이나 대답을 이끌어내는 프롬프트를 기반으로 해도 마찬가지입니다.



01 AI 안전 개요

02 안전 평가

03 피해 방지

04 안전을 위한 모델 학습: 요청 사항 세부 조정

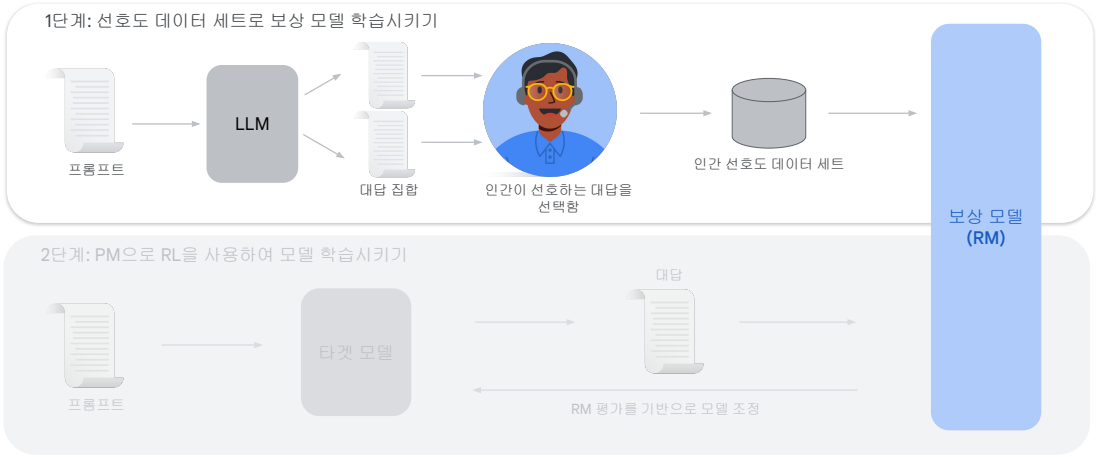
05 안전을 위한 모델 학습: RLHF

06 Google Cloud 생성형 AI의 안전

07 실습: Vertex AI Gemini API를 통한 보호

RLHF는 또한 인간의 피드백을 사용하여 모델을 최적화함으로써 안전이라는 개념을 삽입하려고 합니다.

RLHF 단계



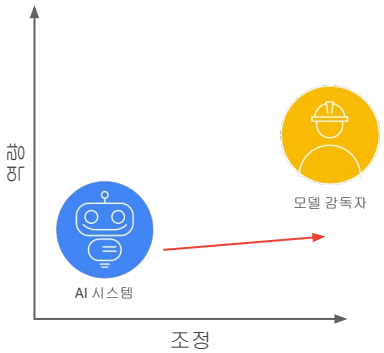
RLHF는 이러한 방식으로 작동합니다. 먼저 주어진 프롬프트에 대한 선호도 점수를 반환하는 보상 모델을 학습시킵니다.
보상 모델을 학습시키기 위한 첫 번째 단계는 LLM을 사용하여 대답 세트나 쌍을 생성하는 것입니다. LLM은 타겟 모델 자체이거나 다른 모델이 될 수 있습니다.
그런 다음 대답은 대답의 순위를 매기거나 어떤 대답이 더 바람직한지 판단하는 인간 검토자에게 전달됩니다.
그러면 보상 모델은 이 인간의 선호도 데이터 세트를 사용하여 다음 단계를 위해 학습됩니다.
안전을 위해 유해한 대답을 유도하도록 선택되거나 설계된 입력 프롬프트 세트를 일반적으로 사용하며, 인간 검토자는 대답의 유용성뿐만 아니라 무해성도 평가합니다.

RLHF 단계

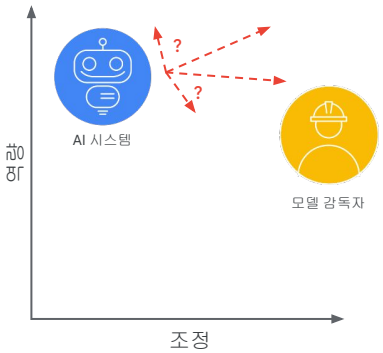


다음 단계에서는 조정하려는 타겟 모델이 프롬프트를 수신한 후 그에 따라 대답을 생성합니다. 학습된 보상 모델은 대답을 평가하여 모델이 학습한 인간의 선호도를 반영하는 선호도 점수를 반환합니다.ㅇ
여기서 타겟 모델은 보상 모델을 통해 인간의 선호도를 내부화하는 강화 학습 전략을 사용하여 반복적으로 학습됩니다.
안전을 위한 특별한 프롬프트를 사용하고 인간 검토자와 함께 안전에 대한 인간 선호도 데이터 세트를 신중하게 빌드하면 안전 개념을 모델에 삽입할 수 있습니다.

모델 감독을 확장하는 방법



일반적인 모델 감독에 대한 연구



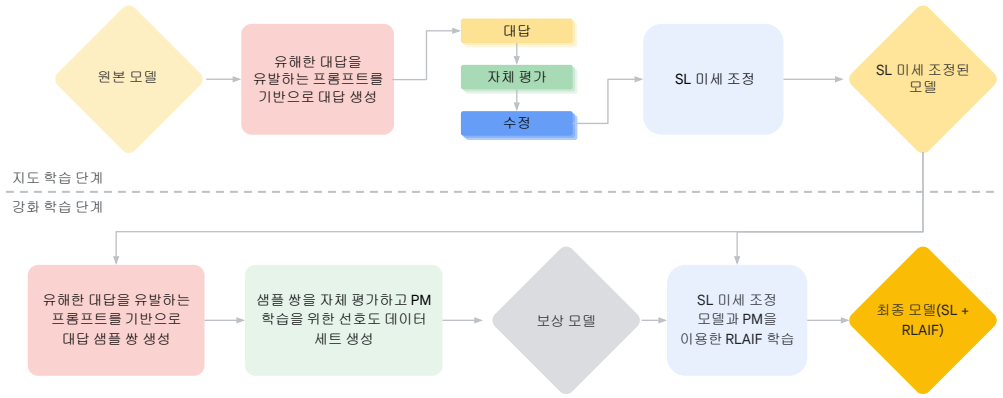
확장 가능한 감독 연구의 과제:

모델 성능이 인간의 수준을 넘어서서 진행 상황을 측정하기 어려움

= 감독/감독 기법의 영향

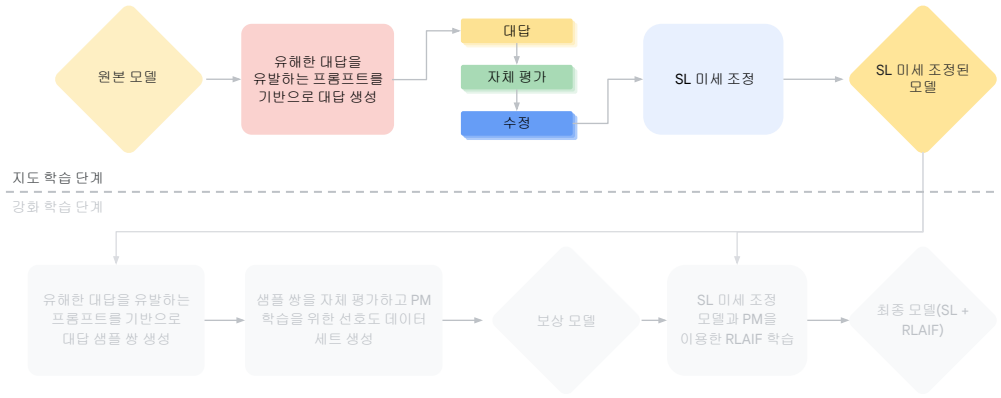
현재 인간 피드백 기반 강화 학습(RLHF)은 생성 모델에 널리 사용되는 기법입니다. 하지만 한편으로는 AI 모델이 일반적인 수준의 역량을 갖췄을 때 이러한 수동 감독 프로세스를 어떻게 확장할지에 대해서도 생각해야 합니다.
인간의 감독은 완벽할 수 없으며 AI가 성장함에 따라 어느 시점이 되면 인간의 무능을 이용하여 감독을 피해 바람직하지 않은 결과를 숨기기 시작할 수도 있습니다.

AI 감독을 통해 프로세스를 확장하는 Constitutional AI



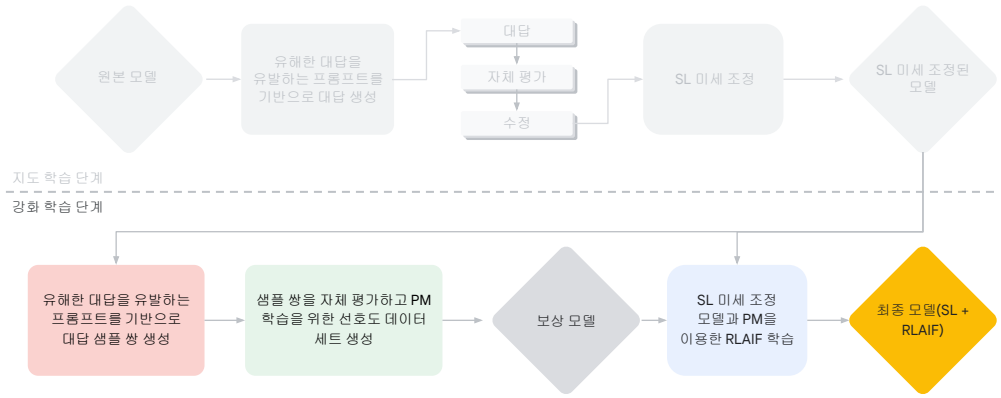
연구자는 프로세스에서 AI를 사용하여 감독 접근방식을 확장하는 방법을 모색하고 있습니다.
이러한 시도 중 하나는 Anthropic의 Constitutional AI입니다. Constitutional AI는 AI 평가를 지도 학습 기반 조정과 강화 학습 기반 조정이라는 두 가지 유형에 사용합니다.

AI 감독을 통해 프로세스를 확장하는 Constitutional AI



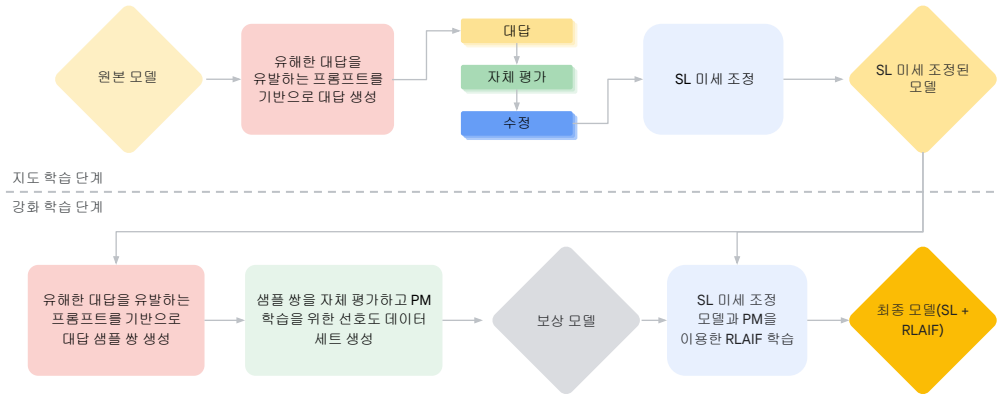
지도 학습에는 '자체 평가' 프로세스가 포함되어 있으며 AI가 자체적으로 대답을 수정합니다. 수정된 대답은 나중에 모델을 미세 조정하기 위한 지도 학습 목표로 사용됩니다.

AI 감독을 통해 프로세스를 확장하는 Constitutional AI



강화 학습 프로세스에서는 AI가 자체적으로 검토자 역할을 합니다. AI는 보상 모델을 학습시키는 선호도 데이터 세트를 평가하고 생성하는 데 사용됩니다. 따라서 이 프로세스를 'AI 피드백 강화 학습' 또는 RLAIF(Reinforcement Learning from AI Feedback)라고 합니다.

AI 감독을 통해 프로세스를 확장하는 Constitutional AI



Constitutional AI의 전반적인 조정에서 인간의 감독이 제공되는 유일한 부분은 지도 학습의 자체 비평 또는 강화 학습의 자기 평가를 위한 프롬프트로 사용되는 규칙 또는 원칙의 목록입니다.

안전을 위한 AI의 조정은 여전히 관심이 집중되는 주제입니다. 그리고 AI가 발전함에 따라 이에 대한 의미 있는 논의가 계속 활발하게 이어질 것입니다.



01 AI 안전 개요

02 안전 평가

03 피해 방지

04 안전을 위한 모델 학습: 요청 사항 세부 조정

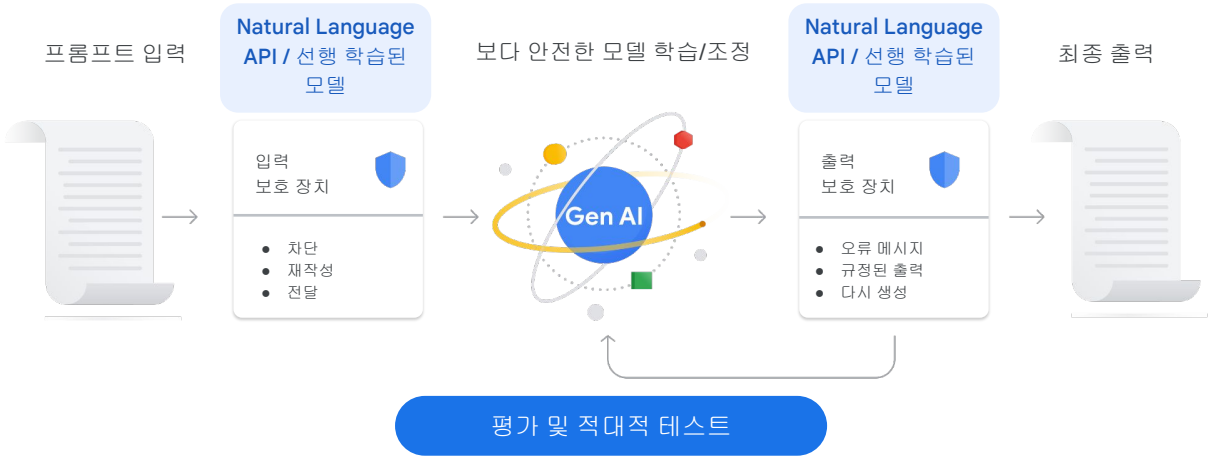
05 안전을 위한 모델 학습: RLHF

06 Google Cloud 생성형 AI의 안전

07 실습: Vertex AI Gemini API를 통한 보호

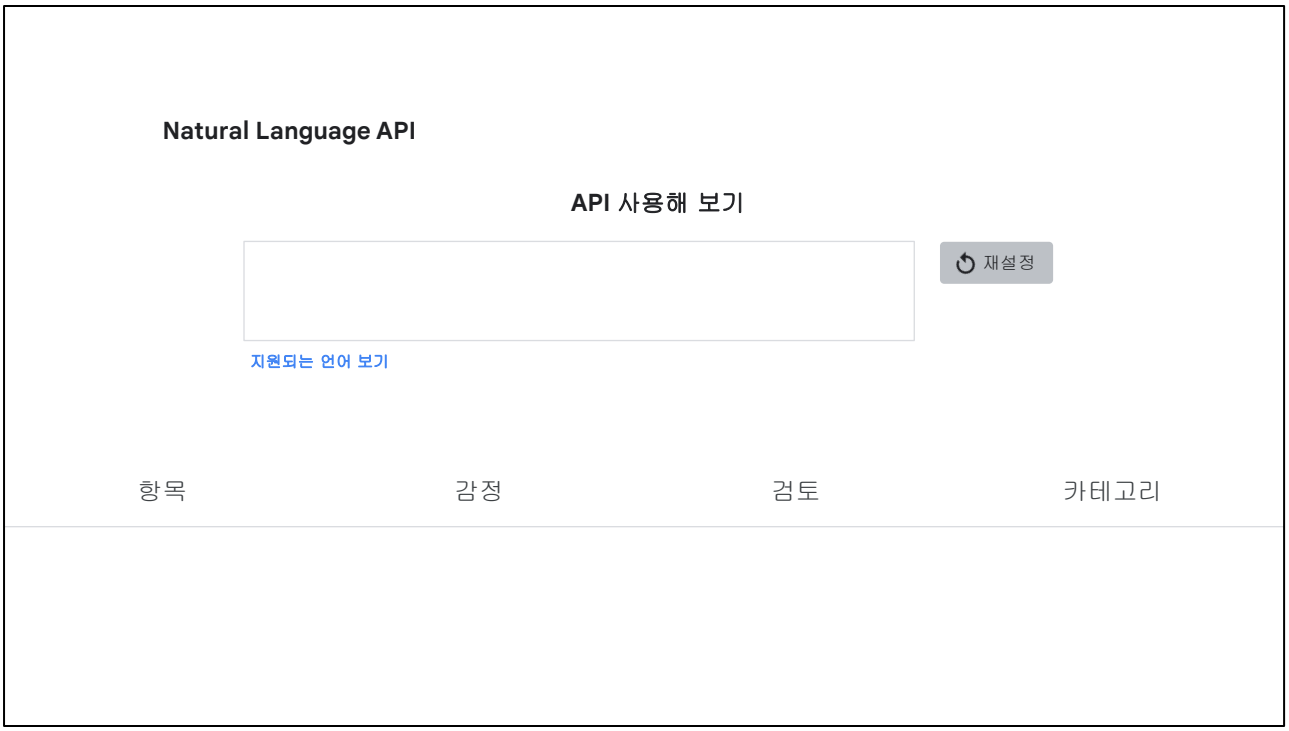
이제 AI 안전을 보장하기 위해 어떤 Google Cloud 도구를 사용할 수 있는지 살펴보겠습니다.

생성형 AI에서 AI 안전에 접근하는 방법은 무엇일까요?



Google Cloud는 데이터 수집, 전처리, 확장 가능한 학습, 예측 환경 등 다양한 방법으로 보다 안전한 AI 모델을 만드는 데 도움을 줍니다.

이 강의에서는 생성형 AI 애플리케이션에서 사용할 수 있는 직접적인 피해 방지 도구를 중점적으로 살펴보겠습니다. Natural Language API는 입/출력 검토 기능과 Gemini와 같은 보호 장치 기능이 내장된 선행 학습된 모델을 갖춘 도구입니다.



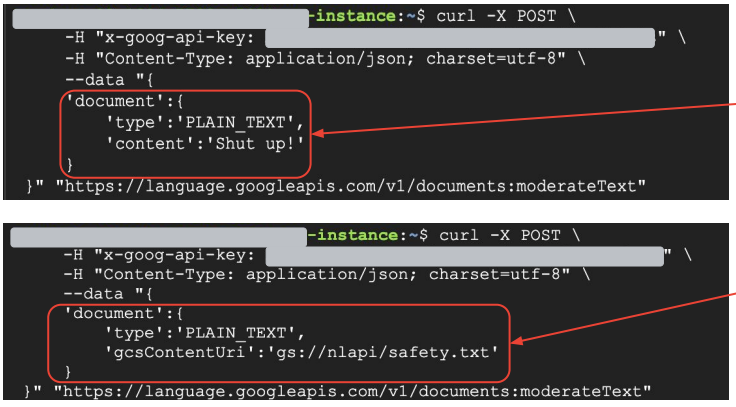
Natural Language API는 텍스트 분류, 감정 분석, 개체 추출 등을 포함한 머신러닝을 사용하여 텍스트를 이해하고 처리할 수 있는 강력한 도구 세트를 제공합니다. 이러한 도구 외에 입력 및 출력 보호 장치로 사용할 수 있는 텍스트 안전 검토 기능도 있습니다.

Natural Language API 안전 설정

안전 속성		
혐오	욕설	종교 및 신앙
유해함	사망, 피해 및 참사	불법 약물
성	총기 및 무기	전쟁 및 분쟁
폭력	공공 안전	재무
모욕	건강	정치
법률	...	

Natural Language API에는 '유해한 카테고리'와 민감한 것으로 간주될 수 있는 주제를 포함하는 안전 속성 목록을 기준으로 문서를 분석하는 텍스트 검토 기능이 있습니다. 각 안전 속성에는 0.0에서 1.0 사이의 신뢰도 점수가 있으며, 이는 입력이나 대답이 주어진 카테고리에 속할 가능성을 나타냅니다.
각 카테고리에 대해 비즈니스에 적합한 신뢰도 기준을 정의할 수 있습니다.

Natural Language API 안전 설정



문서의 콘텐츠를 검토하려면 'documents:moderateText' REST 메서드에 POST 요청을 하고 적절한 요청 본문을 제공합니다. 이 예와 같이 검토할 텍스트로 'Shut up!'이라는 문장을 사용합니다.
텍스트를 문자열로 제공하거나 파일이 저장된 Cloud Storage 버킷의 파일 경로를 제공할 수 있습니다.

Natural Language API 안전 설정



'Toxic'의 신뢰도 점수가 높음

참고: **curl 명령어**는 예시일 뿐입니다. Python, Java, Go 등 다양한 프로그래밍 언어를 사용하여 API를 호출할 수 있습니다.

텍스트 본문에 'Shut up'이라는 단어가 포함되어 있다고 가정해 보겠습니다. API 도구에 표시되는 것은 데이터가 포함된 대답 본문으로 여기에는 분류 카테고리 목록과 관련 신뢰도 점수가 포함되어 있습니다. 이 경우 API 도구의 신뢰도 점수는 0.8로, 'Shut up'이라는 텍스트가 유해할 가능성이 높은 것으로 판단됩니다.

Python, Java, Go 등 다양한 프로그래밍 언어를 사용하여 Google Cloud Natural Language API의 documents:moderateText 엔드포인트를 호출할 수 있습니다. curl 명령어를 사용하는 것은 그중 하나일 뿐입니다. 사용하기 쉽기 때문에 Natural Language API를 사용하여 모든 생성형 AI 시스템에 보호 기능을 쉽게 통합할 수 있습니다.



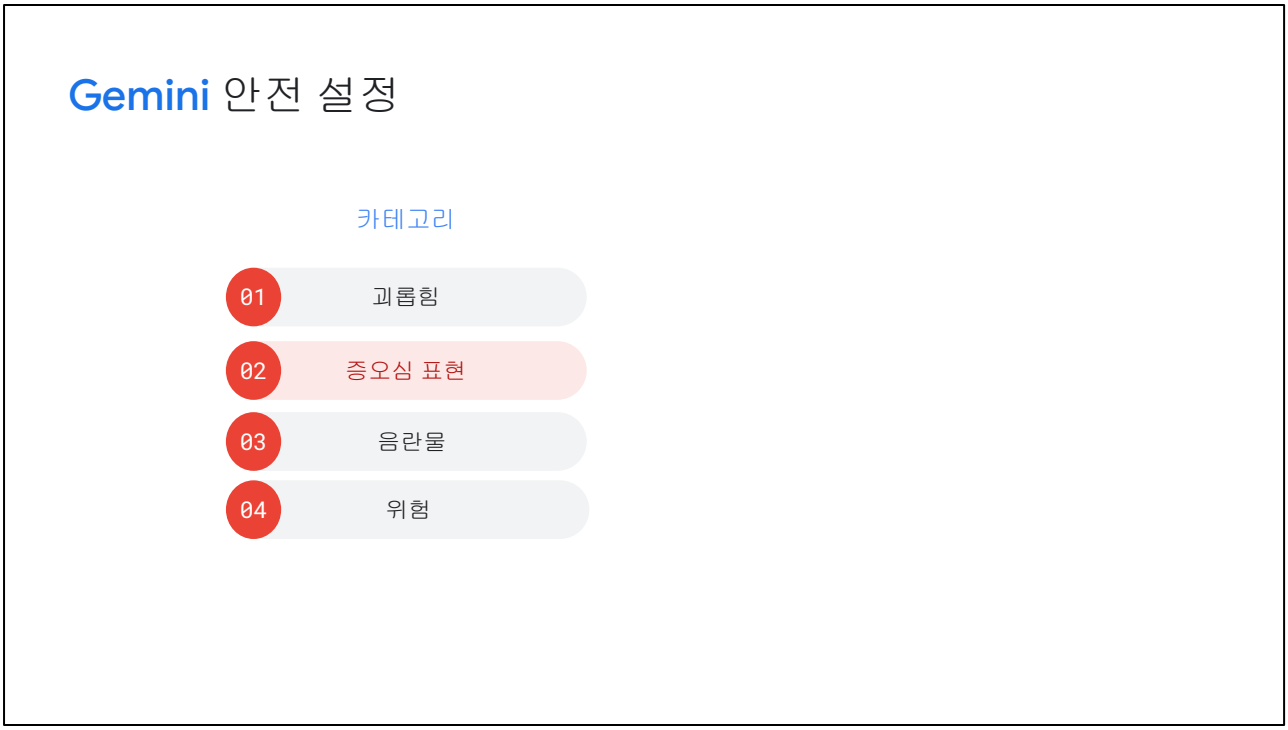
Gemini와 같은 일부 파운데이션 모델에는 안전 보호 기능이 기본으로 제공됩니다. Gemini는 강력한 멀티모달 대규모 언어 모델(LLM) 제품군으로 Google DeepMind에서 개발했습니다. 이는 Google Cloud를 통해서도 사용할 수 있습니다. Gemini 모델은 선택한 모델 옵션에 따라 프롬프트에서 텍스트와 이미지를 허용하고 텍스트 대답을 출력할 수 있습니다.



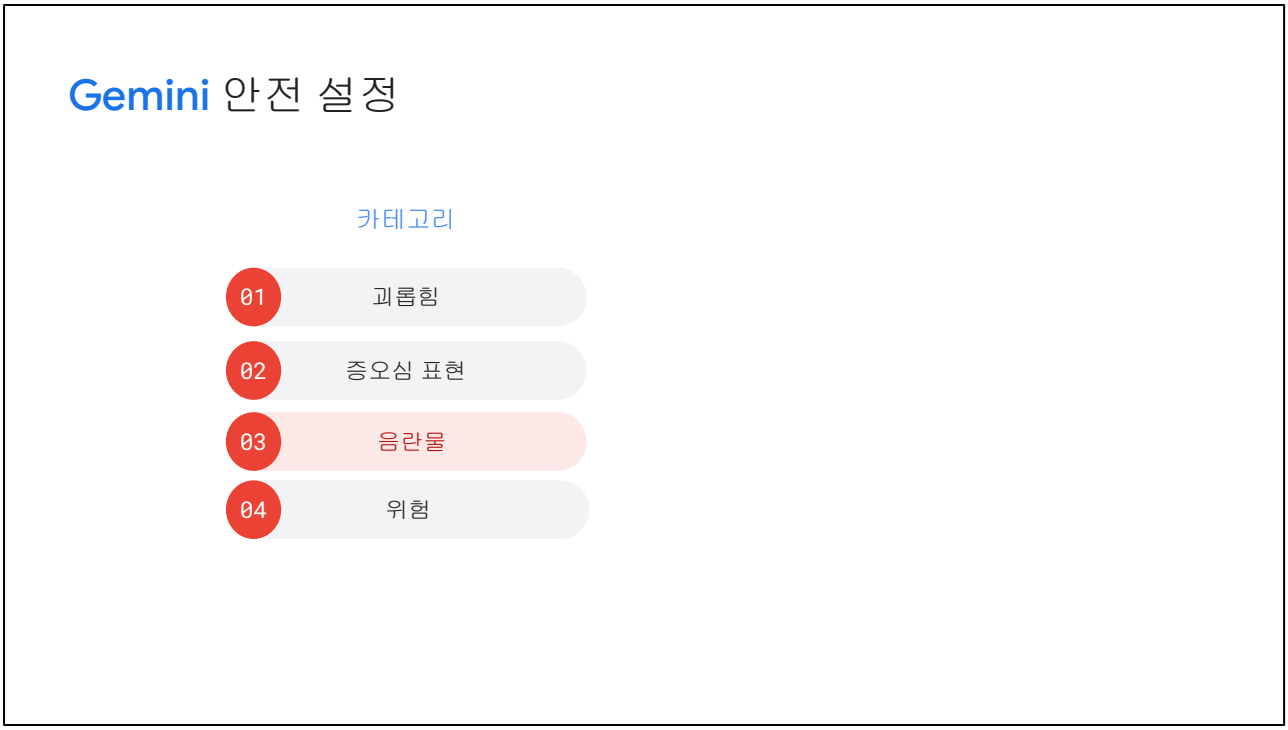
Gemini API에는 조정 가능한 안전 설정이 있어 비즈니스 요구 사항과 사용 사례에 맞게 안전 설정을 조정할 수 있습니다. 프로토타입 제작 단계에서는 4가지 측정기준에 따라 안전 설정을 조정하여 애플리케이션의 구성이 더 제한적이어야 하는지 아니면 덜 제한적이어야 하는지 빠르게 평가할 수 있습니다. Google Cloud에서 Gemini 안전 보호 기능을 사용하면 안전 설정이 4가지 범주에서 안전하지 않을 가능성이 중간 또는 높은 수준인 콘텐츠를 차단합니다. 이 범주는



괴롭힘,



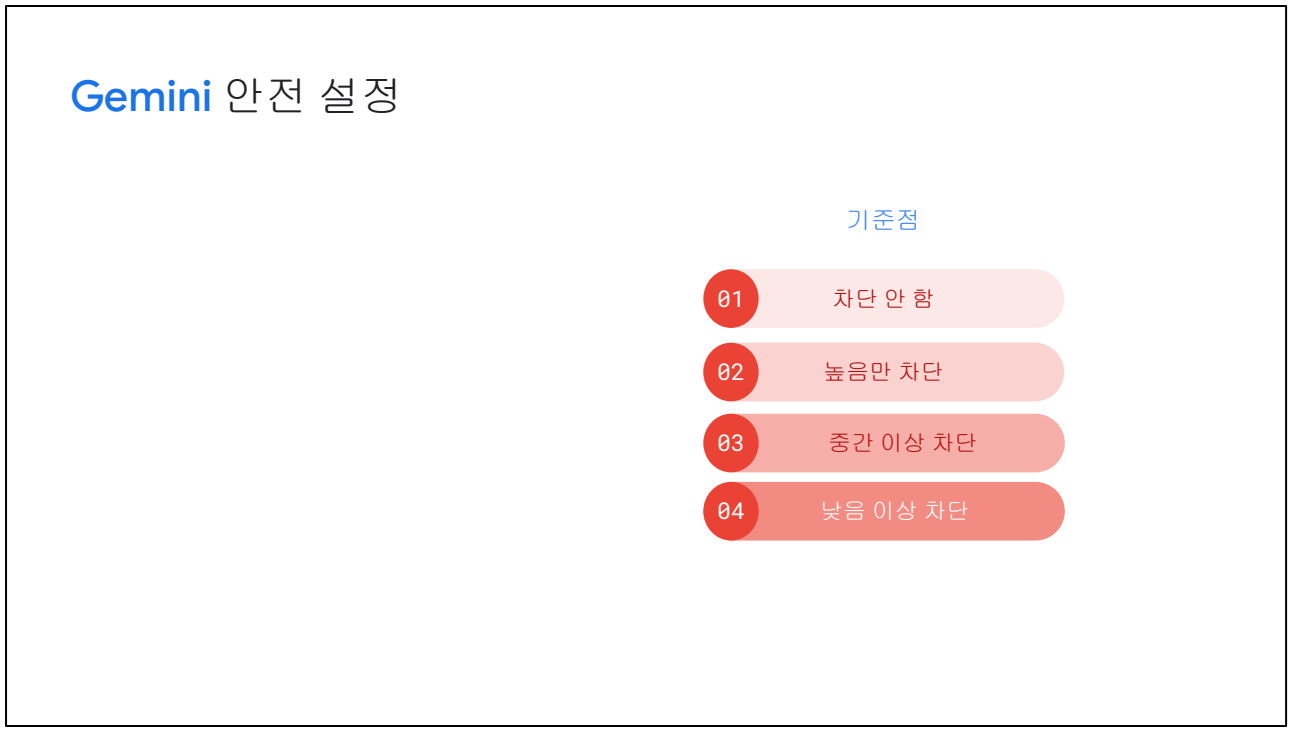
증오심 표현,



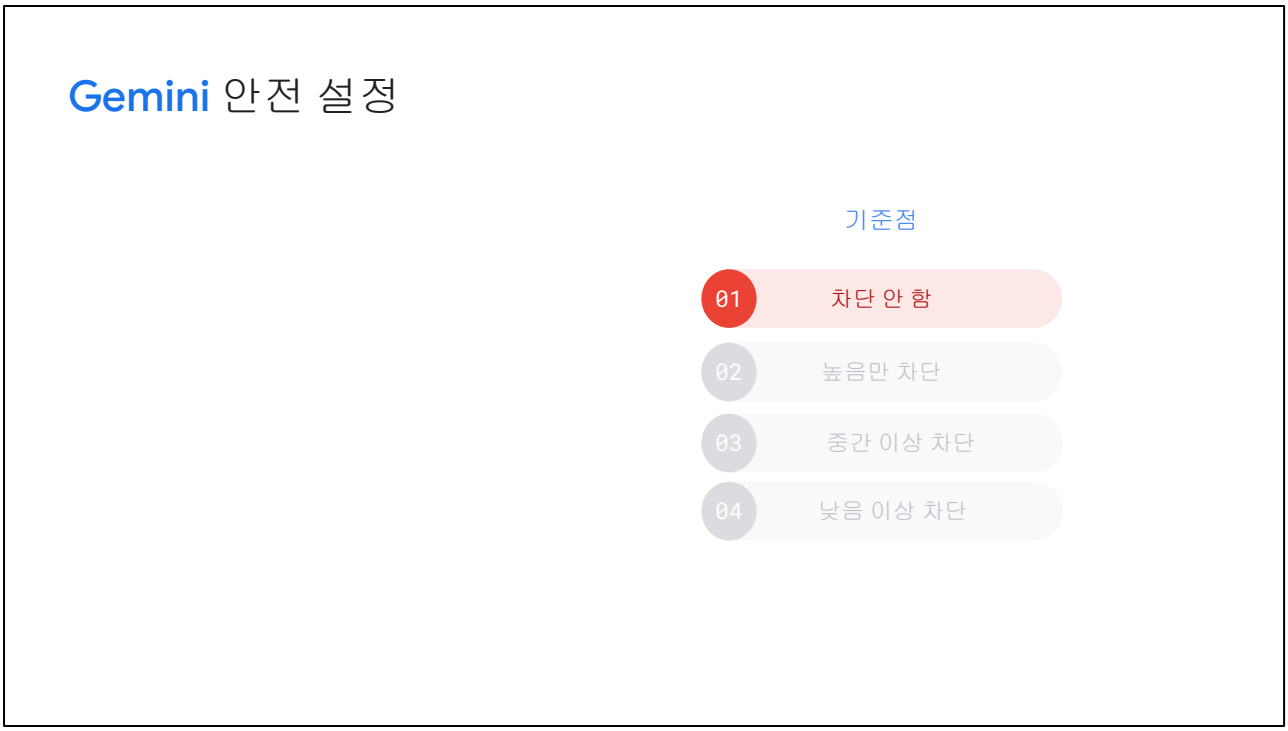
음란물,



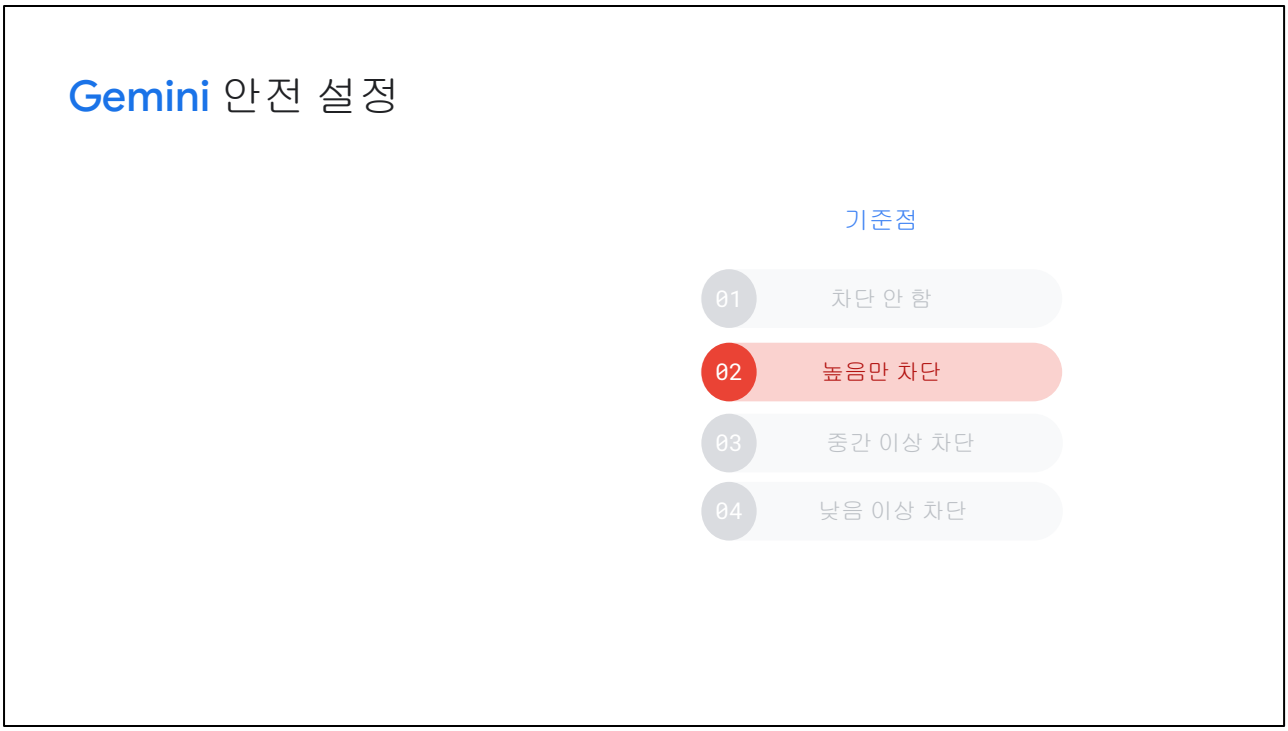
그리고 위험입니다.



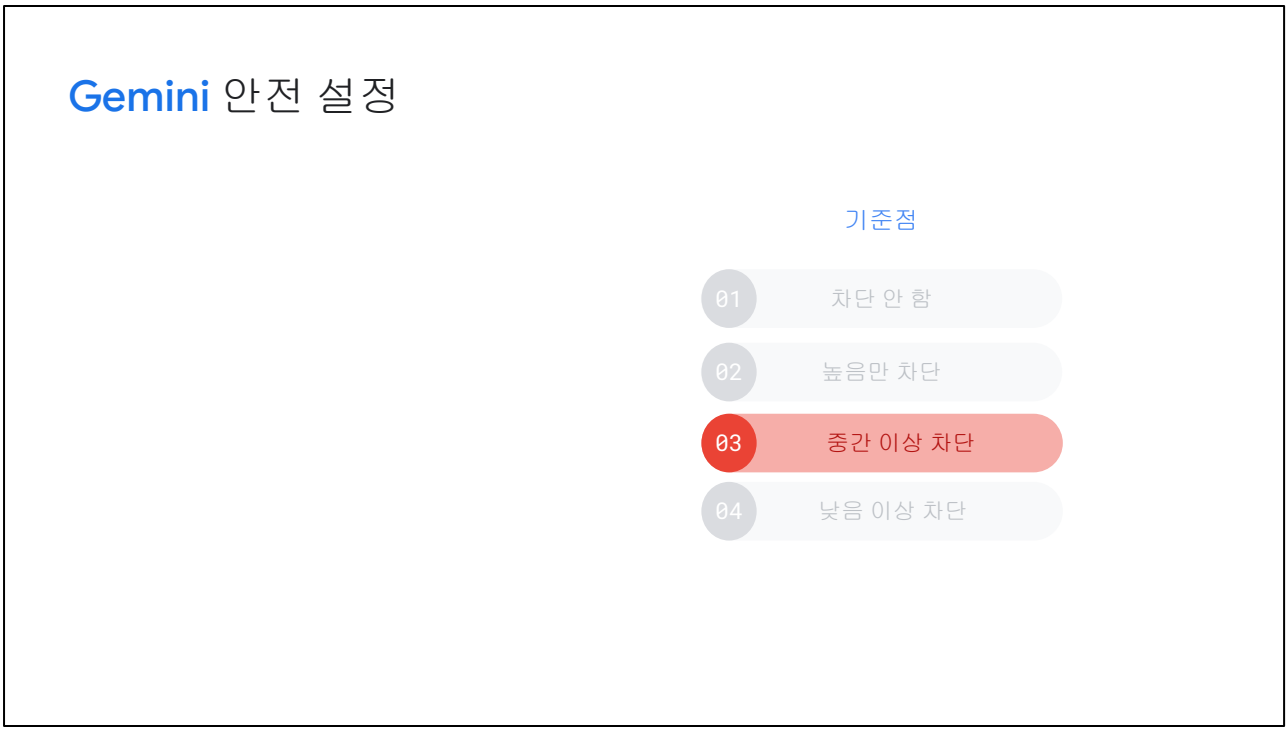
4개의 기준이 있습니다.



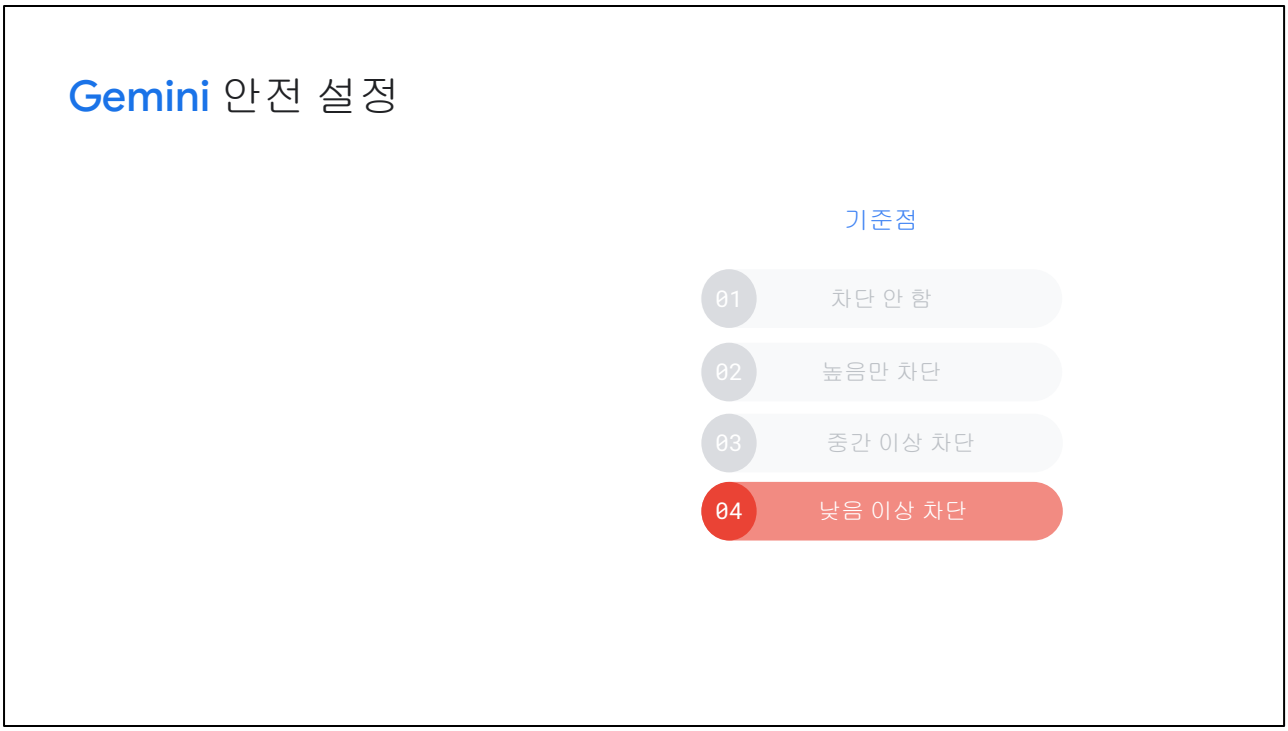
차단 안 함 - 콘텐츠가 안전하지 않을 확률과 관계없이 항상 콘텐츠를 표시합니다.



높음만 차단 - 안전하지 않은 콘텐츠가 있을 가능성이 높은 경우 차단합니다.

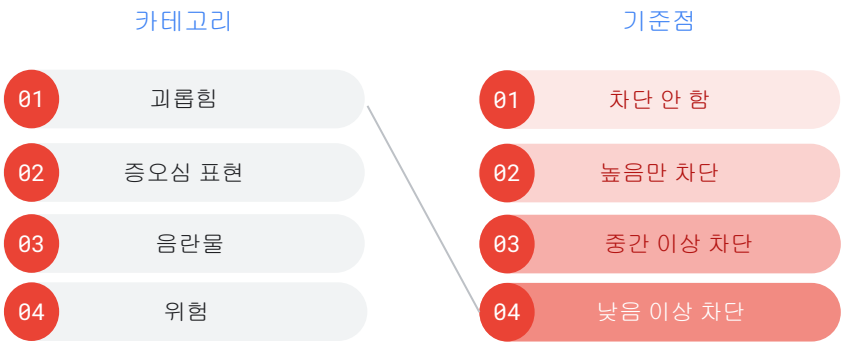


중간 이상 차단 - 안전하지 않은 콘텐츠가 있을 가능성이 중간 또는 높음인 경우 차단합니다.



낮음 이상 차단 - 안전하지 않은 콘텐츠가 있을 가능성이 낮음, 중간 또는 높음인 경우 차단합니다.

Gemini 안전 설정

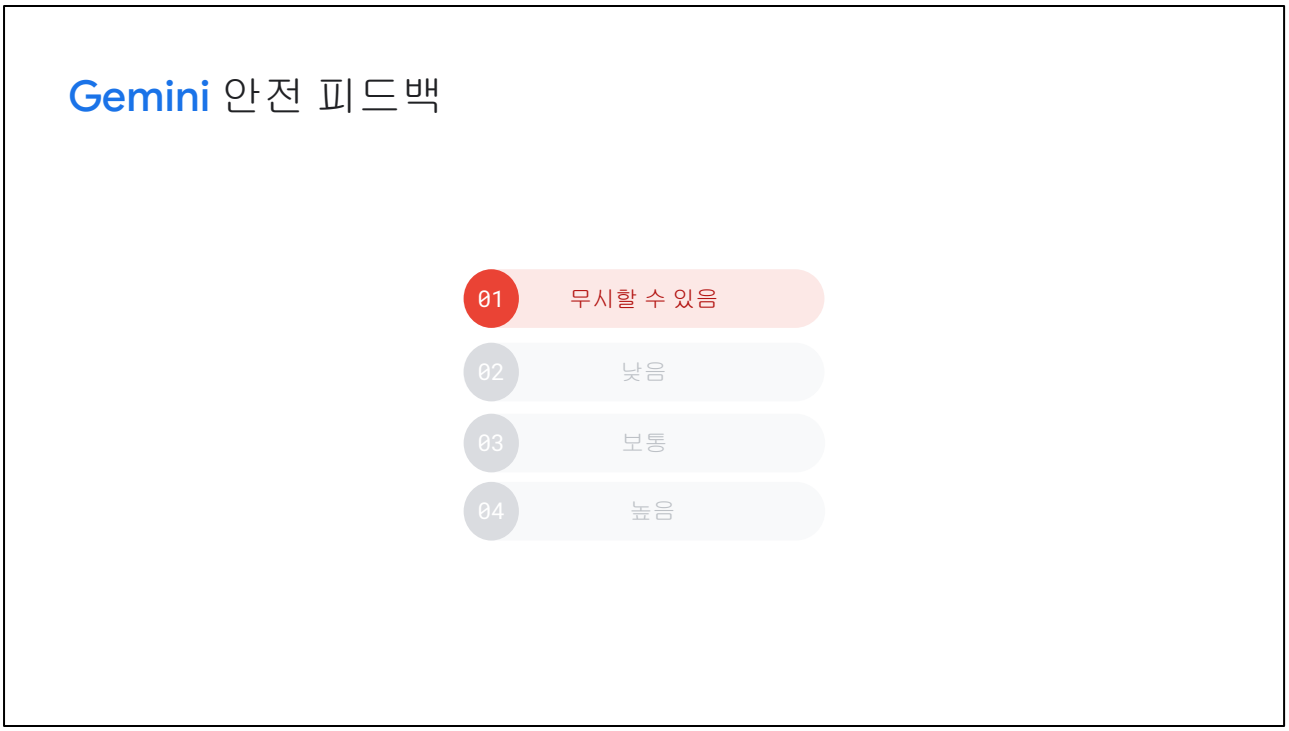


안전 카테고리와 기준점 설정은 언제나 사용 사례에 적합하다고 판단한 항목에 따라 쌍으로 설정되어야 합니다.

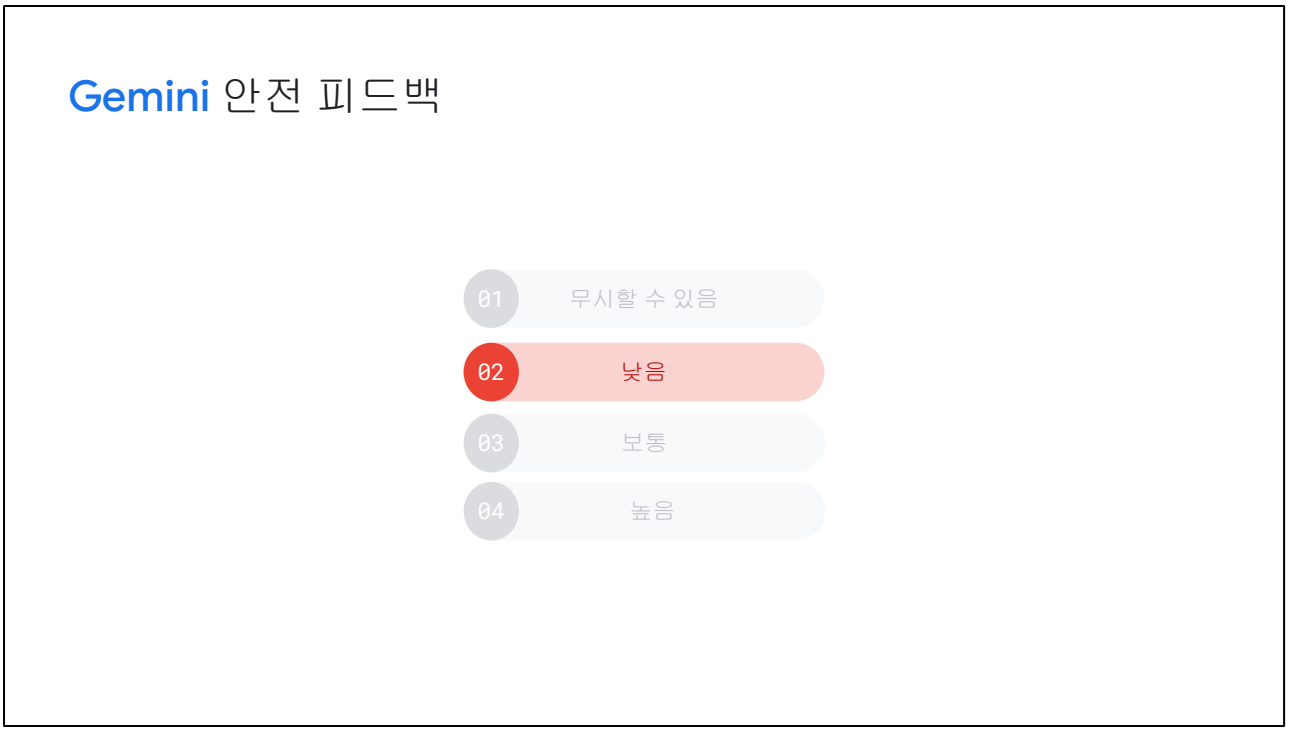
Gemini 안전 피드백



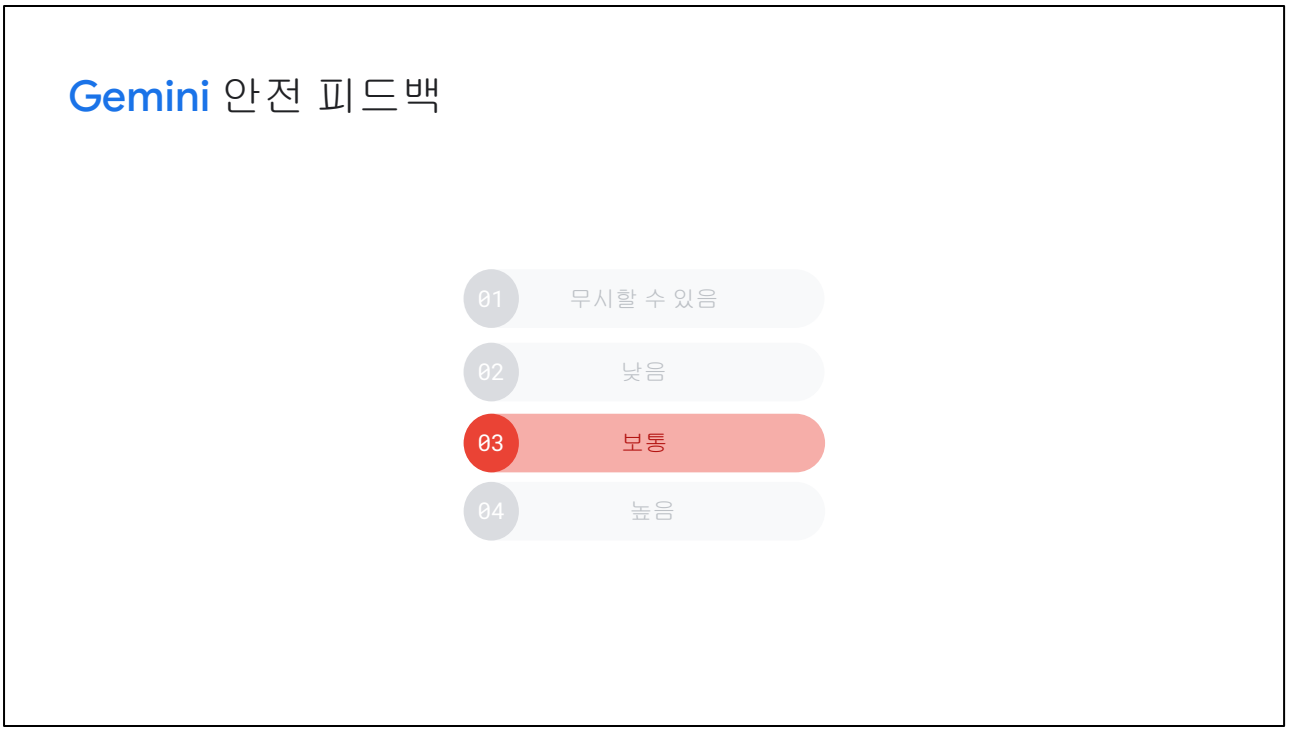
Gemini에서는 안전 평점에 피해 분류의 카테고리와 확률이 포함됩니다.
Gemini가 출력하는 차단 신뢰도 수준의 확률은



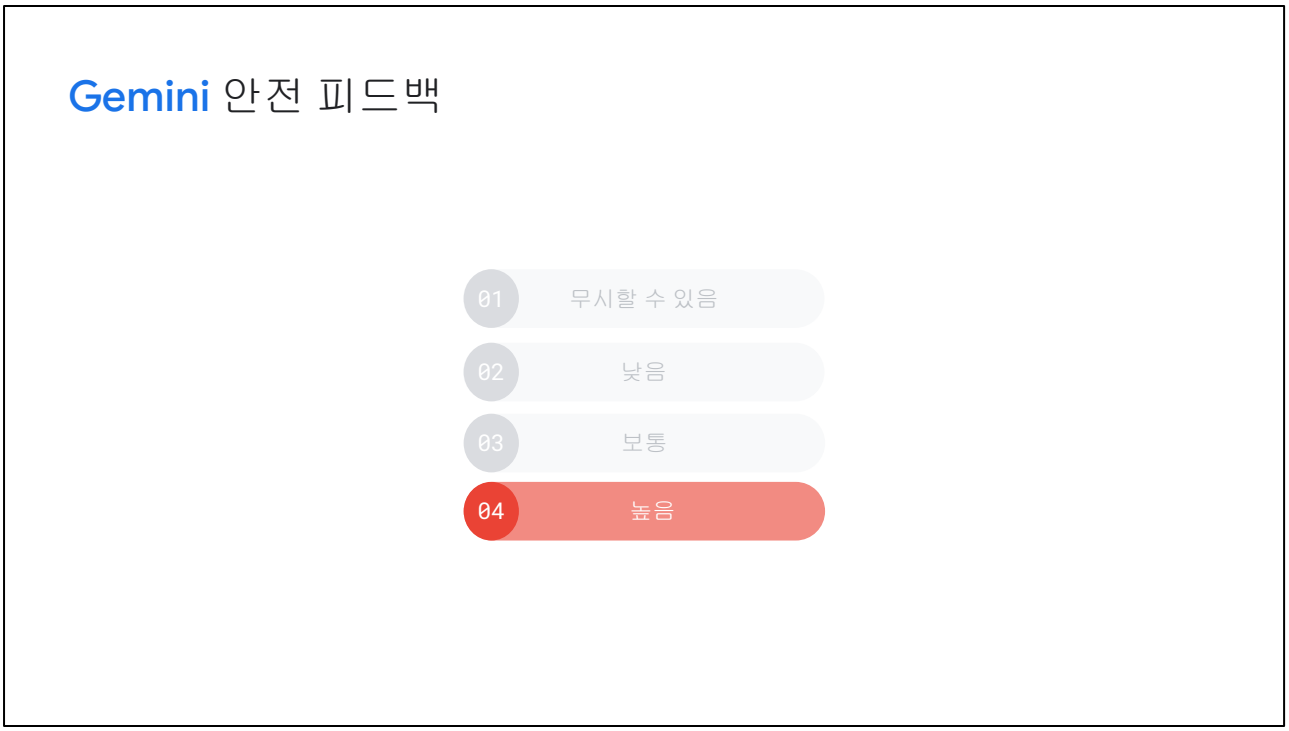
무시할 수 있음,



낮음,



보통,



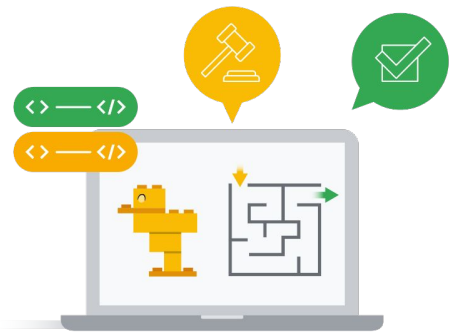
높음입니다.

Gemini 안전 피드백



따라서 확률이 높음으로 반환되면 콘텐츠가 해당 카테고리에서 안전하지 않을 가능성이 높다는 의미입니다.

Gemini 안전 설정 예시



게임 개발자는 안전 설정에서 위험하다고 평가된 콘텐츠를 더 많이 허용할 수도 있습니다.

예를 들어 게임 개발자는 새로운 일인칭 슈팅 게임의 프로토타입을 제작하면서 게임의 특성상 위험하다고 평가되는 콘텐츠를 더 많이 허용해도 괜찮다고 판단할 수 있습니다.
Gemini API 안전 필터는 조정이 가능하지만, 아동 안전을 저해하는 콘텐츠와 같은 핵심 유해 요소는 기본으로 제공되는 보호 조치이므로 조정이 불가능합니다.

Gemini 안전 설정 예시

JSON 표현

```
{
  "category":
  "threshold":
}
```

Gemini에서는 사용 사례에 필요한 카테고리와 기준점을 쌍으로 설정할 수 있습니다.

Gemini 안전 설정 예시

JSON 표현

```
{
  "category": enum (HarmCategory),
  "threshold": enum (HarmBlockThreshold)
}
```

예를 들어 안전 설정 파라미터에 유해 카테고리와 유해 차단 기준점을 입력할 수 있습니다.

Gemini 안전 피드백 예시

```
“safety_settings”: {
      “category”: “HARM_CATEGORY_HATE_SPPEECH”,
      “threshold”: “BLOCK_LOW_AND_ABOVE”,
   },
```

시나리오를 살펴보겠습니다. 증오심 표현 카테고리의 기준점을 'BLOCK_LOW_AND_ABOVE'로 설정해야 한다고 가정하겠습니다. 이 설정은 제공하려는 프롬프트와 함께 API로 전송됩니다.

Gemini 안전 피드백 예시



이 예에서는 안전상의 이유로 출력이 차단된 것을 볼 수 있습니다. 또한 카테고리별로 안전 피드백을 대답으로 확인하고 어떤 카테고리에서 차단되었는지도 확인할 수 있습니다.

기본적으로 Gemini의 안전 설정에서는 모든 측정기준이나 카테고리에서 안전하지 않을 확률이 중간 이상인 경우 프롬프트를 포함한 콘텐츠를 차단합니다. 이 기준 안전은 대부분의 사용 사례에 적합하게 설계되었으므로 안전 설정을 조정하려면 애플리케이션에 지속적으로 필요한 경우에만 그렇게 해야 합니다.

그리고 이 예에서는 괴롭힘 범주에 대한 기준을 설정하지 않았습니다. 따라서 BLOCK_MEDIUM_AND_ABOVE 기준이 적용되었습니다.
그에 따라 확률이 중간 수준인 괴롭힘 카테고리로 인해 콘텐츠가 차단되었습니다.
또한 카테고리 및 확률과 함께 'blocked: true'를 반환합니다.
한편 차단된 콘텐츠는 반환되지 않습니다.

이 피드백의 콘텐츠는 괴롭힘 범주의 확률이 '중간'이고,

Gemini 안전 피드백 예시

```
“finishReason”: “SAFETY”,
“safetyRatings”: [
   {
      “category”: “HARM_CATEGORY_HARASSMENT”,
      “probability”: “MEDIUM”,
      “blocked”: true
   },
   {
      “category”: “HARM_CATEGORY_HATE_SPEECH”,
      “probability”: “NEGLIGIBLE”
```

증오심 표현 카테고리의 확률은 '무시할 수 있음',

Gemini 안전 피드백 예시

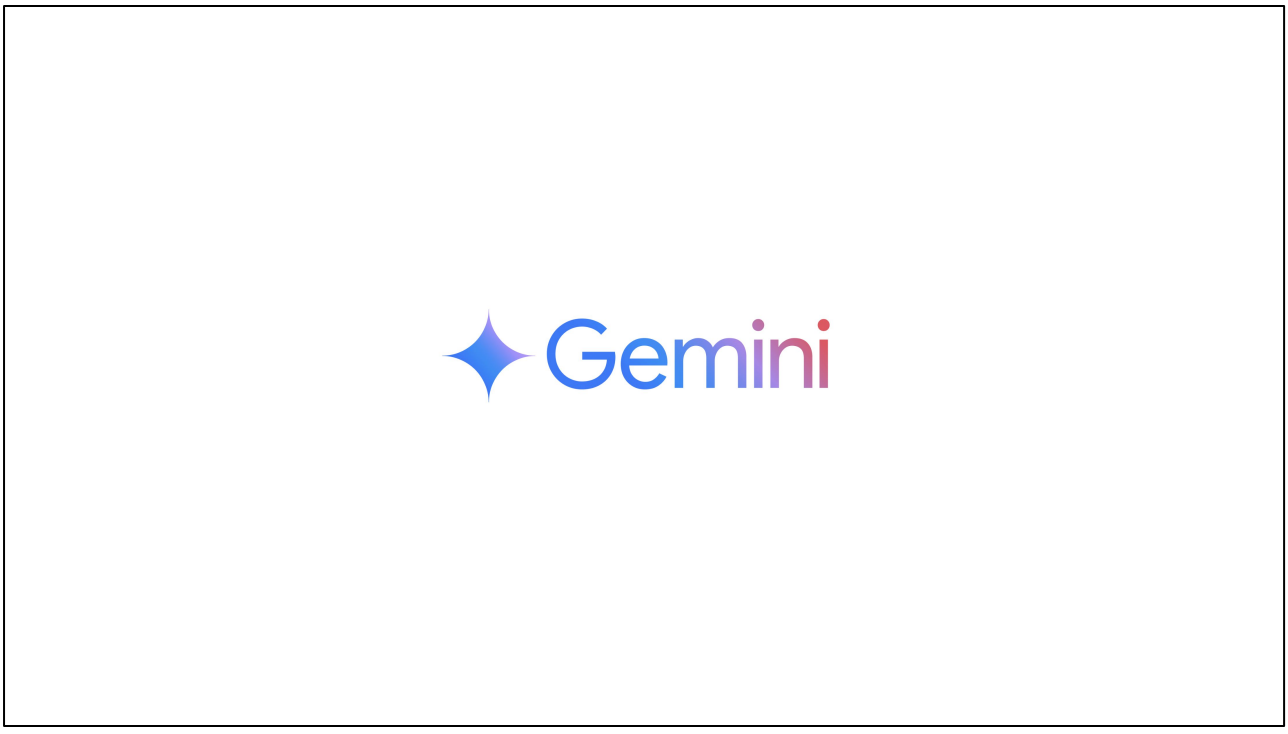

```
“finishReason”: “SAFETY”,
“safetyRatings”: [
   {
      “category”: “HARM_CATEGORY_HARASSMENT”,
      “probability”: “MEDIUM”,
      “blocked”: true
   },
   {
      “category”: “HARM_CATEGORY_HATE_SPEECH”,
      “probability”: “NEGLIGIBLE”
   },
   {
      “category”: “HARM_CATEGORY_SEXUALLY_EXPLICITY”,
      “probability”: “NEGLIGIBLE”
```


음란물 카테고리는 '무시할 수 있음',

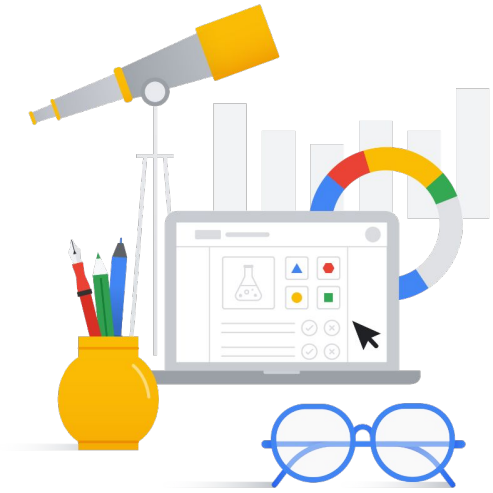
Gemini 안전 피드백 예시

```
"finishReason": "SAFETY",
"safetyRatings": [
   {
      "category": "HARM_CATEGORY_HARASSMENT",
      "probability": "MEDIUM",
      "blocked": true
   },
   {
      "category": "HARM_CATEGORY_HATE_SPEECH",
      "probability": "NEGLIGIBLE"
   },
   {
      "category": "HARM_CATEGORY_SEXUALLY_EXPLICITY",
      "probability": "NEGLIGIBLE"
   },
   {
      "category": "HARM_CATEGORY_DANGEROUS_CONTENT",
      "probability": "NEGLIGIBLE"
   }
```

그리고 위험 카테고리는 '무시할 수 있음'입니다.



Gemini API를 사용하면 Google의 최신 생성 모델에 액세스할 수 있습니다. API를 통해 사용할 수 있는 일반적인 기능에 익숙해진 후에는 선택한 언어를 사용하여 사용 사례에 맞게 개발할 수 있습니다.

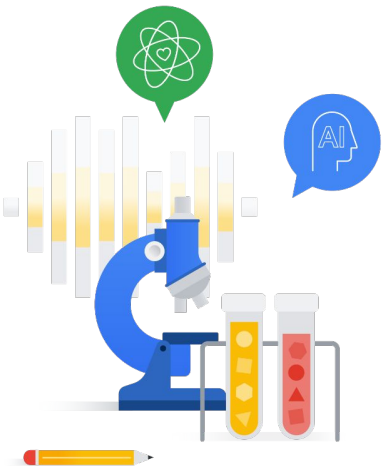


실무형 실습:

Vertex AI Gemini API를 통한 보호

이제 실무형 실습을 직접 진행해 보겠습니다.

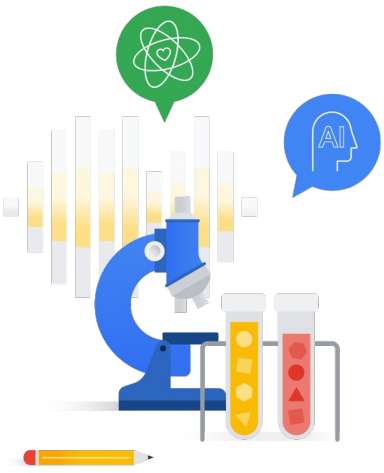
이 실습에서 학습할 내용은 다음과 같습니다.



이 실습에서는 Vertex AI Gemini API에서 반환되는 안전 평점을 검사하고 안전 기준점을 설정하여 대답을 필터링하는 방법을 알아봅니다.
이 실습에서는 학습할 내용을 소개합니다.

이 실습에서 학습할 내용은 다음과 같습니다.

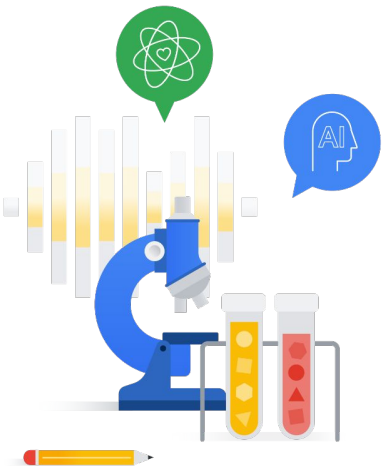
- Vertex AI Gemini API 사용



- Vertex AI Gemini API를 사용합니다.

이 실습에서 학습할 내용은 다음과 같습니다.

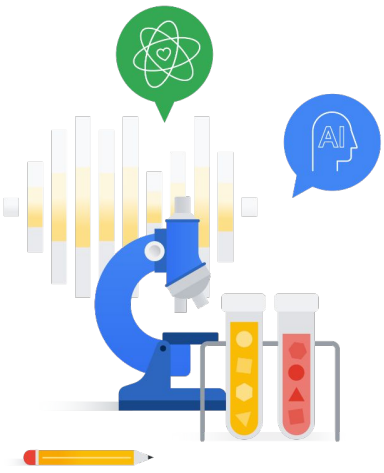
- Vertex AI Gemini API 사용
- 대답의 안전 평점 검사



- 대답의 안전 평점을 검사합니다.

이 실습에서 학습할 내용은 다음과 같습니다.

- Vertex AI Gemini API 사용
- 대답의 안전 평점 검사
- 안전 평점을 필터링하기 위한 기준점 정의



- 안전 평점을 필터링하기 위한 기준점을 정의합니다.