KOITA 연구활동보고서 별첨 자료

별첨 1: 오픈소스 AI 모델 벤치마크 검토 (1p)

검토 배경

MONKOS 서비스의 로컬 AI 추론 및 온디바이스 처리를 위해 오픈소스 경량 특화 모델을 지속적으로 벤치마크하고 있습니다.

시장 흐름 분석

트렌드	상세
파라미터 경쟁 종료	거대 모델(100B+) → **특화 경량화(7B~30B)** 경쟁으로 전환
영역별 분화	코딩(Codestral), 다국어(Qwen), 이미지(Flux) 등 포지션별 특화
성능 역전	"7B인데 특정 영역에서 70B급 성능" 모델 등장

벤치마크 대상 모델

모델	파라미터	특화 영역	VRAM 요구	비고
Llama 3 8B	8B	범용	~6GB	Meta, 오픈소스
Mistral 7B	7B	범용/추론	~6GB	유럽 오픈소스 리더
Qwen 14B	14B	다국어/한중일	~12GB	알리바바, 아시아 강점
Codestral	22B	코딩 전용	~18GB	Mistral, 코드 특화
Flux	-	이미지 생성	~23GB	오픈소스 Stable Diffusion 계열
DeepSeek	7B~67B	범용/코딩	가변	중국, 성능 대비 저비용

MONKOS 적용 시나리오

```
[멀티 에이전트 동시 구동] 64GB VRAM 기준
├── 코딩 특화 7B (6GB)      → 개발 자동화
├── 범용 대화 7B (6GB)      → 고객 응대
├── 이미지 특화 Flux (23GB) → 비주얼 생성
├── 라우터/오케스트레이터 3B (3GB)
└── 여유 26GB               → QLoRA 튜닝 동시 가능
```

결론

- 오픈소스 경량 특화 모델이 증가할수록 MONKOS의 조합 가능성 확대
- 빅테크 API 의존 탈피 → 로컬 오케스트레이션으로 비용 절감 및 프라이버시 강화

별첨 2: 글로벌 공략국가 전략 비교 및 일본 선택 과정 (1p)

후보 국가 비교 분석

국가	수요 근거	인프라 갭	K-뷰티 호감도	우선순위
일본	재일 한국인 45만, 방일 200만+, 규격 혼동 빈발	사진관 비쌈, AI 앱 부재	수출 3위 ($10.87억)	**1순위**
베트남	인구 1억+, 한국 비자 수요 폭발	지방 사진관 부재	82.9% (5위)	2순위
인도네시아	인구 2.78억, 비자 필수	히잡 증명사진 니치	86.5% (2위)	3순위
호주	순이민 46.8만, 아시안 다수	PhotoAiD 규격 미달 사례	영어권 교두보	4순위

일본 선택 근거

1. 즉각적 수요

- 재일 한국인 45만 + 한국 방문 일본인 연간 200만+
- 일본 여권 45×45mm vs 한국 35×45mm → 규격 혼동 반려 빈발

2. 인프라 갭

- 일본 사진관(　　館): 1,500~3,000엔 (비쌈)
- 증명사진 기기(　明　　機): AI 코칭/보정 없음
- AI 증명사진 전문 앱 거의 없음, 중국산 앱 거부감 강함

3. K-뷰티 프리미엄

- "한국식 증명사진 = 깔끔하고 예쁜" 인식 이미 존재
- K-뷰티 수출 $10.87억 (글로벌 3위)

4. 규제 환경

- AI 규제 매우 관대 (OECD 최하위 수준)
- 여권 리터칭은 금지이나, **실시간 코칭은 규제 대상 아님**

진입 전략

단계	타겟	채널
1단계	재일 한국인	LINE 채널, 한인 커뮤니티
2단계	한국 방문 일본인	일본어 LP, 리쿠르토 사진 특화
3단계	일본 현지	기존　　館 패치(프랜차이즈)

별첨 3: 경쟁사 분석 요약 (1p)

시장 규모

- AI 이미지 편집 시장: 2024년 $51.2억 → 2035년 $487.4억 (CAGR 22.73%)
- Remini 단독: 2024년 다운로드 1.2억 건, 수익 $2억+

주요 경쟁사 비교

경쟁사	포지셔닝	가격	약점
Remini	AI 사진 보정 + 헤드샷	$9.99/주	체형 왜곡 논란, 여권 미지원
HeadshotPro	비즈니스 헤드샷	$29~99	증명사진 규격 비대응
AI Passport Photo	여권/비자 전용	저가	실시간 코칭 없음, 발급보장 없음
AI증명사진어플 (국내)	한국 전규격	~6,000원	여권 반려 빈발, 중국 서버
캐럿 (국내)	AI 콘텐츠 플랫폼	크레딧	증명사진은 부가 기능

MONKOS 차별점

차별 요소	MONKOS	경쟁사 전체
실시간 촬영 코칭 (Gemini Live)	**O**	X (전무)
환경 체크 (조명/배경/포즈)	**O**	X
AI 본인 확인 검증	**O**	X
전문가 휴먼 검수	**O**	X
여권 발급보장	**O**	X
인화 + 택배	**O**	X

경쟁 맵

```
[헤드샷/프로필 전용]
HeadshotPro ─── Aragon AI ─── Secta Labs
                    │
              [AI 생성 중심]
Remini ─── 캐럿 ─── Media.io ─── 포토디렉터
                    │
              [규격 맞춤 중심]
AI Passport Photo ── VisaPhoto ── AI증명사진어플
                    │
         [규격 + 코칭 + 검수 + 발급보장]
                ★ MONKOS ★ (유일)
```

핵심 요약

> ***기존 앱들은 "찍은 사진을 AI로 보정"하는 도구이고, MONKOS는 "촬영부터 발급까지 책임지는 풀서비스"다.***

별첨 4: RTX 5090 / Mac Studio M5 도입 당위성 (1p)

도입 배경

- 클라우드 API 의존 → 비용 증가, 프라이버시 우려
- 로컬 AI 추론 → 비용 절감, 데이터 주권 확보
- 오픈소스 경량 모델 발전 → 로컬 구동 가능성 증가

RTX 5090 선택 근거

항목	RTX 5090	RTX 4090 (비교)
CUDA 코어	21,760	16,384
VRAM	32GB GDDR7	24GB GDDR6X
대역폭	1,792 GB/s	1,008 GB/s
멀티GPU 스케일링	**0.91~0.97**	0.76 (제한)
가격	~$2,000	~$1,600

핵심 포인트: 5090은 4090 대비 멀티GPU 제한이 크게 완화됨

5090 x2 (64GB VRAM)로 가능한 작업

작업	가능 여부
7B 풀 파인튜닝	O
7B~30B QLoRA 튜닝	O
70B 4bit 추론	O
Flux 커스터마이징	O
멀티 에이전트 동시 구동	O

Mac Studio M5 선택 근거

항목	Mac Studio M5 Ultra (예상)
통합 메모리	128~192GB
대역폭	~30% 향상 (vs M4)
출시	2026년 3~6월 예상
용도	70B 추론, MLX 개발 환경

핵심 포인트: TinyCorp 드라이버 + MLX CUDA 백엔드로 Mac ↔ NVIDIA 연결 가능

분리 세트 구조의 우위

항목	원보드 2GPU	분리 세트 (채택)
장애 격리	한 GPU 문제 → 전체 다운	세트별 독립
냉각	밀착, 폐열 간섭	독립 냉각
전력	1,500W+ 전용 회선	750W, 일반 콘센트
유연성	역할 전환 어려움	세트 단위 전환 자유

결론

> *2025년 12월 설계한 (5090 멀티 + Mac Studio M5) 구조가 2026년 2월 벤치마크 검증 결과 최적 시나리오로 확인됨.*

별첨 5: MONKOS 사업 로드맵 (1p)

4단계 성장 전략

```
┌─────────────────────────────────────────────────────────┐
│                                                         │
│  Stage 1: AI 앱 (무한 스케일)              [현재]       │
│  └── Gemini 코칭 → 규격 맞춤 → 디지털 파일              │
│                                                         │
│  Stage 2: 원격 검수 (프리미엄)             [2026 Q1]    │
│  └── 전문가 검수 → 발급보장 → 학습 데이터 축적          │
│                                                         │
│  Stage 3: 프랜차이즈 (국내)                [2026 Q2~]   │
│  └── 기존 사진관 패치 → AI 시스템 제공 → 로열티         │
│                                                         │
│  Stage 4: 글로벌 라이선스                  [2026 H2~]   │
│  └── 일본/베트남/인도네시아/호주 현지 파트너            │
│                                                         │
└─────────────────────────────────────────────────────────┘
```

기술 로드맵

시기	기술 목표
2026 Q1	Gemini Live 실시간 코칭 상용화
2026 Q2	eKYC 본인확인 연동
2026 Q3	AI 모델 에이전시 (가상 모델 생성)
2026 Q4	영상 생성 파이프라인 (Veo 등)
2027~	온디바이스 AI, 로컬 LLM

하드웨어 로드맵

```
[현재] 4060
  └── 3B 튜닝, 7B 추론 테스트

[1차 — 2026 Q1] 5090 x2 + Mac Studio M5
  ├── 5090: 7B~30B 튜닝, Flux, 추론 서버
  └── Mac: 70B 추론, 개발 환경

[2차 — 2026 H2] 5090 x4 풀세트
  ├── 세트 A: 글로벌 서비스 (상시 온라인)
  └── 세트 B: ML 실험 (유동적)

[3차 — 2027~] PRO 6000 도입
  └── 안정적 추론 서버, 5090은 튜닝 전용
```

글로벌 확장 로드맵

단계	시장	진입 방식
1단계	일본	LINE 채널, 리쿠르토 특화
2단계	베트남	Zalo 미니앱, 비자 수요
3단계	인도네시아	WhatsApp, 히잡 특화

4단계	호주	영어권 교두보, 이민자 타겟

핵심 메시지

> ***"전문가가 AI를 가르치고, AI가 고객을 가르칩니다. 국가가 늘어나도 전문가는 추가 불필요합니다."***

별첨 자료 끝

본 별첨 자료는 내부 전략 문서를 기반으로 R&D 연구활동 증빙 목적으로 요약 정리되었습니다.